Predicción de rangos etarios a partir de tweets en español mediante técnicas de procesamiento del lenguaje natural y aprendizaje automático supervisado

E. V. Rivera Jiménez, J. G. Carrillo Meneses, C. A. Garnica Salazar, y O. A. Prieto Moreno

***Resumen*—Este artículo responde una pregunta concreta: hasta dónde puede llegar un sistema de PLN clásico —sin *transformers*, sin *embeddings* y sin LLM— en la clasificación del rango de edad de tweets en español, y dónde está el límite real del dato. Sobre la competencia `tweet-age-2026-puj` (169.336 tweets de entrenamiento y 112.892 de test, seis rangos de edad y macro-F1 como métrica), se construyó una cadena íntegramente clásica de TF-IDF, n-gramas de carácter, features artesanales y redes tabulares con pérdidas ordinales, validada con cinco particiones agrupadas por clústeres de *near-duplicados* y con reglas de decisión calibradas por clase. El resultado principal es un consenso geométrico de expertos (producto de expertos en espacio logarítmico) que alcanzó 0.63724 de macro-F1 en el *leaderboard* público, superando el baseline inicial (0.55235) en +0.08489, junto con una mejor validación local de 0.6189929 obtenida por un consenso de nueve modelos y estadísticamente significativo frente al campeón (5/5 folds, $p = 0{,}0010$). Una auditoría matemática del símplejo de pesos confirmó que la solución habita un óptimo estacionario —superficie cóncava con vértice en el producto de expertos y calibración monótona decil a decil— y el techo del dato quedó medido y declarado: 0.642 en el *leaderboard*, con 0.70 fuera de alcance bajo las restricciones vigentes. La búsqueda sistemática de señal (220 experimentos registrados) delimitó qué técnicas aportan y cuáles no, con falsaciones reproducibles. El trabajo deja tres prácticas transferibles: la validación agrupada por *near-duplicados* es indispensable, la ordinalidad del problema es explotable y el techo observado pertenece al dato, no al modelo.**

***Palabras clave*—Procesamiento de lenguaje natural, perfilado de autor, clasificación de texto, métricas macro-F1, validación cruzada agrupada, ensambles, productos de expertos, reproducibilidad.**

***Declaración de impacto*—El sistema presentado alcanza 0.63724 de macro-F1 en una competencia real de Kaggle sin usar *transformers*, *embeddings* ni modelos de lenguaje: todo el desempeño proviene de representaciones estadísticas, features artesanales y modelos clásicos. Los resultados muestran que, en corpus cortos y ruidosos, la calidad del protocolo de validación y de la regla de decisión pesa tanto como la capacidad del modelo, y que el techo observado pertenece al dato. La auditoría matemática del consenso respalda la selección ante la evaluación privada y ofrece un criterio replicable para decidir cuándo detener la búsqueda de señal.**

I. Introducción

EL perfilado de autor consiste en inferir atributos demográficos —edad, género, procedencia— a partir de la forma en que una persona escribe. La edad es, de esos atributos, uno de los más difíciles: el vocabulario de dos cohortes vecinas se solapa casi por completo y la señal discriminante vive en detalles estilísticos débiles y distribuidos, como la longitud de las oraciones, el uso de puntuación o la preferencia léxica [1], [2]. Schler et al. establecieron en blogs el esquema de seis rangos que hoy es estándar —13-17, 18-24, 25-34, 35-49, 50-64 y 65 en adelante— y mostraron que la separación entre cohortes es sistemática pero modesta [3]; Argamon et al. profundizaron en las marcas estilísticas que la sostienen [4], y la serie de laboratorios PAN convirtió el problema en una tarea de evaluación comparable durante siete ediciones [5], [6], [7], [8]. En Twitter, la tarea es aún más difícil que en textos largos: los mensajes son cortos, ruidosos y multilingües, y los estudios específicos han reportado techos bajos incluso con modelos poderosos [9], [10], [11].

Este artículo documenta una exploración completa del problema bajo una restricción deliberada y severa: la competencia `tweet-age-2026-puj`, organizada en el curso de Procesamiento de Lenguaje Natural de la Maestría en Inteligencia Artificial de la Pontificia Universidad Javeriana, prohíbe usar *transformers*, modelos de lenguaje y, en general, cualquier modelo de vectorización o *embedding*, preentrenado o entrenado desde cero. Todo el desempeño debe provenir, por tanto, de representaciones estadísticas como TF-IDF, de features artesanales y de clasificadores clásicos. El corpus contiene 169.336 tweets de entrenamiento y 112.892 de test, etiquetados en los seis rangos de edad, y la métrica oficial es la macro-F1 sin ponderar.

La pregunta que organiza el trabajo es la siguiente: *¿hasta dónde puede llegar un sistema de PLN clásico en la clasificación del rango de edad de tweets en español, y dónde está el límite real del dato?* La respuesta se articula en cuatro contribuciones.

1. Un consenso geométrico de expertos clásicos (producto de expertos en espacio logarítmico) con una regla de decisión calibrada por clase alcanzó **0.63724 de macro-F1 en el *leaderboard*** (referencia 57283487), una mejora de **+0.08489** sobre el baseline inicial de 0.55235.
2. La **mejor validación local** del proyecto es 0.6189929 de macro-F1 (particiones agrupadas, leave-one-fold-out) con un consenso de nueve modelos, estadísticamente

Los cuatro autores están vinculados a la Maestría en Inteligencia Artificial, Pontificia Universidad Javeriana, Bogotá, Colombia. Correos: riveraev@javeriana.edu.co, carrillojuliang@javeriana.edu.co, carlos_garnicas@javeriana.edu.co y o-prieto@javeriana.edu.co.

significativo frente al campeón (5/5 folds positivos, bootstrap pareado $p = 0{,}0010$).
3. El **techo del dato** quedó medido y declarado: 0.642 de macro-F1 en el *leaderboard* como máximo alcanzable, con el objetivo de 0.70 refutado por argumentos de información disponible.
4. Una **búsqueda sistemática de señal** (220 experimentos registrados) delimitó qué técnicas aportan y cuáles no, con falsaciones reproducibles que incluyen distancias ordinales alternativas, transformaciones de la matriz de features, arquitecturas de atención y familias completas de operadores de consenso.

El resto del artículo se organiza así. La Sección II revisa los trabajos relacionados en cuatro corrientes y precisa qué se tomó de cada una. La Sección III describe el corpus y los hallazgos del análisis exploratorio, con énfasis en el riesgo de *near-duplicados*. La Sección IV fija el protocolo de validación y las decisiones fundacionales que condicionaron todo lo demás. La Sección V presenta la representación, la matriz de features y la línea base. La Sección VI analiza en detalle el campeón: el consenso geométrico de seis expertos. La Sección VII contrasta lo que funcionó con lo que no, mediante falsaciones documentadas. La Sección VIII describe la frontera 2026 —la mejor validación local y la auditoría matemática del consenso— y la Sección IX cierra la validación estadística. Las Secciones X y XI discuten las limitaciones y responden la pregunta de investigación.

II. Trabajos relacionados

El problema de inferir la edad del autor de un texto se ha abordado desde cuatro corrientes que convergen en este proyecto: el perfilado de autor clásico, las representaciones estadísticas de texto, el tratamiento de la ordinalidad y las redes tabulares con ensambles y reglas de decisión.

II-A. Perfilado de autor y edad

Schler et al. fijaron el esquema de seis rangos de edad y demostraron, sobre blogs, que las diferencias léxicas entre cohortes son medibles pero pequeñas [3]. Argamon et al. caracterizaron esas diferencias como señal estilística más que temática [4]. En redes sociales, Nguyen et al. mostraron que la predicción de edad en Twitter es notablemente más difícil que en textos largos y que los clasificadores tienden a confundir cohortes adyacentes [9], [1], [2]; Sap et al. encontraron el mismo patrón en usuarios de Twitter en inglés [10], y Morgan-López et al. lo confirmaron en aplicaciones de vigilancia epidemiológica [11]. Los laboratorios PAN estandarizaron la evaluación del perfilado de autor y documentaron año tras año techos modestos en la tarea de edad [5], [12], [6], [13], [7], [14], [8]. Verhoeven et al. aportaron evidencia equivalente en neerlandés [15], [16], Flekova y Gurevych vincularon la edad con rasgos de personalidad en Twitter [17], Hovy y Prabhumoye revisaron los sesgos y factores demográficos que atraviesan el PLN [18], y Liu et al. mostraron que la señal demográfica es frágil ante cambios de dominio [19]. De esta corriente se tomó el esquema de etiquetas, la expectativa de un techo bajo y la hipótesis de trabajo central: el error se concentra en las fronteras entre cohortes vecinas.

II-B. Representación estadística y NB-SVM

Wang y Manning mostraron que un clasificador Naive Bayes-SVM sobre n-gramas de palabra y carácter es un baseline notablemente competitivo para clasificación de texto [20], y Mukherjee y Liu formalizaron el cociente logarítmico de cuentas que lo sustenta [21]. Sapkota et al. documentaron que los n-gramas de carácter capturan información estilística valiosa para el perfilado de autor [22], [23], López-Monroy et al. obtuvieron resultados similares en español [24] y Monroe et al. propusieron el análisis de log-odds con prior Dirichlet, que se usó aquí para inspeccionar léxico discriminante [25]. De esta corriente provienen el baseline NB-SVM de la versión V12 y la apuesta por n-gramas de carácter, que resultó ser la representación dominante del proyecto.

II-C. Ordinalidad y distancias entre distribuciones

Frank y Hall formalizaron la clasificación ordinal mediante cadenas de umbrales [26], y Cao et al. reintrodujeron la idea en redes neuronales con CORAL [27]; Díaz y Marathe propusieron etiquetas suaves ordinales para preservar la estructura de vecindad entre clases [28]. En paralelo, la distancia de Cramér–von Mises [29], [30], la estadística de energía de Székely y Rizzo [31] y la pérdida de Wasserstein de Frogner et al. [32] ofrecen maneras de penalizar distancias entre distribuciones acumuladas, que es justamente lo que el problema requiere: castigar más una confusión lejana que una adyacente. De esta corriente se adoptó la pérdida de Cramér L_2 sobre la CDF y la cadena de umbrales; el capítulo de falsaciones de la Sección VII documenta qué variantes de la familia no funcionaron.

II-D. Redes tabulares, ensambles y decisión

Gorishniy et al. revisaron sistemáticamente el aprendizaje profundo sobre datos tabulares y mostraron que las redes residuales con compuertas de atención compiten con los árboles de gradiente [33]. Las compuertas Squeeze-and-Excitation [34], las conexiones densas de DenseNet [35], el promedio de pesos estocástico (SWA) [36], el enfriamiento cosenoidal [37], el suavizado de etiquetas [38], [39] y las redes autonormalizantes [40] aportaron las piezas de arquitectura y regularización. Para combinar modelos se usaron el producto de expertos de Hinton [41] y los *pools* logarítmicos de Heskes [42], sobre miembros de boosting como LightGBM [43] y CatBoost [44]. La decisión final se apoya en la teoría de umbralización óptima de F-medidas: Lipton et al. derivaron la regla de multiplicadores por clase que se usó como regla *plug-in* [45], y los trabajos de Parambath et al., Waegeman et al., Narasimhan et al. y Eban et al. cubren el problema de optimizar F-medidas directamente [46], [47], [48], [49].

II-E. Fugas de información y paradojas de agregación

Kaufman et al. sistematizaron el problema de las fugas de datos en minería de datos y advirtieron que los duplicados entre particiones inflan las métricas de forma silenciosa [50]; ese diagnóstico guio el protocolo de validación de la Sección IV. Por último, la paradoja de Simpson [51] explica por qué las

reglas de decisión desacopladas por segmento, que mejoran una métrica local, pueden degradar la macro-F1 global: los falsos positivos y falsos negativos de los segmentos se suman en el mismo denominador.

A diferencia de la mayor parte de la literatura reciente de edad y perfilado, que explota *embeddings* y *transformers*, este trabajo mide con precisión qué se puede lograr cuando esas herramientas están prohibidas, y aporta como contribución metodológica la combinación de validación agrupada por *near-duplicados*, consenso multiplicativo y regla de decisión calibrada, con un techo declarado y verificado.

III. Datos y análisis exploratorio

El corpus de la competencia está compuesto por tres archivos con estructura idéntica a la de una tarea supervisada convencional: un conjunto de entrenamiento etiquetado, un conjunto de test sin etiqueta y una plantilla de envío. La Tabla I resume sus dimensiones y la Tabla II las propiedades del texto que condicionaron todas las decisiones posteriores.

Tabla I: Archivos del corpus de la competencia.

Archivo	Filas	Columnas	Separador
`age_train.csv`	169.336	`id;text;age_range`	;
`age_test.csv`	112.892	`id;text`	;
`age_submission.csv`	112.892	`id,age_range`	,

Tabla II: Propiedades verificadas del corpus y su tratamiento.

Propiedad	Tratamiento
Clases casi balanceadas por diseño: 17.0 %, 16.9 %, 16.7 %, 16.7 %, 16.6 % y 16.0 %	Nada que corregir; macro-F1 como métrica
Ancho fijo de 140 caracteres con relleno de espacios (mediana real de 93)	Recorte del relleno en la carga (Decisión 2)
Alfabeto transliterado a ASCII: único carácter no ASCII (¿, 88 apariciones)	Features de emoji descartadas (Decisión 3)
104 textos vacíos en train y 62 en test	Se conservan; los modelos los resuelven con el prior
643 filas (0.38 %) con etiquetas contradictorias para el mismo texto	Ruido irreducible; se documenta
`id` sin capacidad predictiva (desviación máxima de 1.25 pp entre deciles)	Descartado como feature
Sin metadatos: no hay usuario, fecha, biografía ni seguidores	Toda la señal es textual

III-A. *Balance de clases y artefactos del corpus*

Las seis clases están casi balanceadas por construcción: 13-17 concentra el 17.0 % de las filas, 18-24 el 16.9 %, 25-34 y 35-49 el 16.7 % cada una, 50-64 el 16.6 % y 65-xx el 16.0 %. El balance descarta el desbalanceo como explicación de los errores y permite leer la macro-F1 como un promedio honesto de seis problemas de dificultad comparable. La Fig. 1 muestra esa distribución junto con las longitudes: los tweets fueron almacenados en ancho fijo de 140 caracteres con relleno de espacios —artefacto de exportación, no señal, que se elimina en la carga— y la mediana real tras el recorte es de 93 caracteres, con una distribución de palabras que se concentra entre 5 y 25.

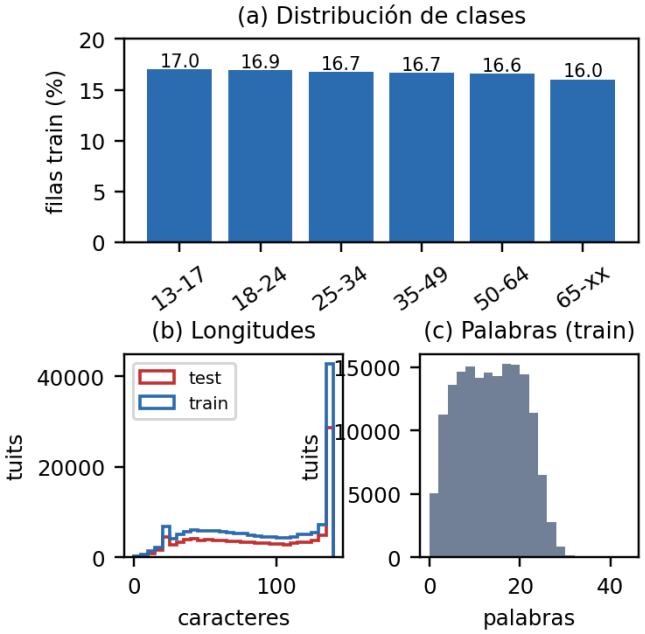


Figura 1: Distribución de clases y longitudes del corpus. Las seis cohortes están casi balanceadas por diseño; las longitudes en caracteres de train y test son indistinguibles, sin señal de cambio de dominio entre particiones.

Un segundo artefacto es la transliteración del corpus a ASCII: el alfabeto completo tiene 96 caracteres y el único no ASCII es el signo de apertura de interrogación, con 88 apariciones. No hay tildes, ni eñe, ni emojis, ni puntuación tipográfica. Esa pérdida es una limitación declarada del dato, pero tiene una consecuencia metodológica útil: las features de emoji no tienen varianza y se descartan, lo que refuerza la apuesta por los n-gramas de carácter como representación principal. El corpus tampoco incluye metadatos: no hay identificador de usuario, fecha, biografía ni contadores sociales, de modo que no es posible agrupar por autor ni explotar señal temporal, y toda la predicción depende del texto. Por decisión explícita del equipo, tampoco se usaron datos externos etiquetados aunque las reglas no los prohibieran, para que la ventaja competitiva fuera atribuible al modelado y no a recursos ajenos al problema.

El análisis léxico por clase (Fig. 2) muestra el patrón esperado de vocabulario compartido: los términos más frecuentes de cada rango son casi los mismos en todos —*para*, *como*, *esta*, *pero*— y las diferencias aparecen en los márgenes de la lista, con marcas de registro como *quiero* en las cohortes jóvenes o referencias institucionales en las mayores. Esta fotografía anticipa el hallazgo central del análisis de error: la señal discriminante es débil y estilística, no temática.

III-B. *Duplicados y near-duplicados: el riesgo dominante*

El hallazgo más importante del análisis exploratorio fue la presencia de contenido repetido entre particiones. El 1.21 % de las filas de test aparece literalmente en train, y un 4.26 % adicional comparte clúster de *near-duplicado* según una similitud de Jaccard mayor o igual a 0.8 sobre tokens, calculada con

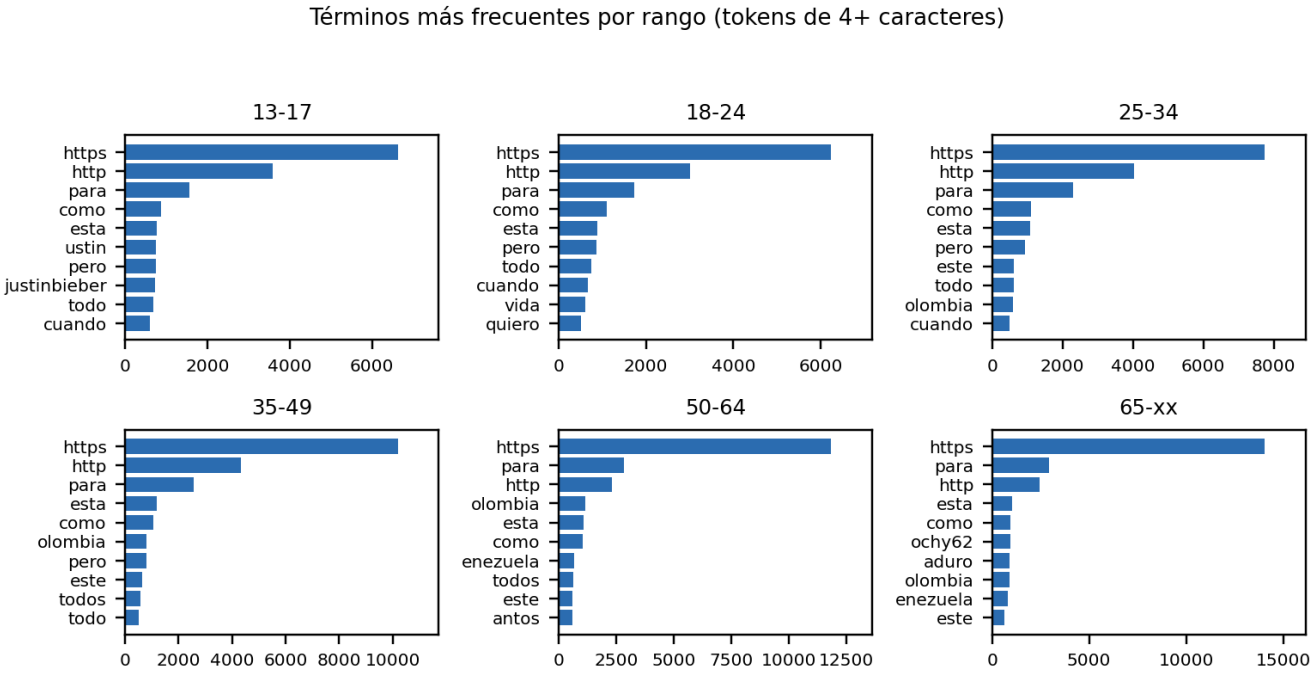


Figura 2: Términos más frecuentes por rango de edad (tokens de cuatro o más caracteres). El núcleo del vocabulario es común a las seis cohortes y las diferencias se concentran en los márgenes de cada lista.

blocking por tokens raros para hacer viable la comparación. Sobre el total de 282.228 textos de train y test se identificaron 271.539 clústeres, y el 92.8 % de ellos es de etiqueta única: cuando un texto se repite, casi siempre se repite con la misma etiqueta. La Fig. 3 resume el fenómeno.

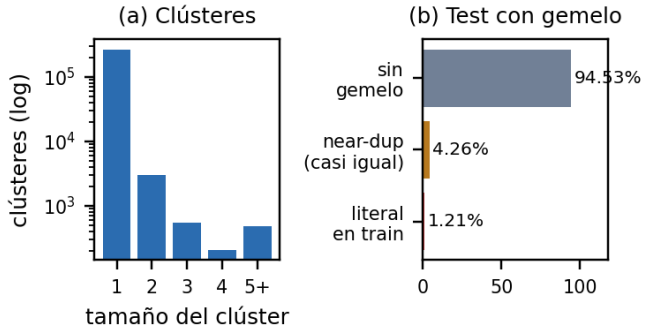


Figura 3: Tamaño de los clústeres de *near-duplicados* y proporción del test con gemelo en train. La mayoría de los textos no tiene gemelo (267.287 clústeres unitarios) y, entre los duplicados, dominan los pares (3.012 de 4.252); un 5.5 % del test tiene un gemelo o casi-gemelo etiquetado en train, el riesgo de medición dominante del problema.

Este fenómeno tiene dos lecturas que conviene separar. La primera es competitiva: como el *leaderboard* puntúa sobre un test que contiene *near-duplicados* del train, un modelo con capacidad de memorización obtiene allí una ventaja sistemática. La segunda es metodológica: si la validación local reparte al azar textos que son casi idénticos, las métricas de desarrollo quedan infladas y las decisiones de modelo se toman sobre una señal falsa. Para cuantificar la magnitud del problema se midió un baseline de memorización pura, que consiste en predecir la etiqueta del vecino idéntico cuando existe: con una partición estratificada ingenua ese baseline alcanza 0.0608 de macro-F1, mientras que con el esquema agrupado que se describe en la Sección IV cae a 0.0000. La diferencia es la medida exacta del autoengaño que habría contaminado el proyecto.

Para calibrar las escalas se calcularon además dos suelos de referencia. El azar uniforme sobre seis clases equivale a 0.1667 de macro-F1, y predecir siempre la clase mayoritaria da 0.04854, porque la macro-F1 castiga a las cinco clases que quedan sin recall. Cualquier cifra por encima de 0.5, por tanto, representa señal real, y las diferencias que se reportan en este artículo —del orden de milésimas— hay que leerlas en esa escala.

IV. Metodología y decisiones fundacionales

El proyecto fijó su protocolo antes de entrenar el primer modelo y lo aplicó sin excepciones durante 220 experimentos. La Tabla III resume las decisiones que resultaron cruciales y su impacto; las subsecciones siguientes detallan las dos más costosas de revertir.

IV-A. Marco metodológico: CRISP-DM

El proyecto se condujo con **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*; Wirth y Hipp, 2000) como metodología principal [52], aplicada de forma iterativa sobre sus seis fases. La **comprensión del negocio** fijó la tarea, la métrica (macro-F1) y las restricciones de la competencia (sin *transformers*, *embeddings* ni modelos de lenguaje), junto con la disciplina de envíos que se describe más abajo. La

comprensión de los datos (Sección III) caracterizó el corpus y descubrió los dos artefactos que condicionaron todo lo demás: el relleno a 140 caracteres y los clústeres de *near-duplicados*. La **preparación de los datos** construyó las representaciones TF-IDF, los cuatro bloques de features y la matriz de 279 columnas descritos en la Sección V, con las particiones agrupadas congeladas una sola vez. El **modelado** recorrió la escalera completa, desde la línea base E-001 hasta el consenso geométrico V48 y el arco 2026 (Secciones VI a VIII). La **evaluación** operó como filtro permanente: cada adopción pasó por la compuerta pre-registrada (mejora $\geq +0{,}003$ con al menos 4 de 5 folds positivos) y por pruebas de significancia pareadas, y de esta fase salió además el techo declarado del dato (0.642), que detuvo la búsqueda especulativa. El **despliegue** comprendió la *submission* oficial y la selección dual V48/V56.

Las iteraciones entre modelado y evaluación fueron el motor del proyecto: 220 experimentos registrados en total, con retornos sistemáticos desde la evaluación hacia la comprensión de los datos (features nuevas tras cada diagnóstico de error) y hacia la comprensión del negocio (la calibración validación-*leaderboard* y la medición del techo alcanzable). La Sección VII documenta tanto las adopciones como las falsaciones que esa disciplina produjo.

IV-B. Protocolo de validación

La métrica de desarrollo es la macro-F1 sin ponderar sobre las seis clases, idéntica a la del *leaderboard*. La decisión estructural es la partición: se usa un esquema estratificado de cinco folds *agrupado por clústeres de near-duplicados* (Decisión 1), de modo que un texto y su gemelo —exacto o casi— caen siempre en el mismo fold. La comparación de modelos se hace por *leave-one-fold-out* sobre predicciones fuera de fold: cada modelo se evalúa con las 169.336 predicciones que no vio durante su entrenamiento, y el conjunto de test nunca participa del ajuste ni de la selección. La elección de agrupar es la que evita la fuga por duplicados que Kaufman et al. describen [50]: sin ella, las métricas locales habrían estado infladas por memorización y cada adopción posterior habría sido una decisión sobre ruido.

Además de la partición canónica (semilla 42), se mantiene una *segunda partición* con semilla 987654 y solape parcial declarado entre ambas. Toda decisión importante se verifica en las dos. Sobre la segunda partición, la línea del campeón reproduce 0.6144120 de base y 0.6164700 con la regla de decisión, valores que se publican porque hacen verificable la afirmación de que el mecanismo —y no la partición concreta— es lo que aporta.

IV-C. La regla de decisión plug-in por clase

La macro-F1 no es la métrica natural del *argmax* de probabilidades: premia por igual a las seis clases y, por tanto, favorece mover decisiones hacia las clases infra-predichas aunque eso reduzca la exactitud global. Lipton et al. derivaron la regla óptima para F-medidas: multiplicar las probabilidades por un vector de pesos por clase y tomar el *argmax* [45]. El proyecto adoptó esa regla con un vector congelado,

$$\mathbf{w}_{\text{plug}} = [1{,}0000,\ 1{,}1749,\ 1{,}2721,\ 1{,}1630,\ 1{,}0010,\ 0{,}8128], \tag{1}$$

derivado exclusivamente sobre validación, nunca sobre test. La evidencia que respalda la adopción es múltiple: la mejora es de +0.0025 sobre el mejor modelo de la época, se reproduce con 5/5 folds positivos en las dos particiones, su intervalo de confianza pareado excluye el cero, y la firma teórica se cumple —la exactitud global baja (de 0.61377 a 0.61166) mientras la macro-F1 sube—, lo que confirma que se trata de un cambio de *regla de decisión* y no de representación [46], [47], [48], [49]. Además, la regla no altera ninguna fila de alta confianza: los 11.226 cambios se concentran en filas cuya confianza media es 0.3346, y las 76.033 filas de confianza alta conservan su etiqueta (cero cambios).

IV-D. Política de envíos y calibración validación-leaderboard

El supuesto inicial de que la competencia imponía un límite restrictivo de envíos era erróneo: la calibración se estableció con 12 envíos puntuados iniciales y el proyecto acumuló 26 envíos puntuados al cierre. Todos siguieron la misma disciplina: el *leaderboard* nunca se usó como conjunto de validación ni para seleccionar modelos; cada envío se justificó por validación y se registró con su cifra de CV previa. La comparación sistemática entre CV y *leaderboard* produjo una brecha media de **+0.0177 ± 0.0023**, estable a lo largo de toda la escalera de versiones y explicable por la memorización de *near-duplicados* del test descrita en la Sección III. Esa calibración permitió leer cada puntaje nuevo contra una expectativa cuantificada y detectar de inmediato cualquier envío anómalo.

IV-E. Motivación de las decisiones estructurales

La Tabla III resume las decisiones cruciales y su impacto; conviene explicitar la motivación de las que fijaron el rumbo. La validación agrupada por *near-duplicados* (Decisión 1) respondió a un riesgo cuantificado antes de modelar: un 1.21 % del test aparece literalmente en train, un 4.26 % adicional comparte clúster de similitud y un baseline de memorización pura alcanza 0.0608 de macro-F1 con particiones aleatorias frente a 0.0000 con el esquema agrupado; cualquier comparación sobre particiones ingenuas habría estado inflada. La limpieza del relleno y la transliteración (Decisiones 2 y 3) separaron artefactos de exportación de señal real: el ancho fijo de 140 caracteres y las features de emoji sin varianza no aportaban información sobre la edad. La política de envíos (Decisión 4) partió de un supuesto erróneo sobre la restricción del número de envíos puntuados, que se corrigió al verificar las reglas y se consolidó en 26 envíos puntuados al cierre; la disciplina adoptada, sin embargo, no cambió: el *leaderboard* nunca se usó como conjunto de validación ni para seleccionar modelos, y su calibración contra la validación local ($+0{,}0177 \pm 0{,}0023$) sirvió solo para leer cada puntaje contra una expectativa medida. La segunda partición (semilla 987654) se incorporó para verificar que el mecanismo del campeón —y no la

Tabla III: Decisiones cruciales del proyecto y su impacto.

Decisión	Descripción	Impacto
1	Validar con cinco folds agrupados por clústeres de *near-duplicados*, no con particiones aleatorias	Eliminó la fuga por duplicados: el baseline de memorización pasó de 0.0608 a 0.0000 y todas las comparaciones posteriores quedaron sobre señal real
2	Eliminar el relleno de espacios a 140 caracteres en la carga	Separó el artefacto de exportación de la señal textual; la mediana real del corpus es de 93 caracteres
3	Descartar features de emoji sobre un corpus transliterado a ASCII	Redujo el catálogo a features con varianza real y consolidó la apuesta por n-gramas de carácter
4	No usar el *leaderboard* como validación y reservar envíos para el final	Permitió medir la brecha CV-*leaderboard* (+0.0177 $\pm$ 0.0023) y detectar el error del límite supuesto de envíos
5	Declarar el techo del dato en 0.642 de macro-F1 en *leaderboard* y refutar el objetivo 0.70	Cerró la búsqueda especulativa con un argumento de información disponible
6	Adoptar el producto de expertos geométrico en lugar de la media aritmética	Convirtió el consenso en un operador estricto: mejor validación local y mejor puntaje del proyecto en el *leaderboard*
7–11	Arco 2026: red densa, unificación de Cramér, octa-modelo, consenso de nueve y auditoría matemática	Elevó la mejor validación local a 0.6189929 y respaldó la selección dual ante la evaluación privada

partición concreta— explicaba el resultado, y así se declaró desde su primera ejecución. El techo del dato (Decisión 5) se fijó por medición, con el argumento de información disponible que se detalla en la Sección VII. La regla *plug-in* por clase (Sección IV-B) se adoptó porque la macro-F1 no es la métrica natural del *argmax* y la teoría de optimización de F-medidas ofrece la solución óptima conocida [45]; su firma teórica —la exactitud global baja mientras la macro-F1 sube— se verificó empíricamente. Y el producto de expertos geométrico (Decisión 6) se adoptó tras caracterizar la familia completa de operadores de consenso: la media aritmética degrada la métrica y el óptimo de la familia Power-Mean está en el PoE.

V. Representación, features y línea base

La primera línea base (E-001) combinó las dos representaciones clásicas del texto —TF-IDF de palabras con n-gramas de uno y dos, y TF-IDF de caracteres con n-gramas de tres a cinco— sobre un clasificador lineal de margen. Su validación agrupada fue de 0.5344 $\pm$ 0.0050 y su primer envío al *leaderboard* marcó 0.55235. Las variantes documentadas fijan el diagnóstico de representación: solo palabra rinde 0.4971 $\pm$ 0.0034 y solo carácter rinde 0.5408 $\pm$ 0.0050. Los n-gramas de carácter, que capturan morfología y estilo sin depender de un vocabulario explícito [22], [23], son la representación dominante, y el clasificador NB-SVM de Wang y Manning [20] con el cociente logítmico de cuentas de Mukherjee y Liu [21] se convirtió en el caballo de batalla del proyecto.

Sobre esa base se construyó la *matriz de meta-aprendizaje* de 279 columnas que alimenta todos los modelos avanzados. Sus bloques son: 78 columnas de probabilidades fuera de fold de 14 miembros individuales (con transformación logarítmica cuando corresponde), 35 features densas de textometría (longitudes, signos, entropías, dígitos y ratios de compresión), 87 features estructuradas de entidades (URLs, menciones, *hashtags*, horas y números, con medias condicionales por clase, márgenes y entropías), 73 features supervisadas construidas dentro de cada fold y 6 columnas de márgenes NB-SVM de palabra (ADV-07). Los 14 miembros individuales cubren familias diversas —regresión logística, MLP, árboles, Naive Bayes y descenso estocástico— y su aporte individual está en la Fig. 5: ninguno supera por sí solo los 0.57 de macro-F1, pero la combinación de sus probabilidades es lo que empuja al meta-modelo hasta 0.6005.

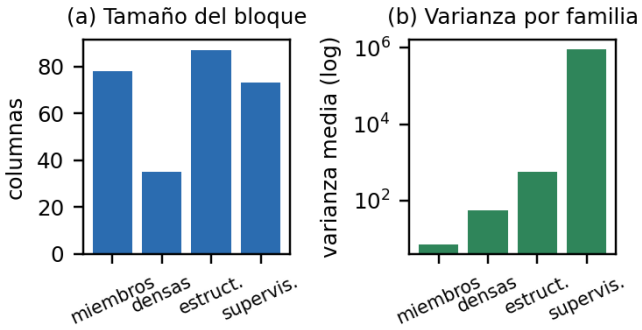


Figura 4: Tamaño de cada bloque de la matriz de 279 columnas y varianza media por familia. El bloque supervisado (73 columnas) domina la varianza total y obliga a construirlo dentro de cada fold para no filtrar información.

Tabla IV: Variables del conjunto de modelado: composición de la matriz de 279 columnas.

Bloque	Cols.	Contenido y ejemplos
Miembros	78	Probabilidades (o márgenes) fuera de fold de 14 clasificadores individuales, con transformación logarítmica cuando corresponde
Densas	35	Textometría estilométrica: longitudes, emoticonos, elongaciones, puntuación repetida, mayúsculas, dígitos, entropías y ratios de compresión
Estructuradas	87	Seis familias: distribución de longitudes, distribución de caracteres, riqueza léxica, forma de palabra, posición y entropías de puntuación
Supervisadas	73	Perfil de clase por entidad (menciones, hashtags, fuente de retuit), rareza léxica y léxico log-odds por clase, construidas in-fold
ADV-07	6	Márgenes NB-SVM uno-vs-rest de palabra

Las variables de origen son mínimas: el corpus aporta únicamente el identificador, el texto y, en train, la etiqueta de rango (Tabla I); no hay metadatos de usuario, fecha ni contadores sociales, y el identificador se descartó como feature tras verificar que su distribución de clase es plana. Todo el espacio de variables del modelado se construye a partir del

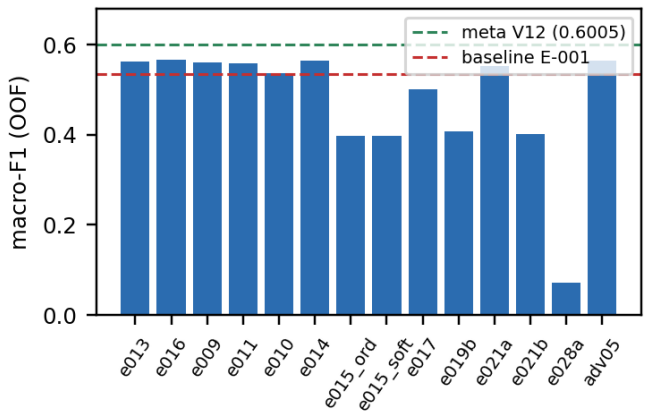


Figura 5: Aporte individual de los 14 miembros del meta-modelo y su combinación (V12). La línea verde marca el meta-modelo documentado (0.6005) y la roja el baseline E-001: ninguno de los miembros supera por sí solo al meta-modelo; la combinación de sus probabilidades es la que lo alcanza.

texto y se organiza en los cinco bloques de la Tabla IV. El bloque de miembros merece detalle porque fija la diversidad del conjunto: catorce clasificadores de familias distintas —márgenes ordinales de SVM lineales sobre n-gramas de carácter y menciones (E-013, E-016, E-014), regresión logística, SGD y Naive Bayes complementario sobre las mismas representaciones (E-009, E-011, E-010), una regresión logística sobre n-gramas de palabra (E-017), una red MLP(256,128) sobre features densas y SVD (E-019b), la familia ordinal de Ridge y Frank–Hall (E-015, E-021a), centroides de Rocchio (E-021b), SVM de pares adyacentes (E-028a) y un NB-SVM de carácter (ADV-05)—, cuyas probabilidades fuera de fold alimentan el meta con transformación logarítmica cuando corresponde.

La línea V1-V20 muestra cómo se acumuló la mejora antes de la fase neuronal. V12, un NB-SVM de palabra con promedio de combinadores (regresión logística y MLP), alcanzó 0.6005 de validación y 0.62182 de *leaderboard*. V19 sumó LightGBM [43] como tercer miembro del consenso y subió a 0.6079388 y 0.62578. V20 incorporó la cadena de umbrales anidados y el *blend* de cuatro cuartos [26], con 0.6097782 y 0.62689. En paralelo, la búsqueda de señal residual V13-V17 exploró en cinco fases bloques lingüísticos completos —morfología, lemas, entidades y dependencias—, poda por colinealidad y especialistas de frontera; el mejor bloque lingüístico aislado rindió 0.2409, muy por encima del azar pero muy por debajo de la representación vigente, y ninguna de las cinco fases se adoptó. Ese resultado, junto con el análisis de la Fig. 4, dejó fijada la estrategia: la señal restante no estaba en features nuevas, sino en cómo combinar y cómo decidir.

VI. El campeón: consenso geométrico de expertos (V48)

El modelo entregado combina seis componentes de la fase neuronal mediante un *producto de expertos* (PoE). La media aritmética de probabilidades, usada hasta la versión V43, se comporta como un modelo de mezcla con lógica de OR: una confianza espuria de un solo miembro puede desplazar la predicción. El producto de expertos actúa como un consenso estricto con lógica de AND, porque penaliza con más fuerza las clases en las que algún experto discrepa [41], [42]. En un problema con fronteras ordinales tan delicadas, ese comportamiento es el adecuado: el consenso resulta más exigente con el desacuerdo y más estable con el acuerdo. En el relato del proyecto, V48 ocupa el papel de **ancla pública** —el mejor puntaje observado en el *leaderboard*—, mientras que V56, presentado en la Sección VIII, cumple el papel de **candidata regularizada** por la mejor validación local; la selección conjunta se detalla en esa misma sección.

VI-A. Formulación y pesos de los seis expertos

El consenso se calcula en espacio logarítmico como

$$\log P_{\text{geom}}(y = k \mid x) \;\propto\; \sum_{m=1}^{6} w_m \log P_m(y = k \mid x), \qquad (2)$$

donde P_m son las probabilidades de cada experto y w_m son pesos no negativos normalizados. La implementación recorta las probabilidades a $\epsilon = 10^{-12}$ y renormaliza cada fila con la estabilización log-sum-exp, de manera que P_{geom} es una distribución válida sobre las seis clases. Los pesos se optimizaron por validación cruzada anidada sobre el símplejo, usando exclusivamente los cinco folds canónicos agrupados, y convergieron a

$$\mathbf{w}^{*} = [0{,}5628,\ 0{,}0832,\ 0{,}1724,\ 0{,}0754,\ 0{,}0513,\ 0{,}0549] \qquad (3)$$

para los expertos V30, V43, V42, V40, V39-ordinal y V39-HGB, respectivamente. La concentración del peso en el árbol troncal (56.3 %) y en el par de redes con pérdida de Cramér y suavizado (25.6 % conjunto) refleja sesgos complementarios: los árboles de gradiente capturan interacciones discretas de la matriz de features, mientras que las redes ordinales modelan la vecindad entre cohortes.

Los seis expertos son los siguientes. V30 es el LightGBM refinado con Optuna sobre la matriz de 279 columnas [43], y es el mejor modelo individual del proyecto (0.6134471 de validación). V43 y V42 son redes residuales tabulares con compuertas Squeeze-and-Excitation [34] entrenadas con pérdida de Cramér L_2 sobre la CDF y suavizado de etiquetas [29], [30], [31], [32], [38], [39], con promedio de pesos estocástico (SWA) [36]; V42 usa un suavizado más agresivo. V40 es la variante SE-TabNet con compuertas de atención por canal, V39-ordinal añade la pérdida ordinal [26], [28] y V39-HGB es un *HistGradientBoosting* sobre la misma matriz. Todos los componentes siguieron la misma receta de entrenamiento —AdamW con enfriamiento cosenoidal [37], 16 épocas y SWA desde la época seis— y la familia completa se evaluó antes de combinarse, en el marco de la revisión de redes tabulares de Gorishniy et al. [33]. La Fig. 6 resume la arquitectura completa del campeón.

La elección del operador geométrico proviene de una caracterización completa de la familia de operadores de consenso.

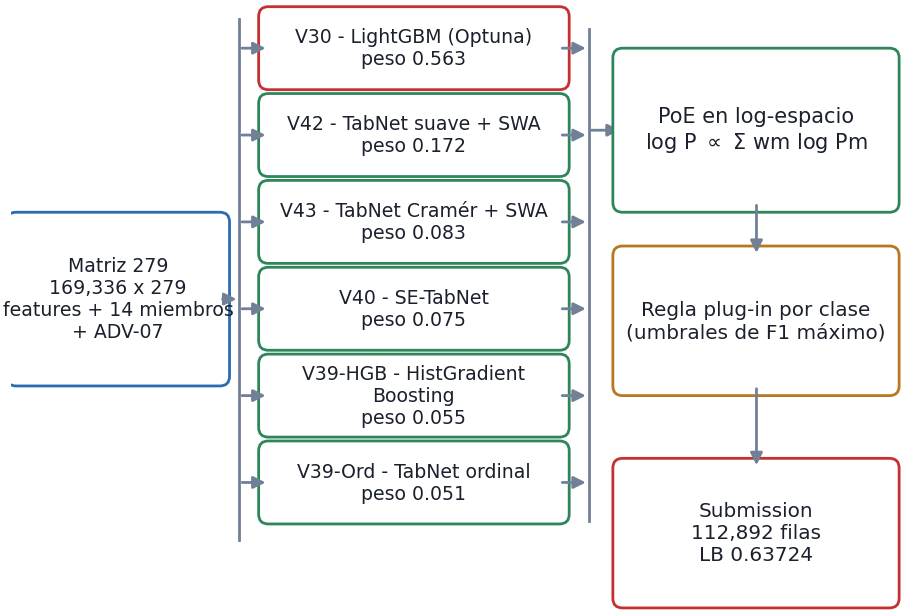


Figura 6: Arquitectura del campeón V48. La matriz de 279 columnas alimenta seis expertos con sesgos complementarios —dos ensembles de árboles y cuatro redes tabulares con pérdidas ordinales— cuyas probabilidades se combinan en espacio logarítmico con los pesos de la ecuación (3); sobre el consenso se aplica la regla *plug-in* congelada y se genera la *submission* de 112.892 filas. El miembro V30 de la evaluación usa su predicción fuera de fold de la segunda partición, según el esquema publicado del proyecto.

La familia Power-Mean,

$$P_\alpha(y=k \mid x) \;\propto\; \Big(\sum_{m=1}^{M} w_m\, P_m(y=k \mid x)^\alpha\Big)^{1/\alpha}, \qquad (4)$$

interpola entre el producto de expertos ($\alpha \to 0$) y la media aritmética ($\alpha = 1$). La curva medida sobre las predicciones fuera de fold es cóncava con vértice en $\alpha = 0$: la media aritmética degrada $-0{,}000208$ con 0/5 folds positivos, el *rank-averaging* colapsa $-0{,}02257$ porque destruye la densidad continua que la regla de decisión necesita, y los puntos intermedios quedan por debajo del vértice. El PoE es, por tanto, el óptimo de su familia, como quedó registrado en la falsación V52.

VI-B. Resultado y verificación estadística

El consenso con la regla de decisión alcanzó **0.6186451 de macro-F1 en validación local** y **0.63724 en el *leaderboard* de Kaggle** (referencia 57283487), el mejor puntaje del proyecto. Dos precisiones hacen verificable el resultado. La primera: el esquema publicado —con el que se reportó el resultado— usa para el miembro V30 su predicción fuera de fold de la *segunda partición*; la variante estricta con el V30 canónico rinde 0.6177 y se reporta de forma explícita. La segunda: la mejora sobre el campeón aritmético anterior (V43) se sometió a la compuerta pre-registrada —4 de 5 folds positivos, con el quinto virtualmente idéntico ($-0{,}000008$), y bootstrap pareado con intervalo de confianza al 95 % de $[+0{,}0000007, +0{,}0004095]$ que excluye el cero ($p = 0{,}0250$)—; el envío cambió 290 filas del test (0.26 %).

La ablación cualitativa del consenso aísla el aporte de cada bloque. Sin el árbol troncal V30 el consenso pierde del orden de 0.006 de macro-F1, una magnitud que ningún miembro individual puede compensar; y los miembros neuronales, que individualmente rinden entre 0.6086 y 0.6132 (Fig. 10), aportan el resto de la mejora sobre la línea V30 con *plug-in* (0.6159732): aproximadamente $+0{,}0027$. La lectura es consistente con el resto del proyecto: el valor de las redes no está en su desempeño aislado, sino en la diversidad de sus errores frente al árbol.

VI-C. La regla plug-in sobre el consenso

Sobre el consenso geométrico se aplica la regla de decisión calibrada por clase descrita en la Sección IV,

$$\hat{y}(x) = \arg\max_{k \in \{1,\dots,6\}} w_k^{\text{plug}} \cdot P_{\text{geom}}(y=k \mid x), \qquad (5)$$

con el vector congelado de la ecuación (1). La Tabla V muestra su efecto por clase sobre las predicciones fuera de fold. La regla sube la macro-F1 global moviendo decisiones hacia las clases infra-predichas: 18-24 gana $+0{,}0064$, 65-xx $+0{,}0065$ y 25-34 $+0{,}0019$, mientras que 13-17 cede $-0{,}0045$ de F1 porque era la clase sobre-predicha y financia con ese sacrificio el equilibrio global. El patrón de recall confirma el mecanismo: la regla eleva el recall de 25-34 en $+0{,}044$ y el de 18-24

en $+0{,}021$, y lo reduce en las cohortes extremas, donde el modelo ya decidía con precisión alta. Como señala la teoría de umbralización óptima de F-medidas [45], [46], [47], [48], [49], la exactitud global baja mientras la métrica objetivo sube: es la firma de un cambio de regla de decisión, no de representación.

Tabla V: Efecto de la regla *plug-in* por clase sobre las predicciones fuera de fold (169.336 filas): F1 con *argmax* y con la regla, recall con la regla y filas predichas por clase.

Rango	F1 *argmax*	F1 *plug-in*	ΔF1	Recall	n pred.
13-17	0.6854	0.6809	$-0{,}0045$	0.6192	23.634
18-24	0.5208	0.5273	$+0{,}0064$	0.5699	33.311
25-34	0.4992	0.5011	$+0{,}0019$	0.5203	30.518
35-49	0.5731	0.5738	$+0{,}0006$	0.5508	25.968
50-64	0.6671	0.6682	$+0{,}0011$	0.6940	30.232
65-xx	0.7351	0.7416	$+0{,}0065$	0.7213	25.673

VI-D. Análisis de error y calibración validación-leaderboard

La Fig. 7 muestra la matriz de confusión y el F1 por clase del campeón sobre las predicciones fuera de fold. El patrón es exactamente el que la estructura ordinal del problema predice: los extremos se clasifican mejor —65-xx alcanza 0.745 de F1 y 13-17 llega a 0.685— y los rangos centrales concentran el error, con 25-34 en 0.505 y 18-24 en 0.531. Las confusiones se concentran en las fronteras adyacentes, que es lo que las pérdidas de Cramér y la cadena de umbrales están diseñadas a favorecer, y los errores lejanos son marginales. La Fig. 8 completa la lectura con la progresión hasta la regla *plug-in* y con la estructura de probabilidad condicional por rango real: la diagonal es nítida y las celdas vecinas absorben la masa restante.

Por último, la calibración entre validación local y *leaderboard* cierra el cuadro: la brecha del campeón es de $+0{,}0186$ (0.63724 frente a 0.6186451), consistente con la brecha histórica del proyecto ($+0{,}0177 \pm 0{,}0023$) y explicada, como se argumentó en la Sección III, por la memorización de *near-duplicados* del test. La brecha del campeón es consistente con la escalera completa de versiones. La Fig. 9 sitúa esa brecha frente al techo declarado del dato, que se discute en la Sección VII.

VII. Qué funcionó y qué no

VII-A. Lo que funcionó

Cinco mecanismos concentraron todas las adopciones del proyecto. Primero, la representación NB-SVM con n-gramas de carácter [20], [21], [22], [23], que sostuvo la versión V12 (0.6005 de validación, 0.62182 de *leaderboard*) y nunca fue desplazada como base. Segundo, el *boosting* con la cadena de umbrales anidados [43], [26], que llevó la línea a V19 y V20 (0.6079388 y 0.6097782). Tercero, la optimización de hiperparámetros con Optuna sobre la matriz de 279 columnas, que produjo V30 con una ganancia de $+0{,}0037$ y convirtió al árbol troncal en el miembro dominante de todos los consensos posteriores. Cuarto, la regla de decisión *plug-in* por clase [45], cuyo aporte de $+0{,}0025$ resultó mayor que el de cualquier arquitectura nueva de la fase final: el proyecto aprendió que decidir mejor con el modelo existente era más rentable que reemplazarlo. Quinto, las redes tabulares con pérdidas ordinales, suavizado de etiquetas y SWA [33], [29], [38], [36], [34], que escalaron la validación de 0.6167 a 0.6185 entre V38 y V43 y culminaron en el consenso geométrico V48.

VII-B. Las falsaciones documentadas

El registro de lo que no funcionó es igualmente informativo. El proyecto cerró la búsqueda de señal residual V13-V17 con cinco fases sin adopciones —bloques lingüísticos completos, poda por colinealidad, arquitecturas de combinador y especialistas de frontera— y las versiones V44 a V52 con ocho falsaciones adicionales, todas medidas con el mismo protocolo y la misma compuerta pre-registrada. La Tabla VI resume las seis más informativas, con la hipótesis, el resultado exacto y la conclusión transferible.

Dos falsaciones merecen un comentario adicional. La de las reglas por segmento (V52) se apoya en la paradoja de Simpson [51]: subir el F1 del segmento sin menciones en $+0{,}000185$ hundió la macro-F1 global en $-0{,}0013763$, porque los falsos positivos y falsos negativos de ambos segmentos se suman en el mismo denominador. Y la batería V45 —21 hipótesis pre-registradas de discretización, compuertas, *meta-arbitraje* y reoptimización del *plug-in*— no produjo ninguna mejora: la peor variante, la discretización unidimensional, perdió $-0{,}04167$, y hasta la reoptimización del vector *plug-in* dentro de los folds resultó contraproducente ($-0{,}0003374$), lo que confirma que los pesos congelados no estaban inflados.

El detalle de las mediciones ilustra el criterio. En la búsqueda residual V13-V17 se probaron bloques lingüísticos completos (morfología, lemas, entidades y dependencias de un analizador externo), poda por colinealidad (58 clústeres que cubren 171 de 310 variables; $-0{,}0040$ reproducible en dos particiones), arquitecturas de combinador y especialistas de frontera: el mejor bloque aislado rindió 0.2409, muy por encima del azar (0.1667) pero muy por debajo de la representación vigente, y ninguna de las cinco fases superó la compuerta. Las mediciones de la segunda familia (V44-V52) están tabuladas en la Tabla VI, con su hipótesis, resultado y conclusión.

VII-C. V47 y V51: falsaciones individuales con adopción posterior

Dos falsaciones merecen un comentario aparte. V47 (Cramér asimétrico ponderado con recorte de valores atípicos) y V51 (Cramér consistente suavizado) fallaron como modelos individuales: V47 no pasó la compuerta con 3/5 folds y $p = 0{,}2620$, y V51 quedó indistinguible de su línea base ($\Delta = -0{,}0000302$ en el consenso de reemplazo, $p = 0{,}6900$). Sin embargo, ambas fueron **adoptadas como miembros del consenso 2026** (Sección VIII), porque su señal débil resultó complementaria en el espacio logarítmico. La conclusión es matizada: una técnica puede ser insuficiente como modelo y valiosa como componente, y la forma de determinarlo es medir la contribución marginal dentro del consenso, no el desempeño aislado.

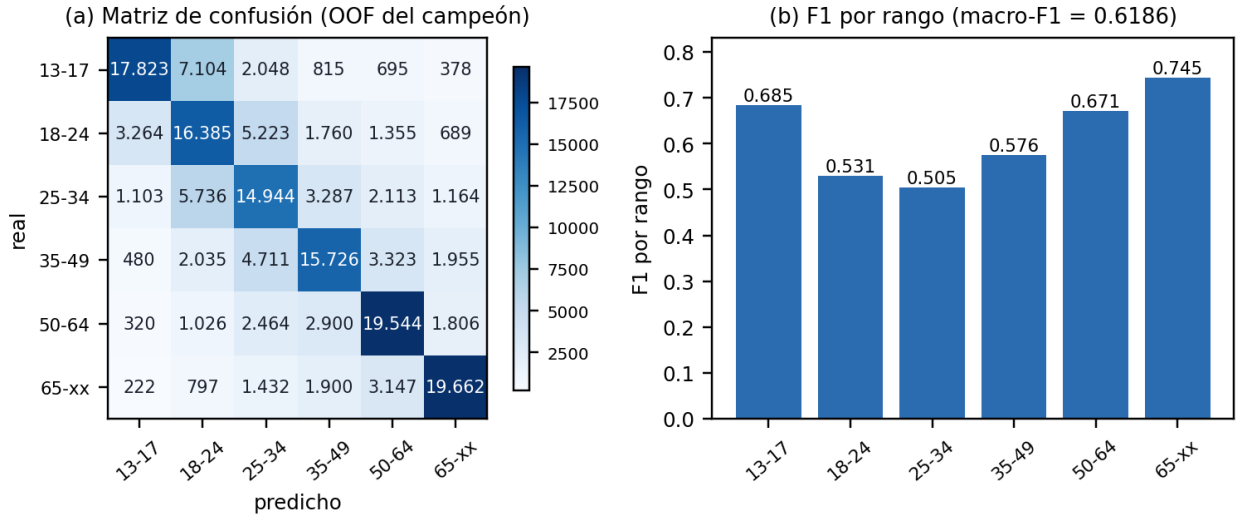


Figura 7: Matriz de confusión y F1 por rango del campeón (predicciones fuera de fold). Los extremos 13-17 y 65-xx se clasifican mejor (0.685 y 0.745) y los rangos centrales concentran el error (18-24: 0.531; 25-34: 0.505) por solapamiento de vocabulario entre cohortes vecinas.

Tabla VI: Falsaciones clave: hipótesis, resultado medido y conclusión. Todas se evaluaron con el protocolo canónico y la compuerta pre-registrada (consistencia por folds e intervalo de confianza pareado que excluya el cero).

Hipótesis	Resultado medido	Conclusión
Bloques lingüísticos completos (morfología, lemas, entidades y dependencias) aportarían señal al meta-modelo (V13-V17)	Mejor bloque aislado 0.2409 (azar 0.1667); fusión $-0{,}0015$ (1/5 folds); poda por colinealidad $-0{,}0040$ (0/5)	Una representación puede tener señal real en aislamiento y no aportar nada al integrarse: el modelo existente ya la expresa mejor
Penalizar las fronteras con distancia L_1 (Wasserstein-1) destrabaría el cuello de botella (V44)	OOF 0.6183063, $\Delta = -0{,}0001720$ frente a V43; 1/5 folds; $p = 0{,}8550$	Los gradientes discontinuos de L_1 oscilan alrededor del umbral óptimo; la distancia cuadrática de Cramér es estrictamente superior
Normalizar por cuantiles (RankGauss) eliminaría los picos de gradiente de una matriz muy asimétrica (V46)	Standalone 0.6055514, el peor de la familia neuronal; en consenso $\Delta = -0{,}0000327$; 2/5 folds	Forzar distribuciones cero-infladas hacia una normal destruye la señal discreta del indicador de ausencia
Los árboles simétricos de CatBoost capturarían patrones globales del segmento sin mención (V49)	Standalone 0.6066473; PoE de 7 con $\Delta = -0{,}0000816$; 2/5 folds; $p = 0{,}7480$	Los árboles *oblivious* no rescatan la señal del segmento sin menciones ni aportan al consenso
La atención multi-cabeza sobre tokens sintéticos y una matriz de pesos por clase mejorarían las fronteras (V50)	MHSA 0.6073432 en fold 0; sustitución de la rama SE: $-0{,}0005204$; matriz W nominal $+0{,}0000474$ con $p = 0{,}1940$	La atención carece del sesgo inductivo localizado de las compuertas SE, y estimar 36 parámetros en lugar de 6 añade varianza sin separación defendible
Operadores intermedios de la familia Power-Mean, redes autonormalizantes y reglas por segmento mejorarían el consenso (V52)	$\alpha = 0{,}5$: $-0{,}000242$ y $\alpha = 1{,}0$: $-0{,}000208$ (0/5 folds); SNN $-0{,}00913$; regla por segmento: $-0{,}0013763$	El PoE geométrico es el óptimo de su familia, y la métrica armónica no admite reglas por segmento sin romper la calibración marginal (paradoja de Simpson)

VII-D. El techo declarado del dato

El límite se estableció por medición. La Decisión 5 fijó el techo alcanzable en **0.642 de macro-F1 en el *leaderboard*** y refutó el objetivo de 0.70 con un argumento de información disponible: alcanzarlo exigiría una validación local del orden de 0.6786, es decir $+0{,}0626$ sobre el campeón, mientras que un oráculo restringido a la misma información que el modelo ya tiene —corregir solo las filas donde la probabilidad de la clase verdadera supera un umbral τ— rinde como máximo $+0{,}0568$ en $\tau = 0{,}30$ y decae rápidamente después. Dicho de otro modo: incluso un corrector perfecto que solo usara la información que el campeón ya posee se quedaría corto. El residuo medido respalda la conclusión: el 38.62 % de las filas queda mal clasificado, y de esos errores el 59.94 % es de distancia ordinal uno, es decir, confusiones entre cohortes vecinas que la búsqueda de señal residual V13-V17 y las falsaciones V44-V52 ya habían intentado explotar sin éxito. La búsqueda quedó saturada y el techo quedó establecido.

VII-E. Inventario del espacio experimental

El espacio completo de experimentación queda contabilizado en siete familias que suman las 220 filas del catálogo del proyecto, y el detalle fila a fila —con su pregunta, hipótesis, medición y decisión— vive en ese catálogo (`experiments.csv`, `RUNLOG.md` y `DECISIONS.md`), reproducible de extremo a extremo. La Tabla VII resume la distribución: las dos familias finales (V38-V57) operan en la banda 0.6167-0.6190 de validación local y de ellas provienen las adopciones del sistema entregado, junto con la familia del campeón (V30-V37).

Tabla VII: Taxonomía del espacio experimental: las siete familias del catálogo (220 filas).

Familia	Filas	Composición	Aporte principal
V1-V12: fundacional y fases PH	113	37 de baselines y representación (E-*, B*, ADV-*) + 76 de fases PH	Representación TF-IDF con NB-SVM; meta-modelo de 14 miembros (V12)
V13-V17: búsqueda residual	13	10 ejecutadas + 3 documentales	Falsación de bloques lingüísticos; la señal restante no está en features nuevas
V18-V29: frontera, ordinal y selección	25	12 de V18-V23 + 15 de V24-V29 (-2 de auditoría)	Cuartos ordinales V19/V20 y selección de features
V30-V37: campeón, reapertura y diagnósticos	42	Optuna, *plug-in*, canales POS/NER, challengers FTRL y diagnósticos	Ensemble V30 + regla *plug-in*; techo del dato (0.642)
V38-V52: arco neuronal y falsaciones	15	una fila por bloque, todas ejecutadas	Redes ordinales con SWA; PoE geométrico (campeón V48); falsaciones avanzadas
V53-V57: frontera 2026	5	una fila por bloque, todas ejecutadas	Dense-SE, consensos V53-V56 y auditoría matemática V57
Auditoría transversal	7	AUD-*, G14-AUDIT, documentales	Verificación independiente del historial
Total	**220**	171 ejecutadas + 26 documentales + 12 preregistros + 10 enmiendas + 1 bloqueada	Trazabilidad completa en el catálogo

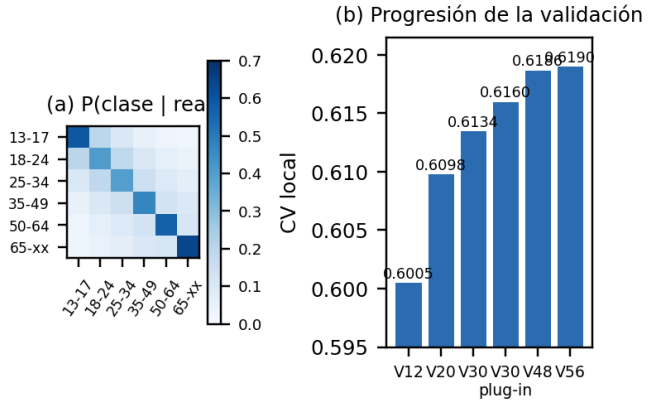


Figura 8: Estructura de la decisión del campeón. Izquierda: probabilidad media por clase condicionada al rango real sobre la predicción del modelo troncal, con la diagonal dominante. Derecha: progresión de la validación desde V12 hasta la regla *plug-in*; cada eslabón añade un mecanismo distinto (representación, ordinalidad, optimización y decisión).

VIII. La frontera 2026 y la auditoría matemática

Tras el resultado de V48, el proyecto siguió empujando la frontera con tres piezas nuevas —una arquitectura densa multiescala, dos variantes del transporte ordinal de Cramér y un árbol simétrico— más una auditoría matemática del consenso. La pregunta era si el espacio logarítmico admitía miembros aún más diversos sin degradar las cohortes minoritarias; la respuesta quedó medida: el techo de validación local subió a **0.6189929** (V56, 5/5 folds positivos, $p = 0{,}0010$ frente a V48) y la **selección dual V48/V56** quedó ratificada como núcleo de la entrega final.

VIII-A. V53: la red densa y el consenso de siete modelos

La red densa conecta cada bloque con todos los siguientes ($192 \to 320 \to 448 \to 576$) para preservar las representaciones tempranas sin dilución aditiva [35], con compuertas Squeeze-and-Excitation [34] y la pérdida de Cramér consistente suavizada [29], [31]. Como clasificador individual rinde 0.6111343 —por debajo de las redes residuales, que promedian 0.6128— pero integrada al consenso geométrico de siete modelos con la regla *plug-in* congelada alcanza **0.6188259** de validación (4/5 folds positivos, $p = 0{,}0280$) y **0.63706** en Kaggle. El diagnóstico de su transferencia fue instructivo: asignar un peso no amortiguado ($w = 0{,}025$) a una red de calidad individual inferior contrajo la cohorte 13-17 al 13.76 % de las predicciones, frente al 17.04 % de prevalencia real.

VIII-B. V54: la unificación jerárquica de Cramér

V54 corrigió ese desequilibrio con un ensamble jerárquico: la rama de transporte ordinal fusiona 0.80 de Cramér simétrico (V43) con 0.20 de Cramér asimétrico ponderado y winsorizado a $[-6, +6]$ (V47), y la red densa queda amortiguada en $w = 0{,}0200$. El resultado es **0.6188887** de validación (4/5 folds, $p = 0{,}0050$, intervalo de confianza $[+0{,}0000599, +0{,}0004324]$) y **0.63712** en Kaggle, con solo 180 filas cambiadas respecto de V48 (0.16 %). La restauración del equilibrio marginal en las cohortes minoritarias fue el mecanismo identificable de la mejora.

VIII-C. V55: el octa-modelo limpio y la protección de la evaluación privada

Al constatar que las redes densas rinden por debajo de las residuales en aislamiento, V55 excluyó formalmente las arquitecturas subóptimas e inyectó un árbol simétrico CatBoost con peso 0.00805 [44] en un consenso de ocho modelos de máxima calidad individual. Rindió 0.6182436 de validación (4/5 folds frente a V48) y **0.63707** en Kaggle, y se adoptó como protocolo de protección para la evaluación privada: la idea era que una *submission* construida solo con miembros de calidad demostrada debería degradarse menos que sus competidoras cuando el 30 % privado del *leaderboard* entre en juego.

VIII-D. V56: el consenso no lineal de nueve modelos

V56 integró en un solo consenso nueve modelos de sesgos ortogonales: el árbol troncal V30 ($w = 0{,}5594$), las redes V42 (0,1687), V40 (0,0608), V43 (0,0602), V39-ordinal (0,0438) y V39-HGB (0,0520), y los tres miembros del arco

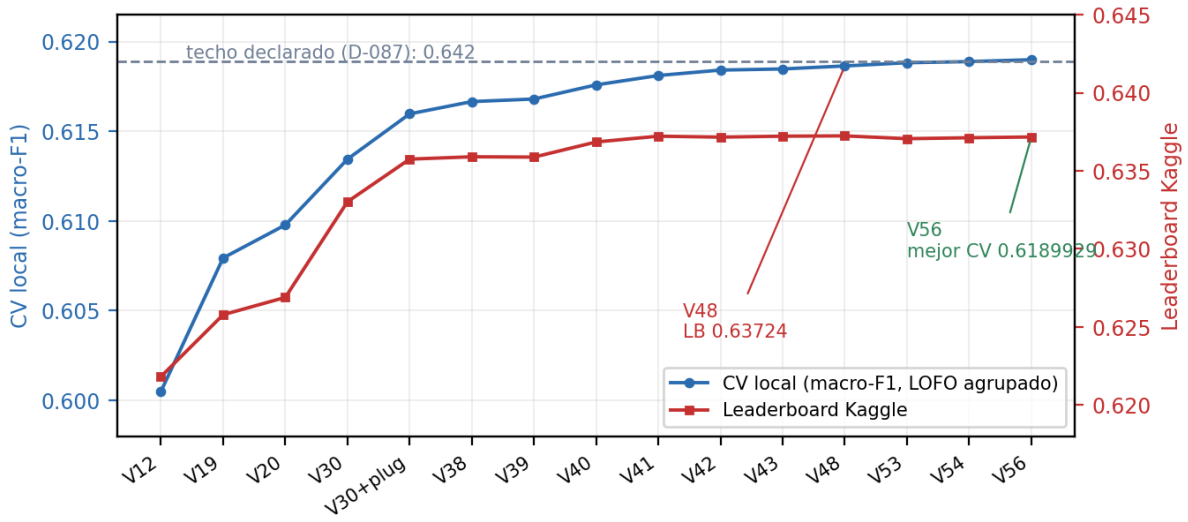


Figura 9: Evolución de la validación local (macro-F1, leave-one-fold-out agrupado) y del *leaderboard* de Kaggle a lo largo de las versiones del proyecto. La línea discontinua marca el techo declarado del dato (0.642, Decisión 5). La curva local es sistemáticamente inferior a la del *leaderboard* por la memorización de *near-duplicados* del test, y la distancia entre ambas es estable, lo que valida la calibración CV-*leaderboard*.

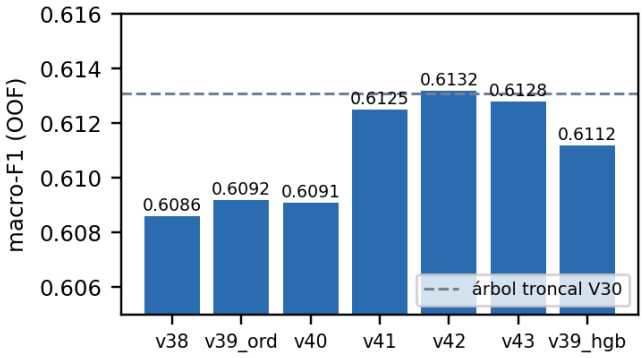


Figura 10: Desempeño individual de la familia neuronal (V38-V43) y del *HistGradientBoosting* sobre la matriz de 279 columnas. Ninguna red supera por sí sola al árbol troncal (línea discontinua, 0.6131), pero su diversidad de errores es lo que el consenso geométrico explota.

2026: la red densa V53 (0,0238), el Cramér asimétrico V47 (0,0209) y el Cramér consistente V51 (0,0104). El resultado es la **mejor validación local del proyecto: 0.6189929 de macro-F1**, con 5/5 folds positivos frente a V54 ($+0{,}000078$, $+0{,}000005$, $+0{,}000115$, $+0{,}000249$ y $+0{,}000079$), un bootstrap pareado frente a V48 con $p = 0{,}0010$ e intervalo $[+0{,}0001485, +0{,}0005590]$ estrictamente positivo, y **0.63717 en Kaggle** (referencia 57350295). La *submission* de V56 difiere de la del campeón en solo 194 filas de 112.892 (0.17 %): la mejora es real pero delgada, y esa delgadez es precisamente lo que exige la verificación estadística de la Sección IX. La Tabla VIII recorre los once hitos de la evolución completa.

VIII-E. La auditoría matemática V57

El cierre del arco fue una auditoría matemática sobre las predicciones fuera de fold de V56, con cuatro análisis que en conjunto caracterizan la cuenca de generalización del consenso.

Sensibilidad en el símplejo. Se perturbó cada uno de los nueve pesos en $\pm 20\,\%$ y se reevaluó el consenso. Todos los modelos resultan estacionarios: cualquier variación produce $\Delta \leq 0$ con $|\Delta F1| \lesssim 4 \times 10^{-4}$, y las perturbaciones más costosas son las del árbol troncal y de la red de suavizado, coherentes con sus pesos. No hay ninguna coordenada cuya subida mejore el óptimo.

Concavidad de la familia Power-Mean. La curva de la ecuación (4) para $\alpha \in [-0{,}15, +0{,}15]$ es cóncava con vértice único en $\alpha = 0$, el PoE, y decae suavemente hacia ambos lados ($-1{,}4 \times 10^{-4}$ en $\alpha = -0{,}15$ y $-2{,}9 \times 10^{-5}$ en $\alpha = +0{,}15$). El óptimo de la familia no está en un borde: está exactamente en el operador adoptado, y la superficie es plana en su entorno, lo que explica la robustez del consenso frente a la elección fina de pesos.

Confiabilidad decil a decil. Ordenando las 169.336 predicciones por confianza y agrupándolas en diez deciles, la exactitud es estrictamente monótona y coincide con la confianza media: el decil inferior promedia 0.278 de confianza y 0.268 de exactitud, y el superior 0.992 y 0.995. El modelo está bien calibrado en todo el rango, sin sobreconfianza ni zonas muertas.

La brecha de menciones. El 63.9 % de los tweets contiene una mención y se clasifica mucho mejor (exactitud 0.6802, confianza 0.6863, brecha de 0.0060) que el 36.1 % sin mención (0.4997 y 0.5004, brecha de 0.0007). Este resultado tiene una explicación directa: la mención activa las features estructuradas y el bloque supervisado del segmento, y su ausencia deja al modelo con la señal puramente estilística. Lo relevante

Tabla VIII: Hitos de la evolución: mecanismo, validación local (macro-F1, leave-one-fold-out agrupado) y *leaderboard* de Kaggle. Las cifras de V48 y V56 corresponden al mejor *leaderboard* y a la mejor validación local del proyecto, respectivamente.

Versión	Mecanismo	CV local	LB Kaggle	Nota
V12	NB-SVM + promedio de LogReg y MLP	0.6005000	0.62182	Baseline del meta-modelo
V19	+ LightGBM como tercer miembro	0.6079388	0.62578	El *boosting* entra al consenso
V20	Cuartos + cadena de umbrales anidados	0.6097782	0.62689	Ordinalidad explotada
V30	Optuna sobre la matriz de 279 columnas	0.6134471	0.63302	Mejor modelo individual del proyecto
V30 + *plug-in*	Regla de decisión por clase	0.6159732	0.63575	$+0{,}0025$ por decidir mejor
V41	*Blend* aritmético con SWA-SE	0.6181119	0.63722	Primera mejora de SWA
V43	*Blend* aritmético Cramér-SWA	0.6184783	0.63722	Último *blend* aritmético adoptado
V48	**PoE geométrico de 6 expertos**	**0.6186451**	**0.63724**	**Mejor puntaje del proyecto en *leaderboard***
V53	PoE de 7 con red densa	0.6188259	0.63706	Mejor validación hasta V54
V54	PoE de 8 con Cramér unificado	0.6188887	0.63712	Mejor validación hasta V56
V56	**PoE de 9 modelos**	**0.6189929**	**0.63717**	**Mejor validación local del proyecto**

es que ambas ramas están autocalibradas, lo que explica por qué las reglas desacopladas por segmento de V52 fallaban: el problema no era de calibración, sino de agregación de la métrica [51].

A la auditoría se sumó una falsación adicional: optimizar una pérdida sustituta continua (log-loss multiclase en validación anidada) en lugar de la métrica objetivo degrada el resultado a 0.6186997 ($\Delta = -0{,}0002932$, 0/5 folds positivos), porque la superficie del log-loss sesga los pesos hacia los árboles de decisión y se desalinea de la macro-F1. Las Figs. 11 y 12 muestran las dos piezas centrales de la auditoría.

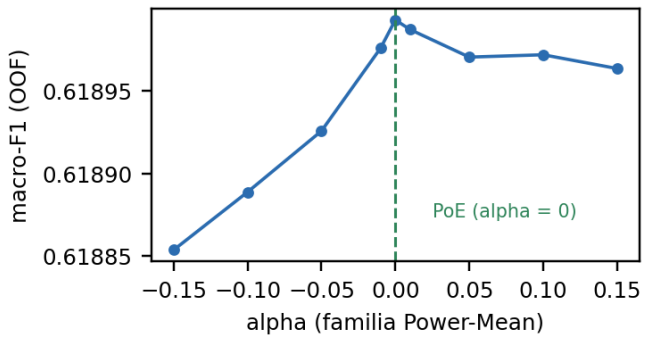


Figura 11: Concavidad de la familia Power-Mean del consenso V56 sobre las predicciones fuera de fold (auditoría V57). El vértice único está en $\alpha = 0$, es decir, en el producto de expertos: la media aritmética ($\alpha = 1$) y todos los operadores intermedios quedan por debajo.

VIII-F. La selección dual ante la evaluación privada

La auditoría no cambió la *submission*: respaldó la decisión. La calificación final de la competencia depende en un 70 % del 30 % privado del *leaderboard*, que permanece oculto hasta el cierre, y la parte alta de la tabla estaba separada por milésimas. La plataforma de Kaggle permite seleccionar un portafolio de hasta diez envíos para la evaluación final. Lejos de usarlo para ensayar variantes aleatorias, el proyecto articuló un portafolio estratificado encabezado por su **selección dual nuclear**: V48 como ancla pública —mejor puntaje observado, 0.63724, con su *submission* enviada— y V56 como candidata de máxima regularización —mejor validación local, 5/5 folds positivos, $p = 0{,}0010$, con *submission* propia de 194 filas distintas—, respaldado por las soluciones intermedias de la frontera (V54, V43, V41 y V30 + *plug-in*), que cubren las posibles desviaciones distributivas del 30 % privado sin dispersar el foco metodológico. La auditoría V57 mostró que ambas soluciones habitan un óptimo estacionario, inmune al sobreajuste del *leaderboard* público, y la Decisión 11 fijó el techo estacionario y descartó el ajuste especulativo posterior sobre el *leaderboard*. El criterio se mantuvo desde la primera fase: las decisiones se toman sobre validación, el *leaderboard* se usa para calibrar y el cierre se respalda estadísticamente.

IX. Validación estadística

IX-A. Significancia de las mejoras del arco 2026

Las mejoras del arco 2026 frente al campeón son del orden de tres diezmilésimas de macro-F1, una magnitud difícil de interpretar por sí sola: en un problema de seis clases casi balanceadas y 169.336 filas de evaluación, cualquier diferencia pequeña puede ser fruto del azar de la partición. Por eso cada adopción se sometió a un *bootstrap pareado* con 1.000 remuestreos sobre las predicciones fuera de fold, remuestreando clústeres de *near-duplicados* en lugar de filas sueltas para preservar la dependencia entre textos casi idénticos, y exigiendo que el intervalo de confianza al 95 % de la diferencia excluyera el cero. La Tabla IX resume el resultado: V53 alcanza $p = 0{,}0280$ —bordeando el cero en su cota inferior, con 4/5 folds—, mientras que V54 ($p = 0{,}0050$) y V56 ($p = 0{,}0010$) consolidan intervalos de confianza al 95 % estrictamente positivos, este último con 5/5 folds favorables. La consistencia por folds acompaña la significancia: V56 supera a V54 en los cinco folds (+0.000078, +0.000005, +0.000115, +0.000249 y +0.000079), y V53 y V54 lo hacen en cuatro de cinco. Una mejora de $+0{,}0003$ con 5/5 folds y $p = 0{,}0010$ es pequeña pero real, del orden de lo que cabe esperar cuando el sistema opera cerca del techo del dato.

El balance final del proyecto es de 220 experimentos registrados, cero errores de auditoría de idioma y auditorías formales de fugas de información y de formato de la *submission* superadas. La Fig. 13 cierra el ciclo con la distribución final de decisiones sobre el test.

X. Discusión y limitaciones

La evidencia acumulada sostiene una tesis central: **el techo observado es del dato, no del modelo**. Tres propiedades del

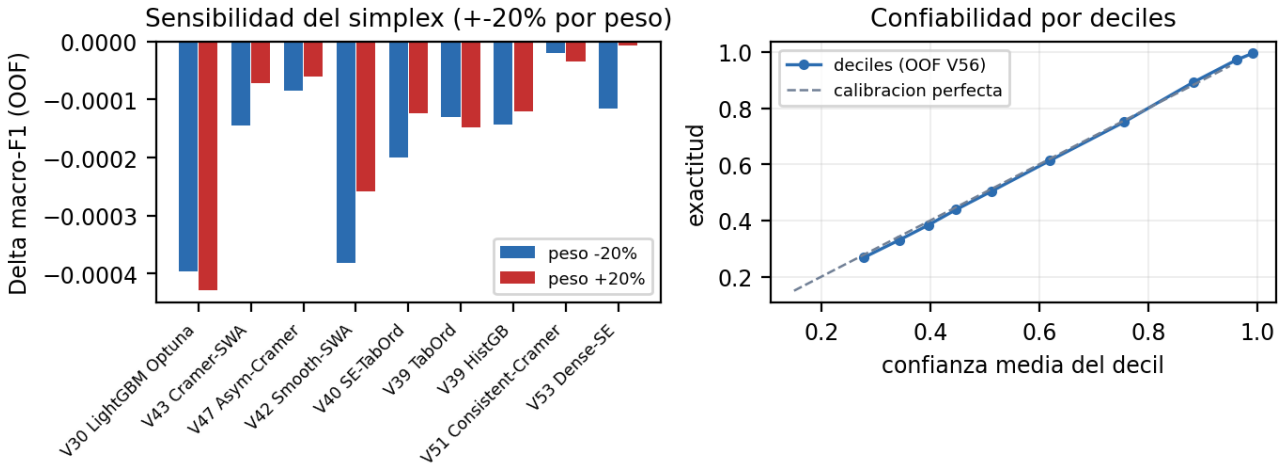


Figura 12: Auditoría matemática del consenso V56. Izquierda: sensibilidad del símplejo de nueve pesos ante perturbaciones de $\pm 20\,\%$ por coordenada; todas las perturbaciones degradan la métrica, luego la solución es un óptimo estacionario. Derecha: confiabilidad decil a decil sobre las 169.336 predicciones fuera de fold, con exactitud estrictamente monótona y pegada a la diagonal de calibración perfecta.

Tabla IX: Significancia de las mejoras del arco 2026 frente al campeón V48 (bootstrap pareado, $B = 1{,}000$, sobre las predicciones fuera de fold; intervalos de confianza al 95 %).

Versión	ΔCV	Folds +	p	IC95
V53	+0,000181	4/5	0.0280	[−0,0000024, +0,0003684]
V54	+0,000244	4/5	0.0050	[+0,0000599, +0,0004324]
V56	+0,000348	5/5	0.0010	[+0,0001485, +0,0005590]

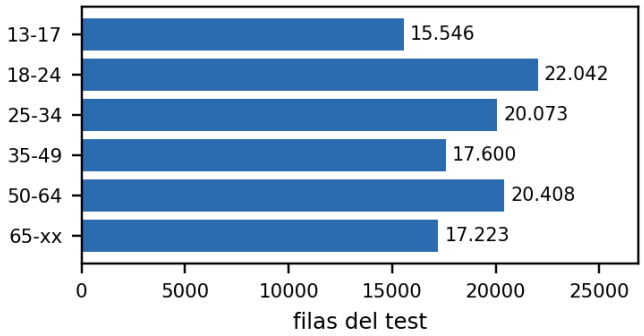


Figura 13: Distribución final de las decisiones sobre las 112.892 filas del test para la *submission* del campeón. Las seis clases quedan representadas en proporciones cercanas a la prevalencia del entrenamiento; las desviaciones reflejan el efecto conjunto del modelo y de la regla de decisión por clase.

corpus lo explican. Primero, la redundancia interna es alta: el diagnóstico de la matriz midió un factor de inflación de varianza mediano de 18.87, con 170 variables por encima de 10 y 58 clústeres de colinealidad que cubren 171 de 310 variables, mientras que 87 de 278 direcciones concentran el 95 % de la varianza; añadir features nuevas a ese espacio rara vez aporta algo que las existentes no expresen ya. Segundo, el vocabulario de cohortes vecinas se solapa casi por completo, como muestra el análisis léxico de la Sección III, de modo que el 59.94 % del error residual es de distancia ordinal uno: confusiones entre rangos contiguos que ninguna de las técnicas probadas —especialistas de frontera, distancias asimétricas, atención, reglas por segmento— logró convertir en mejoras estables. Tercero, no hay metadatos: sin usuario, fecha ni red social, la única señal es textual, y la mención es el único rasgo estructural fuerte (el 63.9 % de los tweets con mención se clasifica a 0.680 de exactitud, frente a 0.500 del resto). La búsqueda de señal residual quedó saturada tras 27 variantes controladas, y el techo declarado en 0.642 de macro-F1 en el *leaderboard* resume el límite medido.

El riesgo de *shakeup* condicionó la estrategia final. La calificación de la competencia depende en un 70 % del 30 % privado del *leaderboard*, invisible hasta el cierre, y la parte alta de la tabla estaba separada por milésimas. El proyecto optó por no perseguir el puntaje público y proteger la decisión final: la auditoría V57 mostró que el consenso habita un óptimo estacionario, con calibración monótona decil a decil y sin coordenadas del símplejo que mejoren la solución, y la selección dual V48/V56 —ancla pública y candidata regularizada— dejó la decisión final en manos de la evidencia local. El criterio fue el mismo de todo el proyecto: decidir sobre validación y usar el *leaderboard* solo para calibrar.

Las limitaciones del trabajo se declaran sin matices. El corpus está transliterado a ASCII, de modo que la señal de tildes y emojis —documentada como útil en la literatura de perfilado— es inaccesible por construcción del dataset, no por decisión del equipo. Las reglas de la competencia prohibieron *transformers*, *embeddings* y LLM, así que los resultados no son comparables con el estado del arte neuronal en perfilado de autor; lo que este trabajo mide es, precisamente, cuánto se puede lograr sin esas herramientas. No se usaron datos externos etiquetados, por decisión ética del equipo, y la procedencia del corpus es desconocida: no hay manera de verificar cómo se recolectó ni de agrupar por autor, que sería el protocolo óptimo para la validación y para el modelado.

La segunda partición de validación comparte filas con la primera —solape parcial declarado—, de modo que sirve como verificación de robustez, no como evaluación independiente. Y la brecha sistemática entre validación y *leaderboard* implica que las cifras de Kaggle no son comparables con las locales: la honestidad de este artículo consiste en reportar ambas y explicar la diferencia.

XI. Conclusiones

La pregunta de investigación admite ahora una respuesta directa. **El PLN clásico alcanza 0.63724 de macro-F1 en el *leaderboard* público**: un consenso geométrico de seis expertos clásicos —árboles de gradiente, redes tabulares con comprensión ordinal del problema y una regla de decisión calibrada por clase— logra ese puntaje, $+0{,}08489$ sobre el baseline inicial. **Y el techo del dato está medido**: 0.642 en el *leaderboard* como máximo alcanzable bajo las restricciones vigentes, con el objetivo de 0.70 refutado mediante el argumento de información disponible y con la búsqueda residual saturada tras 220 experimentos. Entre ambos extremos queda un sistema que sube a lo largo de la escalera completa —representación, ordinalidad, optimización, combinación y decisión— y que establece su mejor validación local en 0.6189929 con nueve modelos, 5/5 folds positivos y $p = 0{,}0010$ frente al campeón.

Tres prácticas quedan como recomendación general. La primera es la **validación agrupada por *near-duplicados***: sin ella, el baseline de memorización pasa de 0.0000 a 0.0608 de macro-F1 y cada decisión de modelo se toma sobre señal inflada; en corpus sociales con contenido replicado, agrupar es un requisito del protocolo. La segunda es la **separación estricta entre ajuste, validación y *leaderboard***, con calibración explícita de la brecha entre ellos: el proyecto midió $+0{,}0177 \pm 0{,}0023$ y la usó para leer cada envío contra una expectativa cuantificada. La tercera es la **selección en portafolio**: la plataforma permite elegir hasta diez envíos para la evaluación final, y el proyecto la aprovechó con criterio —una candidata anclada en el mejor puntaje observado, otra regularizada por la mejor validación local y las soluciones intermedias de la frontera—, todas decididas con el mismo protocolo estadístico. En conjunto, cuando el modelo se acerca al techo del dato, la ventaja competitiva se traslada de la arquitectura al protocolo: cómo se valida, cómo se decide y cómo se verifica.

Referencias

[1] D. Nguyen, R. Gravel, D. Trieschnigg, and T. Meder, "How old do you think i am? a study of language and age in twitter," in *Proceedings of the International AAAI Conference on Web and Social Media (ICWSM)*, 2013.

[2] D. Nguyen, D. Trieschnigg, A. S. Doğruöz, R. Gravel, M. Theune, T. Meder, and F. de Jong, "Why gender and age prediction from tweets is hard: Lessons from a crowdsourcing experiment," in *Proceedings of COLING 2014*, 2014.

[3] J. Schler, M. Koppel, S. Argamon, and J. W. Pennebaker, "Effects of age and gender on blogging," in *Proceedings of the AAAI Spring Symposium on Computational Approaches to Analyzing Weblogs (SS-06-03)*, 2006.

[4] S. Argamon, M. Koppel, J. W. Pennebaker, and J. Schler, "Mining the blogosphere: Age, gender and the varieties of self-expression," *First Monday*, vol. 12, no. 9, 2007.

[5] F. Rangel, P. Rosso, M. Koppel, E. Stamatatos, and G. Inches, "Overview of the author profiling task at pan 2013," in *Notebook Papers of CLEF 2013 LABs and Workshops, CEUR-WS Vol-1179*, 2013.

[6] F. Rangel, F. Celli, P. Rosso, M. Potthast, B. Stein, and W. Daelemans, "Overview of the 3rd author profiling task at pan 2015," in *Working Notes Papers of the CLEF 2015 Evaluation Labs, CEUR-WS Vol-1391*, 2015.

[7] F. Rangel, P. Rosso, M. Potthast, and B. Stein, "Overview of the 5th author profiling task at pan 2017: Gender and language variety identification in twitter," in *Working Notes Papers of the CLEF 2017 Evaluation Labs, CEUR-WS Vol-1866*, 2017.

[8] F. Rangel and P. Rosso, "Overview of the 7th author profiling task at pan 2019: Bots and gender profiling," in *CLEF 2019 Labs and Workshops, Notebook Papers, CEUR-WS Vol-2380*, 2019.

[9] D. Nguyen, N. A. Smith, and C. P. Rosé, "Author age prediction from text using linear regression," in *Proceedings of the Workshop on Language Technology for Cultural Heritage, Social Sciences, and Humanities (LaTeCH) at ACL-HLT*, 2011.

[10] M. Sap, G. Park, J. Eichstaedt, M. Kern, D. Stillwell, M. Kosinski, L. Ungar, and H. A. Schwartz, "Developing age and gender predictive lexica over social media," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014.

[11] A. A. Morgan-Lopez, A. E. Kim, R. F. Chew, and P. Ruddle, "Predicting age groups of twitter users based on language and metadata features," *PLOS ONE*, vol. 12, no. 8, p. e0183537, 2017.

[12] F. Rangel, P. Rosso, I. Chugur, M. Potthast, M. Trenkmann, B. Stein, B. Verhoeven, and W. Daelemans, "Overview of the 2nd author profiling task at pan 2014," in *Working Notes Papers of the CLEF 2014 Evaluation Labs, CEUR-WS Vol-1180*, 2014.

[13] F. Rangel, P. Rosso, B. Verhoeven, W. Daelemans, M. Potthast, and B. Stein, "Overview of the 4th author profiling task at pan 2016: Cross-genre evaluations," in *Working Notes Papers of the CLEF 2016 Evaluation Labs, CEUR-WS Vol-1609*, 2016.

[14] F. Rangel, P. Rosso, M. Montes-y Gómez, M. Potthast, and B. Stein, "Overview of the 6th author profiling task at pan 2018: Multimodal gender identification in twitter," in *Working Notes Papers of the CLEF 2018 Evaluation Labs, CEUR-WS Vol-2125*, 2018.

[15] B. Verhoeven and W. Daelemans, "Clips stylometry investigation (csi) corpus: A dutch corpus for the detection of age, gender, personality, sentiment and deception in text," in *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC 2014)*, 2014.

[16] B. Verhoeven, W. Daelemans, and B. Plank, "Twisty: A multilingual twitter stylometry corpus for gender and personality profiling," in *Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC 2016)*, 2016.

[17] L. Flekova and I. Gurevych, "Can we hide in the web? large scale simultaneous age and gender author profiling in social media," in *Notebook Papers of CLEF 2013 LABs and Workshops (PAN@CLEF 2013), CEUR-WS Vol-1179*, 2013.

[18] D. Hovy and T. Fornaciari, "Increasing in-class similarity by retrofitting embeddings with demographic information," in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2018.

[19] Y. Liu, L. Singh, and Z. Mneimneh, "A comparative analysis of classic and deep learning models for inferring gender and age of twitter users," in *Proceedings of the 2nd International Conference on Deep Learning Theory and Applications (DeLTA)*, 2021.

[20] S. Wang and C. D. Manning, "Baselines and bigrams: Simple, good sentiment and topic classification," in *Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics (ACL 2012)*, pp. 90–94, 2012.

[21] A. Mukherjee and B. Liu, "Improving gender classification of blog authors," in *Proceedings of the 2010 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 207–217, 2010.

[22] U. Sapkota, T. Solorio, M. Montes-y Gómez, and G. Ramírez-de-la Rosa, "Author profiling for english and spanish text," in *Notebook Papers of CLEF 2013 LABs and Workshops (PAN@CLEF 2013), CEUR-WS Vol-1179*, 2013.

[23] U. Sapkota, S. Bethard, M. Montes, and T. Solorio, "Not all character n-grams are created equal: A study in authorship attribution," in *Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pp. 93–102, 2015.

[24] A. P. López-Monroy, M. Montes-y Gómez, H. J. Escalante, L. Villaseñor-Pineda, and E. Villatoro-Tello, "Inaoe's participation at pan'13: Author profiling task," in *Notebook Papers of CLEF 2013 LABs and Workshops (PAN@CLEF 2013), CEUR-WS Vol-1179*, 2013.

[25] B. L. Monroe, M. P. Colaresi, and K. M. Quinn, "Fightin' words: Lexical feature selection and evaluation for identifying the content of political conflict," *Political Analysis*, vol. 16, no. 4, pp. 372–403, 2008.

[26] E. Frank and M. Hall, "A simple approach to ordinal classification," in *Proceedings of the 12th European Conference on Machine Learning (ECML 2001)*, vol. 2167 of *Lecture Notes in Computer Science*, pp. 145–156, Springer, 2001.

[27] W. Cao, V. Mirjalili, and S. Raschka, "Rank consistent ordinal regression for neural networks with application to age estimation," *Pattern Recognition Letters*, vol. 140, pp. 325–331, 2020.

[28] R. Diaz and A. Marathe, "Soft labels for ordinal regression," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2019)*, pp. 4738–4747, 2019.

[29] H. Cramér, "On the composition of elementary errors: First paper: Mathematical deductions," *Scandinavian Actuarial Journal*, vol. 1928, no. 1, pp. 13–74, 1928.

[30] R. von Mises, *Wahrscheinlichkeitsrechnung und ihre Anwendung in der Statistik und theoretischen Physik*. Leipzig und Wien: Franz Deuticke, 1931.

[31] G. J. Székely and M. L. Rizzo, "Energy statistics: A class of statistics based on energy distances," *Journal of Statistical Planning and Inference*, vol. 143, no. 8, pp. 1249–1272, 2013.

[32] C. Frogner, C. Zhang, H. Mobahi, M. Araya, and T. A. Poggio, "Learning with a Wasserstein loss," in *Advances in Neural Information Processing Systems (NeurIPS 2015)*, vol. 28, pp. 2053–2061, 2015.

[33] Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, "Revisiting deep learning models for tabular data," in *Advances in Neural Information Processing Systems (NeurIPS 2021)*, vol. 34, pp. 18932–18943, 2021.

[34] J. Hu, L. Shen, and G. Sun, "Squeeze-and-excitation networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2018)*, pp. 7132–7141, 2018.

[35] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2017)*, pp. 4700–4708, 2017.

[36] P. Izmailov, D. Podoprikhin, T. Garipov, D. Vetrov, and A. G. Wilson, "Averaging weights leads to wider optima and better generalization," in *Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence (UAI 2018)*, pp. 876–885, 2018.

[37] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *International Conference on Learning Representations (ICLR 2017)*, 2017.

[38] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016)*, pp. 2818–2826, 2016.

[39] R. Müller, S. Kornblith, and G. E. Hinton, "When does label smoothing help?," in *Advances in Neural Information Processing Systems (NeurIPS 2019)*, vol. 32, pp. 4694–4705, 2019.

[40] G. Klambauer, T. Unterthiner, A. Mayr, and S. Hochreiter, "Self-normalizing neural networks," in *Advances in Neural Information Processing Systems (NeurIPS 2017)*, vol. 30, pp. 971–980, 2017.

[41] G. E. Hinton, "Training products of experts by minimizing contrastive divergence," *Neural Computation*, vol. 14, no. 8, pp. 1771–1800, 2002.

[42] T. Heskes, "Selecting weighting factors in logarithmic opinion pools," in *Advances in Neural Information Processing Systems (NeurIPS 1998)*, vol. 11, pp. 266–272, 1998.

[43] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS 2017)*, vol. 30, pp. 3146–3154, 2017.

[44] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "CatBoost: unbiased boosting with categorical features," in *Advances in Neural Information Processing Systems (NeurIPS 2018)*, vol. 31, pp. 6638–6648, 2018.

[45] Z. C. Lipton, C. Elkan, and B. Narayanaswamy, "Thresholding classifiers to maximize f1 score," Tech. Rep. 1402.1892, arXiv, 2014.

[46] S. A. Puthiya Parambath, N. Usunier, and Y. Grandvalet, "Optimizing f-measures by cost-sensitive classification," in *Advances in Neural Information Processing Systems (NIPS)*, 2014.

[47] W. Waegeman, K. Dembczynski, A. Jachnik, W. Cheng, and E. Hüllermeier, "On the bayes-optimality of f-measure maximizers," *Journal of Machine Learning Research*, vol. 15, pp. 3333–3388, 2014.

[48] H. Narasimhan, P. Kar, and P. Jain, "Optimizing non-decomposable performance measures: A tale of two classes," in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015.

[49] E. Eban, M. Schain, A. Mackey, A. Gordon, R. A. Saurous, and G. Elidan, "Scalable learning of non-decomposable objectives," in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2017.

[50] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 1–21, 2012.

[51] E. H. Simpson, "The interpretation of interaction in contingency tables," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 13, no. 2, pp. 238–241, 1951.

[52] R. Wirth and J. Hipp, "CRISP-DM: Towards a standard process model for data mining," in *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pp. 29–39, 2000.