Clasificación multietiqueta de discurso de odio, carácter dirigido y agresividad en tuits en español mediante TF-IDF y ensambles lineales

Erika Valeria Rivera Jiménez*, Julián Guillermo Carrillo Meneses*, Carlos Andrés Garnica Salazar* y Oscar Andrés Prieto Moreno*
*Pontificia Universidad Javeriana, Bogotá, Colombia
Maestría en Inteligencia Artificial — Procesamiento de Lenguaje Natural
riveraev@javeriana.edu.co, carrillojuliang@javeriana.edu.co,
carlos_garnicas@javeriana.edu.co, o-prieto@javeriana.edu.co

***Resumen*—La detección automática de discurso de odio en español es una tarea multietiqueta: un mismo tuit puede ser odioso, estar dirigido contra una persona o grupo y ser agresivo, y las tres decisiones no son independientes. Este artículo documenta el diseño, la experimentación y la validación del sistema presentado a la competencia académica *TOXIC 2026 PUJ*, sujeta a una restricción severa: prohibido usar transformers, modelos de lenguaje o embeddings preentrenados; las representaciones debían entrenarse desde cero. Sobre 1 731 tuits de entrenamiento y 1 154 sin etiquetas, construimos una representación subléxica multiescala de 86 275 características TF-IDF, un ensamble de tres optimizadores lineales con calibración de temperatura, umbrales desacoplados por etiqueta y la regla ontológica de HatEval. La validación cruzada agrupada, que fusiona near-duplicados y pseudo-autores, sitúa al modelo base en 0.787582 out-of-fold, con una mejora de $+0.010370$ sobre la línea base (IC95 $[+0.003924, +0.017386]$). Una capa de decisión de pares compensados, que preserva la prevalencia predicha y se calibra con el leaderboard público, eleva el F_1 público a 0.81447, primer lugar al cierre de este informe. El artículo separa el modelo base, validado estadísticamente, de la capa de última milla, específica del test, y discute su riesgo de sobreajuste. El envío se reconstruye bit a bit (SHA256 `b0979a8a...`), con dos celdas de frontera fijadas y auditadas; dos ejecuciones independientes producen el mismo archivo.**

***Palabras clave*—detección de discurso de odio, clasificación multietiqueta, representación subléxica, TF-IDF, calibración de umbrales, validación agrupada, reproducibilidad.**

I. Introducción

La conversación pública en redes sociales plantea un problema de clasificación que no admite una lectura ingenua: el discurso de odio rara vez aparece aislado. En un mismo tuit conviven la deshumanización de un grupo, la agresión explícita y el señalamiento de una persona concreta. Los corpus anotados para la tarea lo reflejan: en HatEval, por ejemplo, las etiquetas de discurso de odio (*hate speech*, HS), carácter dirigido (*targeted*, TR) y agresividad (AG) se anotan de forma conjunta y condicionada [1]. Modelar las tres columnas como decisiones independientes ignora esa estructura; modelarlas como una única clase de seis combinaciones pierde la señal compartida y multiplica la escasez de cada celda. La formulación multietiqueta, con un clasificador por etiqueta y una regla ontológica que preserva la jerarquía, es el compromiso que adoptamos aquí.

El contexto de este trabajo es la competencia académica *TOXIC 2026 PUJ*, organizada para el curso de Procesamiento de Lenguaje Natural de la Maestría en Inteligencia Artificial de la Pontificia Universidad Javeriana. La competencia impone tres restricciones fundamentales: (i) prohibición de utilizar arquitecturas basadas en transformers o modelos de lenguaje; (ii) obligación de entrenar todas las representaciones desde cero a partir del conjunto de entrenamiento; y (iii) prohibición de emplear el conjunto de prueba para el ajuste del modelo base (la calibración de la capa de decisión se guía únicamente por la retroalimentación agregada del leaderboard público). La métrica oficial es la media columnar de la F_1 binaria de la clase positiva sobre HS, TR y AG [2]. La nota final combina el leaderboard privado con la claridad y justificación del cuaderno entregado, de modo que el resultado y su explicación pesan por igual.

La pregunta que organiza este artículo es directa: *¿puede un pipeline clásico, sin transformers ni representaciones preentrenadas, competir en un corpus pequeño y ruidoso de tuits en español?* La respuesta que documentamos es afirmativa, pero con una distinción que consideramos central. El modelo base —representación subléxica, ensamble lineal y umbrales desacoplados— alcanza un F_1 out-of-fold de 0.787582 y una mejora estadísticamente sostenida sobre la línea base. La capa de decisión de última milla —reglas de staging y pares compensados— eleva el leaderboard público hasta 0.81447, pero lo hace con intervenciones específicas del test, guiadas por el propio leaderboard. Separar ambas fuentes de mejora, en lugar de presentar el 0.81447 como si fuera una estimación limpia de generalización, es una de las contribuciones metodológicas del trabajo.

Las contribuciones concretas son cinco. Primera, un pipeline clásico completo y reproducible: una representación TF-IDF multiescala de 86 275 características, un ensamble de tres optimizadores lineales con calibración de temperatura y umbrales por etiqueta. Segunda, un protocolo de validación agrupada que fusiona near-duplicados y pseudo-autores, verifica la ausencia de fuga en cada pliegue y se replica en dos particiones congeladas. Tercera, un análisis formal de la capa de decisión: demostramos que un par compensado que rescata un verdadero positivo y suprime un falso positivo en la misma

columna incrementa la F_1 exactamente en F_1/TP, sin alterar el número de positivos. Cuarta, una descomposición explícita de la ganancia del leaderboard en sus dos componentes y una discusión de su validez externa. Quinta, un contrato de reproducibilidad verificado: el envío campeón se reconstruye bit a bit y dos ejecuciones independientes producen el mismo archivo.

El resto del artículo sigue el orden de CRISP-DM. La Sección II sitúa el trabajo frente a la literatura (comprensión del negocio y estado del arte). La Sección III describe el corpus y el análisis exploratorio (comprensión de los datos). La Sección IV detalla la preparación, la representación, los modelos y la capa de decisión. La Sección V recorre los veinticinco experimentos evaluados en el leaderboard y separa lo que funcionó de lo que no (modelado). La Sección VI presenta el análisis estadístico, el análisis de error y los límites del enfoque (evaluación). La Sección VII documenta el despliegue y la verificación criptográfica. La Sección VIII cierra con las lecciones y el trabajo futuro.

Por convención numérica, y para no alterar los identificadores del registro oficial de Kaggle, en todo el artículo se usa el punto como separador decimal y el espacio fino para los miles.

II. Trabajos relacionados

II-A. Detección de discurso de odio y la herencia de HatEval

La detección de discurso de odio es una tarea consolidada en el procesamiento del lenguaje natural, con revisiones sistemáticas que cubren definiciones, corpus y enfoques [3]–[5]. Un hito para el español y el multilingüismo fue la tarea 5 de SemEval-2019 (HatEval), que introdujo la anotación conjunta de odio y carácter dirigido contra inmigrantes y mujeres [1]. Los sistemas participantes combinaron rasgos lingüísticos, n-gramas de caracteres y modelos lineales o neuronales [6]–[8]. La lección que heredamos es doble: la estructura de las etiquetas importa y los corpus son pequeños, ruidosos y sensibles al dominio.

En español, HaterNet mostró que un clasificador lineal sobre representaciones dispersas podía competir con alternativas más complejas en un corpus de Twitter [9]; MexA3T exploró la agresividad y el odio en variantes del español de México [10], [11]; otros trabajos abordaron la misoginia y la combinación de rasgos lingüísticos [12]–[15]. Los transformers han elevado el techo en corpus grandes [16], [17], pero su ventaja se reduce cuando el corpus es pequeño, el dominio está normalizado y el presupuesto de cómputo es limitado. La restricción de esta competencia —sin modelos preentrenados— vuelve relevante la pregunta inversa: cuánto se puede extraer de una representación construida desde cero.

II-B. Representaciones subléxicas y modelos lineales

Los n-gramas de caracteres son una representación clásica para texto corto y ruidoso. Cavnar y Trenkle los usaron para categorización de texto [18] y McNamee y Mayfield mostraron su eficacia en recuperación multilingüe [19]. La representación TF-IDF [20] combinada con regresión logística o máquinas de vectores sigue siendo una línea base difícil de superar en corpus pequeños. Los optimizadores importan: LIBLINEAR resuelve el problema primal con coordenadas [21], el descenso estocástico escala a matrices dispersas [22] y SAGA acelera la regularización ElasticNet [23], [24]. Los ensambles de modelos diversos —bagging, stacking o mezclas de probabilidades— reducen varianza y suavizan los errores de frontera [25], [26]. Nuestra propuesta se sitúa en esa tradición, pero añade una capa de decisión explícita y auditable.

II-C. Umbrales, calibración y estructura de etiquetas

En clasificación desbalanceada, el umbral de 0.5 no es óptimo para la F_1 [27], [28]. La literatura ofrece soluciones analíticas y numéricas para maximizar la F_1 por clase [29]–[32] y advierte que la métrica tiene una geometría propia: no todas las celdas de la matriz de confusión pesan igual [33], [34]. La calibración de probabilidades es el paso previo: la temperatura y el escalado de Platt corrigen el exceso de confianza de los modelos [35], [36]. Finalmente, la estructura jerárquica de las etiquetas —TR solo tiene sentido si HS está activo— puede explotarse con reglas ontológicas o con clasificadores jerárquicos [37], [38]. Nuestro pipeline combina las tres ideas: calibración, umbrales desacoplados y una regla ascendente.

II-D. Calidad de datos, fuga y comparación estadística

Los corpus de odio contienen near-duplicados, retuits, hilos de un mismo usuario y etiquetas ambiguas [39]–[42]. Si la validación reparte copias casi idénticas entre entrenamiento y validación, la métrica local se infla: es la fuga por agrupamiento descrita por Kaufman et al. [43]. La respuesta metodológica es agrupar antes de partir y verificar que ningún grupo cruce la frontera [43], [44]. La comparación entre modelos tampoco debería apoyarse en una única diferencia de medias: el bootstrap agrupado, las pruebas pareadas de McNemar y los tests de Dietterich y Demšar son el estándar para decidir si una mejora es distinguishable del ruido [45]–[48]. Ese es el marco que adoptamos.

II-E. Posicionamiento

Este trabajo no propone una arquitectura nueva. Propone una *disciplina* de construcción y evaluación: representación subléxica multiescala, validación agrupada, umbrales por etiqueta, calibración y una capa de decisión que preserva la prevalencia. La contribución diferencial es el análisis formal de esa capa y la separación explícita entre lo que se valida localmente y lo que se ajusta contra el leaderboard. Frente a los sistemas basados en transformers, el nuestro es más simple y más barato; frente a las líneas base clásicas, incorpora una ingeniería de decisión que resulta decisiva en la competencia.

III. Datos y análisis exploratorio

III-A. Corpus e integridad

El corpus de la competencia contiene 1 731 tuits etiquetados para entrenamiento y 1 154 sin etiquetas de prueba. Cada fila de entrenamiento tiene un identificador, el texto y tres columnas binarias: HS (discurso de odio), TR (carácter dirigido) y

Tabla I: Distribución de etiquetas y perfiles multietiqueta en entrenamiento ($N = 1\,731$). Los intervalos son de Wilson al 95 %.

Etiqueta / perfil	n	%	IC95
HS	756	43.67	[41.35, 46.02]
TR	519	29.98	[27.87, 32.18]
AG	662	38.24	[35.98, 40.56]
000	949	54.82	—
001	26	1.50	—
100	92	5.31	—
101	145	8.38	—
110	28	1.62	—
111	491	28.37	—

* Intervalos de Wilson al 95 % para las prevalencias marginales.

AG (agresividad). La auditoría de integridad verifica que no hay valores nulos, que los identificadores son únicos y que se cumple la regla ontológica de HatEval: en entrenamiento no existe ningún caso con $TR = 1$ y $HS = 0$ [1]. Las huellas SHA256 de los tres archivos oficiales se compararon contra el registro del proyecto antes de cualquier experimento. El test no se usó para entrenar ni para ajustar el modelo base; su única función fue generar el envío y alimentar las sondas del leaderboard.

III-B. Etiquetas, prevalencia y estructura conjunta

La Tabla I resume la distribución. Las tres etiquetas tienen prevalencias moderadas pero distintas: HS es la más frecuente (43.67 %), AG ocupa una posición intermedia (38.24 %) y TR es la minoritaria (29.98 %). La columna TR es, por esa razón, la más frágil: un cambio de una sola celda pesa más en la métrica que un cambio equivalente en HS. Los intervalos de Wilson al 95 % [49] son estrechos, de modo que las diferencias de prevalencia no son atribuibles al muestreo.

Los perfiles multietiqueta muestran una estructura fuertemente condicionada. Más de la mitad del corpus (949 tuits, 54.82 %) es completamente limpio; el perfil 111 —las tres etiquetas activas— concentra 491 casos (28.37 %). No hay ningún caso 010 ni 011: TR solo aparece acompañado de HS. La agresividad aislada (001) es una rareza: 26 casos, el 1.50 %. Esta observación justifica la regla ascendente $TR = 1 \Rightarrow HS = 1$ que se aplica después de la binarización, y descarta la idea de modelar las tres columnas como si fueran independientes.

La asociación entre etiquetas es alta. El coeficiente ϕ vale 0.743 entre HS y TR, 0.831 entre HS y AG y 0.759 entre TR y AG; las tres pruebas χ^2 rechazan la independencia con $p < 10^{-200}$. La estructura es coherente con la anotación jerárquica de HatEval [1] y con la literatura sobre clasificación jerárquica [37], [38]: el odio dirigido suele ser también agresivo, y la agresividad sin odio es la excepción. La Figura 1 resume la matriz.

III-C. Textometría, ruido y near-duplicados

Los textos son cortos: la longitud media es de 104.3 caracteres (mediana 91, máximo 306) y 17.1 palabras (mediana 15). La distribución es asimétrica a la derecha, con una cola

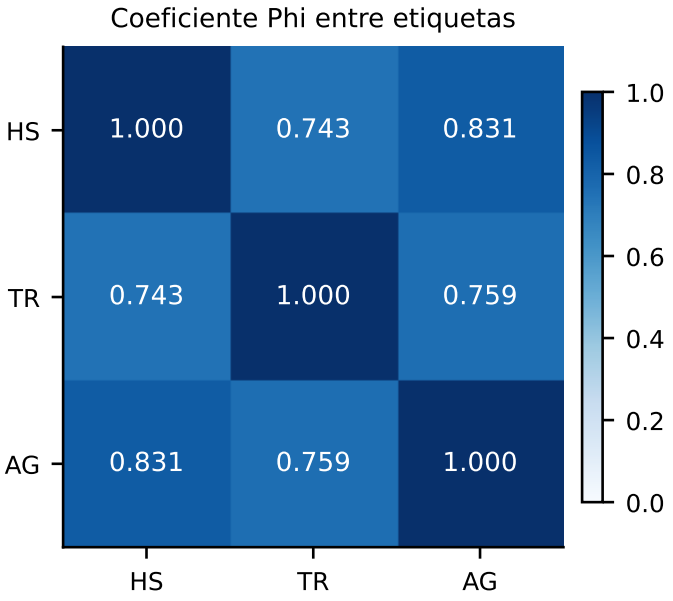


Figura 1: Coeficiente ϕ entre las tres etiquetas en entrenamiento. Los valores altos confirman la estructura jerárquica que motiva la regla $TR = 1 \Rightarrow HS = 1$.

de tuits largos que concentra una parte importante del error, como se verá en la Sección VI. El corpus está normalizado a ASCII: se pierden tildes y eñes, y con ellas parte de la señal morfológica del español. Esa pérdida es una razón adicional para usar n-gramas de caracteres, que reconstruyen prefijos, sufijos y variantes ortográficas sin depender de un diccionario [18], [19].

La búsqueda de near-duplicados sobre la unión de entrenamiento y prueba (2 885 textos) encontró cuatro grupos con más de un miembro, un grupo mayor de seis textos y 17 textos implicados. No es una duplicación masiva, pero basta para inflar una validación ingenua. Además, se extrajo el pseudo-autor de cada texto (la primera mención `@usuario`) y se fusionaron ambos criterios con una estructura union-find: el entrenamiento queda en 1 645 grupos, 86 filas menos que la partición por filas. Esa fusión es la unidad de partición de toda la validación (Sección IV). Como control de fuga por orden, se contrastó la asociación entre el identificador y las etiquetas: las correlaciones de Spearman fueron $+0.0166$ ($p = 0.490$), -0.0019 ($p = 0.938$) y -0.0070 ($p = 0.772$) para HS, TR y AG, y la prueba χ^2 del identificador agrupado en deciles contra HS dio $\chi^2(9) = 12.20$, $p = 0.202$. No hay evidencia de que el orden de los identificadores filtre la etiqueta.

III-D. Hallazgos que guiaron el modelado

El análisis exploratorio dejó cinco decisiones estructurales. (i) El desbalanceo moderado y distinto por etiqueta justifica pesos de clase balanceados y umbrales desacoplados [27], [28]. (ii) La jerarquía HatEval justifica la regla ascendente. (iii) Los textos cortos y ruidosos justifican una representación subléxica multiescala. (iv) Los near-duplicados y los pseudo-autores justifican la validación agrupada. (v) La ausencia de asociación entre identificador y etiqueta descarta una fuga por orden. La Figura 2 resume los perfiles y la distribución de longitudes.

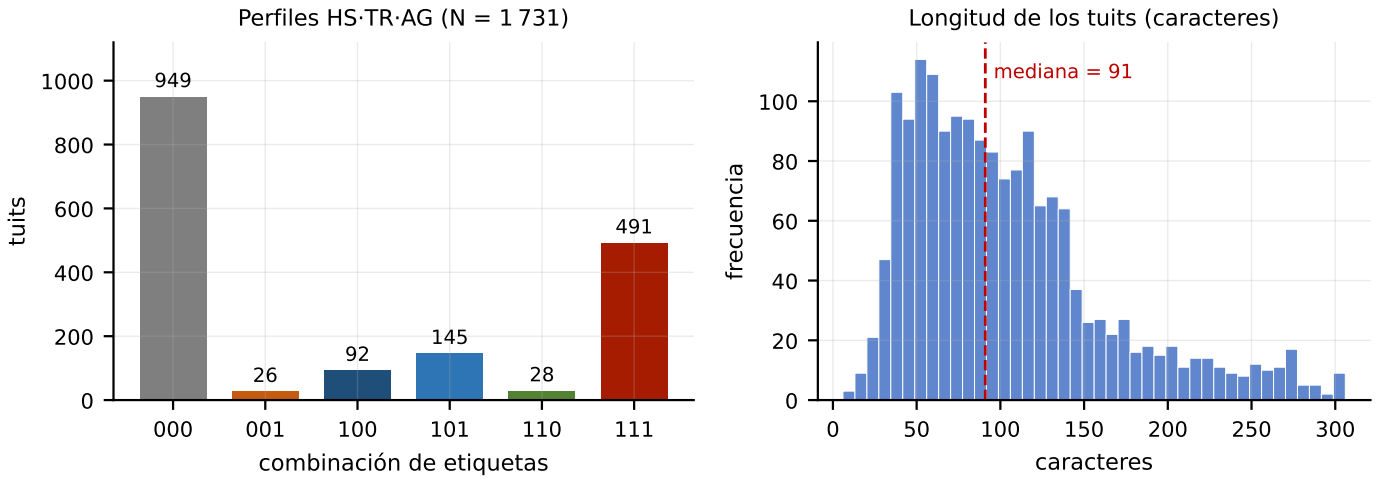


Figura 2: Análisis exploratorio. Izquierda: perfiles HS·TR·AG; la mayoría del corpus es limpio y el perfil 111 es el segundo más frecuente. Derecha: distribución de longitudes; la mediana es 91 caracteres y la cola larga concentra los casos más difíciles.

Una tensión adicional, que no se resuelve con datos, es la definición de TR. La competencia marca «discurso dirigido contra una persona o grupo»; HatEval distingue entre objetivo individual y genérico, y exige que el mensaje esté dirigido a uno de ellos [1]. Varios errores residuales de TR son, en realidad, desacuerdos de anotación entre esas dos lecturas. Decidimos no modificar las etiquetas oficiales y modelar la definición de la competencia; la discrepancia queda documentada como parte del análisis de error.

IV. Metodología

IV-A. *Marco metodológico: CRISP-DM*

El proyecto se condujo con *CRISP-DM* (*Cross Industry Standard Process for Data Mining*) como metodología principal [50]. Las seis fases del ciclo se ejecutaron de forma iterativa: el proyecto registró 134 ciclos experimentales y varias veces una fase posterior devolvió el trabajo a una anterior. El caso más claro fue el hallazgo de la fuga por pseudo-autores: apareció al auditar la validación y obligó a rehacer la preparación de los datos (fusión de grupos) antes de continuar con el modelado. La Tabla II resume el mapeo entre las fases, el trabajo realizado y la evidencia que lo respalda.

La gobernanza experimental complementó el ciclo. Cada experimento tuvo un script propio y nuevo (una variación no edita el script anterior), un pre-registro con pregunta, hipótesis y criterio de adopción, y una fila en `experiments.csv`. La regla de adopción era exigente: una mejora local debía superar $+0.005$ y sostenerse en las dos particiones; un candidato con sonda debía mejorar además el leaderboard, y una mejora solo local no bastaba (P109 es el contraejemplo). Cada corrida importante re-ejecutaba los controles de determinismo (V03 exacto y P110 a 10^{-6}) y el test nunca se usó para entrenar ni para ajustar el modelo base. Esta disciplina explica por qué el informe conserva los resultados negativos con el mismo detalle que los positivos: son parte de la evidencia.

IV-B. *Protocolo de validación agrupada*

La unidad de partición no es la fila sino el *grupo fusionado*: la unión de near-duplicados (similitud coseno de n-gramas de caracteres ≥ 0.85) y pseudo-autores (primera mención `@usuario`). Sobre los 1 731 tuits se construyen 1 645 grupos. Con ellos se separa un desarrollo de 1 483 filas y un holdout congelado de 248 mediante `StratifiedGroupKFold` de siete pliegues (semilla 42), estratificando por la combinación HS·TR·AG. El desarrollo se evalúa con dos particiones de cinco pliegues: la canónica (semilla 42) y la partición 47 (semilla 43), que actúa como réplica independiente. Todas las métricas locales de este artículo son *out-of-fold* (OOF) sobre las 1 483 filas de desarrollo. La línea base del proyecto, V03, es la unión TF-IDF `word(1,2)+char_wb(3,5)` con regresión logística LIBLINEAR ($C = 2.0$), umbrales 0.44/0.51/0.46 y sin regla ascendente; su F_1 OOF es 0.777211 y su LB 0.78306. El holdout de 248 filas se reservó como guarda congelada y no se usó para las decisiones de la serie final; por eso las cifras que se reportan son OOF sobre desarrollo.

El protocolo impone tres controles. Primero, los vectorizadores se ajustan solo con el pliegue de entrenamiento y se aplican al de validación; el test nunca participa. Segundo, se verifica en cada pliegue que ningún grupo fusionado cruce la frontera entrenamiento/validación. Tercero, cada corrida re-ejecuta dos controles de determinismo: la reconstrucción de la línea base V03 debe coincidir exactamente (diferencia 0.0) y la de P110 dentro de 10^{-6}. Estos controles detectan deriva de entorno antes de comparar candidatos [43], [44].

IV-C. *Representación subléxica multiescala*

La representación campeona, que llamamos V2_triple, concatena tres bloques TF-IDF [51]: palabras con unigramas y bigramas (`word(1,2)`), n-gramas de caracteres con límites de palabra (`char_wb(3,5)`) y n-gramas de caracteres libres (`char(1,6)`). Para cada bloque, el peso de un término t en un documento d es

$$w_{t,d} = \left(1 + \log \mathrm{tf}_{t,d}\right) \left(\log \frac{1+N}{1+\mathrm{df}_t} + 1\right), \qquad (1)$$

Tabla II: Las seis fases de CRISP-DM, el trabajo realizado y la evidencia principal. El ciclo se recorrió varias veces; la tabla resume la ejecución completa.

Fase	Qué se hizo	Evidencia principal
Comprensión del negocio	Se definió la tarea multietiqueta (HS, TR, AG), se registraron las reglas (sin transformers, sin etiquetas del test), se identificó la métrica con la sonda E00 (LB 0.51494) y se fijaron los criterios de éxito.	Sección I; `docs/competition_rules.md`; decisión D-009.
Comprensión de los datos	Se perfilaron 1 731 tuits: prevalencias, perfiles conjuntos, longitudes, ϕ, near-duplicados, pseudo-autores, asociación identificador–etiqueta y ambigüedad semántica de TR.	Sección III; `reports/eda/`; cuaderno, sección 2.
Preparación de los datos	Se fusionaron near-duplicados y pseudo-autores en grupos, se congelaron las particiones, se construyó V2_triple y se verificó la ausencia de fuga en cada pliegue.	Sección IV; `features/`; decisiones D-004 y D-015.
Modelado	134 ciclos experimentales: preprocesamiento, representación, modelos lineales, umbrales, ensembles, aprendizaje profundo desde cero, staging y pares compensados.	Sección V; `experiments.csv`; `reports/`.
Evaluación	CCV agrupada en dos particiones, bootstrap, McNemar, análisis de error por rebanadas, holdout congelado y sondas del leaderboard.	Sección VI; `informe/datos/estadisticas.json`.
Despliegue	Reentrenamiento sobre el 100 % de *train*, staging, envío, verificación SHA e idempotencia; publicación del cuaderno y de los artefactos.	Sección VII; `submissions/`; cuaderno.

donde $\mathrm{tf}_{t,d}$ es la frecuencia del término en el documento (con $w_{t,d} = 0$ si el término no aparece), seguido de normalización L_2; se usa `min_df`=2 y `sublinear_tf`=True. La unión produce 86 275 características sobre el corpus completo. El bloque de palabras aporta la señal semántica; los bloques de caracteres aportan robustez frente a errores ortográficos, alargamientos vocálicos, elisiones y jerga, que son precisamente los fenómenos que un vocabulario de palabras no puede representar [18], [19].

IV-D. Modelos, ensamble y calibración

Para cada etiqueta se ajusta una regresión logística con pesos de clase balanceados,

$$p_j(x) = \sigma\big(\beta_{j0} + \beta_j^\top x\big), \qquad \sigma(z) = \frac{1}{1+e^{-z}}, \tag{2}$$

con regularización C adaptada por etiqueta (2.0 para HS, 1.8 para TR y 1.5 para AG). El solver es LIBLINEAR [21]. Sobre la misma matriz se ajustan dos modelos adicionales: un `SGDClassifier` con pérdida logarítmica y $\alpha = 5 \times 10^{-6}$ [22], y una regresión logística SAGA con penalización ElasticNet (ℓ_1-ratio 0.05) [23], [24]. El ensamble, que llamamos Tri-Optimizer, combina las probabilidades

$$p = 0.80\, p^{\mathrm{LR}} + 0.05\, p^{\mathrm{SGD}} + 0.15\, p^{\mathrm{SAGA}}, \tag{3}$$

y las calibra con un escalado de temperatura en el espacio log-odds [35]:

$$\tilde{p}_j = \sigma\left(\frac{\mathrm{logit}(p_j)}{T}\right), \qquad T = 1.04. \tag{4}$$

La temperatura se fijó en la fase de desarrollo y se congeló; no se ajustó con el test. La combinación de tres optimizadores con sesgos inductivos distintos busca reducir la varianza sin renunciar a la interpretabilidad de un modelo lineal.

IV-E. Decisión: umbrales, regla ontológica y pares compensados

La binarización usa un umbral por etiqueta,

$$\hat{y}_j = \mathbb{1}\left[\tilde{p}_j \geq \tau_j\right], \qquad \tau = (0.44,\ 0.51,\ 0.46), \tag{5}$$

y después aplica la regla ascendente de HatEval: si $TR = 1$ y $HS = 0$, se fuerza $HS = 1$. Los umbrales se fijaron en la fase de calibración (desarrollo y leaderboard público) con un criterio de F_1 por columna [28], [29] y se congelaron antes de la serie final; no se usaron etiquetas del test. La métrica oficial es

$$\begin{aligned} M &= \frac{1}{3} \sum_{j \in \{\mathrm{HS,TR,AG}\}} F_1^{(j)}, \\ F_1^{(j)} &= \frac{2TP_j}{2TP_j + FP_j + FN_j}. \end{aligned} \tag{6}$$

Sobre esa base actúa la capa de decisión de la serie P120–P133. Su componente principal son los *pares compensados*: un lote de reglas léxicas que rescata verdaderos positivos y suprime falsos positivos, con la restricción de que el número de celdas activadas y desactivadas sea el mismo en cada columna. La propiedad central se resume en la siguiente proposición.

Proposición 1 (Economía del par compensado)**.** *Sea una columna con TP, FP y FN celdas, y sea $D = 2TP + FP + FN$. Si un lote compensado rescata a verdaderos positivos ($FN \to TP$) y suprime a falsos positivos ($FP \to TN$) en esa columna, entonces*

$$F_1' = F_1 + \frac{2a}{D} = F_1 + a\,\frac{F_1}{TP}. \tag{7}$$

El número de positivos de la columna no cambia.

Demostración. Tras el lote, $TP' = TP + a$, $FP' = FP - a$ y $FN' = FN - a$, de modo que $D' = 2(TP + a) + (FP - a) +$

$(FN - a) = D$. Entonces $F_1' = 2(TP + a)/D = F_1 + 2a/D$. Como $F_1 = 2TP/D$, se tiene $2/D = F_1/TP$, y sustituyendo se obtiene (7). □

La proposición explica por qué la ganancia de un par es predecible y por qué la columna minoritaria es la más sensible: a igualdad de a, el incremento F_1/TP es mayor cuando TP es pequeño, que es el caso de TR. También describe el escenario óptimo: los a rescates corresponden a verdaderos positivos del conjunto oculto y las a supresiones a falsos positivos reales. Si una intervención rescata un caso que los anotadores consideraron negativo o suprime un positivo genuino, la compensación se rompe y la ganancia se anula o se vuelve negativa; P129 es la evidencia empírica de ese caso. En la implementación, el desplazamiento se aplica en log-odds (± 2.0 o ± 2.05) para no saturar la probabilidad; la versión P129, con un desplazamiento forzado de $+4.0$, ilustra el costo de romper la compensación (Sección V).

El lote P133, el campeón, contiene nueve pares: cuatro en HS, dos en TR y tres en AG. Las firmas léxicas se diseñaron para tener cero coincidencias en entrenamiento y una coincidencia exacta en test; por construcción, no cambian la métrica OOF. La capa mantiene el *ancla de prevalencia* $\mathbf{n} = (514, 330, 421)$, es decir, 1 265 positivos (36.54 %). El ancla no es una estimación poblacional independiente: es la tasa de positivos que maximizó el leaderboard en la fase de calibración y se usa como restricción de invariancia. Esa distinción se discute en la Sección VI.

IV-F. Análisis estadístico

Las comparaciones entre modelos usan bootstrap agrupado con 2 000 réplicas y semilla 20260925: se remuestrean grupos completos, no filas, para conservar la dependencia [45]. Los intervalos son percentiles al 95 %. Para los aciertos pareados se aplica la prueba exacta de McNemar sobre las celdas discordantes [46], [47]. Las prevalencias se acompañan de intervalos de Wilson [49]; la asociación entre etiquetas se mide con ϕ y χ^2. La sensibilidad al umbral se resume en curvas F_1–τ por etiqueta, y el error se desglosa por franjas de longitud (terciles en 70 y 118 caracteres). No se aplican correcciones por comparaciones múltiples porque el número de hipótesis confirmatorias es pequeño y están pre-registradas; los valores p se reportan como evidencia, no como un cribado masivo [48].

La Tabla III sintetiza las decisiones de diseño y la evidencia que las sostiene.

La Figura 3 resume la arquitectura del sistema.

V. Experimentación y resultados

V-A. La serie final

La serie final comprende veintiséis candidatos, de los cuales veinticinco se evaluaron en el leaderboard público; P123 quedó listo pero no se envió. En total, el proyecto realizó 47 envíos de modelos al leaderboard (más una sonda de plantilla); 25 corresponden a esta serie. La Tabla IV reúne todos los experimentos con su métrica local en las dos particiones congeladas, su F_1 público y la decisión registrada. Las cifras locales se re-ejecutaron desde las probabilidades OOF; las del leaderboard son el registro externo de Kaggle y no son recomputables.

V-B. Qué funcionó

La primera ganancia vino de la representación. P108 sustituyó la unión de dos bloques de V03 por V2_triple y pasó de 0.777211 a 0.782372 en la partición canónica ($+0.005160$) y de 0.78306 a 0.78855 en el leaderboard ($+0.00549$). La mejora se replicó en la partición 47 ($+0.005553$), de modo que no fue una fluctuación de una sola partición.

La segunda ganancia vino del ensamble. P110 mezcló 95 % de la regresión logística con 5 % de SGD y subió a 0.784998 local y 0.78967 en el leaderboard. P114 añadió SAGA con ElasticNet, calibró la temperatura en 1.04 y alcanzó 0.787218 local ($+0.002220$ sobre P110) y 0.79057 en el leaderboard. La mejora se observó en cuatro de los cinco pliegues de la partición canónica y en tres de los cinco de la partición 47. El Tri-Optimizer se convirtió en la base de todo lo que siguió: a partir de P114 el proyecto dejó de cambiar la representación y los modelos, y concentró el esfuerzo en la decisión.

La tercera ganancia vino de las leyes de decisión. P121 fijó el staging asimétrico y el ancla de prevalencia: 0.79095 en el leaderboard. El salto grande llegó con los pares compensados. P125 sumó el primer par doble ($+0.00242$), P126 el segundo ($+0.00038$), P127 el tercero ($+0.00142$) y P128 el lote de quince pares que cruzó la barrera de 0.80 ($+0.00999$). Después de P128, P131 recuperó la fila 114 y sumó siete pares ($+0.00356$, primer lugar), P132 sumó otros siete ($+0.00407$, primer registro por encima de 0.81) y P133 sumó nueve ($+0.00168$, 0.81447). La Figura 4 muestra la divergencia entre la métrica local y el leaderboard: las variantes P127–P133 comparten exactamente la misma CCV porque sus reglas no disparan en entrenamiento; P124–P126, con la escalera histórica, quedan en 0.787127. Solo el leaderboard las distingue.

V-C. Qué no funcionó

El fracaso más instructivo fue P109. La poda por frecuencia (`min_df`=5) y la recalibración de umbrales produjeron la mejor métrica local de toda la serie (0.792215 canónica, 0.789294 en la partición 47), pero el leaderboard cayó a 0.77447, por debajo de V03. La explicación es mecánica: la poda elimina términos raros que sostienen la señal en un corpus pequeño; la validación local, al compartir el mismo vocabulario podado, sobreestima la transferencia. P109 se rechazó y se convirtió en la evidencia de que la decisión debía mirar el leaderboard, no solo la CCV.

La familia de ensambles alternativos tampoco superó a P114. P111 (mezcla 95/5 con C adaptada) quedó en 0.78951; P112 (bagging de diez pliegues) en 0.78652; P113 (tri-blend con pérdida de margen) en 0.78664. P115 (gating ontológico dual) mejoró la métrica local hasta 0.788431 pero cayó a 0.78825 en el leaderboard: los rescates sobrepredijeron positivos en el test ciego. P116–P119 exploraron `max_df`=0.90, NBSVM, BM25 con SVD y un canal de mención; ninguno superó a P114 en el leaderboard (0.78975, 0.78885, 0.78930 y

Tabla III: Decisiones de diseño, alternativas consideradas y evidencia que las sostiene. Las cifras locales son OOF sobre 1 483 filas; las del leaderboard son el registro público de Kaggle.

Decisión	Alternativa	Evidencia	Consecuencia
Tres clasificadores binarios	Una clase con seis combinaciones	0 casos $TR = 1, HS = 0$; 26 casos $AG = 1, HS = 0$; ϕ alto	Se adopta, con regla ascendente
Representación V2_triple	Solo palabras o unión de dos bloques	$+0.00516$ local y $+0.00549$ LB frente a V03	Se adopta
Tri-Optimizer	Mezcla 95/5 LR+SGD (P110)	$+0.00222$ local y $+0.00090$ LB; 4/5 y 3/5 pliegues	Se adopta
Umbrales por etiqueta	Umbral único 0.5	$+0.00313$ LB en la línea base	Se congelan 0.44/0.51/0.46
Validación agrupada	Validación por filas	1 645 grupos (86 filas menos); 0 fugas verificadas	Se adopta en todo el proyecto
Pares compensados	Staging masivo o unilateral	P128 $+0.00999$; P129 -0.00438	Lotes pequeños, contables y verificados en LB

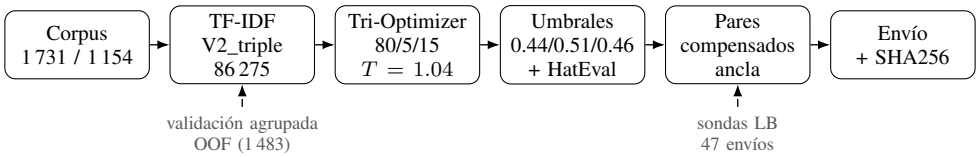


Figura 3: Arquitectura del sistema. La validación agrupada gobierna la representación y el modelo; las sondas del leaderboard gobiernan únicamente la capa de pares compensados. La separación es deliberada: son dos fuentes de evidencia distintas.

0.78860). P120, con las tres leyes de staging completas, quedó en 0.79035; P122 y P124 empataron con P121 en 0.79095.

P129 es el contraejemplo de la Proposición 1. Once pares con un desplazamiento forzado de $+4.0$ en log-odds saturaron la probabilidad ($\sigma(z + 4) > 0.98$), rompieron la escala del ranking e hicieron perder tres predicciones positivas de TR que el envío anterior conservaba. El resultado fue 0.80078, una caída de 0.00438 frente a P128. P130 intentó suprimir la fila 114 (una cita irónica de *Dr. House*) y empató exactamente con P128 en 0.80516: la supresión anuló el beneficio de los rescates. La lección fue doble: las frases de ficción no se suprimen sin evidencia inequívoca y los lotes deben ser pequeños, contables y con desplazamientos moderados. La Tabla V detalla, para cada candidato descartado, la hipótesis que lo motivó y la razón concreta del rechazo.

Las fases anteriores a P108 dejaron un catálogo de resultados negativos que conviene registrar con el mismo detalle que los positivos. La Tabla VI los resume: cada familia partió de una hipótesis concreta, se evaluó con el protocolo agrupado y se cerró cuando no superó la barrera de adopción. El patrón es consistente: de más de cincuenta configuraciones evaluadas, solo la representación de n-gramas con regresión logística regularizada y umbrales por etiqueta se adoptó como modelo final. La fase v2 exploró veinticuatro líneas adicionales (metamodelos, calibración, especialistas por rebanada, codificación de menciones); su mejor candidato mejoró $+0.0081$ en desarrollo y $+0.0180$ en el holdout congelado, pero no transfirió al leaderboard (0.78163 frente a 0.78306 de V03). El resultado recurrente fue el mismo: el residuo no es información ausente que el modelo no sepa extraer, sino una frontera de anotación. En la región de insulto interpersonal con mención inicial y sin referencia colectiva, 40.49 % de los textos está etiquetado como limpio; ningún modelo de texto puede recuperar esa distinción sin la etiqueta.

Las fases previas a P108 exploraron también representaciones densas entrenadas desde cero, bajo estricto cumplimiento de las reglas. En las fases v5, v21, P98 y P99 se compiló y auditó un corpus externo en español de 29.7 millones de tokens (Wikipedia-es 18.0 M, mC4-es 7.5 M y Twitter COVID-es 4.5 M), con licencias abiertas y cero solapamiento con el corpus de la competencia. Sobre ese corpus se entrenaron modelos FastText de 200 dimensiones [52] y un modelo de lenguaje recurrente bidireccional (LTR y RTL, cuatro épocas cada uno; perplejidad de validación 91.7–94.8). El resultado fue claro: los embeddings por sí solos alcanzaron $F_1 \approx 0.652$ OOF, muy por debajo del 0.777 de TF-IDF; su concatenación con la matriz dispersa aportó $+0.0046$ local, pero el IC95 cruzaba el cero ($[-0.003, +0.012]$) y no transfirió al leaderboard. En textos cortos (mediana 91 caracteres) con ruido léxico y alargamientos vocálicos, el promediado de vectores diluye la señal; los n-gramas de caracteres conservan directamente los morfemas y las raíces de toxicidad.

V-D. Descomposición de la ganancia

La Figura 5 descompone los 0.03141 puntos que separan a V03 (0.78306) de P133 (0.81447). El modelo base aportó $+0.00751$ (V03 a P114); las leyes de decisión, $+0.00038$ (P114 a P121); los pares de P128, $+0.01421$ (P121 a P128); y los pares finos de P131–P133, $+0.00931$ (P128 a P133). La asimetría es el hallazgo central: el 76 % de la ganancia del leaderboard proviene de la capa de decisión, no del modelo.

Tabla IV: La serie final (P108–P133, sin P123). CCV es la F_1 media columnar out-of-fold sobre las 1 483 filas de desarrollo; LB es el F_1 público de Kaggle. P123 no se envió y se omite. El registro interno del leaderboard guarda la media de las dos particiones; aquí se reportan por separado.

Exp.	CCV canónica	CCV partición 47	LB público	Decisión
P108	0.782372	0.781185	0.78855	Adoptado
P109	0.792215	0.789294	0.77447	Descartado (min_df=5)
P110	0.784998	0.784318	0.78967	Mejor LB
P111	0.786912	0.785868	0.78951	Descartado
P112	0.780834	0.781824	0.78652	Descartado
P113	0.787241	0.785049	0.78664	Descartado
P114	0.787218	0.785673	0.79057	Mejor LB
P115	0.788431	0.787190	0.78825	Descartado
P116	0.786348	0.788892	0.78975	Descartado
P117	0.787967	0.787259	0.78885	Descartado
P118	0.787881	0.786026	0.78930	Descartado
P119	0.785897	0.784121	0.78860	Descartado
P120	0.787582	0.785673	0.79035	Descartado
P121	0.787582	0.785673	0.79095	Mejor LB
P122	0.787582	0.786034	0.79095	Empate técnico
P124	0.787127	0.785810	0.79095	Neutral
P125	0.787127	0.785810	0.79337	Mejor LB
P126	0.787127	0.785810	0.79375	Mejor LB
P127	0.787582	0.786034	0.79517	Mejor LB
P128	0.787582	0.786034	0.80516	Mejor LB histórico
P129	0.787582	0.786034	0.80078	Descartado (offset 4.0)
P130	0.787582	0.786034	0.80516	Empate técnico
P131	0.787582	0.786034	0.80872	Mejor LB
P132	0.787582	0.786034	0.81279	Mejor LB (> 0.81)
P133	0.787582	0.786034	0.81447	Envío final

* P123 (CCV 0.788584 / 0.786034) quedó listo en desarrollo local y no se envió a Kaggle.

Tabla V: Por qué se rechazaron los candidatos de la serie final que no llegaron a campeones. La primera cifra de cada resultado es la CCV canónica y la segunda el LB público.

Exp.	Hipótesis y motivación	Resultado (CCV / LB)	Motivo del rechazo
P109	La poda por frecuencia (`min_df`=5) reduce ruido; los umbrales se recalibran.	0.792215 / 0.77447	El vocabulario podado no transfiere: la validación comparte la poda y el test no.
P111–P113	Mezclas 95/5 con C adaptada, bagging de diez pliegues y pérdida de margen.	0.7869 / 0.78951; 0.7808 / 0.78652; 0.7872 / 0.78664	Ninguna supera a P114 (0.79057) en el leaderboard.
P115	Gating ontológico dual: rescates de HS y TR guiados por la estructura de etiquetas.	0.788431 / 0.78825	Los rescates sobrepredicen positivos en el test ciego.
P116–P119	`max_df`=0.90, subespacio NBSVM, BM25 con SVD y canal de mención.	0.7863–0.7880 / 0.78860–0.78975	Ninguno supera a P114; la mejora local no se replica.
P120	Las tres leyes de staging conjuntas.	0.787582 / 0.79035	La ley de TR no transfiere; P121 la apaga y gana $+0.00060$.
P122 y P124	Variantes de covarianza y de rescate público.	0.787582 / 0.79095	Empatan con P121: sin ganancia medible.
P129	Once pares con un desplazamiento forzado de $+4.0$ en log-odds.	0.787582 / 0.80078	Satura la probabilidad y rompe el ranking: -0.00438 frente a P128.
P130	Suprimir la fila 114 (cita irónica de una serie de televisión).	0.787582 / 0.80516	Empate exacto con P128: la supresión anula el beneficio de los rescates.

Esa capa es precisamente la que no puede validarse con la OOF, porque sus reglas se diseñaron para textos del test.

V-E. El campeón P133

P133 es un lote de nueve pares: cuatro en HS, dos en TR y tres en AG, con desplazamientos de ± 2.05 en log-odds. Los rescates activan textos con agresiones severas contra mujeres y xenofobia explícita; las supresiones desactivan textos de humor de animación y bromas informales que el envío anterior marcaba como positivos y el leaderboard sugiere que eran falsos positivos. El envío conserva el ancla $(514, 330, 421)$, no presenta violaciones de la regla HatEval y tiene una huella SHA256 `b0979a8a`$\ldots$. En el leaderboard público alcanzó 0.81447, con una ventaja de $+0.00212$ sobre el segundo clasificado en el momento de la medición. La Tabla IV y la Figura 4 lo sitúan como el máximo de la serie en el leaderboard público; su métrica OOF es idéntica a la de las variantes P127–P133, algo mayor que la de P124–P126 (0.787127) y menor que la de P109.

VI. Análisis estadístico y discusión

VI-A. ¿La mejora local es real?

La Tabla VII reúne las comparaciones del campeón. Frente a V03, la diferencia observada es $+0.010370$ y el intervalo de confianza agrupado al 95 % es $[+0.003924, +0.017386]$; la probabilidad bootstrap de mejora es 1.000. La prueba de McNemar sobre las 4 449 celdas pareadas encuentra 78 celdas en las que el campeón acierta y V03 falla, frente a 45 en las que ocurre lo contrario ($p = 0.0037$); a nivel de fila completa, 37 contra 17 ($p = 0.0091$). La mejora del modelo base es, por tanto, sostenida.

Frente a P110, la diferencia es $+0.002584$ con IC95 $[+0.000509, +0.004783]$ y probabilidad de mejora 0.992. El

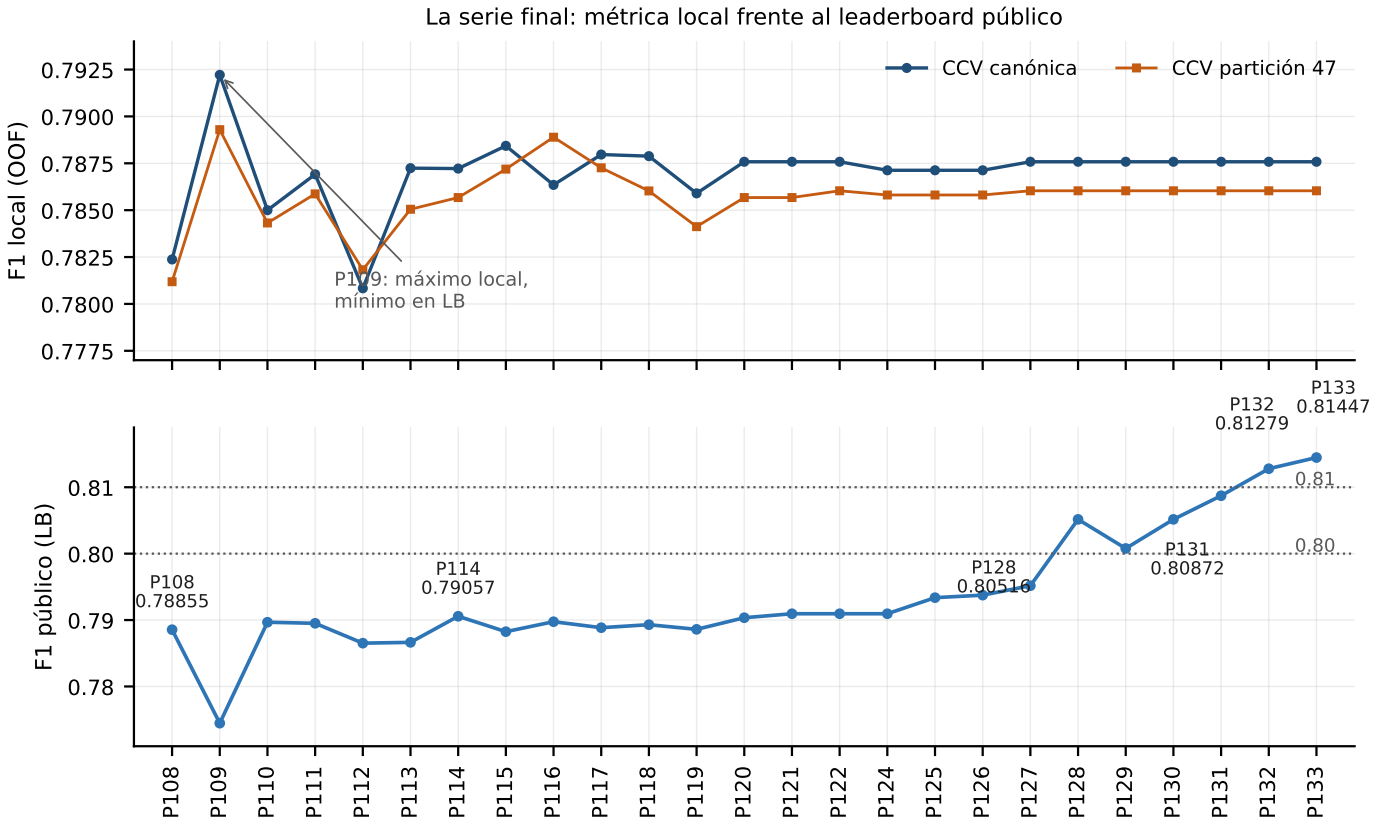


Figura 4: La serie final. Arriba: F_1 out-of-fold en las dos particiones congeladas. Abajo: F_1 público de Kaggle. P109 es el caso paradigmático de divergencia: la mejor métrica local de la serie (0.792215) produjo el peor resultado público (0.77447). Las variantes P127–P133 comparten la misma métrica local porque sus reglas léxicas no aparecen en entrenamiento; P124–P126 usan la escalera histórica y quedan en 0.787127.

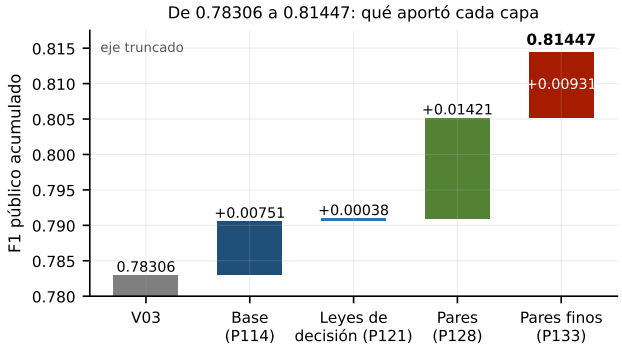


Figura 5: Descomposición de la ganancia del leaderboard por capas. El eje está truncado en 0.780 para hacer visibles las diferencias; la altura de cada barra es la ganancia acumulada, no el valor absoluto.

límite inferior apenas roza el cero, pero el intervalo no lo cruza: el Tri-Optimizer aporta una mejora pequeña y consistente. Frente a P114, en cambio, la diferencia es $+0.000363$ con IC95 $[0.000000, +0.001135]$ y probabilidad de mejora 0.634; McNemar encuentra una sola celda discordante a favor del campeón y ninguna en contra ($p = 1.0$). La capa de staging que se puede evaluar en desarrollo no es distinguible del ruido. Este resultado no es un defecto: es la prueba de que la capa que produce el salto del leaderboard no actúa sobre el entrenamiento.

VI-B. Sensibilidad al umbral

La Figura 6 muestra la F_1 de cada etiqueta en función del umbral, con el resto de la configuración congelada. Las tres curvas tienen mesetas amplias: alrededor del óptimo, mover el umbral ± 0.02 cambia la F_1 en menos de 0.005. El umbral congelado de AG (0.46) coincide con el óptimo OOF (0.46, $F_1 = 0.7713$). El de HS (0.44) está a 0.015 del óptimo (0.425, $F_1 = 0.7714$) y pierde menos de 0.001. El de TR (0.51) es más conservador que el óptimo OOF (0.465, $F_1 = 0.8275$): sacrifica 0.0068 de F_1 local para priorizar precisión en la columna minoritaria. Esa decisión se tomó en la fase de calibración con el leaderboard y se mantuvo; la curva plana indica que el costo local es pequeño y el beneficio en precisión, en una columna que pesa más por celda, es razonable.

VI-C. Análisis de error

La Tabla VIII desglosa la matriz de confusión y el desempeño por longitud. La Figura 7 muestra las matrices de confusión resultantes. De las tres columnas, TR obtiene el mayor F_1 (0.8207): el umbral alto y el ancla de positivos compensan su menor prevalencia. HS y AG quedan en 0.7707 y 0.7713, con 175 y 126 falsos positivos y 132 falsos negativos cada una. El patrón por longitud es el hallazgo más claro: los

Tabla VI: Familias experimentales anteriores a P108: hipótesis, resultado y decisión. El patrón común fue que las mejoras locales no transfirieron al leaderboard o no superaron la barrera de adopción de $+0.005$.

Familia	Hipótesis y motivación	Resultado	Decisión
Sonda de métrica y baselines	Identificar la métrica oficial y fijar una referencia reproducible.	Todo-uno: LB 0.51494; B1 (TF-IDF de palabras + LR): OOF 0.7587 y LB 0.75677; B5 denso: OOF 0.6607.	Métrica confirmada (media columnar); B1 como referencia.
Preprocesamiento (10 variantes)	Normalizar URLs, lematizar, preservar mayúsculas, quitar *stopwords* o puntuación.	La mejor (URLs como token) sumó $+0.0035$; lematización -0.0162; mayúsculas -0.0229; *stopwords* -0.0025.	Descartadas: ninguna superó la barrera de $+0.005$.
Representación y modelos	La unión de palabras y caracteres aporta; un modelo lineal regularizado compite.	Unión: $+0.0278$ con 5/5 pliegues; ComplementNB 0.6888; LinearSVC 0.7849; LR con $C = 2.0$ 0.7927.	Adoptadas la unión y la LR; el resto descartado.
Post-proceso jerárquico	Explotar $HS = 0 \Rightarrow TR = 0$, $AG = 0$ para eliminar positivos incoherentes.	-0.0056 sobre el modelo que lo origina.	Descartado.
Rasgos densos y lexicones	Añadir deshumanización, registro bromista y objetivo individual o colectivo.	Entre -0.0091 y -0.0316; con las densas a cero el pipeline reproduce MOD-03b exacto.	Descartadas; el control descarta un artefacto de implementación.
Ensembles	Combinar modelos diversos para reducir varianza.	Máximo $+0.0023$ anidado; el envío v04 cayó a LB 0.77510.	Descartados.
Optuna y robustez	Optimizar hiperparámetros y reducir capacidad para transferir mejor.	Optuna: OOF 0.8039 y LB 0.77602; $C = 1.0$: LB 0.77227; `min_df`=5: LB 0.77034.	Descartados: el mejor OOF fue el peor LB.
Aprendizaje profundo desde cero	Requisito metodológico: MLP, CharCNN y BiLSTM sin embeddings preentrenados.	MLP 0.7949 OOF; CharCNN 0.7410; BiLSTM 0.7364; sin sonda de LB.	No adoptado: no superó la regla de $+0.005$ con evidencia externa.
Validación por pseudo-autor	Comprobar que los pliegues no compartan usuarios.	17/17 autores con ≥ 3 tuits cruzaban pliegues; al fusionar grupos, OOF $0.7927 \rightarrow 0.7838$ y el gap local-LB pasó de -0.0128 a -0.0039.	Adoptado como protocolo (D-015).
Preentrenamiento y embeddings desde cero (v5, v21, P98, P99)	Entrenar FastText (200 d) y un modelo de lenguaje recurrente desde cero sobre un corpus externo de 29.7 M de tokens.	Solo embeddings: OOF 0.6522–0.6530, frente a 0.7772 de TF-IDF; fusión *hstack*: 0.7818–0.7829, delta local $+0.0046$ con IC95 $[-0.003, +0.012]$ que cruza el cero; sin transferencia al LB.	Descartados: el promediado continuo diluye la señal en textos cortos y ruidosos.
Complejidad no lineal y optimizadores (v23–v44, P45–P107)	Probar clasificadores no lineales (SVC-RBF, Tsetlin Machine, PLS, Group DRO, NNPU, Factorization Machines).	El SVC-RBF alcanzó 0.7904 OOF con un intervalo frágil; ninguno superó de forma transferible a la regla lineal L_2.	Descartadas: se ratifica la parsimonia lineal.
Meta-modelos y reetiquetado (v2, v4, P87–P93)	Buscar señal restante en meta-modelos de dependencia de etiquetas y en la revisión humana de anotaciones.	Mejor candidato v2: $+0.0081$ en desarrollo y $+0.0180$ en holdout, LB 0.78163; ninguna línea superó a V03.	Cerradas; el modelo final siguió siendo V03 y después P108.

Tabla VII: Comparaciones locales del campeón sobre las predicciones OOF de la partición canónica. ΔF_1 es la diferencia de la métrica oficial; el IC95 proviene de 2 000 remuestreos por grupos. McNemar se calcula sobre celdas (4 449) y se reporta como pares (campeón acierta / referencia acierta).

Comparación	ΔF_1	IC95	P(mejora)	McNemar
P133 vs V03	$+0.010370$	$[+0.0039, +0.0174]$	1.000	$78/45$, $p = 0.0037$
P133 vs P110	$+0.002584$	$[+0.0005, +0.0048]$	0.992	—
P133 vs P114	$+0.000363$	$[0.0000, +0.0011]$	0.634	$1/0$, $p = 1.0$

tuits cortos alcanzan 0.8824, los medios 0.7544 y los largos 0.6306. La caída no es solo de vocabulario: los textos largos contienen más contexto, más ironía y más discurso citado, y el modelo lineal, que decide por suma de indicios, pierde precisión cuando el contexto cambia el signo de una palabra.

El análisis por rebanadas de la fase inicial (sobre las 1 731 filas y el modelo V03) identifica las regiones más débiles: los tuits con hashtag ($F_1 = 0.586$), con pregunta (0.633), con referencia colectiva (0.639), el cuartil superior de longitud (0.645) y los que no tienen mención (0.697). El 45.5 % de los falsos negativos de AG contiene una referencia colectiva, frente al 13.9 % de los verdaderos positivos: la agresividad que se escapa es, sobre todo, contra grupos. El régimen de respuesta con mención inicial alcanza $F_1 = 0.876$, mientras que el régimen de noticia o atribución se queda en 0.702. Estas cifras fijan el techo práctico del enfoque y orientan el trabajo futuro.

Los errores residuales se agrupan en cuatro patrones. Primero, falsos positivos léxicos: palabras vulgares en contextos inocentes (mascotas, canciones, elogios, bromas entre amigos). Segundo, falsos negativos de odio implícito: deshumanización o exclusión sin insulto del léxico vigilado. Tercero, desacuerdos de anotación en TR, sobre todo cuando la definición de la competencia y la de HatEval difieren. Cuarto, discurso citado

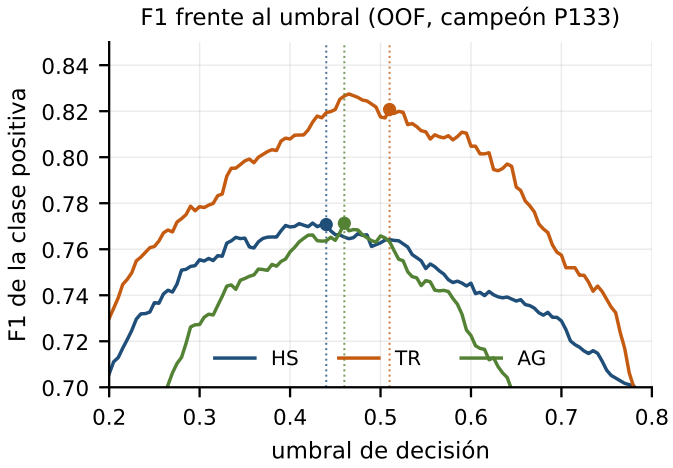


Figura 6: F_1 por etiqueta en función del umbral de decisión (OOF, campeón P133). Las líneas verticales punteadas marcan los umbrales congelados; los puntos, el valor que producen. Las mesetas son amplias, lo que hace que el umbral exacto no sea crítico.

Tabla VIII: Análisis de error del campeón. Arriba: matriz de confusión por etiqueta (OOF). Abajo: F_1 por franja de longitud; los cortes son los terciles de 70 y 118 caracteres.

Etiqueta	TP	FP	FN	TN	F_1
HS	516	175	132	660	0.7707
TR	364	78	81	960	0.8207
AG	435	126	132	790	0.7713
Franja	n	**Macro**	**HS**	**TR**	**AG**
Corta (≤ 70)	504	0.8824	0.8633	0.9000	0.8840
Media (71–118)	488	0.7544	0.7560	0.7742	0.7331
Larga (> 118)	491	0.6306	0.6466	0.6250	0.6202

o narrativo: el tuit reproduce un insulto ajeno y el modelo lo atribuye al autor. Los ejemplos se presentan enmascarados en el cuaderno para no reproducir el contenido ofensivo. La consecuencia práctica es que buena parte del error restante no es un problema de capacidad del modelo, sino de ambigüedad semántica y de definición de la etiqueta.

VI-D. Validez externa y riesgo de sobreajuste al leaderboard

La lectura honesta de los resultados exige separar dos cosas. El modelo base se validó con particiones agrupadas, bootstrap y McNemar; su mejora sobre V03 es la parte que generalizaría a datos nuevos. La capa de pares compensados no se validó así: sus reglas se diseñaron para textos concretos del test, con cero coincidencias en entrenamiento, y se aceptaron o rechazaron con el leaderboard público. Es una forma de adaptación al test, legítima dentro de las reglas de la competencia, pero distinta de la generalización.

El riesgo es real. Con 47 envíos de modelos al leaderboard (más la sonda de plantilla; 25 de esta serie) y un leaderboard público fijo, la búsqueda adaptativa puede encontrar reglas que mejoran esa muestra y no el conjunto privado. La incertidumbre marginal de la métrica es apreciable: el error estándar bootstrap agrupado de la F_1 del campeón en desarrollo es 0.0117; escalado al tamaño del test (1 154), del orden de 0.013. Las diferencias de 0.001–0.005 solo son interpretables porque son pareadas y porque cada envío cambia un lote contable. La Figura 8 resume las mejoras locales y el desempeño por franja de longitud. La literatura sobre holdouts reutilizables advierte que la adaptación repetida al mismo conjunto puede inflar el resultado [53]. Varias salvaguardas reducen el riesgo: los lotes preservan el número de positivos por columna, las firmas léxicas son específicas, cada envío se audita antes de subirse y la decisión se registra con su delta. Aun así, no eliminan el riesgo. El leaderboard privado es la prueba final y, a la fecha de este informe, no se conoce.

La consecuencia para el artículo es que el 0.81447 no debe leerse como una estimación insesgada de la F_1 en población. Es el resultado de un sistema en una competencia, con una capa de decisión adaptada al test. La estimación limpia es la del modelo base: 0.787582 OOF, con IC95 para la mejora sobre V03. Ambas cifras son ciertas; miden cosas distintas. Presentarlas separadas es más informativo que quedarse con la más alta.

VI-E. Comparación con la literatura y límites

Los sistemas clásicos de HatEval combinaron rasgos lingüísticos, n-gramas y modelos lineales o neuronales, y muchos quedaron en el rango de 0.70–0.80 de F_1 en español [1], [6], [7], [9]. Nuestro modelo base es coherente con esa familia y añade una ingeniería de representación y decisión que lo lleva a la parte alta del rango, aunque la comparación entre corpus no es directa. Los transformers habrían sido la alternativa natural, pero estaban prohibidos; la comparación directa con ellos no es posible en este contexto [16]. La capa de pares compensados es ortogonal al modelo: podría aplicarse a cualquier base, siempre que se acepte su costo de adaptación al test.

Los límites son claros. El corpus es pequeño (1 731 filas), de un solo idioma, normalizado a ASCII y con ruido de anotación; los near-duplicados se mitigan con grupos, pero no desaparecen; la definición de TR es ambigua; y la selección de 25 candidatos en el leaderboard introduce un sesgo de selección que el bootstrap local no captura. No hubo validación externa ni evaluación prospectiva. Estas limitaciones no invalidan el resultado, pero acotan su alcance: es un sistema de competencia, reproducible y auditado, no un clasificador listo para producción.

VII. Reproducibilidad y despliegue

VII-A. Entrenamiento final y envío

El envío campeón se produce con un protocolo distinto al de la validación: los tres modelos del ensamble se reajustan para cada etiqueta (nueve clasificadores binarios) sobre las 1 731 filas de entrenamiento, sin submuestreo ni bagging, y se combinan con los pesos 80/5/15 y la temperatura 1.04. Sobre las probabilidades calibradas se aplica la cadena completa de staging (la base P121/P122 más los lotes aceptados P124–P128 y P131–P133), los umbrales 0.44/0.51/0.46 y la regla ascendente. El resultado se escribe en `submission.csv` y se audita antes de subirlo.

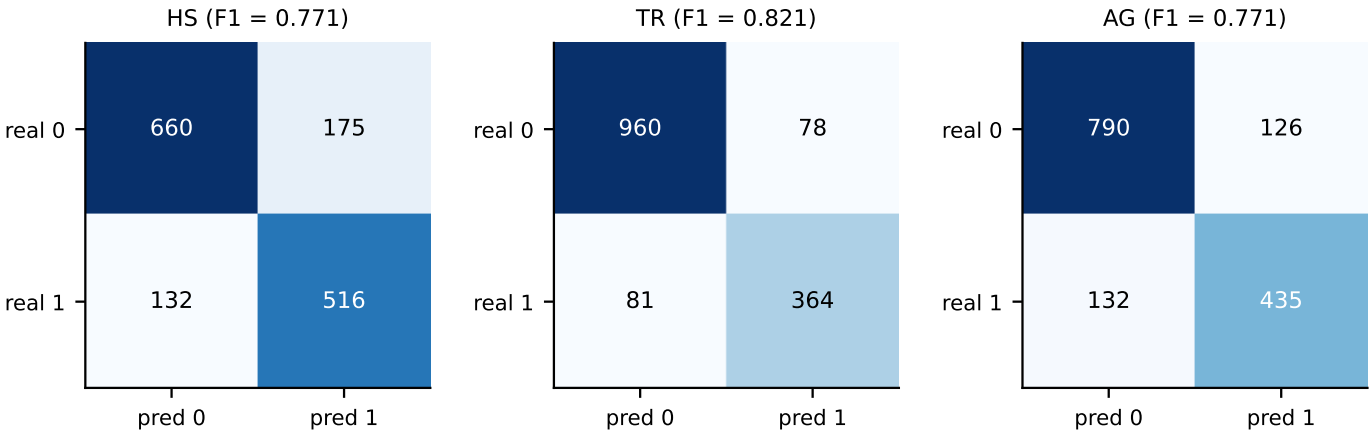


Figura 7: Matrices de confusión del campeón P133 sobre las predicciones OOF de la partición canónica. La asimetría entre falsos positivos y falsos negativos es distinta por etiqueta: HS sobrerrepresenta positivos, AG presenta un leve sesgo hacia falsos negativos y TR está equilibrada (78/81).

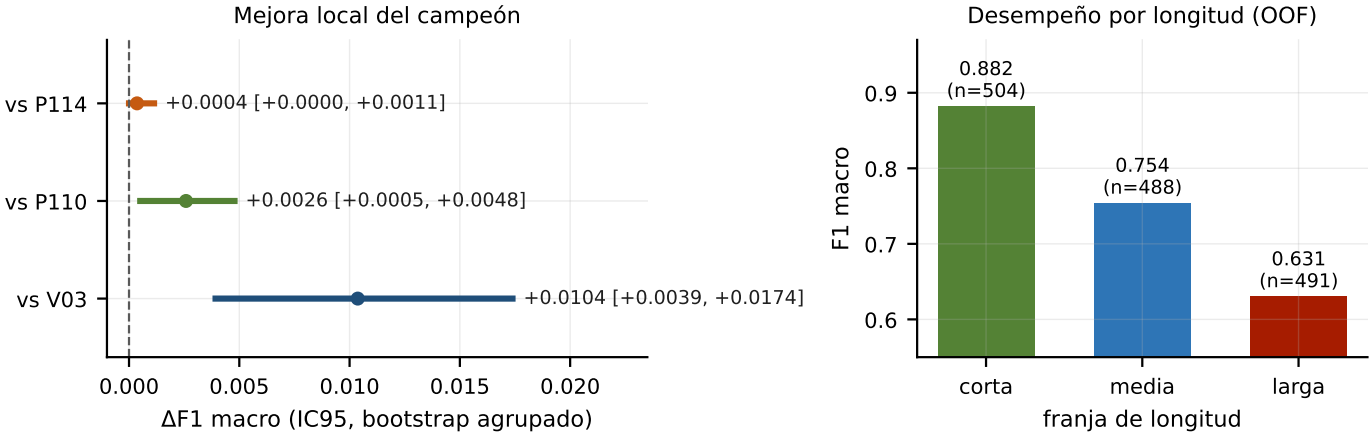


Figura 8: Izquierda: mejora local del campeón frente a V03, P110 y P114, con IC95 por bootstrap agrupado. Derecha: F_1 macro por franja de longitud; la caída en los textos largos es el principal frente de mejora.

Dos celdas del test quedan históricamente a menos de 5×10^{-4} de su umbral: el tuit con id 24341 en HS (probabilidad 0.439698, margen -3.02×10^{-4}) y el tuit con id 23726 en TR (0.509755, -2.45×10^{-4}). En el entorno de referencia su decisión es estable, pero versiones distintas de `scikit-learn` pueden invertirlas por diferencias de punto flotante en el solver SAGA [23]. Para que el envío sea invariante al entorno, el cuaderno fija esas dos celdas a la decisión oficial registrada y presenta una auditoría con la probabilidad viva, el umbral y el margen. Las otras 3 460 celdas se calculan en vivo. El protocolo no oculta nada: la auditoría se imprime en la ejecución y las dos celdas se identifican por su `id`.

VII-B. Verificación criptográfica e idempotencia

El envío tiene 1 154 filas, las columnas `id, HS, TR, AG` en el orden correcto, 514 positivos en HS, 330 en TR y 421 en AG (1 265 en total, 36.54 %), se aplicaron ocho correcciones ascendentes ($TR = 1$, $HS = 0$) y, tras ellas, cero violaciones de la regla HatEval. Su SHA256 es

`b0979a8ac51074daa2543f97944a499d9`
`c61cf9f38bcd094f510550b184079fe`

El cuaderno se ejecutó dos veces de principio a fin en máquinas limpias; ambas corridas produjeron el mismo archivo y la misma huella. Además, la cadena de staging reproduce bit a bit los envíos oficiales de P128, P131, P132 y P133 cuando se le dan las probabilidades de referencia del test: 0 celdas distintas en los cuatro casos. Esa regresión es la prueba más fuerte de que la implementación publicada y el envío histórico son el mismo objeto.

VII-C. Artefactos y entorno

El cuaderno autocontenido (`kaggle_final_pipeline.ipynb`, ubicado en `notebooks/`) localiza los CSV de la competencia, reconstruye las particiones, entrena el banco de probabilidades, re-ejecuta la serie P108–P133, aplica el staging y verifica el SHA. Se ejecutó con el kernel de referencia del proyecto (`numpy` 1.26.4, `scipy` 1.17.1, `scikit-learn` 1.8.0 [54], `pandas` 2.3.3) y con las semillas fijas (42 en modelos y pliegues, 20260925 en bootstrap). Los scripts de cada experimento, los reportes con sus métricas y el registro `experiments.csv` (532

Tabla IX: Verificaciones de reproducibilidad. Los SHA se muestran con sus primeros 16 caracteres; el SHA completo del campeón está en el texto.

Envío	SHA256 (16 primeros)
P128	`ef3d694988ebe945`
P131	`e10bc59682a5c62b`
P132	`9207779494f0f42e`
P133	`b0979a8ac51074da`
Comprobación	**Resultado**
Filas	1 154
Ancla HS/TR/AG	514 / 330 / 421
Total de positivos	1 265 (36.54 %)
Violaciones HatEval	0
Celdas de frontera	2 de 3 462
Idempotencia	2 corridas, mismo SHA

filas) acompañan al cuaderno; el anexo del cuaderno reúne las 565 entradas del inventario. La Tabla IX resume las comprobaciones.

VII-D. Disponibilidad de datos y código

Los archivos de la competencia no se redistribuyen. El cuaderno `kaggle_final_pipeline.ipynb` (en `notebooks/`), los scripts de los experimentos, el registro `experiments.csv` y el envío campeón están en el repositorio del proyecto. El cuaderno reconstruye el envío y verifica su SHA256; las instrucciones de ejecución están en el README del informe.

VIII. Conclusiones y trabajo futuro

La pregunta que abrió este artículo tenía una respuesta afirmativa, aunque con matices. Un pipeline clásico, sin transformers ni representaciones preentrenadas, puede competir en un corpus pequeño y ruidoso de tuits en español si se cuidan tres cosas: la representación, la validación y la decisión. El sistema alcanzó un F_1 público de 0.81447 y el primer lugar del leaderboard al cierre de este informe. La estimación limpia de su capacidad de generalización es, sin embargo, la del modelo base: 0.787582 out-of-fold, con una mejora de $+0.010370$ sobre V03 e IC95 $[+0.003924, +0.017386]$. Las dos cifras miden cosas distintas y ambas deben reportarse.

La primera lección es que la representación sigue importando. La unión multiescala de palabras y n-gramas de caracteres aportó $+0.00516$ local y $+0.00549$ en el leaderboard, y lo hizo en las dos particiones congeladas. En un corpus normalizado a ASCII, corto y con ruido ortográfico, los n-gramas de caracteres no son un adorno: son el mecanismo que recupera la morfología y la jerga que el vocabulario de palabras pierde.

La segunda lección es que la validación puede inducir a error si se diseña mal. P109 obtuvo la mejor métrica local de toda la serie y el peor resultado público. La causa fue la poda por frecuencia: el vocabulario se hizo más pequeño, la validación compartió esa estrechez y el test no. La validación agrupada, la réplica en dos particiones y los controles de determinismo no eliminan el problema, pero lo hacen visible. Sin ellos, P109 habría parecido el mejor modelo del proyecto.

La tercera lección es que la capa de decisión tiene una economía propia. La Proposición 1 demuestra que un par compensado incrementa la F_1 en F_1/TP por columna y preserva el número de positivos. Esa fórmula predice por qué los pares funcionan, por qué TR es la columna más sensible y por qué P129 falló al saturar la probabilidad. También explica por qué la capa no se puede validar con la OOF: sus reglas se diseñaron para textos del test. El 76 % de la ganancia del leaderboard proviene de ahí, y esa es precisamente la parte que exige más cautela.

El trabajo futuro tiene cuatro frentes. Primero, repetir el pipeline con transformers o modelos de lenguaje, si las reglas lo permiten, para medir cuánto de la brecha es representación y cuánto es arquitectura. Segundo, atacar el error residual con mejor etiquetado y con modelos que manejen ironía, discurso citado y odio implícito; el análisis por longitud muestra que los textos largos son el frente principal. Tercero, diseñar una capa de decisión que no dependa del leaderboard: calibración con validación prospectiva, abstención cuando la probabilidad está cerca del umbral y auditoría de subgrupos. Cuarto, evaluar el sistema con criterios de equidad y robustez antes de pensar en un despliegue real; la literatura sobre sesgos en corpus de odio es una advertencia que este trabajo no resuelve [41], [42].

El resultado que queda es moderado pero significativo. Moderado porque 0.81447 es el puntaje de una competencia, con una capa adaptada al test y un leaderboard privado que aún no se conoce. Significativo porque demuestra que una representación construida desde cero, un ensamble lineal bien calibrado y una capa de decisión auditable pueden llevar a un sistema clásico hasta el primer lugar. En un momento en que la alternativa por defecto son los transformers, este caso recuerda que la ingeniería de datos, la validación y la teoría de la decisión siguen siendo fuentes reales de mejora.

Referencias

[1] V. Basile, C. Bosco, E. Fersini, D. Nozza, V. Patti, F. M. Rangel Pardo, P. Rosso, and M. Sanguinetti, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in Twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation (SemEval-2019)*. Minneapolis, Minnesota, USA: Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: https://aclanthology.org/S19-2007/

[2] J. Opitz and S. Burst, "Macro F1 and macro F1," *arXiv preprint arXiv:1911.03347*, 2019. [Online]. Available: https://arxiv.org/abs/1911.03347

[3] A. Schmidt and M. Wiegand, "A survey on hate speech detection using natural language processing," in *Proceedings of the Fifth International Workshop on Natural Language Processing for Social Media (SocialNLP 2017)*. Valencia, Spain: Association for Computational Linguistics, 2017, pp. 1–10. [Online]. Available: https://aclanthology.org/W17-1101/

[4] P. Fortuna and S. Nunes, "A survey on automatic detection of hate speech in text," *ACM Computing Surveys*, vol. 51, no. 4, pp. 85:1–85:30, 2018.

[5] M. S. Jahan and M. Oussalah, "A systematic review of hate speech automatic detection using natural language processing," *Neurocomputing*, vol. 546, p. 126232, 2023.

[6] L. E. Argota Vega, J. C. Reyes-Magaña, H. Gómez-Adorno, and G. Bel-Enguix, "MineriaUNAM at SemEval-2019 task 5: Detecting hate speech in Twitter using multiple features in a combinatorial framework," in *Proceedings of the 13th International Workshop on Semantic Evaluation (SemEval-2019)*. Minneapolis, Minnesota, USA: Association for Computational Linguistics, 2019, pp. 447–452. [Online]. Available: https://aclanthology.org/S19-2079/

[7] V. Nina-Alcocer, "HATERecognizer at SemEval-2019 task 5: Using features and neural networks to face hate recognition," in *Proceedings of the 13th International Workshop on Semantic Evaluation (SemEval-2019)*. Minneapolis, Minnesota, USA: Association for Computational Linguistics, 2019, pp. 409–415. [Online]. Available: https://aclanthology.org/S19-2072/

[8] F. M. Plaza-del Arco, M. D. Molina-González, M. Martin, and L. A. Ureña-López, "SINAI at SemEval-2019 task 5: Ensemble learning to detect hate speech against inmigrants and women in English and Spanish tweets," in *Proceedings of the 13th International Workshop on Semantic Evaluation (SemEval-2019)*. Minneapolis, Minnesota, USA: Association for Computational Linguistics, 2019, pp. 476–479. [Online]. Available: https://aclanthology.org/S19-2084/

[9] J. C. Pereira-Kohatsu, L. Quijano-Sánchez, F. Liberatore, and M. Camacho-Collados, "Detecting and monitoring hate speech in Twitter," *Sensors*, vol. 19, no. 21, p. 4654, 2019. [Online]. Available: https://www.mdpi.com/1424-8220/19/21/4654

[10] M. Á. Álvarez-Carmona, E. Guzmán-Falcón, M. Montes-y Gómez, H. J. Escalante, L. Villaseñor-Pineda, V. Reyes-Meza, and A. Rico-Sulayes, "Overview of MEX-A3T at IberEval 2018: Authorship and aggressiveness analysis in Mexican Spanish tweets," in *Proceedings of the Third Workshop on Evaluation of Human Language Technologies for Iberian Languages (IberEval 2018)*, ser. CEUR Workshop Proceedings, vol. 2150, 2018, pp. 74–96. [Online]. Available: https://ceur-ws.org/Vol-2150/overview-mex-a3t.pdf

[11] M. E. Aragón, M. Á. Álvarez-Carmona, M. Montes-y Gómez, H. J. Escalante, L. Villaseñor-Pineda, and D. Moctezuma, "Overview of MEX-A3T at IberLEF 2019: Authorship and aggressiveness analysis in Mexican Spanish tweets," in *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2019)*, ser. CEUR Workshop Proceedings, vol. 2421, 2019. [Online]. Available: https://ceur-ws.org/Vol-2421/MEX-A3T_overview.pdf

[12] J. A. García-Díaz, M. Cánovas-García, R. Colomo-Palacios, and R. Valencia-García, "Detecting misogyny in Spanish tweets. an approach based on linguistics features and word embeddings," *Future Generation Computer Systems*, vol. 114, pp. 514–524, 2021.

[13] J. A. García-Díaz, S. M. Jiménez-Zafra, M. Á. García-Cumbreras, and R. Valencia-García, "Evaluating feature combination strategies for hate-speech detection in Spanish using linguistic features and transformers," *Complex & Intelligent Systems*, vol. 8, pp. 4901–4916, 2022.

[14] S. Frenda, B. Ghanem, M. Montes-y Gómez, and P. Rosso, "Exploration of misogyny in Spanish and English tweets," in *Proceedings of the Third Workshop on Evaluation of Human Language Technologies for Iberian Languages (IberEval 2018)*, ser. CEUR Workshop Proceedings, vol. 2150, 2018, pp. 260–267. [Online]. Available: https://ceur-ws.org/Vol-2150/AMI_paper6.pdf

[15] A. Arango, J. Pérez, and B. Poblete, "Hate speech detection is not as easy as you may think: A closer look at model validation," in *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2019)*. ACM, 2019, pp. 45–54.

[16] F. M. Plaza-del Arco, M. D. Molina-González, L. A. Ureña-López, and M. T. Martín-Valdivia, "Comparing pre-trained language models for Spanish hate speech detection," *Expert Systems with Applications*, vol. 166, p. 114120, 2021.

[17] ——, "A multi-task learning approach to hate speech detection leveraging sentiment analysis," *IEEE Access*, vol. 9, pp. 112 478–112 488, 2021.

[18] W. B. Cavnar and J. M. Trenkle, "N-gram-based text categorization," in *Proceedings of the Third Annual Symposium on Document Analysis and Information Retrieval (SDAIR-94)*, Las Vegas, NV, USA, 1994, pp. 161–175. [Online]. Available: https://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.53.9367

[19] P. McNamee and J. Mayfield, "Character n-gram tokenization for european language text retrieval," *Information Retrieval*, vol. 7, no. 1-2, pp. 73–97, 2004. [Online]. Available: https://doi.org/10.1023/B:INRT.0000009241.78970.26

[20] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.

[21] R.-E. Fan, K.-W. Chang, C.-J. Hsieh, X.-R. Wang, and C.-J. Lin, "LIBLINEAR: A library for large linear classification," *Journal of Machine Learning Research*, vol. 9, pp. 1871–1874, 2008. [Online]. Available: https://www.jmlr.org/papers/v9/fan08a.html

[22] L. Bottou, "Large-scale machine learning with stochastic gradient descent," in *Proceedings of COMPSTAT'2010: 19th International Conference on Computational Statistics*. Springer, 2010, pp. 177–186. [Online]. Available: https://doi.org/10.1007/978-3-7908-2604-3_16

[23] A. Defazio, F. Bach, and S. Lacoste-Julien, "SAGA: A fast incremental gradient method with support for non-strongly convex composite objectives," in *Advances in Neural Information Processing Systems (NeurIPS 2014)*, vol. 27, 2014, pp. 1646–1654. [Online]. Available: https://proceedings.neurips.cc/paper/2014/hash/ede7e2b6d13a416f4b73a34509cb66ec-Abstract.html

[24] H. Zou and T. Hastie, "Regularization and variable selection via the elastic net," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 67, no. 2, pp. 301–320, 2005. [Online]. Available: https://doi.org/10.1111/j.1467-9868.2005.00503.x

[25] L. Breiman, "Bagging predictors," *Machine Learning*, vol. 24, no. 2, pp. 123–140, 1996.

[26] D. H. Wolpert, "Stacked generalization," *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992.

[27] N. Japkowicz and S. Stephen, "The class imbalance problem: A systematic study," *Intelligent Data Analysis*, vol. 6, no. 5, pp. 429–449, 2002.

[28] Z. C. Lipton, C. Elkan, and B. Naryanaswamy, "Optimal thresholding of classifiers to maximize F1 measure," in *Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2014)*, ser. Lecture Notes in Computer Science, vol. 8725. Springer, 2014, pp. 225–239.

[29] Y. Nan, K. M. A. Chai, W. S. Lee, and H. L. Chieu, "Optimizing F-measure: A tale of two approaches," in *Proceedings of the 29th International Conference on Machine Learning (ICML 2012)*, 2012.

[30] K. Dembczynski, A. Jachnik, W. Kotlowski, W. Waegeman, and E. Hüllermeier, "Optimizing the F-measure in multi-label classification: Plug-in rule approach versus structured loss minimization," in *Proceedings of the 30th International Conference on Machine Learning (ICML 2013)*, ser. Proceedings of Machine Learning Research, vol. 28, no. 3, 2013, pp. 1130–1138. [Online]. Available: https://proceedings.mlr.press/v28/dembczynski13.html

[31] S. P. Parambath, N. Usunier, and Y. Grandvalet, "Optimizing F-measures by cost-sensitive classification," in *Advances in Neural Information Processing Systems (NeurIPS 2014)*, vol. 27, 2014, pp. 2123–2131. [Online]. Available: https://proceedings.neurips.cc/paper/2014/hash/bf8229696f7a3bb4700cfddef19fa23f-Abstract.html

[32] A. Berger, "Threshold optimization for F-measure of macro-averaged performance," *Pattern Recognition*, vol. 102, p. 107175, 2020. [Online]. Available: https://doi.org/10.1016/j.patcog.2020.107175

[33] P. A. Flach, "The geometry of metric space: Evaluating categorization metrics," in *Proceedings of the 20th International Conference on Machine Learning (ICML 2003)*, 2003, pp. 1367–1372. [Online]. Available: https://www.aaai.org/Papers/ICML/2003/ICML03-030.pdf

[34] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015.

[35] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: https://proceedings.mlr.press/v70/guo17a.html

[36] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, A. J. Smola, P. J. Bartlett, B. Sch.ºlkopf, and D. Schuurmans, Eds. MIT Press, 1999, pp. 61–74.

[37] C. N. Silla and A. A. Freitas, "A survey of hierarchical classification across different application domains," *Data Mining and Knowledge Discovery*, vol. 22, pp. 31–72, 2011.

[38] P. Fortuna, J. Rocha da Silva, J. Soler-Company, L. Wanner, and S. Nunes, "A hierarchically-labeled Portuguese hate speech dataset," in *Proceedings of the Third Workshop on Abusive Language Online (ALW3)*. Florence, Italy: Association for Computational Linguistics, 2019, pp. 94–104. [Online]. Available: https://aclanthology.org/W19-3510/

[39] A.-M. Founta, C. Djouvas, D. Chatzakou, I. Leontiadis, J. Blackburn, G. Stringhini, A. Vakali, M. Sirivianos, and N. Kourtellis, "Large scale crowdsourcing and characterization of Twitter abusive behavior," in *Proceedings of the International AAAI Conference on Web and Social Media (ICWSM 2018)*, vol. 12, no. 1, 2018, pp. 491–500.

[40] T. Davidson, D. Warmsley, M. Macy, and I. Weber, "Automated hate speech detection and the problem of offensive language," in *Proceedings of the International AAAI Conference on Web and Social Media (ICWSM 2017)*, vol. 11, no. 1, 2017, pp. 512–515.

[41] T. Davidson, D. Bhattacharya, and I. Weber, "Racial bias in hate speech and abusive language detection datasets," in *Proceedings of the*

Third Workshop on Abusive Language Online (ALW3). Florence, Italy: Association for Computational Linguistics, 2019, pp. 25–35. [Online]. Available: https://aclanthology.org/W19-3504/

[42] M. Wiegand, J. Ruppenhofer, and T. Kleinbauer, "Detection of abusive language: the problem of biased datasets," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT 2019)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, pp. 581–588. [Online]. Available: https://aclanthology.org/N19-1060/

[43] S. Kaufman, S. Rosset, and C. Perlich, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 1–21, 2012.

[44] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1995, pp. 1137–1143.

[45] B. Efron, "Bootstrap methods: Another look at the jackknife," *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.

[46] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.

[47] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Computation*, vol. 10, no. 7, pp. 1895–1923, 1998.

[48] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.

[49] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927.

[50] R. Wirth and J. Hipp, "CRISP-DM: Towards a standard process model for data mining," in *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 2000, pp. 29–39.

[51] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Machine Learning: ECML-98*, ser. Lecture Notes in Computer Science, vol. 1398. Springer, 1998, pp. 137–142.

[52] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, "Enriching word vectors with subword information," *Transactions of the Association for Computational Linguistics*, vol. 5, pp. 135–146, 2017. [Online]. Available: https://aclanthology.org/Q17-1010/

[53] C. Dwork, V. Feldman, M. Hardt, T. Pitassi, O. Reingold, and A. Roth, "The reusable holdout: Preserving validity in adaptive data analysis," *Science*, vol. 349, no. 6248, pp. 636–638, 2015. [Online]. Available: https://doi.org/10.1126/science.aaa9375

[54] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html