Pontificia Universidad
JAVERIANA
Colombia

Facultad de Ingeniería
Maestría en Inteligencia Artificial
Parcial 2 - NLP

Informe analisis Cross-lingual distillation for domain knowledge transfer with sentence transformers

Parcial 2

Erika Valeria Rivera Jimenez
riveraev@javeriana.edu.co

Julian Guillermo Carrillo Meneses
carrillojuliang@javeriana.edu.co

Carlos Andres Garnica Salazar
carlos_garnicas@javeriana.edu.co

Oscar Andres Prieto Moreno
o-prieto@javeriana.edu.co

1. ¿La destilación de conocimiento puede transferir sesgos de género y estereotipos presentes en el idioma original hacia otras lenguas?

Si, este es uno de los mayores desafíos del PLN. La destilación de conocimiento transfiere el conocimiento del modelo profesor al estudiante, pero no filtra la calidad moral o social de esa información. Si el modelo profesor en inglés aprendió a asociar la palabra 'enfermera' siempre con el género femenino o ciertas enfermedades con grupos étnicos específicos debido al sesgo en sus datos de entrenamiento, el estudiante multilingüe heredará exactamente los mismos sesgos.

2. ¿Cómo se pueden reducir los sesgos en los modelos de PLN?

Aunque el sesgo nunca se puede quitar en su totalidad, en el paper se explica que los experimentos ya cuentan con mecanismos como la métrica BLEU y funciones de pérdida para lidiar con ciertos sesgos, pero esto no elimina el problema cuando la calidad de los datos no es fiable. También se puede utilizar la métrica BLEU en combinación con otras métricas, o bien, introducir un filtro de evaluación manual donde un humano valide las representaciones en ambos idiomas (inglés y el idioma meta).

Otra estrategia efectiva es aumentar la cantidad de datos equilibrada antes del entrenamiento. Esto implica generar variaciones de las oraciones originales donde se intercambien los pronombres de género o se neutralicen ciertos términos para que el modelo profesor no asocie mecánicamente roles a géneros.

3. ¿Cómo se garantiza que los pares multilingües tengan un significado equivalente y no solamente una traducción superficial, considerando que mBERT es un modelo generalista?

La función de perdida MNRL que utilizan en el paper es clave aquí porque alinea los espacios vectoriales basándose en relaciones semánticas complejas y no en coincidencias léxicas. Sin embargo, para compensar la naturaleza generalista de mBERT en el dominio médico, una solución ideal sería realizar un preentrenamiento continuo del modelo mBERT exclusivamente con grandes corpus médicos multilingües (como literatura médica o bases de datos de la OMS) antes de aplicar la destilación. De esta forma, el modelo estudiante ya conocería las sutilezas de la jerga médica en diferentes idiomas antes de intentar imitar al profesor, reduciendo la dependencia de una validación humana constante.

Aunque parte del experimento realizado en el paper también era validar que tanto afectaba tener un modelo que no tuviera conocimiento medico.

Reflexión final

La discusión permite concluir que la destilación de conocimiento ofrece una alternativa para transferir representaciones entre idiomas y desarrollar modelos más eficientes, pero su utilidad depende de la calidad del conocimiento que se transfiere y de la manera en que se evalúan los resultados.

En particular, es necesario diferenciar entre la similitud lingüística y la equivalencia semántica. Aunque las métricas automáticas y las funciones de pérdida permiten optimizar determinados aspectos del modelo, no garantizan por sí solas que las representaciones sean correctas, especializadas o libres de sesgos.

Desde una perspectiva de investigación en PLN, se considera que el principal reto consiste en combinar la eficiencia de la destilación con mecanismos de validación que permitan comprobar la conservación del significado, la calidad de las representaciones y la presencia de posibles sesgos. Esto resulta especialmente importante en el dominio médico, donde una traducción aparentemente correcta puede omitir distinciones relevantes para la interpretación de la información.

En consecuencia, el desarrollo de modelos multilingües confiables requiere no solo mejorar sus resultados cuantitativos, sino también comprender sus limitaciones y verificar que el conocimiento transferido sea adecuado para el contexto en el que se utilizará.