Ing. Luis Gabriel Moreno Sandoval, PhD
morenoluis@javeriana.edu.co

Entrega 1 – Corpus, Idea de Proyecto y Textometría

Objetivo

En esta primera entrega, cada grupo deberá definir el tema de su proyecto, justificar la elección, seleccionar un corpus inicial de trabajo y realizar un análisis exploratorio básico mediante técnicas de textometría.

---

1. Idea de proyecto (2–3 páginas)

- **Área de aplicación / dominio:** explicar brevemente el contexto (ej: salud, derecho, economía, educación, redes sociales, etc.).
- **Problema por abordar:** plantear qué tipo de tarea de PLN podría resolverse (ej: clasificación de textos, análisis de sentimiento, detección de tópicos, resumen, etc.).
- **Justificación:** por qué consideran relevante este tema y qué potencial aporte tendría.
- **Preguntas de investigación iniciales:** al menos 2–3 preguntas guía.

---

2. Corpus (descripción + evidencia)

- **Fuente del corpus:** detallar de dónde se obtiene (ej: repositorios públicos, páginas web, redes sociales, artículos académicos, etc.).
- **Características del corpus:**
  - Cantidad de documentos / tamaño aproximado.
  - Idioma(s).
  - Tipo de texto (noticias, artículos científicos, tuits, etc.).
- **Ejemplo:** incluir un par de fragmentos o ejemplos representativos.
- **Formato de almacenamiento:** indicar cómo lo tienen (CSV, JSON, TXT, etc.).

---

3. Textometría básica (exploración preliminar)

Realizar un análisis inicial del corpus que incluya:

- **Limpieza básica:** eliminación de caracteres extraños, normalización (ej: minúsculas).
- **Medidas textuales:**
  - Número de documentos.
  - Número total de palabras.
  - Promedio de palabras por documento.
- **Frecuencias:**
  - Top 20 palabras más frecuentes (con y sin stopwords).
- **Visualizaciones simples:** (pueden usar Python, R o cualquier herramienta)
  - Nube de palabras o gráfico de barras de frecuencias.

---

4. Formato de entrega

- Documento en PDF (máx. 8 páginas).
- Adjuntar en un anexo **(o link a Drive/GitHub)** el corpus recolectado hasta el momento.