Pontificia Universidad JAVERIANA Colombia

**Facultad de Ingeniería**
Maestría en Inteligencia Artificial
Avance de proyecto 2 - NLP

# Análisis de sentencias de la Corte Constitucional de Colombia (1992–2021)

**Entrega 2: EDA avanzado, representación de textos y propuesta metodológica**

Erika Valeria Rivera Jimenez
riveraev@javeriana.edu.co

Julian Guillermo Carrillo Meneses
carrillojuliang@javeriana.edu.co

Carlos Andres Garnica Salazar
carlos_garnicas@javeriana.edu.co

Oscar Andres Prieto Moreno
o-prieto@javeriana.edu.co

Pontificia Universidad Javeriana, Bogotá, Colombia

**Resumen**

Esta segunda entrega profundiza el análisis del corpus de 23.742 sentencias de la Corte Constitucional de Colombia (1992–2021), entrega el corpus en su versión medida y define la representación de los textos y la metodología de modelado del proyecto. Primero se documentan las modificaciones respecto a la Entrega 1: el corpus se persiste como conjunto de datos medido (con texto, texto limpio y métricas por documento), se incorpora un EDA avanzado —n-gramas y colocaciones con validación manual, lemas, *stems* y categorías gramaticales, diversidad léxica MTLD, evolución por periodos, granularidad y evaluación de recursos léxicos— y se valida con evidencia la unidad de análisis (sentencia completa). Segundo, se comparan las familias de representación (bolsa de palabras, TF-IDF, *embeddings* y representaciones contextuales) y se selecciona y calcula TF-IDF sobre lemas como representación principal (matriz de $23.742 \times 100.000$ rasgos). Tercero, se propone una metodología de clasificación supervisada multi-clase con particiones estratificadas, criterios anti-*leakage* y comparación entre modelos lineales y *transformers* en español. Los resultados caracterizan el carácter formulaico del género, una diversidad léxica decreciente entre 1992 y 2021, un recambio temático visible en el vocabulario de la última década y la viabilidad de la sentencia completa como unidad de análisis.

***Palabras clave:*** procesamiento de lenguaje natural, lenguaje jurídico, Corte Constitucional de Colombia, EDA avanzado, diversidad léxica, representación de textos, TF-IDF, clasificación de documentos legales.

## 1. Introducción

### 1.1. Contexto y motivación

Este proyecto aborda el análisis computacional de las sentencias de la Corte Constitucional de Colombia emitidas entre 1992 y 2021 mediante técnicas de procesamiento de lenguaje natural (PLN). El corpus

de trabajo reúne 23.742 providencias de tres tipos —tutela (T, 17.099), constitucionalidad (C, 6.246) y unificación (SU, 397)—, obtenidas del repositorio público de Hugging Face *Manuel/sentencias-corte-cons-colombia-1992-2021* [Manuel, 2022]. Se trata de un corpus de "pocos documentos pero muy extensos": cada sentencia promedia $\approx$ 11.000 palabras, con estructura discursiva formal, terminología especializada, fórmulas de estilo estables y abundantes citas normativas y jurisprudenciales; la literatura sobre sentencias largas advierte que este perfil exige cautela al interpretar los conteos globales y recomienda complementarlos con estadísticas por documento [Soh et al., 2019].

La Entrega 1 consolidó ese corpus: documentó su depuración, ejecutó una textometría básica sobre la totalidad de los documentos y dejó planteadas las líneas de trabajo posteriores (lematización, representaciones vectoriales y clasificación automática). Esta segunda entrega responde al propósito del enunciado de la Entrega 2: profundizar en el análisis del corpus, mostrar la representación de los textos según el contexto del proyecto y proponer una metodología de modelado inicial. La motivación es doble: la caracterización léxica y morfológica es un insumo directo para decidir cómo representar los documentos y qué rasgos conservar, y los recursos legales anotados en español para América Latina son escasos [Löffler et al., 2025], de modo que un corpus colombiano depurado, medido y documentado constituye un aporte en sí mismo.

### 1.2. Objetivo del proyecto

El objetivo general del proyecto es construir un sistema de apoyo que, dada una sentencia de la Corte Constitucional de Colombia: (i) valide que se trata de una providencia; (ii) determine su área temática constitucional; (iii) identifique los artículos de la Constitución Política (CP) en los que se sustenta; y (iv) la sitúe en su contexto jurisprudencial. El sistema se concibe como una herramienta de apoyo a la consulta y al análisis especializado, no como un sustituto de la interpretación jurídica.

Esta entrega no ejecuta los modelos de la fase final: prepara el terreno para ellos. Concretamente, entrega el conjunto de datos medido (requisito 3 del enunciado), el análisis exploratorio avanzado (requisito 2), la representación de los textos (requisito 4) y la propuesta metodológica (requisito 5), además de las correcciones y modificaciones respecto a la Entrega 1 (requisito 1) y del formato de entrega con informe y datos adjuntos (requisito 7). El alcance temporal se mantiene estrictamente en 1992–2021; el año 2021 es parcial (20 documentos).

### 1.3. Aportes de esta entrega y organización del documento

Los aportes se organizan así. La sección 2 documenta las correcciones y modificaciones respecto a la Entrega 1 y las razones de cada cambio. La sección 3 describe la fuente, la depuración, el *pipeline* de limpieza y el conjunto de datos medido que se adjunta. La sección 4 presenta el EDA avanzado: n-gramas y colocaciones, morfología, diversidad léxica, evolución por periodos, recursos léxicos y granularidad. La sección 5 compara las familias de representación y justifica la decisión por TF-IDF sobre lemas; la sección 6 formula la propuesta metodológica, y la sección 7 cierra el documento.

## 2. Correcciones y modificaciones respecto a la Entrega 1

Esta sección responde al requisito 1 del enunciado: indicar qué ajustes se realizaron al corpus, a las visualizaciones o al planteamiento inicial, y explicar brevemente las razones. Cada cambio candidato se verificó contra el informe de la Entrega 1 y sus artefactos (la ejecución de análisis y el registro de métricas); se reportan únicamente cambios reales. Las cifras canónicas de la Entrega 1 no requirieron corrección: el EDA extendido reproduce el tamaño del corpus (23.742 documentos) y la distribución por tipos (T 17.099, C 6.246, SU 397), y las medidas globales de palabras crudas y limpias se mantienen (sección 3.4). Los seis cambios efectivos se agrupan en tres frentes: el conjunto de datos entregado, la

profundidad del análisis y las decisiones de planteamiento.

## 2.1. Del anexo de muestra al conjunto de datos medido

La Entrega 1 adjuntó una muestra estratificada de 25 sentencias (17 T, 6 C y 2 SU) con fines de revisión, y conservó los conteos por documento en un registro de metadatos sin texto (identificador, tipo, número, año y conteos de palabras). En esta entrega el corpus completo se persiste como un conjunto de datos medido (sección 3.3): 23.742 filas con texto, texto limpio y métricas por documento. La razón es doble: el enunciado exige entregar el corpus actualizado, preprocesado y con sus métricas, en un formato legible; y el conjunto medido se convierte en el insumo único y trazable del análisis y de la fase de modelado, lo que reduce el riesgo de inconsistencias entre etapas.

## 2.2. EDA avanzado y nuevas visualizaciones

La Entrega 1 reportó textometría básica (medidas globales, top-20 con y sin palabras vacías, distribución temporal y nubes de palabras). Sobre el mismo corpus se calculó un EDA extendido —n-gramas, colocaciones, morfología, diversidad léxica, granularidad y recursos léxicos— que no alcanzó a reportarse entonces; esta entrega lo incorpora con su lectura analítica y sus visualizaciones (sección 4), tal como pide el requisito 2 del enunciado, y conserva las cifras de la Entrega 1, que siguen vigentes.

## 2.3. Unidad de análisis validada con evidencia

La Entrega 1 analizaba implícitamente la sentencia completa como unidad, sin justificarlo. Como segmentar 23.742 documentos para modelar fragmentos es una decisión costosa de revertir, esta entrega evaluó tres granularidades posibles (sentencia, párrafo y subsentencia) antes de fijar la representación y la metodología, con un criterio pre-registrado: la subsentencia solo se propondría como unidad si superaba en al menos 15 puntos porcentuales la pureza temática de la sentencia completa (sección 4.6). El resultado (4,64 % frente a 97,17 %) no superó el criterio: se mantiene la sentencia completa como unidad, ahora con evidencia y no por omisión.

## 2.4. Cumplimiento del análisis por periodos prometido en la Entrega 1

La Entrega 1 anunció que "el análisis cuantitativo de la evolución léxica por periodos se abordará en la entrega 2". Esta entrega cumple esa promesa con un contraste de tres periodos (1992–2001, 2002–2011 y 2012–2021) mediante razones de *log-odds* binarias con suavizado add-0,5 [Hamilton et al., 2016], acompañado de la serie de diversidad léxica (sección 4.2). El análisis diacrónico del discurso judicial está respaldado por la literatura como una vía para detectar cambios de agenda y de estilo de redacción en los tribunales [Raj et al., 2026].

## 2.5. Representación definida y propuesta metodológica

La Entrega 1 dejó como trabajo futuro "representaciones del texto (TF-IDF y vectores densos)" y "experimentos de clasificación automática por tipo y temática". Esta entrega define y justifica la representación principal (TF-IDF sobre lemas, sección 5.5) y formula la propuesta metodológica de los modelos (sección 6). Se trata de un cambio de estado del proyecto —de la exploración descriptiva al diseño experimental—, no de una rectificación de la Entrega 1, cuyos resultados siguen siendo la línea base del proyecto.

# 3. Corpus y preprocesamiento

## 3.1. Fuente y depuración

El corpus proviene del repositorio abierto *sentencias-corte-cons-colombia-1992-2021*, publicado por el usuario *Manuel* en el Hugging Face Hub bajo licencia CC-BY-4.0 [Manuel, 2022]. El conjunto original es un volcado plano de 1,68 GB en UTF-8 con dos columnas, un identificador y el texto completo de la providencia; su nombre sugiere cobertura hasta 2022, pero la cobertura real es 1992–2021: no hay documentos de 2022 y el año 2021 es parcial, con solo 20 sentencias. La fuente primaria de los textos es la relatoría de la Corte Constitucional de Colombia.

La depuración siguió el procedimiento documentado en la Entrega 1. El conjunto original contiene 23.750 filas; el identificador de la sentencia (por ejemplo, `T-293/97`) y el año de emisión se extraen del encabezado mediante expresiones regulares sobre el patrón *Sentencia T-293/97*, con una tasa de éxito del 99,97 % (23.742 de 23.750). Las 8 filas restantes se excluyeron y documentaron: 6 corresponden a autos (no sentencias) y 2 a fragmentos HTML residuales del proceso de recolección. El corpus de análisis queda así conformado por 23.742 sentencias. El universo documental subyacente ya había sido explorado computacionalmente: Anzola Cortés analizó más de 6.000 sentencias de constitucionalidad (1992–2020) con minería de datos y documentó los problemas estructurales de estos textos (fórmulas de estilo y referencias embebidas) [Anzola Cortés, 2021]. La tabla 1 resume la ficha del corpus.

Tabla 1: Ficha del corpus de análisis (1992–2021).

| **Elemento** | **Valor** |
|---|---|
| Origen | Hugging Face: *Manuel/sentencias-corte-cons-colombia-1992-2021* (CC-BY-4.0); volcado plano de 1,68 GB con 23.750 filas [Manuel, 2022] |
| Corpus de análisis | 23.742 sentencias |
| Tipos de providencia | T: 17.099 (72,02 %); C: 6.246 (26,31 %); SU: 397 (1,67 %) |
| Cobertura temporal | 1992–2021 (2021 parcial: 20 documentos) |
| Exclusiones | 8 filas (6 autos; 2 fragmentos HTML) |
| Persistencia | Conjunto de datos medido (texto, texto limpio y métricas por documento) |

## 3.2. Pipeline de limpieza reproducible

El *pipeline* de limpieza se aplicó por etapas medibles y se documenta como decisión metodológica, pues la literatura muestra que el preprocesamiento altera los resultados y que su efecto depende del corpus y de la tarea [HaCohen-Kerner et al., 2020]. La tabla 2 lista los ocho pasos, idénticos a los de la Entrega 1 para garantizar la comparabilidad de las cifras. Los pasos de normalización persiguen un objetivo común: que las variantes de escritura de una misma palabra se cuenten juntas, algo especialmente relevante en un corpus digitalizado donde la acentuación y las mayúsculas son inconsistentes; por eso se pasa a minúsculas, se retiran los diacríticos y se restringe el vocabulario a letras y espacios, de modo que números y signos no fragmenten los conteos. Dos decisiones merecen énfasis. Primero, la normalización Unicode (NFD con retiro de diacríticos) protege la letra *ñ* antes de descomponer, de modo que las grafías del corpus quedan sin tildes pero conservan la virgulilla (*artículo* → *articulo*; *año* → *año*). Segundo, la lista de palabras vacías del español de NLTK se sometió a la misma transformación que el corpus: quedan 306 formas efectivas sin tildes, pues 84 formas acentuadas del conjunto original se normalizaron igual que el texto; de otro modo, dejarían de filtrarse y contaminarían los conteos.

El paso 7 —denominado *filtro de ruido*— evita que tokens de un solo carácter generados por la limpieza (la clave `T-001/21` deja el token *t*; `C-123/19`, el token *c*; las citas de página `p. 45`, el token *p*) escalen

Tabla 2: Pasos del *pipeline* de limpieza aplicado a cada documento.

| # | Paso | Efecto |
|---|---|---|
| 1 | Minúsculas | *Sentencia* y *SENTENCIA* → *sentencia* |
| 2 | Protección de la *ñ* | centinela temporal antes de la descomposición NFD |
| 3 | Normalización NFD y retiro de diacríticos | *artículo* → *articulo* |
| 4 | Filtro de caracteres `[a-zñ]` | elimina dígitos, puntuación y símbolos |
| 5 | Colapso de espacios | series de espacios → un espacio |
| 6 | Tokenización por separación en espacios | token exacto = palabra alfabética |
| 7 | Filtro de ruido | descarta *t*, *c*, *p* (restos de claves y citas de página) y la abreviatura *art* |
| 8 | Palabras vacías normalizadas | 306 formas, con la misma normalización del corpus |

en los conteos de frecuencia, y elimina la abreviatura de cita *art*. Adicionalmente, para las visualizaciones de contenido temático se retiraron 65 formas de vocabulario jurídico-procesal propio del género (*sentencia(s)*, *corte*, *derecho(s)*, *tutela(s)*, *ley(es)*, *magistrado(s)*, *ponente*, entre otras); la literatura sobre corpus judiciales en español justifica complementar las palabras vacías gramaticales con este vocabulario de género [Barbosa Becerra, 2021, González-González et al., 2023].

## 3.3. Conjunto de datos medido

El conjunto de datos medido es el entregable principal del requisito 3 del enunciado. Se adjunta a este informe como un archivo columnar legible que reúne las 23.742 sentencias con su texto original, su texto limpio y las métricas calculadas por documento. La tabla 3 presenta el diccionario de datos del esquema. Lo acompañan una muestra estratificada en formato tabular para inspección rápida —100 filas por tipo y década, con semilla fija 42 para que la selección sea reproducible, que añade las columnas `decada` y `texto_limpio_preview`— y el diccionario de datos de la entrega (14 variables: las 12 del conjunto medido más las 2 de la muestra); además, se incluye una copia de los contadores de lemas por documento para reproducibilidad del análisis morfológico.

Tabla 3: Diccionario de datos del conjunto medido (23.742 filas).

| Columna | Tipo | Descripción |
|---|---|---|
| `id`, `tipo`, `numero`, `ano` | — | identificación del documento: clave estable, tipo de providencia (T, C, SU), número y año de emisión (1992–2021) |
| `texto`, `texto_limpio` | cadena | texto crudo completo (promedio ≈ 11.000 palabras) y texto normalizado (minúsculas, sin diacríticos, solo letras y espacios; tokens de ruido filtrados) |
| `n_chars_texto`, `n_palabras_raw` | entero | caracteres del texto crudo y palabras por separación de espacios (incluye números y claves) |
| `n_palabras_clean`, `n_stopwords` | entero | tokens alfabéticos tras la limpieza y el filtro de ruido, y cuántos son palabras vacías gramaticales (306 formas normalizadas) |
| `n_lemas` | entero | lemas por documento (spaCy) |
| `mtld` | real | diversidad léxica MTLD del documento (umbral 0,72) |

La construcción del conjunto se validó con aserciones duras contra las cifras canónicas del corpus: 23.742 filas, 23.742 identificadores únicos y sin valores nulos en las claves (`id`, `tipo`, `numero`, `ano`) ni en `n_lemas`/`mtld`; las sumas quedan reconciliadas con las medidas globales de la sección 3.4 (palabras

crudas 260.988.316, palabras limpias 250.012.101, palabras vacías 121.205.437 y 248.533.344 lemas totales), y el texto crudo suma 1.640.749.780 caracteres. El conjunto medido ocupa 1.544,7 MB. La muestra estratificada quedó conformada por 100 documentos (72 T, 24 C y 4 SU) distribuidos por tipo y década, y el diccionario de datos documenta cada variable con su tipo, descripción, ejemplo real y fuente.

## 3.4. Medidas globales

La tabla 4 resume las medidas textuales del corpus, todas por conteo real sobre las 23.742 sentencias (no por extrapolación de muestras). Tras la limpieza, los tokens alfabéticos ascienden a 250.012.101; al remover las palabras funcionales quedan 128.806.664 tokens, de modo que las palabras vacías representan el 48,48 % del corpus limpio. El vocabulario de formas del análisis morfológico es de 224.468 tipos, que se reducen a 195.959 lemas (87,3 %) y a 121.696 *stems* (54,2 %) (sección 4.3).

Tabla 4: Medidas globales del corpus de análisis (23.742 sentencias, 1992–2021).

| **Medida** | **Valor** |
|---|---|
| Documentos | 23.742 |
| Palabras crudas (*raw*) | 260.988.316 |
| Palabras normalizadas (limpias) | 250.012.101 |
| Palabras vacías (*stopwords*) | 121.205.437 (48,48 % de las limpias) |
| Palabras sin palabras vacías | 128.806.664 |
| Promedio por documento (palabras crudas / limpias) | 10.992,68 / 10.530,37 |
| Mediana por documento (lemas / palabras limpias) | 7.116 (p25: 3.959; p75: 12.654) / 7.158 |
| Vocabulario de formas (EDA morfológico) | 224.468 tipos |
| Lemas / *stems* (EDA morfológico) | 195.959 / 121.696 tipos |

El top-20 de palabras más frecuentes, con y sin palabras vacías, resume el perfil léxico del corpus (figuras 1 y 2). Con palabras vacías, el top-5 lo encabezan *de* (22.543.375), *la* (14.299.738), *el* (8.225.551), *que* (7.505.218) y *en* (7.208.184); la caída brusca de las frecuencias es consistente con la ley de Zipf y con el peso de las palabras funcionales. Sin palabras vacías emerge el léxico jurídico dominante: *articulo* (947.616), *derecho* (898.926), *ley* (809.313), *corte* (760.197), *sentencia* (736.326), *derechos* (718.194), *constitucional* (689.709) y *tutela* (649.302); las grafías sin tilde son efecto de la normalización descrita en la sección 3. La distribución temporal es relativamente estable entre 1999 y 2014, con un rango de 941 (2013) a 992 (2002) providencias anuales, desciende progresivamente entre 2015 y 2020 y colapsa en 2021 (20 documentos), evidencia de la cobertura parcial de ese año.

La longitud de los documentos merece una lectura propia, porque condiciona la interpretación de los conteos globales y la comparabilidad entre documentos. La figura 3 presenta ese perfil sobre las palabras limpias. El histograma (izquierda) muestra una distribución de cola larga y asimetría positiva: la mediana es de 7.158 palabras, muy por debajo de la media (10.530,37), y el extremo superior alcanza 451.252 palabras. El diagrama de caja por tipo (derecha) añade una diferencia sistemática: las tutelas son las más cortas (mediana 6.329), las sentencias de constitucionalidad ocupan una posición intermedia (9.830) y las de unificación son las más extensas (21.626), más del triple que las tutelas. El corpus combina, así, una mayoría de documentos de tamaño moderado con una minoría de documentos excepcionalmente largos y con brechas de longitud entre tipos; por eso las comparaciones por tipo y por periodo se apoyan en estadísticas por documento y no solo en las sumas globales.

La composición por tipo de providencia completa el retrato del corpus. La figura 4 recapitula los totales —tutelas 17.099 (72,0 %), constitucionalidad 6.246 (26,3 %) y unificación 397 (1,7 %)— y añade su evolución anual apilada entre 1992 y 2021: las tutelas dominan todos los años del periodo, mientras que las C y las SU aportan una fracción minoritaria y relativamente estable, y el bloque de 2021 aparece truncado por corresponder a un año parcial (20 documentos). Este desbalance condiciona la lectura de los n-gramas más frecuentes (sección 4.1) y es el punto de partida de las particiones estratificadas y de

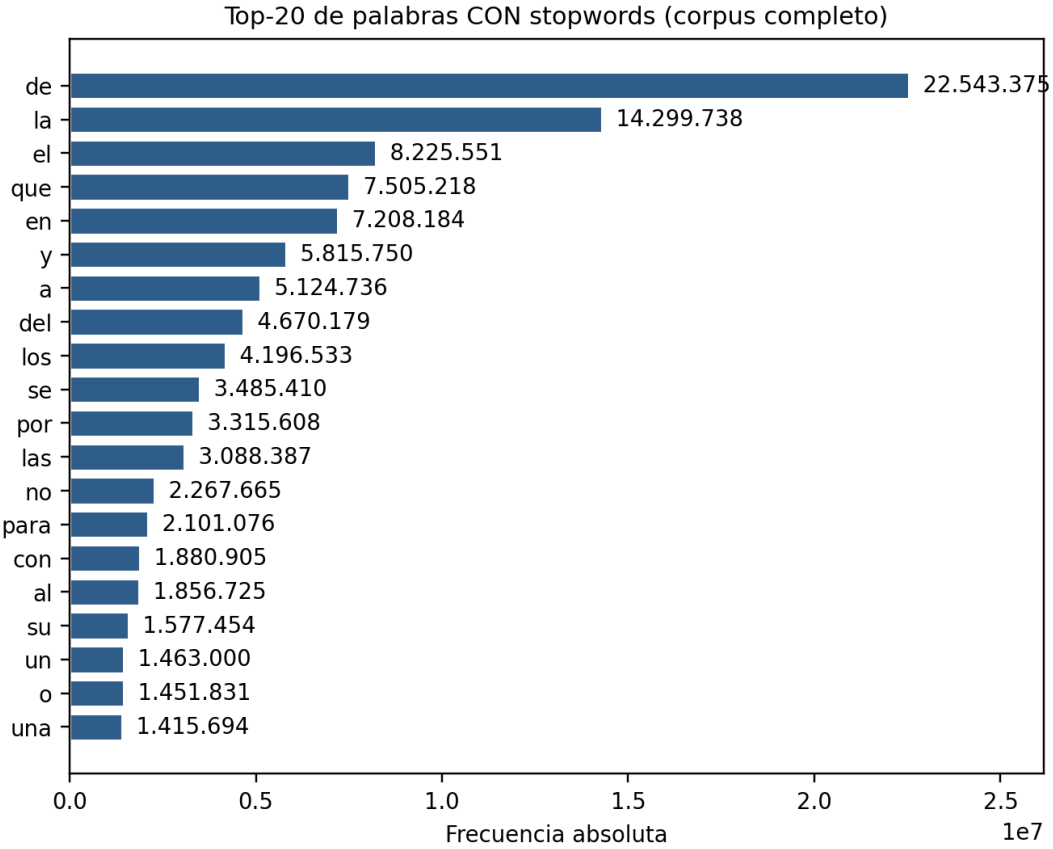



Figura 1: Top-20 de palabras más frecuentes del corpus completo (23.742 sentencias), con palabras vacías gramaticales.

las métricas macro de la propuesta metodológica (sección 6).

# 4. Análisis exploratorio avanzado

Esta sección desarrolla el requisito 2 del enunciado: los análisis se ejecutaron sobre el corpus completo y cada cifra reportada es trazable a su fuente reproducible.

## 4.1. N-gramas y colocaciones

El análisis de n-gramas se ejecutó en una pasada por *streaming* sobre el texto limpio de los 23.742 documentos, con dos reglas de filtrado que buscan retener contenido jurídico y descartar combinaciones de palabras funcionales: los bigramas se conservan solo si ambos extremos son palabras de contenido (sin palabras vacías); los trigramas se conservan con el mismo criterio y se marcan como fórmula (`es_formula`) cuando la palabra intermedia es vacía, patrón típico de las fórmulas jurídicas del tipo *accion de tutela* o *proyecto de ley*. Se guardaron los 20.000 n-gramas más frecuentes de cada orden con poda periódica de hápax: la poda acota el uso de memoria durante la pasada y no altera los conteos altos, que quedan exactos. De los 20.000 trigramas guardados, 16.543 (82,7 %) presentan la palabra intermedia vacía, lo que confirma el carácter formulaico del género.

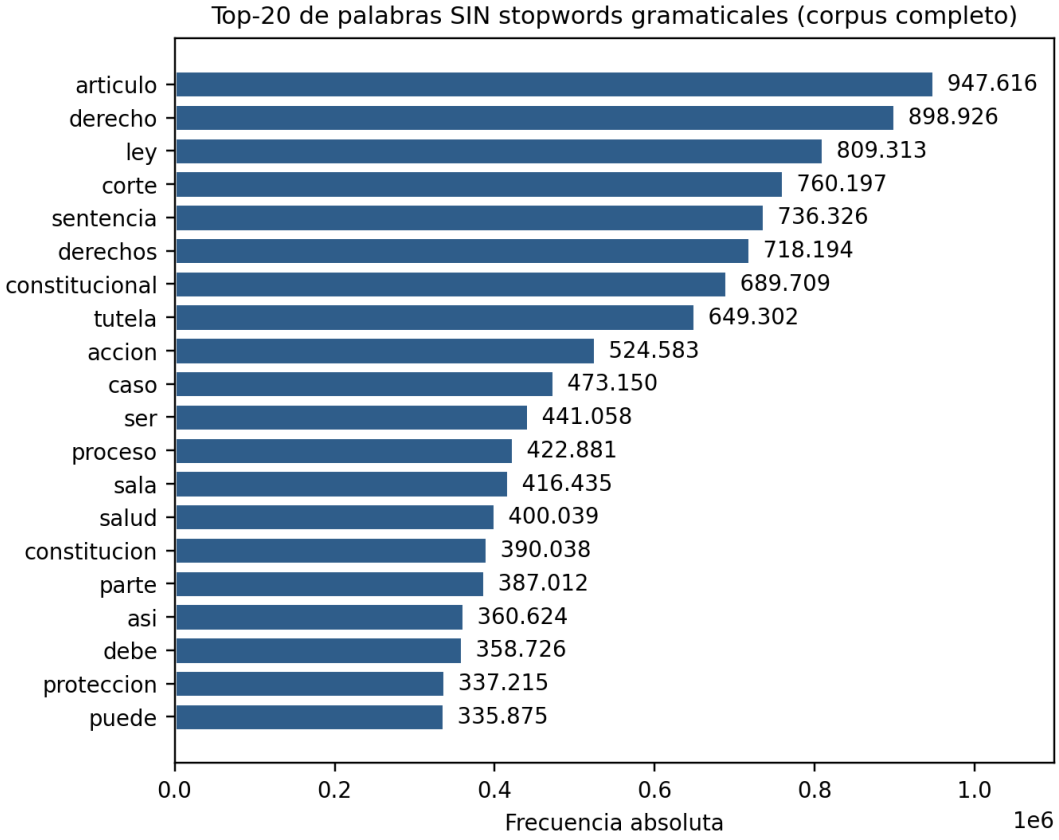



Figura 2: Top-20 de palabras más frecuentes del corpus, sin palabras vacías gramaticales.

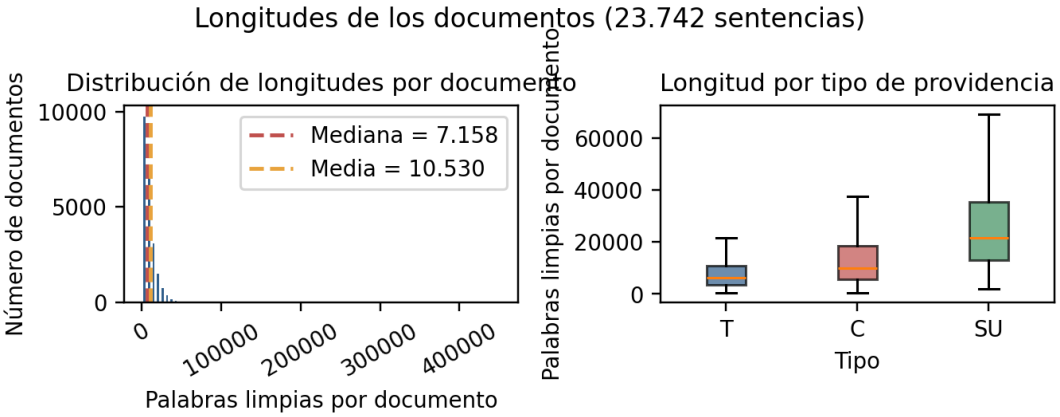



Figura 3: Perfil de longitudes de los documentos (palabras limpias): distribución global con mediana y media (izquierda) y caja por tipo de providencia, sin valores atípicos (derecha).

La tabla 5 muestra los diez bigramas y trigramas más frecuentes: los bigramas combinan conceptos doctrinales (derechos fundamentales, seguridad social, debido proceso) con sintagmas procesales (corte constitucional, primera instancia), y los trigramas están dominados por el mecanismo de amparo: *accion de tutela* (344.893) supera en frecuencia a cualquier otro n-grama de contenido del corpus, lo que refleja que las tutelas representan el 72,02 % de los documentos. Aparecen también fórmulas de cita normativa

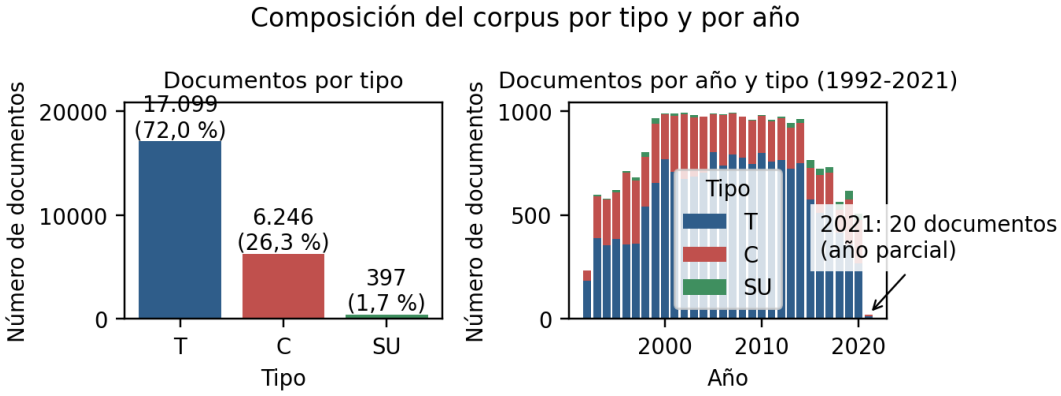



Figura 4: Composición del corpus por tipo de providencia: totales y porcentajes (izquierda) y evolución anual apilada 1992–2021 (derecha); el bloque de 2021 corresponde a un año parcial (20 documentos).

(*articulo del decreto*, 89.352), institucionales (*suprema de justicia*, 50.638) y nombres de magistrados citados con insistencia (*manuel jose cepeda*, 33.071), que la validación manual clasificó como entidades y no como fórmulas temáticas.

La distribución de frecuencias que sostiene estas listas sigue de cerca la ley de Zipf: sobre los 20.000 unigramas más frecuentes, la relación rango–frecuencia en escala logarítmica es prácticamente lineal (pendiente $-1{,}4676$; $R^2 = 0{,}9717$), y los cinco términos de mayor rango son *de*, *la*, *el*, *que* y *en*. Unas pocas formas concentran la masa de ocurrencias y el resto decae de manera regular, lo que respalda las decisiones de vocabulario de la representación final —frecuencia documental mínima de 3, recorte a 100.000 rasgos y ponderación sublineal— documentadas en la sección 5.5.

El espectro de frecuencias completa esta lectura de la cola. Sobre los 128.806.664 tokens de contenido (sin palabras vacías), el vocabulario alcanza 224.202 tipos, de los cuales 74.069 (33,0 %) son hápax —formas que aparecen una sola vez—; en el extremo opuesto, el 4,4 % de los tipos (los que superan las 1.000 ocurrencias) concentra el 93,5 % de los tokens (figura 7). La consecuencia para la representación es directa: como un tercio del vocabulario aporta apenas una fracción marginal de la masa, los filtros por frecuencia (`min_df`) y el recorte del vocabulario eliminan ruido con una pérdida despreciable, mientras que la cabeza de la distribución exige las ponderaciones atenuadas (sublineales) adoptadas en la sección 5.5.

Tabla 5: Diez bigramas y diez trigramas más frecuentes del corpus (texto limpio; bigramas con extremos de contenido).

| **Bigramas** | | **Trigramas** | |
|---|---|---|---|
| **n-grama** | **frec.** | **n-grama** | **frec.** |
| corte constitucional | 286.786 | accion de tutela | 344.893 |
| derechos fundamentales | 241.467 | articulo del decreto | 89.352 |
| seguridad social | 131.119 | suprema de justicia | 50.638 |
| derecho fundamental | 111.146 | proyecto de ley | 43.384 |
| constitucion politica | 109.220 | juez de tutela | 42.253 |
| debido proceso | 105.395 | corte constitucional sentencia | 38.645 |
| primera instancia | 65.203 | articulo del codigo | 38.620 |
| minimo vital | 63.487 | administracion de justicia | 36.178 |
| caso concreto | 63.089 | derecho de peticion | 34.429 |
| debe ser | 62.378 | manuel jose cepeda | 33.071 |

Para decidir qué medida de asociación usar en las fases posteriores, se compararon tres criterios de ordenamiento de colocaciones —frecuencia cruda, información mutua puntual (PMI) y razón de verosimilitud (LLR)— sobre 20 casos evaluados manualmente (10 bigramas y 10 trigramas). La tabla 6 resume el veredicto: la frecuencia cruda alcanza un 55 % de fórmulas válidas, el PMI un 0 % y la LLR un 75 %. El PMI, al favorecer asociaciones raras de bajo soporte, ordena fragmentos ruidosos y no españoles (por ejemplo, *aquaria eaza*, *capromyidae capromys* o cadenas de caracteres), mientras que la frecuencia cruda rescata plantillas institucionales y nombres propios frecuentes pero arrastra combinaciones genéricas (*debe ser*, *primera instancia*). La razón de verosimilitud, en cambio, equilibra frecuencia y asociación y concentra fórmulas de dominio [Dunning, 1993]; por ello se adopta como medida principal para las fases de modelado y recuperación. El top-15 de bi y trigramas (figura 5) y el top-10 de colocaciones por LLR (figura 6) destacan *derechos fundamentales* y *corte constitucional* en bigramas y *accion de tutela* en trigramas.

Tabla 6: Validación manual de 20 colocaciones (10 bigramas y 10 trigramas): porcentaje de fórmulas jurídicas válidas por medida.

| Medida | Bigramas | Trigramas | Promedio |
|---|---|---|---|
| Frecuencia | 55 % | 55 % | 55 % |
| PMI | 0 % | 0 % | 0 % |
| Razón de verosimilitud (LLR) | 50 % | 100 % | 75 % |

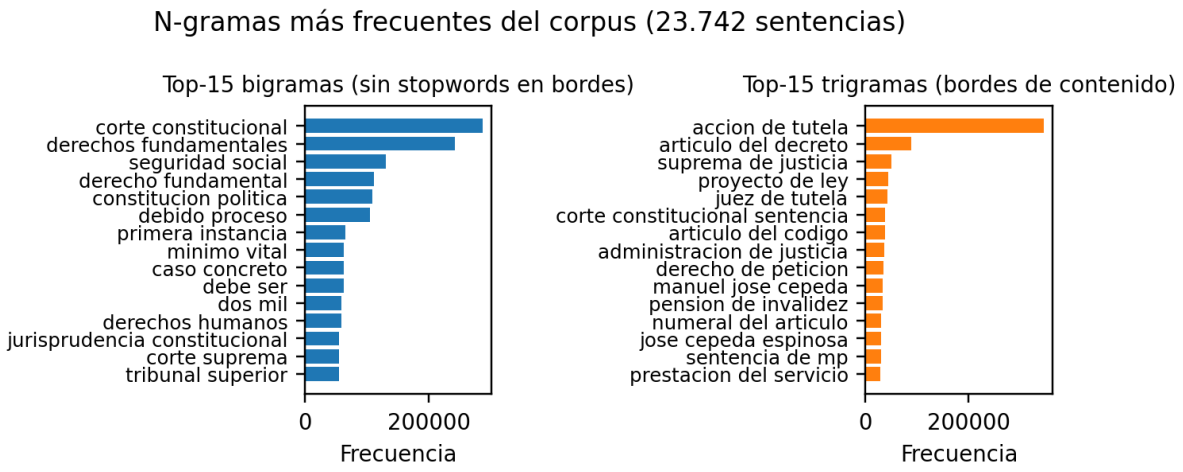



Figura 5: Top-15 de bigramas (con extremos de contenido) y de trigramas más frecuentes del corpus.

## 4.2. Diversidad léxica: MTLD

La diversidad léxica se midió con MTLD (*Measure of Textual Lexical Diversity*), una medida robusta frente a la longitud del texto a diferencia del TTR crudo [McCarthy and Jarvis, 2010]. El algoritmo recorre el documento acumulando TTR y cuenta un factor cada vez que el TTR cae al umbral de 0,72; la MTLD final es la media bidireccional de tokens por factor, calculada por documento sobre los tokens alfabéticos. La MTLD media global es de 61,03 (mediana 60,69; mínimo 25,80; máximo 114,12) y la tabla 7 la desglosa por tipo de providencia y por periodo.

Tres lecturas se desprenden de la tabla. Primero, las tutelas son más diversas léxicamente (61,63) que las sentencias de constitucionalidad (59,54) y de unificación (58,88); una explicación plausible es que las tutelas narran casos individuales heterogéneos, mientras que las C y SU se apoyan más en plantillas doctrinales. Segundo, la diversidad desciende de forma sostenida a lo largo de las tres décadas: de 64,32 en

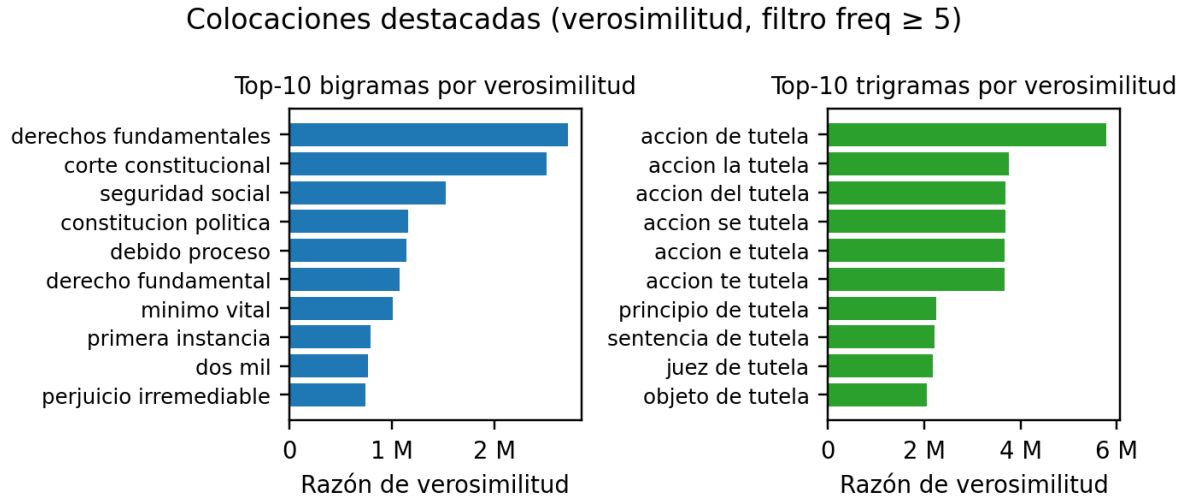



Figura 6: Colocaciones destacadas por razón de verosimilitud (filtro de frecuencia $\geq 5$): top-10 de bigramas y de trigramas.

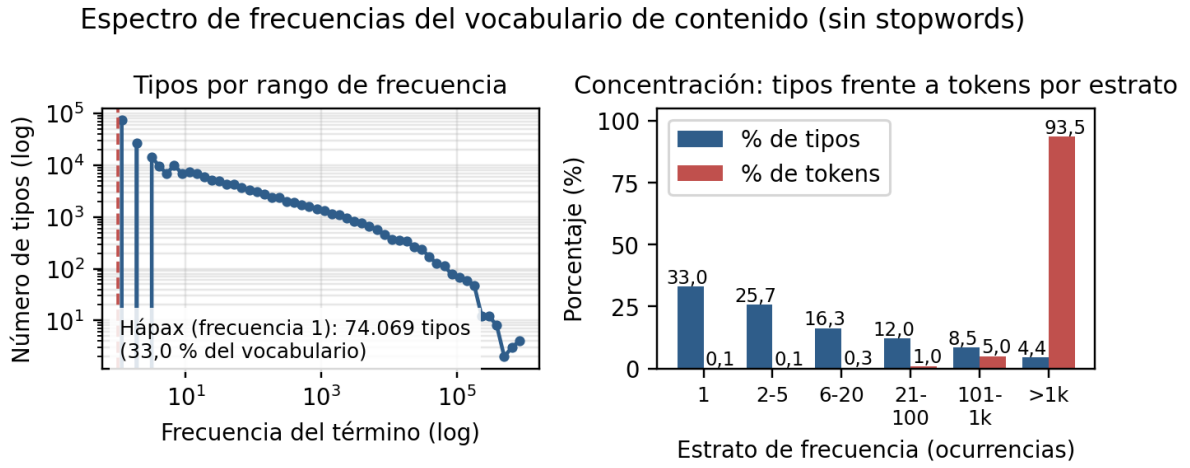



Figura 7: Espectro de frecuencias del vocabulario de contenido (128.806.664 tokens sin palabras vacías): tipos por rango de frecuencia (izquierda, log-log; los hápax están marcados) y concentración de tokens por estrato de frecuencia (derecha).

Tabla 7: MTLD por tipo de providencia y por periodo (umbral 0,72).

| Grupo | Media | Mediana | Documentos |
|---|---|---|---|
| Global | 61,03 | 60,69 | 23.742 |
| T (tutela) | 61,63 | 61,21 | 17.099 |
| C (constitucionalidad) | 59,54 | 59,43 | 6.246 |
| SU (unificación) | 58,88 | 58,72 | 397 |
| 1992–2001 | 64,32 | 64,09 | 7.166 |
| 2002–2011 | 60,37 | 60,19 | 9.779 |
| 2012–2021 | 58,53 | 58,32 | 6.797 |

1992–2001 a 58,53 en 2012–2021. La regresión lineal sobre los 23.742 documentos estima una pendiente de $-0,32$ puntos de MTLD por año (correlación de Pearson $r = -0,328$, $p < 0,001$; Spearman $\rho = -0,330$), con medias anuales que bajan de $\approx$ 65,0 (1992–1998) a 55,69 (2020). Tercero, el patrón es consistente en los tres tipos de providencia, lo que sugiere un fenómeno de estandarización del estilo de redacción de la Corte más que un efecto de composición entre tipos. La figura 8 ilustra ambas dimensiones. Estas tendencias son descriptivas: la sección 4.4 las complementa con el contraste léxico por periodos.

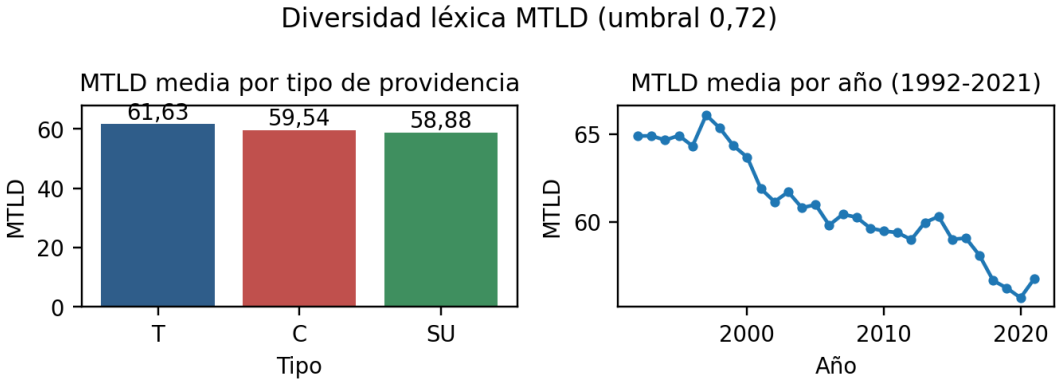



Figura 8: Diversidad léxica MTLD: media por tipo de providencia (izquierda) y evolución de la media anual, 1992–2021 (derecha).

Una propiedad crítica de las medidas de diversidad es su estabilidad frente a la longitud del texto. La figura 9 verifica esa propiedad sobre los 23.742 documentos: el mapa de densidad (*hexbin*) muestra la nube de documentos con el eje de tokens en escala logarítmica (rango observado: 314–449.822 tokens) y la línea roja resume la mediana de MTLD por intervalo logarítmico de longitud. La asociación entre MTLD y longitud, medida con la correlación de Spearman, es débil y negativa ($\rho = -0,2628$): el tamaño del documento no domina la diversidad calculada, lo que respalda el uso de MTLD para comparar documentos de tamaños muy dispares (figura 3) y sostiene las lecturas por tipo y por periodo de la tabla 7.

## 4.3. Morfología: lemas, *stems* y categorías gramaticales

La pasada morfológica se ejecutó sobre los 23.742 documentos con el modelo de spaCy para español `es_core_news_md` ($\approx$ 87 minutos), junto con una pasada adicional de *stemming* Snowball en español ($\approx$ 20 minutos), de modo que ambas reducciones pudieran compararse como candidatas para la representación. La tabla 8 resume el efecto de cada representación sobre el vocabulario. La lematización reduce el vocabulario de formas en un 12,7 % (de 224.468 a 195.959 tipos) y agrupa flexiones que la forma superficial separa (*derechos* $\rightarrow$ *derecho*); el *stemming* lo reduce un 45,8 % (121.696 tipos), a costa de formas menos legibles (*derecho* $\rightarrow$ *derech*) que pueden fusionar términos distintos. La muestra de calidad de la pasada (lema y *stem* de los tokens más frecuentes) se conserva como parte del material de análisis, de modo que la reducción morfológica pueda auditarse.

Tabla 8: Tamaño del vocabulario según la representación morfológica (23.742 documentos).

| Representación | Vocabulario | % del vocabulario de formas | Ejemplo |
|---|---|---|---|
| Formas (tokens) | 224.468 | 100 % | *derechos* |
| Lemas | 195.959 | 87,3 % | *derecho* |
| *Stems* | 121.696 | 54,2 % | *derech* |

La distribución de categorías gramaticales (POS) es estable y coherente con el registro jurídico: NOUN

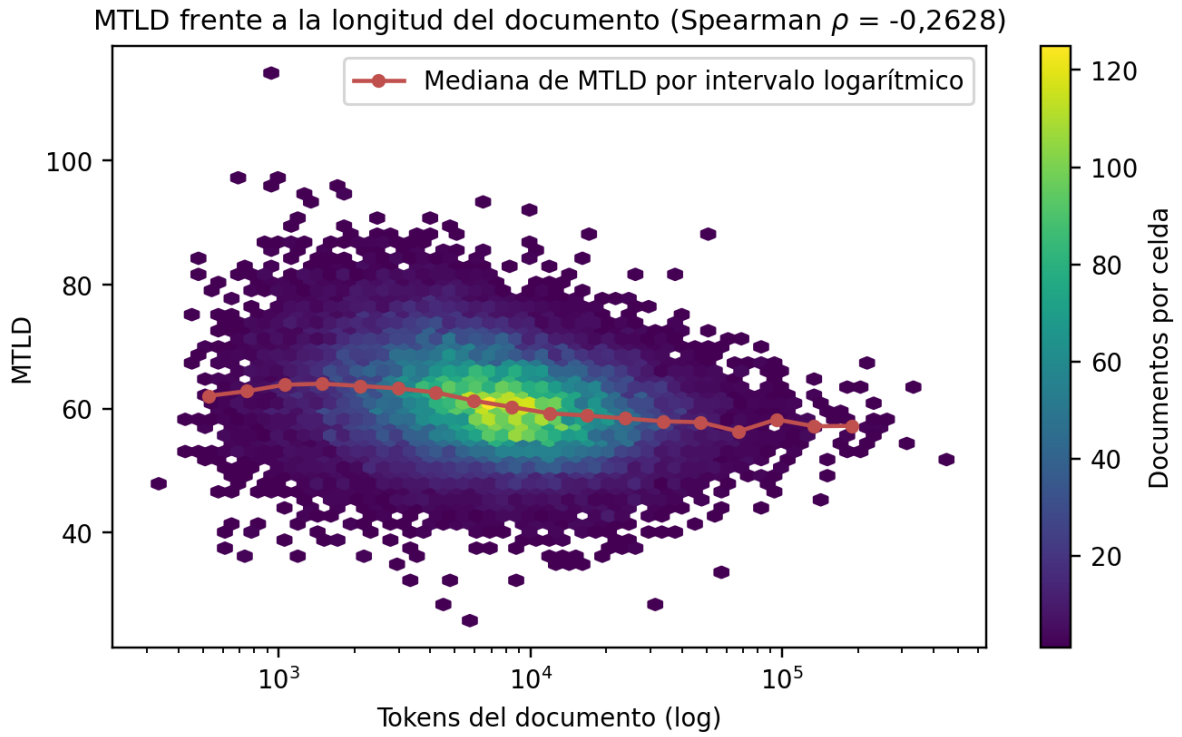
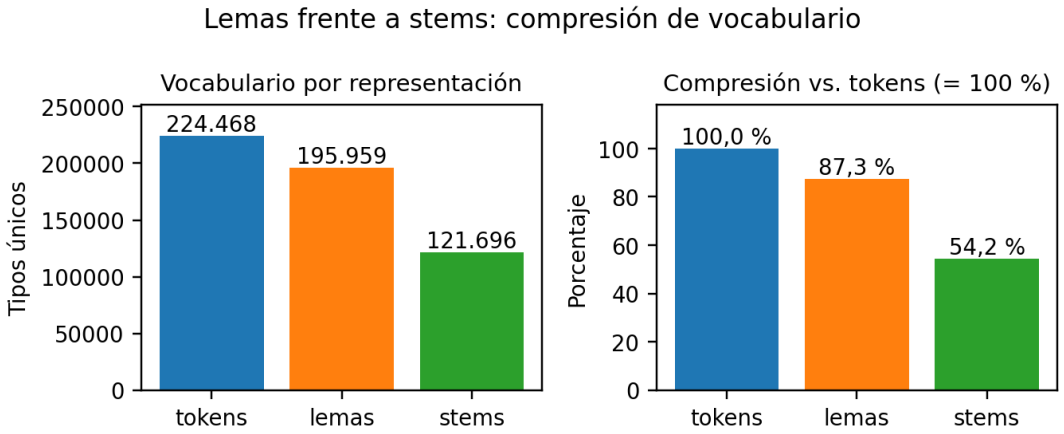
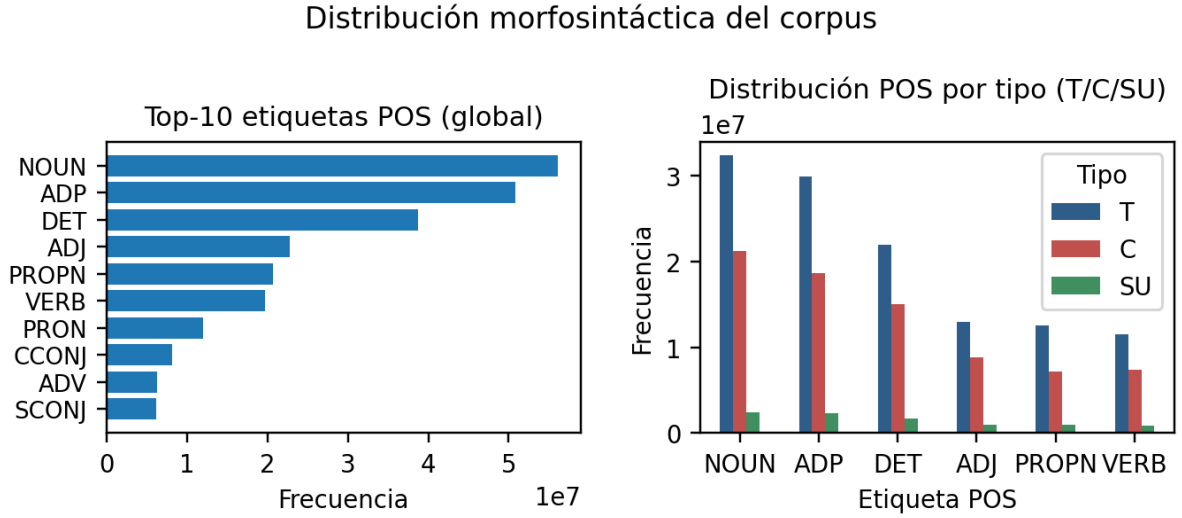



Figura 9: MTLD frente a la longitud del documento: densidad de los 23.742 documentos (*hexbin*, tokens en escala logarítmica) y mediana de MTLD por intervalo logarítmico; Spearman $\rho = -0,2628$.

(22,58 %), ADP (20,45 %), DET (15,57 %), ADJ (9,15 %), PROPN (8,32 %) y VERB (7,94 %) encabezan el conteo global. Por tipo de providencia las diferencias son de pocas décimas: las C presentan algo más de adjetivos (9,47 % frente a 8,96 % en T) y algo menos de nombres propios (7,67 % frente a 8,70 % en T), consistente con un discurso más doctrinal y menos narrativo; las T y SU son casi idénticas entre sí. Las figuras 10a y 10b ilustran la compresión de vocabulario y la distribución POS global y por tipo. En términos de representación, el resultado relevante es que la lematización ofrece una reducción de vocabulario apreciable manteniendo la legibilidad y la interpretabilidad de los rasgos, condición útil para una representación basada en pesos de términos (sección 5.5).




(a) Tamaño del vocabulario por representación (formas, lemas y *stems*).




(b) Distribución de categorías gramaticales (POS) global (top-10) y por tipo de providencia.

Figura 10: Evidencia morfológica: compresión del vocabulario por representación (arriba) y distribución POS global y por tipo de providencia (abajo).

## 4.4. Evolución léxica por periodos

La Entrega 1 prometió el análisis cuantitativo de la evolución léxica por periodos; esta subsección lo ejecuta y reporta. Se definen tres periodos de extensión comparable: 1992–2001 (7.166 documentos; 19.950.956

tokens-lema sin palabras vacías), 2002–2011 (9.779; 48.671.763) y 2012–2021 (6.797; 62.545.530; el año 2021 es parcial, con 20 documentos). El conteo se hizo sobre los lemas normalizados por documento (sección 3.3), sin palabras vacías, y cubrió 192.277 formas únicas en $\approx 40$ segundos. Para cada transición se ordenan los lemas por su razón de *log-odds* binaria con suavizado add-0,5 [Hamilton et al., 2016]: para un lema $w$ y los periodos base $b$ y objetivo $t$,

$$\delta_w = \log\left(\frac{f_w^t + 0,5}{N_t - f_w^t + 0,5}\right) - \log\left(\frac{f_w^b + 0,5}{N_b - f_w^b + 0,5}\right), \tag{1}$$

donde $f_w^b$ y $f_w^t$ son las frecuencias del lema en cada periodo y $N_b$ y $N_t$ los totales de tokens-lema. El suavizado add-0,5 evita valores extremos cuando un lema no aparece en un periodo y estabiliza las estimaciones con conteos bajos, mientras que la frecuencia mínima de 50 sobre la frecuencia combinada descarta lemas esporádicos, cuyo cambio relativo sería esencialmente ruido; ambos parámetros replican la configuración del módulo de diacronía del proyecto, lo que permite contrastar los resultados con la referencia interna. El signo es relativo: un lema que "baja" puede seguir siendo frecuente; lo que cambia es su peso relativo en el vocabulario del periodo. Este contraste es una práctica establecida para identificar el léxico distintivo entre subcorpus, incluido el análisis diacrónico de tribunales [Raj et al., 2026]. La tabla 9 muestra los cinco lemas que más suben y más bajan en cada transición y la figura 11 ilustra la segunda; la tabla completa (42.362 filas) queda disponible en el material de análisis de la entrega.

Tabla 9: Cinco lemas con mayor cambio relativo entre periodos (log-odds con suavizado add-0,5; frecuencia combinada $\geq 50$) en cada transición: 1992–2001 $\rightarrow$ 2002–2011 y 2002–2011 $\rightarrow$ 2012–2021. Valores redondeados a una décima.

| # | **Sube (1.ª)** | **Baja (1.ª)** | **Sube (2.ª)** | **Baja (2.ª)** |
|---|---|---|---|---|
| 1 | incoder (7,1) | juzg (−8,5) | uariv (9,2) | nilser (−6,5) |
| 2 | rupd (6,9) | trasladante (−6,7) | jep (9,0) | fomin (−6,2) |
| 3 | chaljub (6,7) | sgpc (−6,3) | coronavirus (9,0) | superview (−6,0) |
| 4 | fonvivienda (6,6) | indalpe (−6,2) | gnr (8,1) | sarai (−6,0) |
| 5 | cisa (6,4) | dcho (−6,2) | arl (7,9) | guingue (−5,9) |

**Lectura.** En la primera transición (1992–2001 $\rightarrow$ 2002–2011) ganan peso siglas y nombres de entidades que reflejan nuevas materias y actores del periodo (*incoder*, *rupd*, *fonvivienda*, *cisa*) y retroceden formas procesales y ruido de digitalización (*juzg*, *sgpc*, *dcho*). En la segunda (2002–2011 $\rightarrow$ 2012–2021) el ascenso es nítidamente temático: *uariv* (Unidad para las Víctimas), *jep*, *coronavirus*, *arl* y *zidres*, vocabulario asociado al conflicto armado, la pandemia y la institucionalidad reciente, mientras descienden nombres propios y abreviaturas del periodo anterior (*nilser*, *fomin*, *superview*). Los resultados se interpretan como indicios temáticos (nuevas materias y cambios de lenguaje procesal), no como afirmaciones causales.

**Limitación (datos conservados, no ocultos).** Los extremos de las listas incluyen siglas institucionales sin desarrollar, nombres propios y ruido de OCR/abreviaturas del corpus; el método replica la referencia interna del proyecto (mismos periodos, mismo suavizado y misma frecuencia mínima) y el solapamiento del top-10 con esa referencia es de 7/10 a 9/10 en las cuatro listas, con diferencias que provienen de la unidad de análisis (aquí lemas; en la referencia, formas superficiales) y de empates en el corte del top-10. La depuración de siglas y ruido de OCR, y la unificación de variantes, queda documentada como refinamiento para la fase de modelado y no se aplica aquí para no alterar el resultado reproducible del método estándar.

Otra dimensión de la evolución léxica es el tamaño del vocabulario de cada año. La figura 12 presenta los tipos únicos por año (izquierda) y la serie normalizada por 100.000 tokens (derecha): el conteo bruto crece con el volumen documental hasta un máximo de 69.822 tipos en 2017, mientras que la serie normalizada desciende desde 3.583 tipos por 100.000 tokens en 1992 hasta valores cercanos a 900–1.000 en la última década (mínimo de 901 en 2016), en línea con la estandarización del estilo que documenta la MTLD (sección 4.2). El año 2021 (17.287 tipos) corresponde a un año parcial con 20 documentos y no es comparable con el resto de la serie.

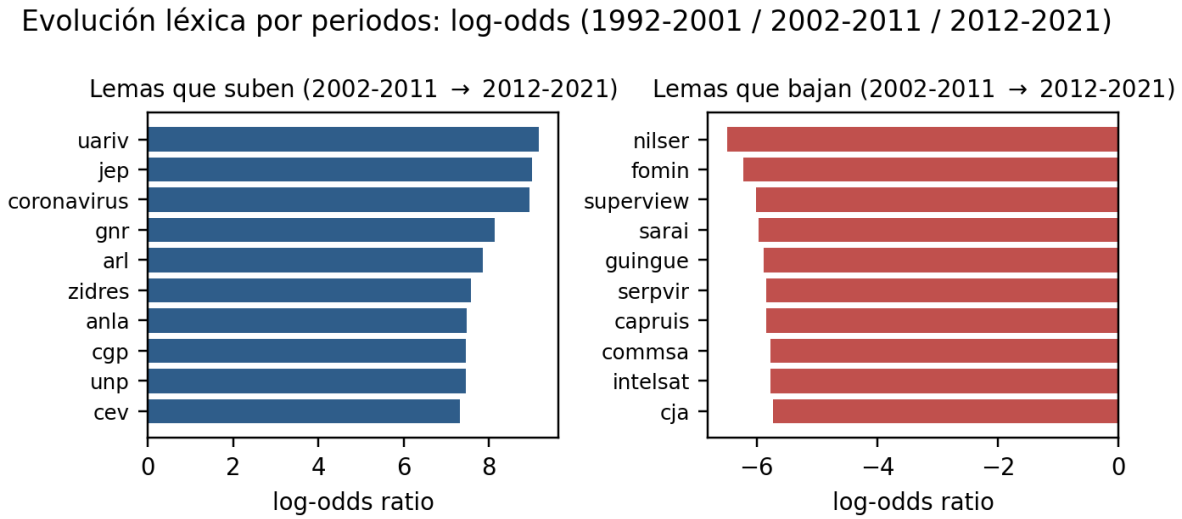



Figura 11: Evolución léxica por periodos: diez lemas con mayor log-odds positivo (izquierda) y negativo (derecha) en la transición 2002–2011 → 2012–2021.

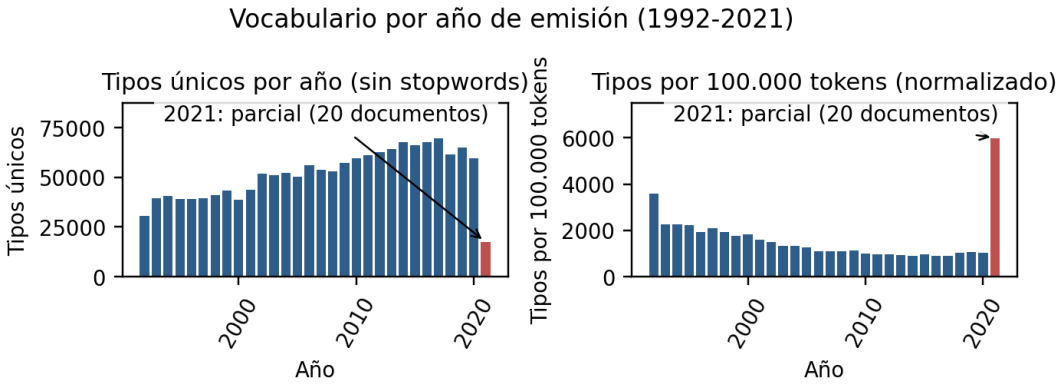



Figura 12: Vocabulario por año: tipos únicos (izquierda) y tipos por 100.000 tokens (derecha); el año 2021 corresponde a un año parcial (20 documentos) y no es comparable.

Como complemento cualitativo, la figura 13 conserva las nubes anuales de la Entrega 1 (tres paneles), que muestran la estabilidad de las fórmulas institucionales y la aparición de vocabulario temático propio de cada época; la serie de MTLD (sección 4.2) aporta la tendencia cuantitativa global.




(a) 1992–2001.




(b) 2002–2011.




(c) 2012–2020.

Figura 13: Nubes de palabras por año (sin palabras vacías gramaticales ni de dominio jurídico), en tres paneles.

## 4.5. Recursos léxicos y ontologías

El enunciado pide integrar, según el caso, ontologías, tesauros u otros recursos léxicos. Se evaluaron cuatro candidatas internacionales. (i) **EuroVoc / MultiEURLEX**: tesauro multilingüe con versión en español, usado en el corpus de 65.000 leyes de la Unión Europea [Chalkidis et al., 2021]; su aplicabilidad es parcial, porque cubre derecho de la Unión Europea y sus descriptores no mapean la Constitución de 1991 ni el amparo de tutela. (ii) **LKIF**: ontología formal OWL de conceptos jurídicos generales (norma, rol, acción), en inglés; aplicabilidad baja, aunque sirve como patrón de modelado. (iii) **ELI / ECLI**: esquemas de identificación y metadatos; no son vocabularios temáticos, si bien inspiran identificadores estables de sentencias. (iv) **LegalRuleML / Akoma Ntoso**: lenguajes de marcado de reglas y estructura documental; aportarían interoperabilidad, pero exigen anotación manual costosa y su aplicabilidad a corto plazo es baja.

La decisión documentada es no adoptar ninguna ontología externa tal cual para el dominio colombiano. En su lugar, se deriva una taxonomía ligera de la propia Constitución Política: los títulos y capítulos funcionan como bloques temáticos y los artículos 1–380 como etiquetas finas, con un mecanismo de respaldo ("derecho a X") para las tutelas cuando la cita constitucional no está explícita. EuroVoc en español se conserva únicamente como referencia de comparación para la fase de clasificación, y LKIF se cita como patrón de modelado futuro. Esta decisión condiciona el diseño de etiquetas de la propuesta metodológica (sección 6); la literatura sobre corpus legales multilingües respalda los protocolos de validación y las particiones cronológicas por la deriva conceptual del dominio [Chalkidis et al., 2021].

## 4.6. Granularidad del análisis

Antes de fijar la unidad de análisis se evaluaron tres granularidades sobre una muestra estratificada de 600 documentos (20 por año disponible, semilla 42): sentencia completa, párrafo y subsentencia. Se definieron marcadores temáticos sobre el texto crudo: citas a la CP (patrón *artículo N ... Constitución*, con y sin tildes) más un respaldo de "derecho a X". El criterio se pre-registró antes de observar los resultados: la subsentencia solo se propondría como unidad si superaba en al menos 15 puntos porcentuales el porcentaje de unidades con marcador de la sentencia completa.

Los resultados del experimento son nítidos (figura 14): la sentencia completa contiene al menos un marcador en el 97,17 % de los casos (media de 20,03 marcadores por documento); la segmentación por párrafos no fragmentó los documentos —el corpus usa saltos simples de línea, de modo que cada documento produce un único fragmento—, por lo que sus métricas coinciden con las de la sentencia (fila degenerada, un hallazgo sobre el formato del corpus y no un error de cómputo). La subsentencia, en cambio, apenas alcanza un 4,64 % de unidades con marcador sobre 219.649 fragmentos. La comparación relevante (sentencia 97,17 % frente a subsentencia 4,64 %) no supera el criterio pre-registrado, de modo que se mantiene la sentencia completa como unidad de análisis. El experimento además deja ejemplos documentados de subsentencias con marcador, que muestran el tipo de fragmento que una segmentación recuperaría.

Esta validación dialoga con la literatura que muestra que distintas secciones de una sentencia tienen distinto poder informativo para el modelado [Aletras et al., 2016]: en este corpus, la señal temática disponible está distribuida a lo largo del documento completo y no concentrada en fragmentos cortos, lo que respalda tanto la unidad elegida como el uso de representaciones agregadas por documento (sección 5).

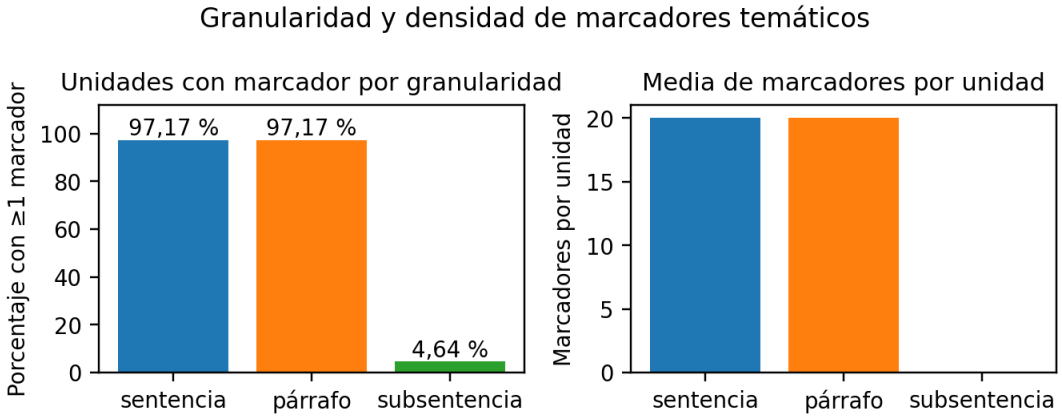



Figura 14: Granularidad y densidad de marcadores temáticos: porcentaje de unidades con marcador (izquierda) y media de marcadores por unidad (derecha).

# 5. Representación de los textos

## 5.1. Familias de representación y criterios de selección

Las familias de representación consideradas fueron cuatro: (i) bolsa de palabras (BoW), que cuenta ocurrencias de términos; (ii) TF-IDF, que pondera los términos por su frecuencia y su especificidad documental; (iii) *embeddings* estáticos (por ejemplo, vectores de palabra entrenados en un corpus), agregados a nivel de documento; y (iv) representaciones contextuales (*transformers*), que codifican cada ocurrencia con su contexto. La elección se guio por cuatro criterios derivados del contexto del proyecto.

**Longitud de los documentos.** Las sentencias promedian $\approx 11.000$ palabras (mediana de lemas: 7.116; de palabras limpias: 7.158), muy por encima de la ventana de 512 *tokens* de los *transformers* estándar; cualquier representación contextual exige segmentación con agregación o truncamiento, con la consiguiente pérdida de información, mientras que las representaciones de bolsa y TF-IDF no tienen ese límite.

**Interpretabilidad.** El proyecto busca ser una herramienta de apoyo a la consulta jurídica; los pesos de términos de TF-IDF permiten inspeccionar qué vocabulario sustenta cada categoría, mientras que las representaciones densas son opacas por construcción.

**Costo computacional.** TF-IDF sobre lemas se construye en minutos en CPU sobre los 23.742 documentos; el ajuste fino de un *transformer* requiere GPU y presupuestos de cómputo mayores.

**Respaldo en la literatura.** La bolsa de palabras y TF-IDF siguen siendo líneas base fuertes en la clasificación de sentencias largas, donde los modelos neuronales no las superan de forma automática [Soh et al., 2019]; el preprocesamiento afecta de forma dependiente del corpus el rendimiento de las representaciones de bolsa [HaCohen-Kerner et al., 2020]; y los vocabularios jurídicos difieren del general, lo que motiva la adaptación de dominio [Chalkidis et al., 2020]. En corpus legales multilingües con etiquetas temáticas, las representaciones de términos sirven además como referencia para comparar transferencia entre lenguas y deriva temporal [Chalkidis et al., 2021].

## 5.2. Bolsa de palabras y TF-IDF

La representación de bolsa de palabras describe cada documento $d$ como un vector $\mathbf{x}_d \in \mathbb{N}^{|V|}$ sobre un vocabulario $V$, donde la componente del término $t$ es el número de ocurrencias de $t$ en $d$. Su limitación principal es que ignora el orden y la composición de las palabras, pero en un género con fórmulas

estables como el judicial conserva una señal léxica potente. La ponderación TF-IDF atenúa el peso de los términos muy frecuentes en el corpus y realza los específicos de cada documento [Manning et al., 2008]. Concretamente, se emplea la variante de frecuencia sublineal, que evita que las repeticiones internas de un término dominen el peso del documento

$$\mathrm{tf}(t,d) = \begin{cases} 1 + \log \mathrm{c}(t,d), & \mathrm{c}(t,d) > 0, \\ 0, & \mathrm{c}(t,d) = 0, \end{cases} \tag{2}$$

donde $\mathrm{c}(t,d)$ es el conteo bruto del término; la frecuencia inversa de documento

$$\mathrm{idf}(t) = \log \frac{N}{\mathrm{df}(t)}, \tag{3}$$

con $N$ el número de documentos y $\mathrm{df}(t)$ el número de documentos que contienen $t$; y el peso final

$$w(t,d) = \mathrm{tf}(t,d) \cdot \mathrm{idf}(t), \tag{4}$$

seguido de una normalización $\ell_2$ del vector, $\mathbf{x}_d \leftarrow \mathbf{x}_d / \|\mathbf{x}_d\|_2$, que evita que los documentos largos dominen las comparaciones por magnitud. La extensión a n-gramas consiste en tratar cada secuencia de 1–2 términos consecutivos como una dimensión adicional del vocabulario, lo que captura fórmulas del género (*accion de tutela*, *debido proceso*) que el unigrama no distingue.

## 5.3. Ejemplos de vectorización

La representación se ajustó sobre los 23.742 documentos lematizados con la configuración de la sección 5.5 y produjo una matriz dispersa de 23.742 × 100.000 rasgos con 103.045.759 valores no nulos, es decir, una esparsidad del 95,66 %; el ajuste tardó ≈ 200 segundos en CPU. Por documento, el vector activa en promedio 4.340 rasgos (mediana 3.717,5; mínimo 378; máximo 37.320) y su norma $\ell_2$ es 1 por la normalización, lo que hace comparables documentos de longitudes muy distintas. La representación exhibe una cola larga (figura 15): ≈2 % de la masa de frecuencia documental se concentra en los 100 primeros rasgos, ≈17 % en los 1.000 y ≈60 % en los 10.000; los rasgos de mayor peso del documento T representativo se listan en la tabla 10.

Para hacer tangible la transformación texto → vector se eligieron tres documentos con un criterio estable e independiente de resultados de modelos: el identificador mínimo de cada tipo. La tabla 10 resume sus rasgos de mayor peso y sus dimensiones efectivas: T-001/2021 (id 0) activa 7.712 rasgos, C-022/2021 (id 14) 11.027 y SU-016/2021 (id 19) 15.820. Los términos principales son específicos de cada caso (*capital salud* y *salud mental* en la tutela; *cdpd* y *capacidad legal* en la de constitucionalidad; *el copey* y *desalojo* en la de unificación), coherentes con el contenido jurídico de cada providencia. La similitud coseno entre los tres vectores es baja (0,242 entre T y C; 0,253 entre T y SU; 0,251 entre C y SU): documentos de materias distintas comparten solo el vocabulario genérico del género. El contraste entre conteo bruto y TF-IDF para el documento T ilustra la ponderación sublineal: *capital salud* aparece 35 veces y recibe peso 0,065, mientras *salud mental* aparece 75 veces y recibe 0,049, porque su frecuencia inversa de documento es menor.

## 5.4. *Embeddings* y representaciones contextuales

Las representaciones densas se consideran complementarias para este proyecto. Los *embeddings* estáticos asignan a cada palabra un vector entrenado y el documento se representa agregando los vectores de sus palabras; los modelos contextuales producen representaciones dependientes del contexto, y las variantes tipo *Sentence-BERT* permiten vectores de fragmento comparables por similitud coseno con un costo de inferencia muy inferior al de comparar pares con BERT completo [Reimers and Gurevych, 2019]. Para el español existen adaptaciones del esquema BERT preentrenadas en este idioma (p. ej., BETO)

Tabla 10: Ocho rasgos de mayor peso TF-IDF para los tres documentos representativos (peso entre paréntesis, redondeado a tres decimales). Algunos rasgos son siglas o abreviaturas del corpus (p. ej., *cdpd*, *eci*), conservadas tal como aparecen en los datos.

| # | **T-001/2021 (id 0)** | **C-022/2021 (id 14)** | **SU-016/2021 (id 19)** |
|---|---|---|---|
| 1 | capital salud (0,065) | cdpd (0,050) | el copey (0,054) |
| 2 | valero (0,056) | pg (0,048) | copey (0,053) |
| 3 | de calle (0,052) | persona titular (0,048) | eci (0,041) |
| 4 | salud mental (0,049) | capacidad legal (0,047) | de desalojo (0,038) |
| 5 | folio historia (0,046) | el cdpd (0,046) | desalojo (0,036) |
| 6 | sustancia psicoactiva (0,046) | top (0,040) | albergue temporal (0,035) |
| 7 | jhon (0,046) | capacidad jurídico (0,040) | no reportar (0,034) |
| 8 | psicoactiva (0,046) | sv (0,038) | el uariv (0,034) |

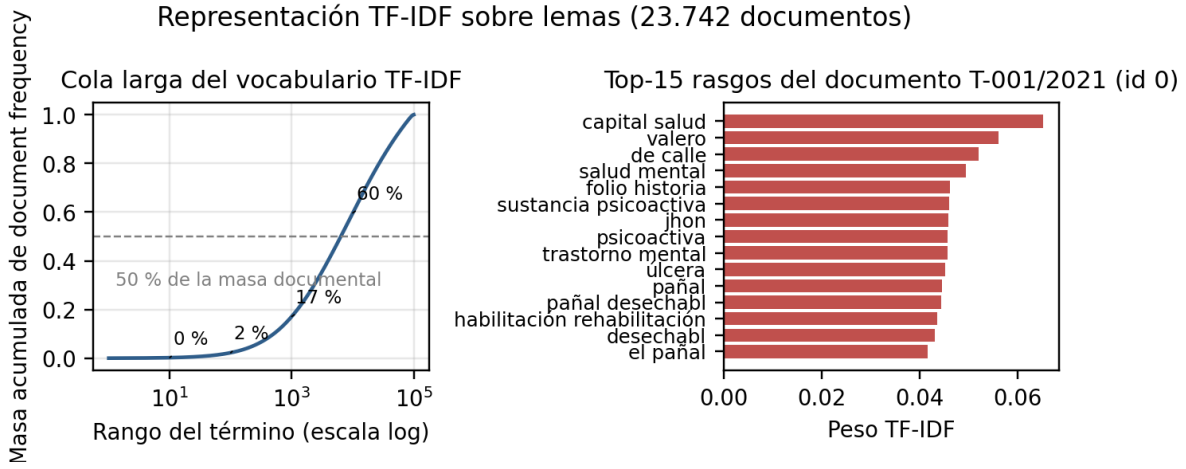



Figura 15: Representación TF-IDF sobre lemas (23.742 documentos): cola larga del vocabulario (izquierda) y top-15 rasgos del documento T-001/2021 (derecha).

y variantes de dominio legal como LEGAL-BERT, que muestran que el vocabulario jurídico difiere del general [Chalkidis et al., 2020]. Su utilidad esperada en el proyecto es doble: comparación semántica entre sentencias y apoyo a la recuperación de fragmentos relevantes. Su adopción como representación principal choca, sin embargo, con la longitud de los documentos ($\approx$ 11.000 palabras frente a ventanas de 512 *tokens*), la opacidad de los vectores y el costo de cómputo; por eso se reservan para experimentos comparativos de la fase de modelado.

La magnitud de esa restricción se cuantifica en la figura 16: el 99,95 % de los 23.742 documentos supera la ventana de 512 *tokens* (T 99,94 %, C 99,95 %, SU 100 %), incluso tomando las palabras limpias como cota inferior de los *tokens* subword (figura 3). La ventana no es, por tanto, una limitación de cola: prácticamente ningún documento cabe completo, de modo que cualquier modelo contextual exige segmentar y agregar fragmentos; TF-IDF, que representa el documento entero sin ventana, queda como la alternativa directa para la señal léxica global (sección 5.5).

La demostración con *embeddings* contextuales se ejecutó con *intfloat/multilingual-e5-base* (768 dimensiones) sobre cinco documentos codificados con sus primeros 512 *tokens* y el prefijo `query:` en ambos lados de la comparación (similitud simétrica), en GPU. La matriz de similitud coseno resultante (figura 17) muestra que los documentos de 2021 mantienen similitudes altas entre sí (0,907–0,926) y el documento de 1992 se separa ligeramente (0,870–0,878); la similitud media es 0,899. La comparación con la representación dispersa es instructiva: para los mismos tres documentos representativos, la similitud coseno es de 0,91–0,92 con los *embeddings* y de 0,24–0,25 con TF-IDF. Los *embeddings* contextuales capturan una

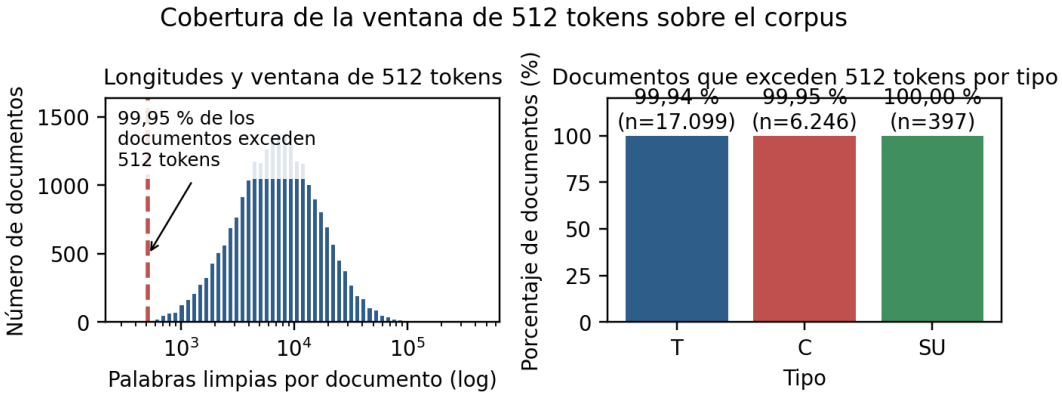



Figura 16: Longitud de los documentos frente a la ventana de 512 *tokens* de los modelos contextuales: distribución global con la ventana marcada (izquierda) y porcentaje de documentos que la exceden por tipo de providencia (derecha).

cercanía semántica y estilística general —con valores típicamente altos y comprimidos, que exigen cautela al fijar umbrales—, mientras que TF-IDF discrimina por solapamiento léxico y es auditable término a término. Ambas vistas son complementarias y así se usarán en la fase de modelado.

## 5.5. Decisión: TF-IDF sobre lemas

La representación principal del proyecto será **TF-IDF sobre lemas** con las siguientes características: rasgos de 1–2 lemas (`ngram_range=(1,2)`), frecuencia mínima documental de 3 (`min_df=3`), vocabulario máximo de 100.000 rasgos (`max_features=100000`) y frecuencia sublineal (`sublinear_tf=True`), sobre los 23.742 documentos del corpus medido (el ajuste efectivo tardó $\approx$ 200 segundos y produjo una esparsidad del 95,66 %; sección 5.3). Cada parámetro responde a la evidencia del corpus: la extensión a bigramas retiene fórmulas de género que el unigrama no distingue; la frecuencia documental mínima de 3 descarta términos esporádicos, de aporte marginal a la masa de tokens; el recorte a 100.000 rasgos conserva la cabeza de la distribución; y la ponderación sublineal amortigua el peso de los términos hiperfrecuentes, en línea con la concentración que describe la ley de Zipf (figura 7). La elección se sostiene, además, en cuatro razones. Primero, los pesos de términos son interpretables: cada categoría puede auditarse inspeccionando los lemas de mayor peso, requisito deseable en una herramienta jurídica. Segundo, la lematización reduce el vocabulario en un 12,7 % y agrupa flexiones (*derechos*/*derecho*) sin sacrificar legibilidad, a diferencia del *stemming* (sección 4.3). Tercero, la literatura reporta que las representaciones de bolsa con ponderación TF-IDF son líneas base competitivas en la clasificación de sentencias largas [Soh et al., 2019] y que su rendimiento depende críticamente del preprocesamiento documentado [HaCohen-Kerner et al., 2020]. Cuarto, su costo es mínimo frente a las alternativas contextuales, lo que reserva el presupuesto de cómputo para la comparación experimental final (sección 6). El vectorizador se ajustará exclusivamente con el conjunto de entrenamiento, de modo que el vocabulario y las ponderaciones IDF no incorporen información del conjunto de prueba (sección 6.2).

La cobertura acumulada del vocabulario precisa el alcance de ese recorte. La figura 18 muestra, sobre los 250.012.101 tokens limpios, que los 1.000 unigramas más frecuentes cubren ya el 77,90 % de la masa; 5.000 cubren el 92,96 %, 10.000 el 96,64 % y 20.000 el 98,66 %. La masa restante fuera del top-20.000 es, por tanto, de apenas el 1,3 %: truncar el vocabulario en la cola —como hace `max_features=100000`, que además incorpora bigramas— sacrifica una fracción mínima de los tokens y concentra la representación en los rasgos informativos, coherente con la cabeza de la distribución descrita por la ley de Zipf (sección 4.1).

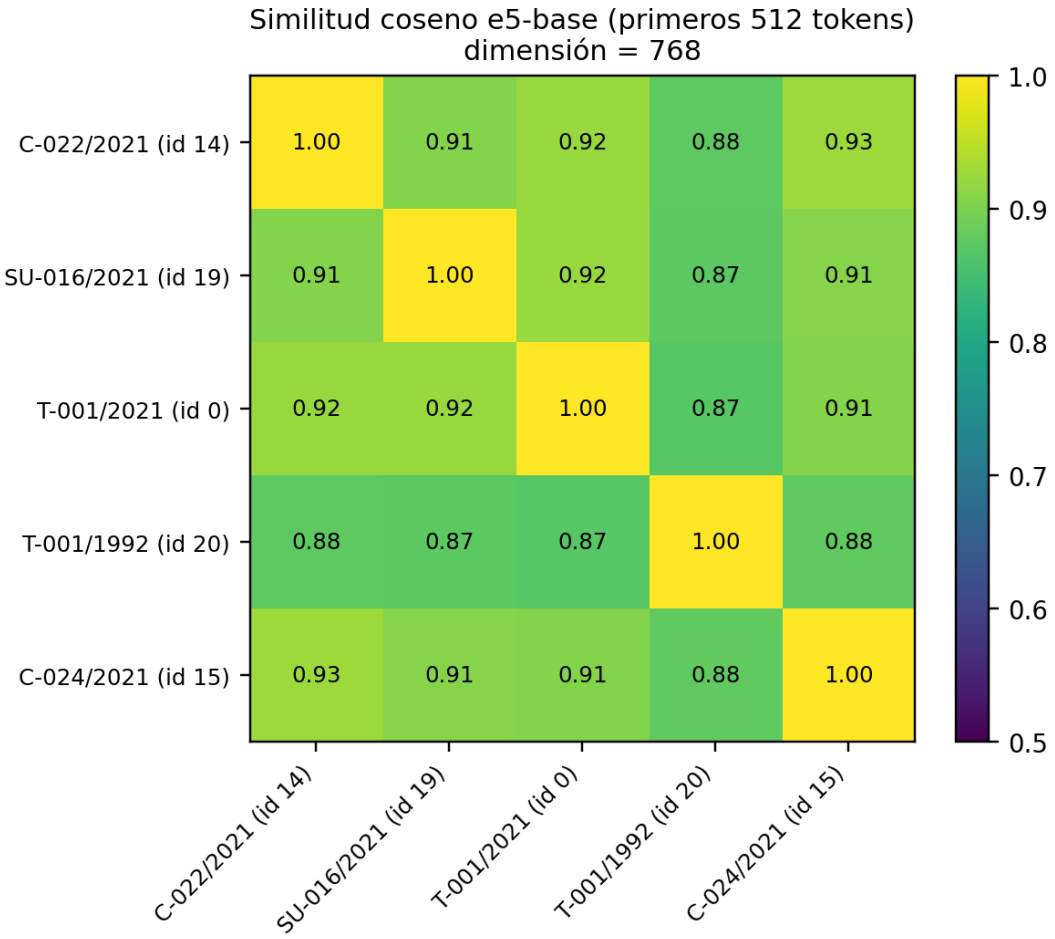



Figura 17: Similitud coseno entre cinco documentos codificados con *multilingual-e5-base* (primeros 512 *tokens*; dimensión 768).

# 6. Propuesta metodológica

## 6.1. Tarea y enfoque

La tarea propuesta es una **clasificación supervisada multi-clase** de sentencias. Se distinguen dos niveles de etiquetas. El primero, inmediato, es el *tipo de providencia* (T, C o SU), que se extrae del encabezado del documento y funciona como categoría inicial: es una tarea de tres clases, útil como banco de pruebas del *pipeline* completo (representación, particiones, métricas) y como línea base interpretable. El segundo, objetivo principal del proyecto, es el *área temática constitucional* de la sentencia, derivada de la taxonomía ligera construida a partir de la Constitución Política (títulos y capítulos como bloques temáticos, artículos como etiquetas finas y respaldo "derecho a X" para tutelas; sección 4.5). Estas etiquetas temáticas están por validar: su definición final y su anotación pasarán por un protocolo de validación antes de usarse como variable dependiente, con su procedencia documentada.

La clasificación supervisada es adecuada porque el objetivo del sistema es asignar categorías a documentos completos, tarea para la que existen antecedentes directos en sentencias judiciales: la comparación de clasificadores clásicos y neuronales sobre sentencias largas de la Corte Suprema de Singapur [Soh et al., 2019], los *pipelines* de clasificación de sentencias en español con categorías dependientes de la

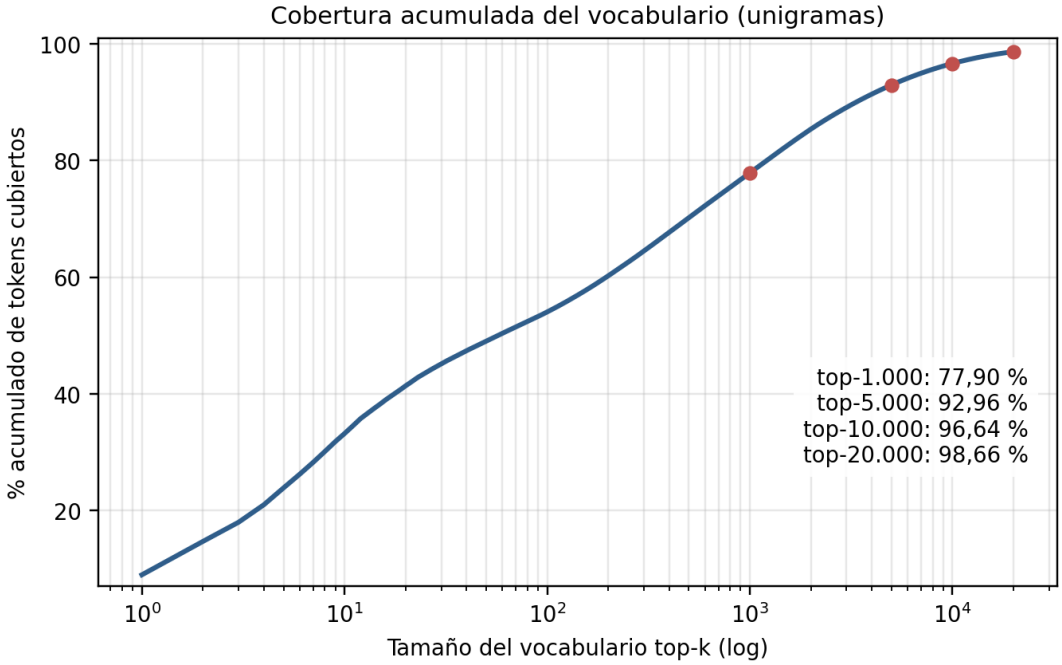



Figura 18: Cobertura acumulada de tokens del vocabulario top-$k$ de unigramas (escala logarítmica), sobre los 250.012.101 tokens limpios del corpus.

jurisdicción [González-González et al., 2023] y la clasificación multietiqueta de documentos legales multilingües con etiquetas de tesauro [Chalkidis et al., 2021]. La naturaleza del área temática (una sentencia puede invocar varios bloques constitucionales) sugiere evaluar, en una segunda iteración, la formulación multi-etiqueta; la primera iteración se plantea multi-clase para obtener una línea base simple y auditable.

## 6.2. Datos, particiones y criterios anti-*leakage*

El insumo es el conjunto de datos medido (sección 3.3) y su representación TF-IDF sobre lemas (sección 5.5). La partición propuesta es **70/15/15 estratificada** por clase, con semilla fija 42 para que el reparto sea reproducible: 70 % entrenamiento, 15 % validación y 15 % prueba. La estratificación se aplica por tipo de providencia y se verifica por año, para evitar que los periodos con menos documentos queden sobrerrepresentados en algún subconjunto. El conjunto de prueba permanece *intocable* durante el desarrollo —todas las decisiones de representación, hiperparámetros y selección de modelo se toman con entrenamiento y validación— y se usa una única vez al final para reportar el desempeño, de modo que la evaluación final sea independiente de las decisiones de desarrollo.

Los criterios anti-*leakage* son parte constitutiva del diseño: (i) la partición es a nivel de documento, nunca de fragmentos, de modo que ninguna parte de una sentencia aparece simultáneamente en entrenamiento y prueba; (ii) el vocabulario y las ponderaciones IDF del vectorizador se ajustan solo con el conjunto de entrenamiento y luego se aplican a validación y prueba; (iii) los pasos de preprocesamiento (normalización, palabras vacías, lematización) son transformaciones fijas y no aprendidas del corpus de prueba; (iv) la selección de hiperparámetros y de modelo se realiza exclusivamente con la métrica de validación; y (v) dada la naturaleza formulaica del corpus, se verificarán duplicados y casi duplicados antes de fijar las particiones. Adicionalmente, por la deriva léxica documentada entre periodos (secciones 4.2 y 4.4) y por la evidencia de que los corpus legales exigen particiones cronológicas para medir generalización temporal [Chalkidis et al., 2021], se contempla una partición cronológica complementaria (entrenar con los periodos antiguos y evaluar en los recientes) como análisis de robustez, sin reemplazar la partición

aleatoria estratificada principal.

## 6.3. Modelos a comparar y criterios de evaluación

Se comparan tres niveles de modelos, de menor a mayor costo. (1) **Línea base mayoritaria**: asignar siempre la clase más frecuente; fija el piso de comparación y permite cuantificar cuánto aporta la representación. (2) **Línea base clásica**: TF-IDF sobre lemas con modelos lineales (regresión logística multinomial y SVM lineal), entrenados sobre los rasgos de la sección 5.5. (3) ***Transformer* contextual en español**: ajuste fino de un modelo tipo BETO con segmentación del documento en fragmentos de 512 *tokens* y agregación de las representaciones (media de fragmentos) para obtener una representación por documento; el modelo de dominio legal se considera como variante si el presupuesto lo permite [Chalkidis et al., 2020].

Los criterios de evaluación son: *macro-F1* como métrica principal (por el desbalance, con T en el 72,02 % de los documentos), F1 por clase con precisión y *recall*, matriz de confusión, análisis cualitativo de errores y evaluación por cortes (desempeño por tipo y por periodo). En cuanto al costo, se registran tiempos de entrenamiento e inferencia, memoria y requerimiento de GPU, con el fin de que la comparación no premie únicamente la métrica sino la viabilidad operativa. La tabla 11 resume la comparación propuesta.

Tabla 11: Modelos a comparar y criterios de evaluación de la fase de modelado.

| **Enfoque** | **Representación** | **Fortalezas** | **Límites esperados y criterios** |
|---|---|---|---|
| Línea base mayoritaria | — | piso de comparación; costo nulo | no aporta información; macro-F1 y F1 por clase |
| Clásica: modelos lineales | TF-IDF sobre lemas (1–2 gramos) | interpretable; bajo costo; robusta en documentos largos | pierde orden y composicionalidad; macro-F1, matriz de confusión, análisis de errores, costo |
| *Transformer* en español | BETO con segmentación y agregación | contexto y composicionalidad; estado del arte | costo de GPU; ventana de 512; requiere segmentación; macro-F1, F1 por clase, robustez por periodo, costo |

## 6.4. Riesgos y mitigaciones

**Desbalance de clases.** Las tutelas dominan el corpus (72,02 %). Mitigación: particiones estratificadas, macro-F1 como métrica principal, ponderación de clases (solo con el conjunto de entrenamiento) y reporte del desempeño por clase, para evitar que la clase mayoritaria oculte fallos en C y SU.

**Documentos largos frente a la ventana del *transformer*.** Con $\approx$ 11.000 palabras por sentencia, el truncamiento simple descarta la mayor parte del contenido. Mitigación: segmentación en fragmentos con agregación y comparación explícita con la línea base TF-IDF, que no sufre este límite.

**Etiquetas temáticas por validar.** La taxonomía derivada de la CP es una construcción del proyecto, no un recurso anotado por terceros. Mitigación: protocolo de validación con anotación experta (al menos una muestra), documentación de la procedencia de cada etiqueta y reporte del acuerdo entre anotadores; mientras la validación no esté cerrada, el tipo de providencia funciona como etiqueta de referencia del *pipeline*. La escasez de recursos legales anotados en español para América Latina [Löffler et al., 2025] refuerza la importancia de esta validación.

**Deriva temporal y composición por periodo.** El vocabulario y la diversidad léxica cambian entre 1992 y 2021 (secciones 4.2 y 4.4). Mitigación: evaluación por cortes temporales, partición cronológica complementaria y reporte del desempeño por periodo.

**Duplicados y plantillas.** El género es formulaico y pueden existir documentos casi idénticos. Mitigación: verificación de duplicados y casi duplicados antes de fijar las particiones y análisis de errores consciente de plantillas.

**Costo computacional.** El ajuste fino de un *transformer* consume GPU y tiempo. Mitigación: la línea base clásica corre en CPU y se ejecuta primero; el *transformer* se reserva para una comparación acotada y su inclusión no bloquea el resto de la metodología.

## 6.5. Trabajo futuro

El trabajo realizado hasta aquí no parte de cero: la curación y limpieza del corpus se apoyan en la evidencia de que el preprocesamiento altera los resultados de forma dependiente del corpus y de la tarea [HaCohen-Kerner et al., 2020]; el análisis de n-gramas y colocaciones adopta la razón de verosimilitud como estadístico de asociación [Dunning, 1993] y la cautela que exige la interpretación de frecuencias en sentencias largas [Soh et al., 2019]; la diversidad léxica se mide con una métrica robusta a la longitud [McCarthy and Jarvis, 2010]; y la representación y el tratamiento del dominio siguen las lecciones de los vocabularios jurídicos y de los corpus legales multilingües [Chalkidis et al., 2020, Chalkidis et al., 2021]. Sobre esos cimientos, el trabajo posterior se plantea como continuidad de los insumos ya construidos —el corpus medido, la representación y las etiquetas temáticas— en cinco frentes.

El primer frente es consolidar las etiquetas temáticas de referencia. Las etiquetas construidas de forma automática se validarán progresivamente mediante anotación experta hasta constituir un estándar de referencia verificado, porque la literatura de corpus legales con etiquetas temáticas respalda los protocolos de validación explícitos y la documentación de la procedencia de cada etiqueta [Chalkidis et al., 2021], y la escasez de recursos legales anotados en español para América Latina [Löffler et al., 2025] hace de esa validación un aporte en sí mismo. El punto de partida es favorable: la taxonomía deriva de la propia Constitución (títulos y capítulos como bloques temáticos, artículos 1–380 como etiquetas finas) y la señal temática está distribuida en el documento completo —el 97,17 % de las sentencias contiene al menos un marcador temático, frente al 4,64 % de las subsentencias—, de modo que las etiquetas pueden asignarse sobre la sentencia completa sin segmentar.

El segundo frente es el modelado supervisado: comparar líneas base lineales sobre TF-IDF con un *transformer* en español segmentado por fragmentos, calibrar umbrales de decisión y analizar errores por periodo y por tipo. Los antecedentes de clasificación de sentencias largas muestran que las representaciones de bolsa siguen siendo competitivas cuando el preprocesamiento está documentado [Soh et al., 2019]; la clasificación de sentencias en español con categorías dependientes de la jurisdicción [González-González et al., 2023] y el vocabulario distintivo del dominio legal [Chalkidis et al., 2020] completan el respaldo. Los datos del proyecto justifican la comparación: el 99,95 % de los documentos excede la ventana de 512 *tokens*, de modo que el *transformer* exige segmentación y agregación, y el desbalance de clases (T 72,02 %) exige macro-F1 y ponderación de clases.

El tercer frente es la recuperación y el reordenamiento con modelos de lenguaje: vincular cada sentencia con los artículos de la Constitución que la sustentan mediante búsqueda híbrida (léxica y densa) y reordenar los candidatos con modelos de lenguaje que comprendan la consulta jurídica, con evaluación sobre una referencia graduada. La literatura de recuperación legal respalda la arquitectura en dos etapas —una primera etapa de recuperación amplia y un reordenamiento neuronal encima— porque los casos largos exceden la ventana de los codificadores [Althammer et al., 2021]; el enriquecimiento explícito con estatutos mejora la recuperación de casos [Fink et al., 2023]; y los sistemas recientes de recuperación de estatutos combinan la comprensión de la consulta y el reordenamiento con modelos de lenguaje [LegalMALR, 2026]. El proyecto aporta el material para esa tarea: el 97,17 % de las sentencias contiene al menos un marcador temático explícito —cita a la Constitución o respaldo "derecho a X"—, lo que convierte el vínculo sentencia–artículo en un objetivo medible sobre el corpus completo.

El cuarto frente son las representaciones contextuales: evaluar *embeddings* de dominio legal y la agregación por fragmentos como complemento de TF-IDF para la comparación semántica. Las variantes

tipo *Sentence-BERT* permiten vectores de fragmento comparables por similitud coseno con un costo de inferencia acotado [Reimers and Gurevych, 2019], y las adaptaciones de dominio legal muestran que el vocabulario jurídico difiere del general [Chalkidis et al., 2020]. La demostración ya ejecutada deja ver su valor y sus límites: los *embeddings* contextuales alcanzan una similitud media de 0,899 (0,91–0,92 entre los documentos representativos, frente a 0,24–0,25 de TF-IDF), con valores altos y comprimidos que exigen cautela al fijar umbrales; además, la segmentación será inevitable, porque el 99,95 % de los documentos excede los 512 *tokens*.

El quinto frente son las aplicaciones de apoyo a la consulta: resumen de sentencias extensas, contexto jurisprudencial (red de precedentes) y análisis diacrónico del vocabulario. La evidencia de que distintas secciones de una sentencia difieren en poder informativo respalda la segmentación y el resumen selectivo [Aletras et al., 2016]; el contraste léxico entre periodos sigue la práctica del análisis diacrónico de tribunales [Hamilton et al., 2016, Raj et al., 2026]. Los datos del corpus sostienen estos objetivos: las sentencias promedian $\approx 11.000$ palabras (mediana de 7.158), lo que hace del resumen una herramienta necesaria; el léxico evoluciona de forma medible (diversidad de 64,32 a 58,53 y recambio temático de *incoder* y *rupd* a *uariv*, *jep* y *coronavirus*); y la densidad de citas jurisprudenciales permite construir la red de precedentes.

# 7. Conclusiones

Esta entrega profundizó el análisis del corpus de 23.742 sentencias de la Corte Constitucional de Colombia (1992–2021) y dejó definidas la representación de los textos y la metodología de modelado del proyecto. En primer lugar, se documentaron y verificaron las modificaciones respecto a la Entrega 1: el corpus se persiste ahora como conjunto de datos medido; el EDA avanzado se incorporó con su lectura analítica; la unidad de análisis (sentencia completa) quedó validada con un experimento pre-registrado; se cumplió la promesa del análisis por periodos; y se formularon la representación y la propuesta metodológica. Las cifras canónicas del corpus no requirieron corrección.

En segundo lugar, el EDA avanzado caracterizó el género con evidencia cuantitativa: el corpus es fuertemente formulaico (*accion de tutela* es el trigrama más frecuente, con 344.893 ocurrencias; el 82,7 % de los trigramas guardados responden al patrón con palabra intermedia vacía); la razón de verosimilitud es la medida de asociación más confiable (75 % de fórmulas válidas frente a 55 % de la frecuencia y 0 % del PMI); la diversidad léxica desciende sostenidamente de 64,32 (1992–2001) a 58,53 (2012–2021), con una pendiente de $-0,32$ puntos por año; el contraste por periodos muestra un recambio temático del vocabulario (de *incoder* y *rupd* a *uariv*, *jep* y *coronavirus*); la lematización reduce el vocabulario en un 12,7 % conservando legibilidad; y la señal temática está distribuida en el documento completo (97,17 % de sentencias con marcador frente a 4,64 % de subsentencias). Ninguna ontología externa cubre el dominio colombiano, por lo que se deriva una taxonomía ligera de la Constitución Política.

En tercer lugar, se seleccionó y calculó TF-IDF sobre lemas (rasgos de 1–2 lemas, frecuencia mínima documental de 3, hasta 100.000 rasgos y ponderación sublineal) como representación principal —matriz de $23.742 \times 100.000$ rasgos con 95,66 % de esparsidad—, por su interpretabilidad, su bajo costo y su respaldo en la literatura, y se propuso una metodología de clasificación supervisada multi-clase con particiones 70/15/15 estratificadas (semilla 42, prueba intocable), criterios anti-*leakage* explícitos y comparación entre modelos lineales y *transformers* bajo macro-F1, F1 por clase, análisis de errores y costo. El conjunto medido, el EDA y la propuesta dejan al proyecto listo para su fase de modelado.

# Referencias

[Aletras et al., 2016] Aletras, N., Tsarapatsanis, D., Preoţiuc-Pietro, D., and Lampos, V. (2016). Predicting judicial decisions of the European Court of Human Rights: a natural language processing perspective. *PeerJ Computer Science*, 2:e93.

[Althammer et al., 2021] Althammer, S., Askari, A., Verberne, S., and Hanbury, A. (2021). DoSSIER@COLIEE 2021: Leveraging dense retrieval and summarization-based re-ranking for case law retrieval. In *Proceedings of the Competition on Legal Information Extraction/Entailment (COLIEE 2021)*.

[Anzola Cortés, 2021] Anzola Cortés, J. S. (2021). Algoritmos, sentencias y derecho constitucional comparado: explorando el uso de jurisprudencia extranjera en colombia. Trabajo de grado (pregrado en Ciencias Políticas), Universidad de La Sabana. Dirección: J. F. Molano Pulido y C. F. Rojas González. Analiza más de 6.000 sentencias de constitucionalidad de la Corte Constitucional de Colombia (1992–2020) con minería de datos.

[Barbosa Becerra, 2021] Barbosa Becerra, J. J. M. (2021). Comportamiento discursivo del enunciado "territorio ancestral" en las sentencias de la corte constitucional de colombia. *Estudios de Derecho*, 78(172).

[Chalkidis et al., 2021] Chalkidis, I., Fergadiotis, M., and Androutsopoulos, I. (2021). MultiEURLEX – a multi-lingual and multi-label legal document classification dataset for zero-shot cross-lingual transfer. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6974–6996, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

[Chalkidis et al., 2020] Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., and Androutsopoulos, I. (2020). LEGAL-BERT: The muppets straight out of law school. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 2898–2904, Online. Association for Computational Linguistics.

[Dunning, 1993] Dunning, T. (1993). Accurate methods for the statistics of surprise and coincidence. *Computational Linguistics*, 19(1):61–74.

[Fink et al., 2023] Fink, T., Recski, G., Kusa, W., and Hanbury, A. (2023). Statute-enhanced lexical retrieval of court cases for COLIEE 2022. In *Proceedings of the JURISIN 2022 Workshop*.

[González-González et al., 2023] González-González, J., de Arriba-Pérez, F., García-Méndez, S., Busto-Castiñeira, A., and González-Castaño, F. J. (2023). Automatic explanation of the classification of spanish legal judgments in jurisdiction-dependent law categories with tree estimators. *Journal of King Saud University — Computer and Information Sciences*, 35(7):101634.

[HaCohen-Kerner et al., 2020] HaCohen-Kerner, Y., Miller, D., and Yigal, Y. (2020). The influence of preprocessing on text classification using a bag-of-words representation. *PLOS ONE*, 15(5):e0232525.

[Hamilton et al., 2016] Hamilton, W. L., Leskovec, J., and Jurafsky, D. (2016). Diachronic word embeddings reveal statistical laws of semantic change. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Berlin, Germany. Association for Computational Linguistics.

[LegalMALR, 2026] LegalMALR (2026). Multi-agent query understanding and LLM-based reranking for chinese statute retrieval.

[Löffler et al., 2025] Löffler, C., Martínez Freile, A., and Rey Pizarro, T. (2025). Predicting potentially abusive clauses in chilean terms of services with natural language processing. *Artificial Intelligence and Law*. Primera versión en línea: 9 de mayo de 2025. Preprint: arXiv:2502.00865.

[Manning et al., 2008] Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press, Cambridge, UK.

[Manuel, 2022] Manuel (2022). sentencias-corte-cons-colombia-1992-2021: 23.750 case law of the colombia's corte constitucional (1992–2021). Hugging Face Hub, dataset "Manuel/sentencias-corte-cons-colombia-1992-2021". Autor: usuario "Manuel" de Hugging Face. Volcado plano con columnas ID y Texto; licencia CC-BY-4.0; creado el 2022-06-30.

[McCarthy and Jarvis, 2010] McCarthy, P. M. and Jarvis, S. (2010). MTLD, vocd-D, and HD-D: A validation study of sophisticated approaches to lexical diversity assessment. *Behavior Research Methods*, 42(2):381–392.

[Raj et al., 2026] Raj, A. Y., Gopi Ranga Nath, V., Mishra, A. N., and Basha, M. S. A. (2026). Collective bargaining in karnataka public sector undertakings: A computational analysis of indian court judgments using NLP and machine learning. In *2026 International Conference on Recent Advancement in Electrical, Computer and Communication Technologies (IECCT)*, pages 1–6, Bangalore, India. IEEE.

[Reimers and Gurevych, 2019] Reimers, N. and Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China. Association for Computational Linguistics.

[Soh et al., 2019] Soh, J., Lim, H. K., and Chai, I. E. (2019). Legal area classification: A comparative study of text classifiers on singapore supreme court judgments. In *Proceedings of the Natural Legal Language Processing Workshop 2019 (co-located with NAACL-HLT 2019)*, pages 67–77, Minneapolis, Minnesota. Association for Computational Linguistics.