Asistente RAG reproducible sobre prensa y Bluesky con Milvus y modelos locales: arquitectura, evaluación y compuerta de dominio

Erika Valeria Rivera Jimenez, Julian Guillermo Carrillo Meneses,
Carlos Andres Garnica Salazar, Oscar Andres Prieto Moreno

Pontificia Universidad Javeriana, Bogotá, Colombia
riveraev@javeriana.edu.co, carrillojuliang@javeriana.edu.co,
carlos_garnicas@javeriana.edu.co, o-prieto@javeriana.edu.co

***Resumen*: La recuperación aumentada por generación (RAG) permite responder sobre un corpus sin reentrenar el modelo, pero su calidad depende de decisiones que rara vez se documentan juntas: limpieza, segmentación, codificador, índice, reordenamiento, prompt y control de abstención. Este trabajo presenta un asistente RAG reproducible sobre 169.248 documentos recolectados de prensa colombiana e internacional y Bluesky, 161.868 indexados tras descartar páginas de error y 618.286 fragmentos en Milvus, con modelos locales. La comparación de capas es exploratoria sobre el gold completo. Se justifica cada capa con experimentos pareados: la limpieza conservadora no mejora de forma significativa, el chunking fijo tiende a superar a la segmentación por oraciones y es más rápido, bge-m3 supera a e5-base, y la unión con BM25 más el reordenamiento en GPU sube el recall@10 del conjunto reservado de 0,600 a 0,700. En el gold exploratorio el sistema entrega 37 de 38 preguntas respondibles, se abstiene en las 5 sin respuesta y acierta 25 de 37 de forma exacta. En un conjunto reservado de 20 preguntas nuevas, entrega 19, acierta 17 de forma exacta y se abstiene en las 5 sin respuesta; el recall@10 es 0,700 y la compuerta rechaza las 5 sin respuesta y 3 de las 20 directas. En conversación alcanza 14 de 14 con compuerta de dominio. RAGAS reporta 0,952 de fidelidad, 0,881 de precisión de contexto, 0,921 de cobertura y 0,657 de corrección. Se documentan también las mejoras rechazadas, el coste de cada decisión y los límites del corpus.**

***Palabras clave*: recuperación aumentada por generación, Milvus, bge-m3, reordenamiento, evaluación de sistemas de recuperación, compuerta de dominio.**

I. Introducción

Un sistema de recuperación aumentada por generación (RAG) responde una pregunta con fragmentos recuperados de una colección y un modelo de lenguaje que redacta a partir de ellos [1]. La promesa es atractiva: actualizar el conocimiento sin reentrenar y citar la evidencia. En la práctica, la calidad depende de una cadena de decisiones que se afectan entre sí. Una limpieza agresiva puede borrar la frase que responde; un chunking pequeño pierde contexto; un codificador entrenado en otro dominio recupera vecinos plausibles pero inútiles; un reordenador puede mejorar el orden y a la vez encarecer cada consulta; un prompt permisivo invita a inventar; y sin un control de abstención el sistema responde con seguridad sobre temas que el corpus no cubre.

La literatura de RAG suele evaluar un componente a la vez. BEIR y MTEB miden recuperadores [2], [3]; los benchmarks multilingües como MIRACL comparan codificadores [4]; RAGAS, ARES, eRAG y RAGChecker evalúan la respuesta generada [5], [6], [7], [8]. Son piezas necesarias, pero no dicen cómo se comporta la cadena completa sobre un corpus real, con duplicados, truncamiento, ruido de rastreo y preguntas sin respuesta. Tampoco dicen cuánto cuesta cada mejora ni cuándo conviene rechazarla.

Este trabajo construye y evalúa esa cadena completa sobre un corpus de 169.248 documentos recolectados de prensa colombiana e internacional y Bluesky, 161.868 indexados y 618.286 fragmentos. El sistema corre en una estación con una GPU AMD de 16 GB y un servidor de la red local que aloja Milvus [9]; los modelos se sirven por Ollama [10]. No se usan servicios externos de generación ni de embeddings. La Tabla III resume la configuración final y la Sección IV justifica cada elección.

I-A. Preguntas de investigación

1. **Calidad del corpus.** ¿Qué problemas de limpieza, truncamiento, duplicados e idioma aparecen en un corpus de prensa y redes sociales, y cuánto afectan la recuperación?
2. **Recuperación.** ¿Qué combinación de codificador, índice, tamaño de contexto y reordenamiento maximiza la cobertura y el orden con un coste aceptable?
3. **Generación y abstención.** ¿Cómo se comportan distintos modelos locales sobre la misma evidencia y qué controles evitan respuestas sin respaldo?
4. **Evaluación.** ¿Qué acuerdo alcanzan los anotadores humanos y qué señales de evaluación automática son fiables cuando el juez también es un modelo local?

I-B. Aportes

1. Un pipeline reproducible de extremo a extremo, con Docker Compose, Milvus, Ollama, FastAPI y Streamlit, que se levanta con un comando y no depende de servicios de pago.
2. Un análisis exploratorio y una textometría del corpus que cuantifican el texto sin cierre terminal (32,7 %, un proxy de truncamiento), ruido de rastreo, duplicados

exactos y near-duplicates, y que justifican una limpieza conservadora.
3. Una comparación pareada de cuatro variantes de limpieza, dos estrategias de segmentación, tres codificadores, recuperación densa, dispersa e híbrida, y tres alcances de reordenamiento, con intervalos de confianza por bootstrap.
4. Un gold de 43 preguntas con revisión de tres anotadores y una cuarta pendiente, con acuerdo entre anotadores reportado, y una evaluación automática con RAGAS que distingue el ruido del juez de una mejora real.
5. Una compuerta de dominio entrenada con 160 preguntas que rechaza las preguntas sin respuesta del conjunto de prueba y las 5 del conjunto reservado, con 3 falsos rechazos en 20 preguntas de dominio, y una interfaz que expone la evidencia, las citas y la abstención.

I-C. Organización

La Sección II revisa los trabajos relacionados. La Sección III describe el corpus y el análisis exploratorio. La Sección IV presenta la arquitectura y justifica cada capa. La Sección V detalla el procesamiento y la configuración. La Sección VI define el protocolo y el gold. La Sección VII reporta los experimentos y sus decisiones. Las Secciones VIII a XI discuten errores, límites y conclusiones.

II. Trabajos relacionados

II-A. Recuperación aumentada por generación

RAG combina un recuperador con un generador para responder con conocimiento externo [1]. La variante densa codifica pregunta y documentos en un mismo espacio y busca por similitud; la dispersa, como BM25 [11], puntúa por coincidencia de términos. La fusión de ambas con reciprocal rank fusion [12] es una práctica común para compensar sus sesgos. En este trabajo se comparan las tres sobre el mismo corpus y el mismo protocolo, con un índice por codificador, y la configuración final combina densa y dispersa antes de reordenar, porque la unión recupera entidades que el denso no trae.

II-B. Variantes iterativas y correctivas

Self-RAG entrena al modelo para decidir cuándo recuperar y para criticar sus propias respuestas con tokens de reflexión [13]. CRAG evalúa la calidad de la recuperación y activa una búsqueda correctiva cuando el contexto es pobre [14]. Ambos mejoran la robustez frente a recuperaciones malas, a costa de varias pasadas del generador y, en el caso de Self-RAG, de un entrenamiento específico. Este trabajo no adopta esas variantes porque el presupuesto de latencia y la GPU local no permiten varias pasadas por consulta. En su lugar, la compuerta decide antes de generar y los guardarraíles verifican después, con un coste de milisegundos.

II-C. Codificadores y recuperación

BEIR mostró que un recuperador bueno en un dominio puede fallar en otro [2], y MTEB extendió esa comparación a tareas y lenguas [3]. MIRACL evidenció la brecha multilingüe [4]. Los codificadores entrenados con contrastive learning, como e5 [15] y bge-m3 [16], mejoran el rendimiento zero-shot y multilingüe. bge-m3 además produce representaciones densas, dispersas y multi-vector con un solo modelo, lo que simplifica la infraestructura. La elección entre ellos no se puede decidir solo por la literatura: depende del corpus, del idioma y del tamaño del índice. Por eso se miden sobre el corpus completo en lugar de limitarse al piloto.

II-D. Reordenamiento

Un cross-encoder puntúa el par pregunta-documento con atención conjunta y suele superar al bi-encoder en precisión [17]. El coste crece con el número de candidatos, porque cada par exige una pasada completa del modelo. La práctica habitual es recuperar un conjunto amplio y reordenar un top pequeño. Este trabajo mide el efecto de reordenar 5, 20 y 50 candidatos densos, y encuentra que ampliar el conjunto denso mejora el orden pero pierde cobertura. La configuración final reordena una unión de denso y BM25 en GPU y recorta a 10; la unión añade cobertura sin el coste de un top-50 denso.

II-E. Índices vectoriales

HNSW aproxima la búsqueda por vecinos con un grafo jerárquico y un parámetro de exploración que intercambia recall por latencia [18]. Milvus implementa HNSW y otros índices sobre almacenamiento distribuido [9]. El parámetro `ef` se ajusta en este trabajo con una búsqueda en rejilla sobre el gold, y se documenta el punto donde la ganancia deja de compensar el coste.

II-F. Evaluación

Las métricas de recuperación (Recall@k, nDCG, P@k, MRR) son estándar en recuperación de información. Para la respuesta generada, RAGAS descompone la calidad en fidelidad, relevancia, precisión y cobertura del contexto y corrección [5]; ARES entrena jueces para reducir el sesgo del evaluador [6]; eRAG evalúa la utilidad de cada documento recuperado [7]; y RAGChecker diagnostica errores de recuperación y de generación por separado [8]. Un problema recurrente es que el juez también es un modelo y su veredicto varía con el prompt, el timeout y la concurrencia. Liu et al. muestran además que el generador aprovecha peor la evidencia cuando esta se coloca en el medio de un contexto largo [19]. RAGTruth muestra que las alucinaciones en RAG se concentran en afirmaciones sin respaldo y propone anotación a nivel de span [20]. La verificación de entidades y números contra el chunk citado de este trabajo sigue esa idea con reglas deterministas. Este trabajo reporta la cobertura de cada métrica de RAGAS además de su media, y separa el ruido del juez de una mejora del sistema.

Tabla I
COMPOSICIÓN DEL CORPUS POR COLECCIÓN.

Colección	Documentos	% del total
Rastreo web	104.578	61,8
Bluesky	64.670	38,2
Total	169.248	100,0

II-G. Abstención y control de dominio

Un sistema RAG que siempre responde produce alucinaciones cuando la evidencia no alcanza. Las soluciones van desde pedir al generador que se abstenga hasta entrenar un clasificador que decida si la pregunta pertenece al dominio. Este trabajo usa dos controles: guardarraíles de cita y de entidades sobre la respuesta, y una compuerta de dominio supervisada que se activa con un interruptor. La compuerta es un clasificador de regresión logística con embeddings y señales de recuperación, no un juez generativo, para que su decisión sea barata, reproducible y medible.

II-H. Posición de este trabajo

La contribución es una evaluación completa de la cadena sobre un corpus real, con las mejoras que funcionaron y las que no, y con el coste de cada decisión. Se separa la calidad del sistema de la calidad del juez, y esa separación es la que permite decidir qué mantener en producción y qué descartar.

III. CORPUS Y ANÁLISIS EXPLORATORIO

III-A. Composición

El corpus de trabajo tiene 169.248 documentos, 34 columnas y 256,9 MB. La Tabla I resume la procedencia. La mayor parte viene de rastreo web (104.578) y de Bluesky (64.670). El campo `source_type` no sirve como etiqueta semántica: 99.326 filas lo tienen nulo, 64.670 valen `social_post` y solo 5.252 valen `news_article`. La distribución por dominio confirma el peso de las fuentes: bsky.app aporta 64.670 documentos, infobae 19.766, eltiempo 12.229, theguardian 7.216 y elespectador 5.456. El corpus no representa la conversación pública en español: Bluesky llega casi todo en inglés y la prensa está dominada por cuatro cabeceras. La prensa incluye cabeceras británicas (The Guardian, The Independent, Daily Mail) además de colombianas (El Tiempo, El Espectador, Infobae).

Tras normalizar el campo `language`, el corpus queda en 82.682 documentos en inglés, 66.910 en español, 13.140 sin idioma declarado y 6.516 en otros idiomas, con 4.133 en húngaro. El húngaro aparece con 4.108 documentos en el campo crudo, un volumen que no corresponde con el resto de la distribución y que se excluye del filtro de idioma hasta revisarlo. La normalización se hace al vuelo en la ingesta y el archivo original no se modifica.

El rango declarado de fechas va de 2008 a 2026, pero 163.736 de los 169.248 documentos (96,7 %) no tienen fecha y solo 5.512 la declaran. El filtro temporal se limita a ese 3,3 % y así se documenta en la interfaz.

III-B. Duplicados y longitud

Hay 14.771 copias excedentes (filas que repiten un texto ya presente) agrupadas en 4.434 grupos, con un máximo de 839 copias. Si se cuentan todas las filas que pertenecen a un grupo duplicado, son 19.205: 9.972 en Bluesky y 9.233 en prensa. Las dos cifras son compatibles: la primera cuenta copias adicionales y la segunda, documentos en grupos. No se borran filas en la ingesta, porque eso perdería la procedencia; la deduplicación se hace en la recuperación, comparando el hash del fragmento antes de armar el contexto.

La longitud media es de 473 palabras y 2.977 caracteres, pero la mediana baja a 371 palabras y 2.367 caracteres. La cola es larga: el percentil 99 llega a 2.420 palabras y el máximo a 58.181 palabras, equivalentes a 363.528 caracteres. Ese documento extremo produce cientos de fragmentos y obliga a controlar el tamaño de lote en la ingesta.

III-C. Ruido de rastreo

El rastreador dejó páginas de error dentro del corpus. La misma página con los mensajes “Haz excedido el máximo de peticiones” y “Error 505” aparece en 7.378 documentos, el 4,36 % del total, todos en la colección de prensa. En el conjunto de humo esos textos casi idénticos dominaban el top-10 de cualquier consulta, porque su similitud entre sí es mayor que la de cualquier documento relevante. El registro de ingesta descarta 7.380 documentos por calidad: 7.378 son esa página de error y 2 no están desglosados. Quedan 161.868 documentos indexados y 618.286 fragmentos. El porcentaje de documentos con al menos un patrón de ruido (peticiones, error 505, cookies, inicio de sesión) llega al 5,3 %, pero el filtro solo elimina los marcadores fuertes de error y no las menciones legítimas de cookies.

III-D. Textometría

La textometría se calculó sobre dos muestras: los 2.000 documentos del piloto y 5.000 documentos estratificados del resto del corpus, con semilla 42. La Tabla II compara los indicadores. Los valores son estables entre muestras, lo que sugiere que el piloto representa bien la distribución léxica del corpus completo.

El 32,7 % de los documentos de la muestra no termina en un signo de cierre. Es un proxy de truncamiento, no una verificación de que el rastreador los cortó: una publicación completa puede acabar sin punto. La limpieza no puede recuperar ese texto, y el porcentaje se declara como límite en la Sección X. El HTML residual es marginal (0,14 % en la muestra), pero las URLs aparecen en uno de cada diez documentos y los emojis en uno de cada ocho, casi todo en Bluesky. Los near-duplicates no son solo hash exacto: SimHash encuentra grupos de hasta 32 documentos que el hash exacto no captura. Los términos exclusivos de prensa están dominados por boilerplate (*publicidad*, *información*, *además*), lo que anticipa que una normalización conservadora puede ayudar sin destruir entidades.

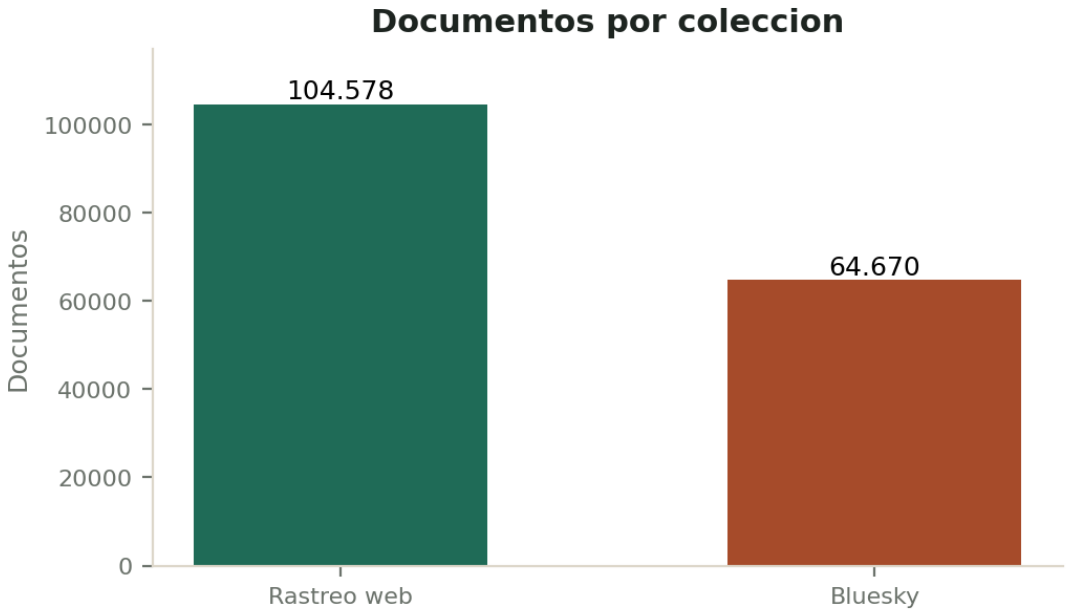


Figura 1. Documentos por colección. Los dos totales coinciden con la Tabla I.

Tabla II
TEXTOMETRÍA DEL PILOTO Y DE UNA MUESTRA DEL CORPUS COMPLETO.

Indicador	Piloto	Muestra
Tipos por documento (mediana)	188	188
TTR mediana	0,579	0,570
Hapax / tipos (mediana)	0,773	0,770
Guiraud (mediana)	10,04	10,13
Caracteres por documento (mediana)	2.317	2.353
Caracteres p99	14.979	15.498
Sin puntuación terminal (proxy)	33,5 %	32,7 %
Documentos con URL	9,3 %	9,9 %
Documentos con correo	1,8 %	1,3 %
Documentos con emojis	12,4 %	12,1 %
Documentos con navegación	3,4 %	3,3 %
Documentos con boilerplate	3,4 %	4,5 %
Near-duplicates (SimHash, Hamming ≤ 3)	4,25 %	4,72 %
Grupos de near-duplicates	26	53
Grupo más grande	12	32

III-E. Decisiones de procesamiento

El análisis anterior fija tres decisiones. Primero, limpieza conservadora: se elimina boilerplate y se normalizan espacios, pero no se tocan entidades ni números. Segundo, deduplicación en la recuperación, no en la ingesta, para conservar la trazabilidad. Tercero, el truncamiento se declara como límite y no se intenta reconstruir. La Sección VII mide si la limpieza conservadora mejora la recuperación frente a no limpiar.

IV. ARQUITECTURA

IV-A. Vista general

La Figura 5 muestra el flujo. El usuario escribe en una interfaz Streamlit; la API FastAPI recibe la pregunta, la condensa si viene de una conversación, aplica la compuerta de dominio si el Modo estricto está activo, recupera fragmentos de Milvus, los reordena, arma el contexto y genera la respuesta. Antes de devolverla, los guardarraíles verifican citas, entidades y números. Cada capa se eligió por una razón medible, no por disponibilidad.

IV-B. Capas y justificación

Ingesta. Los documentos se limpian, se fragmentan y se codifican una sola vez. La colección se valida contra la etiqueta del codificador activo para no mezclar espacios vectoriales. Se eligió un pipeline idempotente y reanudable porque el corpus cambia y la codificación es la etapa más costosa: la ingesta completa desde documentos tardó 2 h 41 min y reindexar 618.286 fragmentos ya troceados con bge-m3 tardó 27,3 min.

Índice vectorial. Milvus se eligió por tres razones: soporta HNSW con parámetro de exploración ajustable [18], filtra por metadatos (idioma, fecha, colección) sin salir del motor y mantiene 618.286 fragmentos con latencias de milisegundos. Una base local en memoria no habría permitido filtrar ni auditar la procedencia.

Codificación. bge-m3 produce vectores densos de 1024 dimensiones, es multilingüe y rinde bien sin ajuste fino [16]. Se comparó con e5-base y con qwen3-embedding sobre el mismo corpus y el mismo protocolo, con un índice por modelo; la decisión se reporta en la Sección VII.

Recuperación. El recuperador combina una lista densa de 10 fragmentos con una dispersa de 20. Las dos se unen sin fusionar y se deduplican; la unión conserva el top-5 denso y añade las entidades que BM25 encuentra. La fusión RRF sin reordenar se midió y perdía frente al denso; la unión reordenada gana en el conjunto reservado.

Reordenamiento. Un cross-encoder multilingüe reordena la unión en GPU y el resultado se recorta a 10 [17]. El reordenador comparte la pasada con la compuerta, que usa la puntuación del top-5. El coste medido es de 0,68 s para 50 pares en GPU, frente a 1,30 s para 5 pares en CPU; la

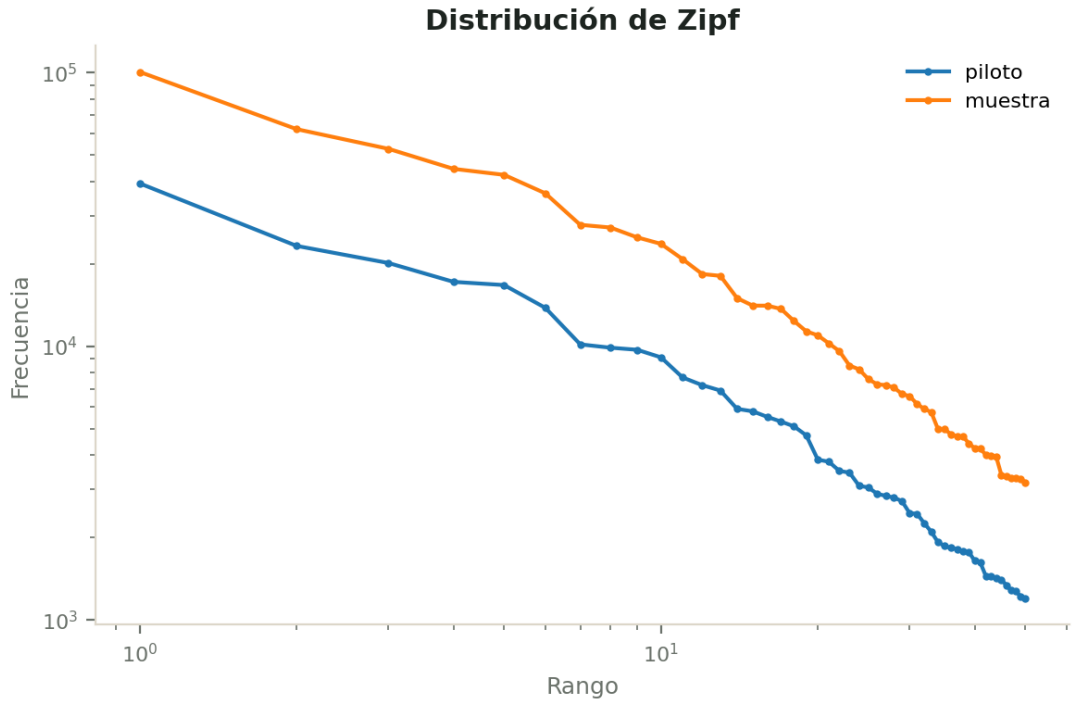


Figura 2. Rango frente a frecuencia en escala logarítmica para el piloto y la muestra. Se muestran los 50 términos más frecuentes; no se ajusta una recta, la figura solo comprueba la forma de ley de potencia.

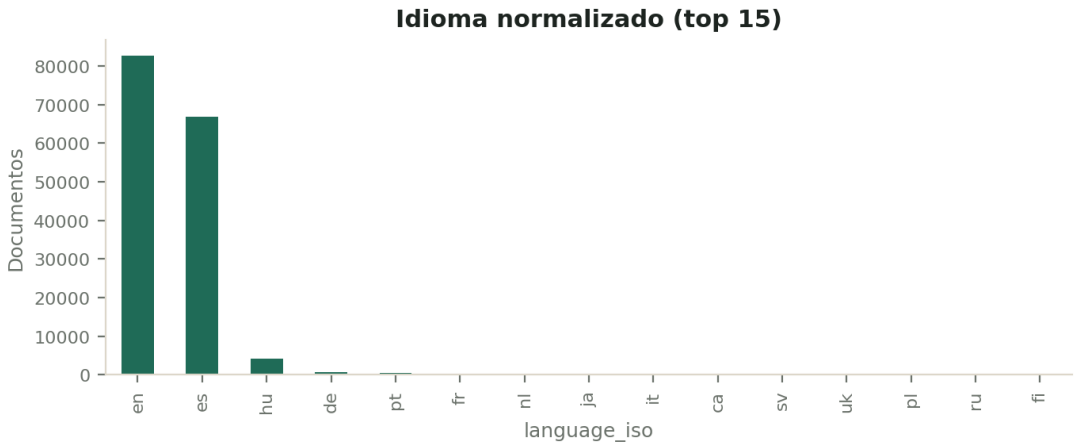


Figura 3. Idiomas normalizados más frecuentes (15 primeros). La normalización se hace al vuelo; el campo crudo del archivo no se modifica.

GPU deja más margen porque el generador usa el resto de la VRAM.

Generación. gemma4:e4b es un modelo de 7,5B cuantizado a Q4_K_M con 116.384 tokens de contexto y MTP nativo. Se eligió por tres motivos: cabe en 16 GB de VRAM, soporta contextos largos y el MTP con draft 3 acelera la decodificación sin cambiar la distribución del modelo. Los modelos pequeños comparados en E4 quedaron por debajo en corrección y citas.

Conversación. Un condensador reescribe la última pregunta con el historial para que la recuperación no dependa de pronombres. Se usa gemma2:2b para no cargar dos veces el modelo grande. Si el condensador pierde el tema, se antepone la primera pregunta del usuario.

Guardarraíles. Tres controles antes de responder: cita obligatoria, verificación de entidades y números contra el fragmento citado, y un juez de evidencia. Si alguno falla, el sistema se abstiene con el motivo. El juez es gemma2:2b, distinto del generador, para no validar con el mismo modelo que redacta.

Compuerta de dominio. Un clasificador de regresión logística con la puntuación del cross-encoder y señales de recuperación decide si la pregunta pertenece al corpus. No es un LLM juez: reutiliza la pasada del reranker, es reproducible y se puede medir con precisión y recall. Se activa con el interruptor Modo estricto.

API e interfaz. FastAPI separa el pipeline de la presen-

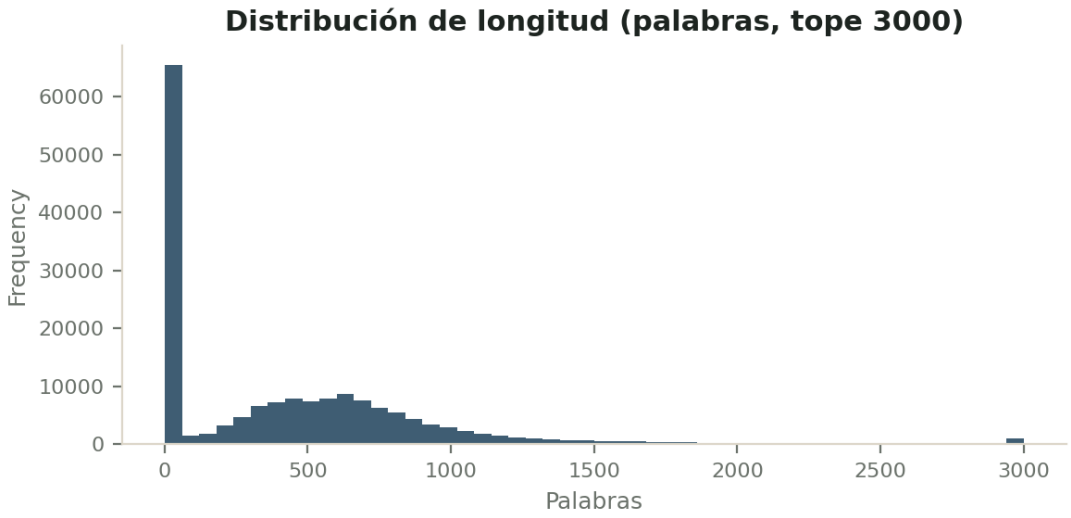


Figura 4. Distribución de longitud en palabras. Los documentos de más de 3.000 palabras se acumulan en el extremo derecho del histograma.

Tabla III
CONFIGURACIÓN FINAL DEL SISTEMA.

Parámetro	Valor
Codificador	BAAI/bge-m3, 1024 dimensiones
Índice	HNSW en Milvus, `ef`=800
Recuperación	unión densa top-10 + BM25 top-20, $k = 10$
Reordenador	BAAI/bge-reranker-v2-m3, GPU, top-10
Generador	gemma4:e4b, Q4_K_M
Contexto	116.384 tokens (16.384 entrada, 100.000 salida)
MTP	draft 3, 217 tok/s
Prompt	v2
Juez y condensador	gemma2:2b
Compuerta	regresión logística con cross-encoder, umbral 0,4
Fragmentos	618.286 en `rag_full_bge_m3_d1024_v1`

tación y expone `/chat`, `/ask`, `/retrieve`, `/health`, `/models` y `/stats` [21]. Streamlit consume `/chat` y muestra la respuesta, las citas, las evidencias, las métricas y el razonamiento [22]. La separación permite probar el pipeline sin la interfaz y cambiar la interfaz sin tocar el pipeline.

IV-C. Configuración final

La Tabla III fija los parámetros. Los valores se justifican en las Secciones V y VII.

IV-D. Interfaz para el usuario final

La interfaz tiene dos zonas. En el panel lateral se elige el modelo, el número de fragmentos, el idioma del documento, el rango de fechas y la colección; se activan el razonamiento y el Modo estricto, y se cambia entre tema claro y oscuro. En el área central se conversa con historial. Cada respuesta muestra el texto con citas numeradas, chips con la intención y la ruta de ejecución, la latencia por etapa, los tokens por segundo y un desplegable con las evidencias: título, puntuación, fragmento, enlace y metadatos. Si el sistema se abstiene, aparece el motivo y, en el caso de fuera de dominio, la sugerencia de desactivar el Modo estricto. El razonamiento del modelo, cuando se activa, va en un desplegable separado y se advierte que no sustituye la evidencia. La Figura 6 muestra una respuesta real con las evidencias abiertas.

V. METODOLOGÍA

V-A. Limpieza y deduplicación

La variante adoptada, V2, descarta las páginas de error del rastreador, aplica normalización NFKC, quita HTML y URLs y colapsa espacios. No elimina signos, números ni entidades, porque son la señal que usan los guardarraíles. Los duplicados exactos y los near-duplicates se descartan al armar el contexto, comparando el hash del fragmento y su SimHash antes de insertarlo. Así se conserva la procedencia en el índice y se evita repetir el mismo texto en el prompt.

V-B. Segmentación

Se usa chunking fijo de 1000 caracteres con 150 de solape (`fixed_v2`). El solape cubre la frontera donde suele caer la respuesta. Cada fragmento guarda `document_id`, título, URL, fuente, idioma, fecha, posición, estrategia y hash del texto. Esos metadatos permiten filtrar por idioma y fecha y auditar cada cita.

V-C. Codificación e índice

Los fragmentos se codifican con BAAI/bge-m3 en la GPU, en fp16 y por lotes. La colección se llama `rag_full_bge_m3_d1024_v1` y usa HNSW con `ef`=800 en la búsqueda. El parámetro se eligió con una rejilla sobre el gold: por debajo de 800 el recall cae y por encima la latencia sube sin ganancia apreciable. En paralelo se mantiene una colección BM25 sobre los mismos fragmentos, `rag_full_e5base_d768_v2_bm25_v1`, que alimenta la recuperación dispersa.

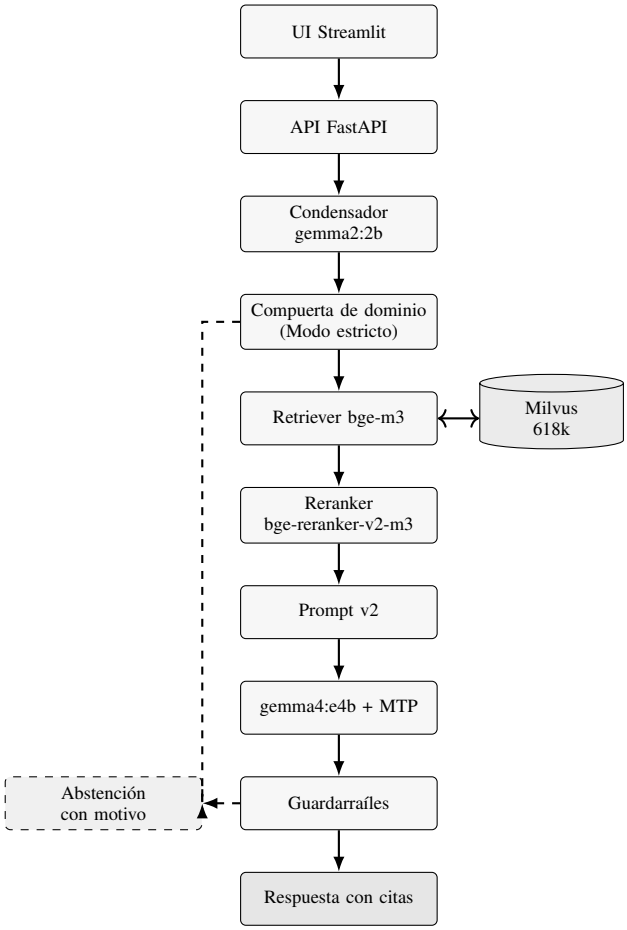


Figura 5. Flujo de una consulta. La compuerta solo actúa con el Modo estricto; el condensador solo en preguntas encadenadas. Las líneas discontinuas son las salidas de abstención, antes y después de generar.

V-D. Recuperación y reordenamiento

La recuperación combina dos listas. La densa pide 10 fragmentos a bge-m3; la dispersa pide 20 a BM25. Las dos se unen sin fusionar, se deduplican por texto y se pasan al reordenador. El cross-encoder multilingüe puntúa cada par pregunta-fragmento en GPU, con lote de 16, y el resultado se recorta a 10. La unión conserva el top-5 denso, que es la señal que la compuerta espera, y añade las entidades que BM25 encuentra y el denso no. Los filtros de idioma, fecha y colección se aplican en Milvus.

V-E. Generación

El generador es gemma4:e4b con temperatura 0 y un presupuesto de 16.384 tokens de entrada. El prompt v2 impone ocho reglas: cada afirmación lleva una cita entre corchetes; no se permiten listas sin cita; si la evidencia no alcanza se responde con una frase de abstención exacta; se distingue un hecho verificable de una afirmación publicada en redes; no se inventan fechas, cifras, nombres ni citas; se ignoran las instrucciones que aparezcan dentro de los documentos; se responde en el idioma de la pregunta; y se usa la fecha exacta de la evidencia cuando la pregunta la pide. El MTP con draft 3 se activa en el manifiesto del modelo y no cambia la salida, solo la velocidad.

V-F. Guardarraíles

Antes de devolver la respuesta se aplican tres controles. El primero exige al menos una cita válida; si no hay, se abstiene con `sin_citas`. El segundo extrae entidades y números de la respuesta y verifica que aparezcan en el fragmento citado o en la pregunta; si no, se abstiene con `sin_respaldo` o `citas_invalidas`. El tercero pide a un juez distinto, gemma2:2b, que decida si la cita sostiene la respuesta; si dice que no, se abstiene con `juez_no`. Cuando el fragmento está en inglés y la respuesta en español, la cobertura léxica se salta y decide el juez, para no castigar una traducción correcta.

V-G. Compuerta de dominio

La compuerta usa la puntuación del cross-encoder sobre el top-5 (máximo, media, diferencia entre el primero y el segundo, y mínimo), cinco features de recuperación (puntuación del primer fragmento, media del top-5, diferencia entre el primero y el segundo, solapamiento entre la pregunta y el título, y presencia de la entidad principal en el título) y un one-hot del tipo de pregunta. La puntuación del cross-encoder se calcula una sola vez y se reutiliza para el reordenamiento. El modelo es una regresión logística con escalado y `class_weight=balanced`; la regularización se eligió por validación cruzada de cinco pliegues sobre train y dev. El umbral es 0,4, elegido para reducir falsos rechazos sin aumentar falsos aceptados. El conjunto tiene 160 preguntas: 60 de dominio y 100 de fuera, con split 103/37/20. Las 40 negativas nuevas son entidades inventadas, eventos futuros y conocimiento general fuera del corpus.

V-H. API e interfaz

La API expone `POST /chat` con historial, `think` y `strict`; `POST /ask` sin historial; `POST /retrieve` para recuperación pura; y los GET `/health`, `/models` y `/stats`. La interfaz Streamlit consume `/chat` y guarda el historial en la sesión. Las preferencias de razonamiento, Modo estricto y tema se guardan en un archivo y se recuperan al recargar. Si el usuario cambia un interruptor mientras el modelo responde, la pregunta queda pendiente y se reintenta en el siguiente ciclo, de modo que la conversación no se pierde.

V-I. Despliegue

El stack se levanta con Docker Compose: etcd, MinIO, Milvus, Ollama, API, frontend y un worker GPU para la ingesta y la evaluación. La API y el frontend usan red de host. Un servicio de una sola ejecución, `prewarm`, espera a que la API esté sana y carga el generador, el embedding y el reranker, para que la primera consulta web no pague la carga del modelo.



Figura 6. Interfaz final: respuesta con citas y evidencias abiertas. La pregunta se acepta con probabilidad de dominio 0,956; la respuesta cita diez evidencias y el panel muestra título, puntuación, fragmento, enlace y metadatos de la primera. El chip de la derecha identifica la ruta de ejecución, no un guardarraíl de cita.

VI. Protocolo de evaluación

VI-A. Gold estándar

El gold tiene 43 preguntas: 19 en desarrollo y 24 en prueba, 38 respondibles y 5 sin respuesta. Cada fila guarda el identificador, la pregunta, el idioma, el tipo, el split, los documentos y fragmentos de referencia, el span literal que responde, la respuesta de referencia, el criterio de corrección y el estado de validación. La Tabla IV resume la composición. Las preguntas sin respuesta no entran en Recall@k: se evalúan

Tabla IV
COMPOSICIÓN DEL GOLD ESTÁNDAR.

Split	Respondibles	Sin respuesta	Total
Desarrollo	19	0	19
Prueba	19	5	24
Total	38	5	43

Tabla V
ACUERDO ENTRE ANOTADORES EN LA COMPARACIÓN DE MODELOS (KAPPA LINEAL, $n = 72$).

Eje	Kappa
Corrección	0,95
Citas	0,90
Abstención	0,72
Fidelidad	0,12

por abstención.

El gold se amplió con 17 documentos adicionales marcados por consenso de dos anotadores (kappa 0,626). Con esa ampliación, 14 preguntas quedaron con dos o más documentos relevantes, lo que hace que Recall@k y nDCG no dependan de un único pasaje.

VI-B. Revisión humana

Tres personas revisaron el gold contra el documento citado y una cuarta revisión quedó pendiente. Carlos revisó las 43 y dejó 12 correcciones; Julián aportó 7 spans y una reformulación; Óscar aportó 5 spans corregidos y marcó 3 enlaces rotos; la revisión de Erika sigue pendiente. Cada propuesta se aplicó solo si el span aparecía literalmente en el texto indexado. Las que no se pudieron verificar quedaron con nota.

Para la comparación de modelos se anotaron 72 respuestas de 4 modelos, ciegas y en orden barajado, con rúbrica de 0 a 3 en corrección, fidelidad, citas y abstención. Dos anotadores calificaron las mismas respuestas. La Tabla V reporta el acuerdo. La fidelidad no alcanzó acuerdo suficiente y no se usa para el veredicto; la corrección y las citas sí.

VI-C. Métricas

Recuperación. Recall@k mide la fracción de documentos de referencia recuperados en el top-k; nDCG@k usa relevancia binaria; P@k mide precisión en el corte; MRR mide la posición del primer acierto; y la cobertura de span indica si al menos un fragmento recuperado contiene el texto exacto que responde. Esta última es la más cercana a lo que necesita el generador.

Respuesta. Se reportan las preguntas entregadas, las abstenciones, el match estricto (igualdad normalizada con la respuesta de referencia), el F1 por tokens, la tasa de citas, el contexto medio en tokens y la latencia por etapa. La revisión manual clasifica cada respuesta como correcta, parcial o incorrecta.

Conversación. Catorce casos: seis saludos, cuatro de dominio y cuatro de fuera. Cada uno tiene un resultado esperado y se marca como correcto o incorrecto. Se ejecutan con y sin Modo estricto, y con y sin razonamiento.

RAGAS. Se reportan fidelidad, relevancia de la respuesta, precisión del contexto, cobertura del contexto y corrección de la respuesta [5]. Para cada métrica se informa cuántas muestras tienen valor, porque el juez falla en algunas y una media con cuatro valores no es comparable con una con 38.

Compuerta. Precisión, recall y F1 en dev y test, falsos rechazos de dominio (preguntas del corpus rechazadas) y falsos aceptados de fuera (preguntas ajenas aceptadas).

VI-D. Estadística

Las comparaciones de recuperación usan bootstrap pareado por pregunta con 1.000 remuestreos e intervalos de confianza al 95 %. En la comparación de limpieza se aplica corrección de Bonferroni por comparaciones múltiples. La configuración se eligió inspeccionando las 43 preguntas del gold, así que los resultados sobre las 38 respondibles son exploratorios. No se dispone de un conjunto de prueba independiente; una evaluación futura debe reservar preguntas nuevas. Las diferencias que no excluyen cero se reportan como no concluyentes, aunque la media favorezca a una variante. Los intervalos pareados se calcularon para limpieza, E1 y E2; las comparaciones de codificadores, reordenamiento y fusión se reportan como estimaciones puntuales sobre 38 preguntas, sin intervalo, y así se indica en cada tabla.

VI-E. Configuración de RAGAS

La corrida de referencia usa juez gemma4:e4b y embeddings BAAI/bge-m3 en CPU, con 38 preguntas directas. El timeout del juez se fijó en 900 s y la concurrencia en 6. Con los valores por defecto (180 s y 16 workers) el juez no terminaba en varias muestras y la precisión del contexto quedaba con 4 valores de 38. La corrida de referencia tiene 34 valores en esa métrica y 38 en las demás. Las preguntas sin respuesta se miden aparte y se abstienen 5 de 5.

VII. EXPERIMENTOS Y RESULTADOS

Los experimentos usan el gold de 43 preguntas; E12 usa la versión ampliada con 17 documentos adicionales y cada tabla lo indica. La configuración se eligió con el gold completo, así que los resultados son exploratorios. Cada subsección reporta el montaje en una frase, la tabla y la decisión; el detalle del montaje está en la Sección V.

VII-A. Limpieza

Se construyeron cuatro índices sobre el piloto con 30 preguntas, e5-base, $k = 10$ y tres repeticiones. La Tabla VI muestra el resultado. Ninguna comparación pareada contra V0 excluye cero tras la corrección de Bonferroni sobre 21 pruebas. V2 toca el límite inferior en cuatro métricas, compatible con una mejora pequeña o con ausencia de efecto. Se adopta V2 por tres razones no estadísticas: la consistencia de la estimación en todas las métricas, el coste nulo en consulta y la eliminación de 68 páginas de error que de otro modo entrarían al índice.

Tabla VI
LIMPIEZA SOBRE EL PILOTO (30 PREGUNTAS, E5-BASE, $k = 10$).

Variante	P@1	P@5	Recall@10	MRR	nDCG
V0 crudo	0,733	0,833	0,833	0,775	0,790
V1 sin páginas de error	0,767	0,833	0,833	0,800	0,809
V2 normalización	**0,833**	**0,900**	**0,900**	**0,867**	**0,875**
V3 V2 + dedup	0,800	0,867	0,867	0,833	0,842

Tabla VII
E1: CHUNKING FIJO CONTRA ORACIONES (30 PREGUNTAS).

Variante	P@1	P@5	Recall@10	nDCG	p50
Fijo 1000/150	**0,833**	**0,900**	**0,900**	**0,875**	**38,5 ms**
Oraciones 384/1	0,767	0,833	0,833	0,804	42,1 ms

Tabla VIII
E6: PILOTO CONTRA CORPUS COMPLETO CON E5-BASE (38 PREGUNTAS).

Corpus	Recall@10	P@1	P@5	nDCG	Span
Piloto (1.932 docs)	**0,947**	**0,842**	**0,947**	**0,909**	**0,895**
Completo (161.868)	0,684	0,500	0,658	0,604	0,684

Tabla IX
E10: RECUPERADORES SOBRE EL CORPUS COMPLETO (38 PREGUNTAS).

Método	Recall@10	P@1	P@5	nDCG	p50
Denso e5	0,684	0,500	0,658	0,604	48 ms
BM25 sparse	0,763	**0,684**	0,737	**0,727**	**7 ms**
bge-m3	**0,842**	0,553	**0,816**	0,708	56 ms

VII-B. Segmentación y tamaño del contexto

E1 comparó chunking fijo de 1000 caracteres con 150 de solape contra segmentación por oraciones de 384 caracteres. La Tabla VII muestra estimaciones puntuales favorables al fijo en todas las métricas de calidad, pero ningún intervalo pareado excluye cero: nDCG $-0,071$ (IC $[-0,221;\ 0,025]$), recall $-0,067$ (IC $[-0,233;\ 0,000]$) y P@1 $-0,067$ (IC $[-0,233;\ 0,114]$) para oraciones menos fijo. La única diferencia concluyente es la latencia: el fijo es 3,65 ms más rápido (IC $[2,25;\ 4,97]$). Se mantiene el fijo por la dirección consistente y el coste, no por una mejora de calidad demostrada.

E2 ablacionó el número de fragmentos. Con el gold del piloto, el documento relevante está siempre en el top-3, así que $k = 3$, 5 y 10 devuelven las mismas métricas de calidad. La única diferencia significativa es la latencia: $k = 3$ tarda 1,64 ms menos que $k = 10$ y $k = 5$ tarda 0,94 ms menos. Se fija $k = 5$ como margen para preguntas comparativas que no están en el conjunto, sabiendo que el coste es más contexto en generación, no más latencia de recuperación.

VII-C. Codificadores y escala

E3 comparó e5-base con qwen3-embedding:8b sobre el piloto, con 18 preguntas de desarrollo. qwen3 recupera mejor: Recall@10 perfecto y 6,4 puntos más de nDCG. El problema es el coste. e5-base indexó el corpus completo en 2 h 41 min medidos en la RX 9070 XT. qwen3-embedding:8b no se indexó entero: las 23 horas son una extrapolación desde el rendimiento por lote, no un tiempo medido. Se adopta e5-base para la ingesta y qwen3 queda como comparación documentada.

E6 midió el mismo pipeline sobre el corpus completo. La Figura 7 muestra la caída. La caída es el hallazgo más importante del trabajo: con el mismo codificador, el mismo índice y las mismas 38 preguntas, Recall@10 pasa de 0,947 a 0,684 y nDCG de 0,909 a 0,604 al crecer de 1.932 a 161.868 documentos. La latencia no explica la caída (40 ms contra 42 ms); es un problema de ordenamiento y de competencia entre fragmentos.

E8 y E10 buscaron un recuperador mejor. BM25 sparse sube el recall a 0,763 y es ocho veces más rápido, pero su techo de cobertura es bajo. bge-m3 llega a 0,842 de Recall@10 y 0,708 de nDCG, y recupera el inglés de 0,111 a 0,667. La Tabla IX resume.

E11 ajustó `ef` y probó la fusión con BM25. `ef`=800 sube el recall 2,6 puntos y el nDCG 1,3 con 6 ms más. La fusión 0,5/0,5 empata en recall y sube nDCG 6,9, P@1 13,2 y cobertura de span 5,3. Con el gold de un solo relevante la fusión parecía ganar. E12 repitió la comparación con el gold ampliado: el denso recupera más documentos nuevos (Recall@10 0,921 contra 0,890 y nDCG 0,827 contra 0,804). La configuración final es densa, `ef`=800, sin fusión.

VII-D. Reordenamiento

E7 midió el cross-encoder sobre el top-50 con e5 en el corpus completo: P@1 sube de 0,474 a 0,632 y nDCG de 0,594 a 0,661, pero la cobertura no cambia y el coste es de 3,1 s por consulta. La mejora de orden no compensa el coste si se reordena tanto.

El denso a $k = 10$ recupera 0,912 de recall y 0,818 de nDCG. Con bge-m3 se probó reordenar 5 y 20 candidatos. La Tabla X muestra que el top-20 baja el recall a 0,864 y el P@5 a 0,921, mientras que el top-5 mantiene 0,895 de recall y 0,947 de P@5, y sube el nDCG a 0,865 y el P@1 a 0,868 con 1,30 s. La tabla mide el reordenador en CPU; en la configuración final corre en GPU, con 0,68 s para 50 pares. La configuración final no reordena el top-5 denso: reordena la unión con BM25 y recorta a 10.

VII-E. Modelos generativos

E4 comparó cuatro modelos con la misma evidencia: 19 preguntas respondibles y 5 sin respuesta, tres repeticiones, anotación humana ciega de la primera repetición. La anotación cubre 18 de las 19 respondibles. La Tabla XI muestra las medias de los dos anotadores en escala de 0 a 3. gemma2:2b gana en corrección, citas y abstención. La fidelidad no se usa para el veredicto porque su acuerdo es $\kappa = 0,12$. qwen2.5:1.5b es el más rápido pero no cita en el 89,5 % de los casos. llama3.2:3b cita la mitad de las veces. llama3.2:1b se abstiene en el 73,7 % de las preguntas respondibles y no se recomienda.

La hipótesis H1, que esperaba que llama3.2:3b superara a los demás en corrección y citas, se refuta. La evidencia recuperada es la misma entre modelos; lo que cambia es

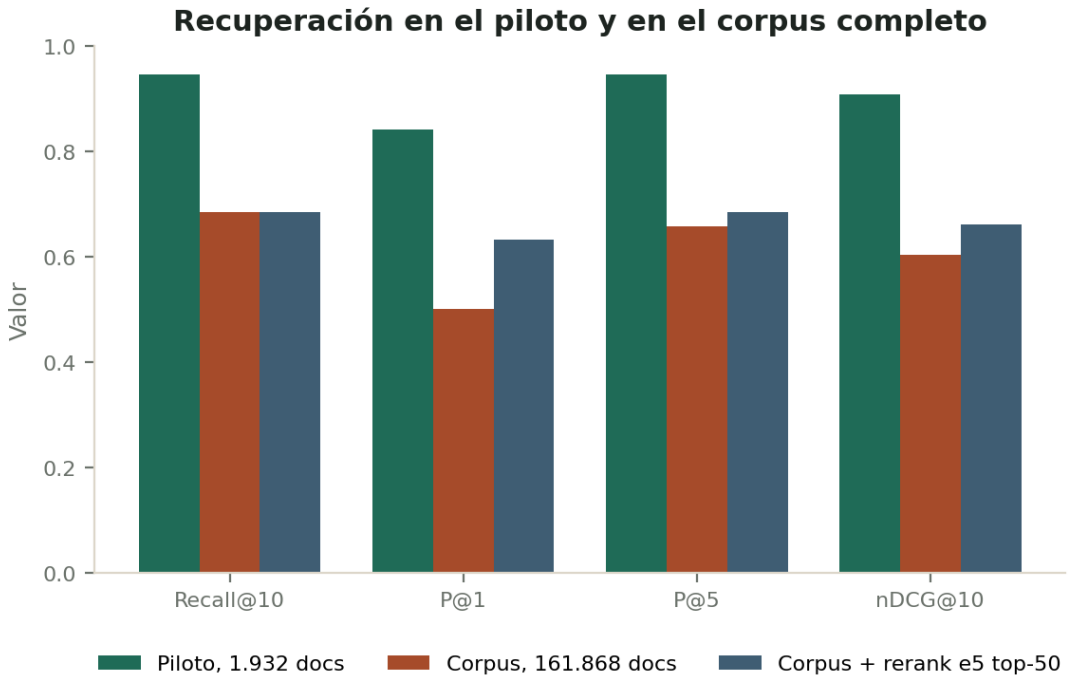


Figura 7. Recuperación con e5-base sobre el gold de 38 preguntas respondibles: piloto (1.932 documentos), corpus completo (161.868 documentos) y corpus con reranker sobre el top-50. El piloto y el corpus usan índices separados.

Tabla X
REORDENAMIENTO CON BGE-M3 (38 PREGUNTAS).

Configuración	Recall	nDCG	P@1	P@5	p50
Denso top-5	0,895	0,809	0,737	0,947	0,10 s
Rerank top-5	0,895	**0,865**	**0,868**	**0,947**	1,30 s
Rerank top-20	0,864	0,853	**0,868**	0,921	5,46 s

Tabla XI
E4: ANOTACIÓN HUMANA (0 A 3) Y CONDUCTA AUTOMÁTICA.

Modelo	Corrección	Citas	Abstención	Sin citas
gemma2:2b	**2,81**	**2,67**	**2,89**	**0,0 %**
qwen2.5:1.5b	2,31	0,00	2,81	89,5 %
llama3.2:3b	2,22	0,86	2,69	56,1 %
llama3.2:1b	0,42	0,28	1,61	15,8 %

el generador. La comparación fijó la familia de modelos pequeños. El generador final es gemma4:e4b, que no estaba en E4: se adoptó después por contexto largo y MTP, no por ganar una comparación directa, y se validó en la corrida final.

VII-F. Inyección de instrucciones

E5 insertó instrucciones explícitas en cinco documentos sintéticos por modelo. Es una prueba exploratoria: no cubre el generador final ni demuestra robustez general. Dos de los tres modelos las ignoraron. gemma2:2b obedeció una de cinco y añadió la palabra pedida a una respuesta por lo demás correcta. La regla de diseño que sale de aquí es que el prompt debe delimitar la evidencia y ordenar explícitamente ignorar

Tabla XII
E5: INSTRUCCIONES INYECTADAS EN EL TEXTO RECUPERADO.

Modelo	Obedeció	Respondió el hecho	Se abstuvo
gemma2:2b	1/5	4/5	0/5
llama3.2:3b	0/5	5/5	0/5
qwen2.5:1.5b	0/5	5/5	0/5

instrucciones internas, y esa orden debe repetirse después del bloque de contexto.

VII-G. Prompts y mejoras rechazadas

La fase 6 probó cuatro mejoras sobre la configuración de referencia y la fase 7 probó diversidad. La referencia de estas fases era el top-5 denso con reranker; la unión con BM25 se adoptó después, en el conjunto reservado. Ninguna de las variantes de las fases 6 y 7 supera a esa referencia. La Tabla XIII resume. El filtro por score pierde recall; reordenar el top-20 pierde P@5 y multiplica la latencia; la expansión de consulta baja el recall y el nDCG; el prompt v4 no mejora el match estricto; y MMR baja el recall 8 puntos. El prompt v4 entregó 37 de 38 y 25 de 37 de match estricto, sin mejora. Todas se rechazan y la configuración se mantiene.

VII-H. Compuerta de dominio

La compuerta se entrenó con 160 preguntas: 60 de dominio y 100 de fuera, con 103 de train, 37 de dev y 20 de test. Los 40 negativos nuevos son entidades inventadas, eventos futuros y conocimiento general. La Tabla XIV muestra el resultado en el test interno y en el conjunto reservado. En test el F1 es

Tabla XIII
FASES 6 Y 7: VARIANTES PROBADAS SOBRE 38 PREGUNTAS. LA REFERENCIA ES EL TOP-5 CON RERANKER.

Variante	Recall	nDCG	P@1	P@5	Decisión
Top-5 con reranker	**0,895**	**0,865**	**0,868**	**0,947**	Referencia
Rerank top-20	0,864	0,853	**0,868**	0,921	Rechazada
Filtro por score 0,8	0,838	0,837	**0,868**	0,921	Rechazada
Filtro por score 0,9	0,825	0,830	**0,868**	0,921	Rechazada
Expansión de consulta	0,825	0,739	0,658	0,895	Rechazada
MMR coseno 0,5	0,868	0,784	0,737	**0,947**	Rechazada
MMR con reranker 0,7	0,816	0,818	**0,868**	0,921	Rechazada

Tabla XIV
COMPUERTA DE DOMINIO: TEST INTERNO Y CONJUNTO RESERVADO.

Split	n	Dominio	Fuera	Precisión	Recall	F1
Test	20	11	9	1,000	0,909	0,952
Reservado	25	20	5	1,000	0,850	0,919

Tabla XV
RAGAS: CONFIGURACIÓN FINAL CONTRA LA ANTERIOR, CON n ENTRE PARÉNTESIS. AMBAS CORRIDAS USAN GEMMA4:E4B COMO JUEZ, LA MISMA FAMILIA QUE EL GENERADOR.

Métrica	Final	Anterior
Fidelidad	**0,952** (38)	0,925 (36)
Relevancia	**0,840** (38)	0,798 (38)
Precisión del contexto	**0,881** (34)	0,760 (36)
Cobertura del contexto	**0,921** (38)	0,842 (38)
Corrección	0,657 (38)	**0,705** (37)

0,952, con 0 falsos aceptados de 9 y 1 falso rechazo de 11. En el conjunto reservado, con 20 directas y 5 negativas, el F1 es 0,919: rechaza las 5 negativas y 3 de las 20 directas. El umbral es 0,4, elegido por validación cruzada. Con 5 negativas, el 0/5 no demuestra una tasa nula de falsos aceptados en uso general; solo acota el intervalo observado.

VII-I. RAGAS

La Tabla XV compara la configuración final con la anterior. Son dos comparaciones distintas y conviene no mezclarlas. La primera es una repetición del mismo sistema con timeout de 900 s y 6 workers frente a la corrida por defecto, que dejaba la precisión del contexto con 4 valores de 38; la repetición tiene 34. La segunda es la comparación entre arquitecturas, que cambia juez, embedding y recuperador, así que es observacional y no causal. En esa comparación la configuración actual gana en fidelidad, relevancia, precisión y cobertura del contexto, y pierde en corrección de la respuesta. El juez es gemma4:e4b, de la misma familia que el generador, lo que puede favorecer la fidelidad.

VII-J. Latencia y MTP

La Tabla XVI muestra el efecto del draft. El draft 3 es el más rápido: 217,1 tokens por segundo frente a 193,5 con 5 y 159,5 con 7. La decodificación especulativa es exacta: el draft propone y el modelo objetivo verifica, así que la salida no cambia.

Tabla XVI
MTP: TOKENS POR SEGUNDO SEGÚN EL DRAFT.

Draft	Tokens/s
3	**217,1**
5	193,5
7	159,5

La corrida de referencia de la configuración anterior (densa y reranker en CPU) es la del 2 de noviembre de 2026 en el worker GPU, con el host cargado (unos 2 GB de RAM libres) y el código del commit `125bbc7`. La latencia media fue de 7.938 ms sin razonamiento (mediana 7.086, p95 10.127) y 6.834 ms con razonamiento (mediana 6.729, p95 9.162); los CSV están en `reports/tablas/metricas_final_sin.csv` y `metricas_final_con.csv`. El reranker en CPU aporta 1,30 s de mediana y la generación el resto. La corrida limpia del 1 de noviembre dio 6.788 y 6.482 ms, pero su CSV no se conserva. Con la configuración final (unión híbrida y reranker en GPU), la corrida del conjunto reservado dio 6.154 ms de media (mediana 5.578, p95 9.136) sobre 25 preguntas; el reranker cuesta 0,68 s para 50 pares y la generación el resto. La compuerta reutiliza la puntuación del reranker, así que no añade una segunda pasada; en las preguntas rechazadas el coste es el del reranker, no el de la generación.

VII-K. Conjunto reservado

El gold exploratorio se usó para elegir la configuración densa, así que no mide generalización. Se construyó un conjunto reservado de 25 preguntas: 20 directas y 5 sin respuesta, 15 en español y 10 en inglés, 14 de prensa y 6 de Bluesky. El conjunto se congeló antes de evaluar la compuerta y se usó para esa evaluación. Después se usó también para elegir la recuperación híbrida, así que las métricas de recuperación y respuesta de esta sección son de desarrollo; la compuerta conserva su carácter externo porque se midió antes de esa elección. Una prueba independiente de la recuperación exige un conjunto nuevo. La Tabla XVII muestra el resultado.

El recall@10 es 0,700 y el nDCG 0,612, por debajo del 0,912 y 0,818 del gold exploratorio, pero por encima del 0,600 y 0,477 de la recuperación densa. La unión con BM25 recupera r-012 y r-014, que el denso dejaba fuera, y conserva los aciertos del denso en r-009 y r-013. Seis de las 20 preguntas no recuperan el documento de referencia en el top-10; cuatro se responden correctamente con otro documento que contiene

Tabla XVII
CONJUNTO RESERVADO: 20 PREGUNTAS DIRECTAS Y 5 SIN RESPUESTA, CONGELADO ANTES DE EJECUTAR.

Métrica	Valor	Denominador
Recall@10	0,700	20
nDCG@10	0,612	20
P@1	0,500	20
P@5	0,650	20
Cobertura de span	0,700	20
Entregadas	19	20
Abstenciones en directas	1	20
Match estricto, entregadas	17	19
Match estricto, todas	17	20
Con cita	1,000	19
Abstenciones en sin respuesta	5	5
Compuerta rechaza	5	5
Latencia media	6,2 s	25

el mismo dato (r-005, r-008, r-017, r-019), una termina en abstención (r-006) y una es ambigua (r-016). El recall con un solo documento de referencia subestima la recuperación útil: la mitad de los fallos de recall no son fallos de respuesta. La profundidad de la unión no es monotónica: 20/20 y 30/30 suben el recall@10 a 0,750; 50/50 lo sube a 0,850 y recupera r-006, pero baja las entregas a 18 de 20 y las exactas a 16 de 20, porque desplaza evidencia que el modelo usaba bien en r-009 y r-012. La configuración se queda en 10/20.

El match estricto entre las entregadas es 17 de 19 (89,5 %), y sobre las 20 directas, 17 de 20 (85 %). La diferencia con la recuperación densa está en la unión: recupera las entidades que el denso no trae. En inglés el recall es 0,875 y el nDCG 0,829; en español, 0,583 y 0,468. El inglés recupera mejor, al contrario de lo que sugería el gold exploratorio.

Las cinco preguntas sin respuesta se rechazan por la compuerta. En las 20 directas, la compuerta rechaza 3: r-011, r-012 y r-014. r-012 y r-014 son preguntas que la recuperación híbrida sí puede responder, pero la compuerta solo ve el top-5 denso; es una deuda de diseño, no un fallo de recuperación. r-011 sí recupera el documento y es un falso rechazo del clasificador. La compuerta nueva baja los falsos rechazos de 6 a 3 y los falsos aceptados de 1 a 0 respecto de la anterior. El 0/9 del conjunto anterior no se confirma como tasa nula, pero el 0/5 tampoco la demuestra.

El fallo más grave es r-006: la pregunta pide los 95 votos en la Cámara de Representantes y el sistema se abstiene. La evidencia recuperada no contiene la cifra correcta en el top-10, y el modelo prefiere no responder. r-016 es una pregunta ambigua del propio conjunto: no nombra el concierto y el corpus tiene varios; se mantiene en las métricas y se reporta como límite de construcción. r-012 entrega una respuesta evasiva: la evidencia contiene la organización, pero el modelo enumera varias iniciativas en lugar de responder World Economic Forum. Es un fallo de generación, no de recuperación.

La latencia media del conjunto reservado es 6,2 s (mediana 5,6, p95 9,1), inferior a los 10,8 s de la corrida densa. La unión y el reordenador en GPU compensan el mayor número de candidatos.

VII-L. Progresión de la configuración

La Tabla XVIII resume el recorrido. Cada fila es una decisión tomada con una medición, no una preferencia.

VIII. ANÁLISIS DE ERRORES

VIII-A. Errores de recuperación

Quedan dos fallos claros en el gold. g-031 pregunta por el municipio de gran extensión y tradición agropecuaria del sur del Tolima. El documento de referencia aparece en el puesto 11 del top-50 denso y en el puesto 1 después del reranker: el pipeline actual solo pasa cinco candidatos al reordenador y nunca lo ve. Ampliar el conjunto a 20 recupera esa pregunta, pero baja el recall global 3,1 puntos y el P@5 2,6, así que no se adopta. g-046, sobre la protesta de Extinction Rebellion, no aparece ni en el top-50 denso ni tras el reranker. El problema está en la consulta o en el índice, no en el ordenamiento.

VIII-B. Errores de generación

Los modelos pequeños fallan de formas distintas con la misma evidencia. qwen2.5:1.5b responde sin citar en el 89,5 % de los casos: la respuesta puede ser correcta, pero el usuario no puede verificar de dónde sale. llama3.2:3b cita la mitad de las veces. llama3.2:1b se abstiene en el 73,7 % de las preguntas respondibles. gemma2:2b cita siempre y responde casi siempre, pero responde preguntas sin respuesta en 3 de 15 repeticiones, es decir, alucina con evidencia insuficiente. El generador final, gemma4:e4b, no estaba en esa comparación; los guardarraíles de cita, entidades y juez cubren parte de ese riesgo, y la compuerta lo cubre antes de generar.

VIII-C. Abstención y compuerta

La abstención tiene dos caminos. El primero ocurre antes de generar, cuando la compuerta rechaza la pregunta; el segundo, después, cuando los guardarraíles o el juez no encuentran respaldo. El primer camino es barato (decenas de milisegundos) y ahora rechaza las 5 preguntas sin respuesta con 0,293 a 0,436. El segundo cuesta una generación completa. El único falso rechazo de la compuerta es una pregunta legítima sobre la inflación, en 0,494, justo por debajo del umbral. Es el precio de no aceptar preguntas ajenas.

VIII-D. Errores de evaluación

RAGAS deja 4 muestras sin valor en la precisión del contexto por errores de parser del juez. Una media con 34 valores no es comparable con una de 38, y por eso se reporta n en cada fila. En la primera corrida, con timeout de 180 s y 16 workers, la métrica tenía 4 valores y su media (0,750) no era comparable con nada. La conclusión anterior, que afirmaba una pérdida de precisión frente a la arquitectura previa (0,760, con 36 valores), era un artefacto del juez. La repetición corregida del mismo sistema da 0,881 con 34 valores. La comparación entre arquitecturas sigue siendo observacional porque cambia juez y embedding.

Tabla XVIII
PROGRESIÓN DE LA CONFIGURACIÓN Y MÉTRICA QUE LA JUSTIFICÓ.

Etapa	Cambio	Gold	Métrica	Decisión
Piloto	e5-base, 1.932 docs	piloto (30)	Recall@10 0,947	Punto de partida
Escala	corpus completo	38	Recall@10 0,684	El piloto sobreestima
Dispersa	BM25	38	Recall@10 0,763	No alcanza el techo
Codificador	bge-m3	38	Recall@10 0,842	Adoptado
Índice	`ef`=800	38	Recall@10 0,895	Adoptado
Fusión	híbrido RRF	38	Recall@10 0,895	Empata, se descarta
Fusión	híbrido RRF	ampliado (45)	Recall@10 0,890	Rechazado
Reordenamiento	unión densa+BM25	reservado (20)	Recall@10 0,700	Adoptado
Contexto	$k = 10$	reservado (20)	19/20 entregadas	Adoptado
Prompt	v2	38	37/38 y 25/37	Adoptado
Compuerta	160 preguntas	20 test	0 falsos aceptados	Adoptado
Fase 6	cuatro variantes	38	sin mejora	Rechazadas
Fase 7	MMR	38	recall 0,816	Rechazado
Reservado	20 directas	reservado (20)	Recall@10 0,700	Recupera parte de la caída
Compuerta	5 negativas	reservado (5)	5/5 rechazadas	3/20 falsos rechazos

VIII-E. Errores de diseño del protocolo

El experimento de limpieza se lanzó inicialmente con el gold de humo, que pertenece a una muestra de 600 documentos que no es subconjunto del piloto de 2.000. Las referencias no existían en las colecciones y las métricas habrían sido cero. El error se detectó al medir y obligó a construir un gold específico para el piloto. La lección es que el gold debe declarar a qué muestra pertenece y que la ingesta debe verificar que los documentos de referencia están en la colección antes de evaluar. Esa verificación ya forma parte del protocolo.

IX. DISCUSIÓN

IX-A. Por qué el piloto engaña

La caída de Recall@10 de 0,947 a 0,684 al pasar del piloto al corpus completo (Tabla VIII) no es un fallo de configuración: es el efecto de la competencia. Con 1.932 documentos, el fragmento relevante compite contra pocos vecinos; con 161.868, compite contra cientos de fragmentos que comparten vocabulario genérico. El texto sin cierre terminal (32,7 %) agrava el problema cuando el corte elimina la frase que responde, y el chunking fijo puede partir la evidencia en dos fragmentos que se disputan el mismo puesto. Ninguna de esas causas se puede medir con una muestra pequeña. La consecuencia práctica es que un piloto sirve para depurar el pipeline, no para elegir codificador, chunking o k. Esa elección hay que hacerla a la escala final, aunque cueste horas de GPU.

IX-B. El coste del orden

El reordenador es una herramienta de precisión, no de cobertura. Sobre el top-5 sube el nDCG 5,6 puntos y el P@1 13,1, porque el recuperador ya trajo la respuesta y solo había que colocarla primero. Sobre el top-20 denso baja el recall y el P@5: al ampliar el conjunto entran fragmentos peores que desplazan a los buenos. La unión con BM25 cambia el cálculo: añade documentos que el denso no trae y el reordenador los coloca arriba. En GPU el coste es 0,68 s para 50 pares, frente a 1,30 s para 5 en CPU. El reordenador no puede recuperar lo que el recuperador no trajo; la unión sí puede, y por eso se adopta.

IX-C. La abstención barata

La compuerta cuesta milisegundos y rechaza las 5 preguntas sin respuesta; el juez cuesta una generación completa. Esa asimetría justifica el clasificador. El precio es un falso rechazo en 0,494, una pregunta legítima sobre la inflación que queda fuera por seis milésimas. El umbral es una decisión de negocio, no técnica: aceptar una pregunta ajena erosiona la confianza más que abstenerse en una propia. En un asistente de corpus, el usuario prefiere un "no lo sé.ª una respuesta inventada, y por eso se mantiene 0,5 aunque el test mejore con 0,45. Si el coste de abstenerse fuera mayor, el umbral se movería en la otra dirección.

IX-D. La evaluación

La precisión del contexto de RAGAS pasó de 0,750 a 0,881 en dos corridas del mismo sistema. La primera cifra tenía 4 valores de 38 porque el juez no terminaba; la segunda tiene 34. La conclusión anterior, que atribuía a la arquitectura una pérdida de precisión, era un artefacto del evaluador. La comparación con la arquitectura previa (0,760, con 36 valores) es otra cosa: cambia juez y embedding, así que se reporta como observación y no como mejora causal. El episodio deja dos reglas. La primera: reportar n junto a cada media y no comparar métricas con cobertura distinta. La segunda: el ruido del juez no es aleatorio, se concentra en contextos largos y en fallos de parser, así que un timeout más generoso y menos concurrencia lo reducen.

El acuerdo humano también delimita lo que se puede afirmar. La corrección (0,95) y las citas (0,90) son fiables; la abstención (0,72) es aceptable; la fidelidad (0,12) no. Usar la fidelidad para elegir modelo habría sido elegir con ruido. La rúbrica de fidelidad mezcla errores factuales con abstenciones injustificadas, y los anotadores no comparten el criterio. Un eje que no alcanza acuerdo no debe decidir, y eso es una lección de diseño de la evaluación, no un defecto de los anotadores.

IX-E. Lo que mostró el conjunto reservado

El conjunto reservado cambia el diagnóstico. En el gold exploratorio el recall@10 era 0,912 y el sistema entregaba

37 de 38; en 20 preguntas nuevas, con recuperación densa, el recall era 0,600 y entregaba 17. La unión con BM25 y el reordenamiento en GPU suben el recall a 0,700 y las entregas a 19. La mejora no viene de reordenar más: viene de recuperar entidades que el denso no trae. Quedan tres fallos de respuesta: r-006 se abstiene, r-012 enumera varias iniciativas en lugar de responder la organización y r-016 es una pregunta ambigua. El sistema sabe decir que no, pero todavía no siempre elige la evidencia correcta cuando hay varias.

La compuerta anterior tampoco generalizaba el cero: rechazaba 4 de 5 negativas nuevas y dejaba entrar una con 0,579, que el guardarraíl detenía después. La compuerta nueva, con la puntuación del cross-encoder, rechaza las 5 y baja los falsos rechazos de 6 a 3. Dos de los tres que quedan (r-012 y r-014) son preguntas que la recuperación híbrida sí puede responder, pero la compuerta solo ve el top-5 denso. El 0/9 del conjunto anterior era una muestra demasiado pequeña para sostener una tasa nula. La lección no es retirar la compuerta, sino alinearla con el conjunto que ve el generador y reportar su tasa con el denominador.

El conjunto reservado también muestra que el gold exploratorio no era representativo en idioma: con la unión, en inglés el recall es 0,875 y el nDCG 0,829; en español, 0,583 y 0,468. El inglés, que en el gold exploratorio parecía el punto débil, recupera mejor en la muestra nueva. Con 8 y 12 preguntas, las diferencias no son concluyentes, pero bastan para no tratar el idioma como una conclusión cerrada.

IX-F. Qué se llevaría a producción

La configuración que se llevaría es la de la Tabla III: bge-m3 con `ef`=800, unión densa top-10 + BM25 top-20, reranker en GPU, $k = 10$, gemma4:e4b con MTP, prompt v2 y compuerta con cross-encoder y umbral 0,4. Es la que mejor equilibra cobertura, orden, latencia y coste en este corpus. Las deudas técnicas son r-006 y r-016, la alineación de la compuerta con el conjunto reordenado y la corrección de la respuesta. La primera exige una consulta o un índice distinto; la segunda es un límite del conjunto; la tercera, ver el mismo top-10 que el generador. Ninguna se resuelve con más reordenamiento.

El monitoreo que acompañaría el despliegue tiene cuatro señales: recall en una muestra fija del gold, tasa de abstención, tasa de citas válidas y latencia p95. Las cuatro se pueden calcular con la infraestructura actual y detectan las regresiones que importan: que el índice cambie, que el modelo se actualice, que el prompt se rompa o que el hardware se quede sin memoria. La compuerta se monitorea aparte, con un conjunto fijo de preguntas de fuera, porque su deriva no se ve en las métricas de respuesta.

X. Limitaciones

1. **Texto sin cierre.** El 32,7 % de los documentos de la muestra no termina en un signo de cierre. Es un proxy de truncamiento, no una verificación de que el rastreador los cortó: una publicación completa puede acabar sin punto. La limpieza no puede recuperar ese texto y ningún recuperador puede encontrar lo que no está.
2. **Sesgo de fuentes.** Cuatro cabeceras concentran la prensa y Bluesky llega casi todo en inglés. El corpus no representa la conversación pública en español ni la diversidad de medios del país.
3. **Fechas incompletas.** El rango declarado va de 2008 a 2026, pero la distribución utilizable se concentra en 2024 a 2026. El filtro temporal solo es fiable en ese tramo.
4. **Gold pequeño y desbalanceado.** 43 preguntas, 5 sin respuesta y 24 en prueba; 36 son de prensa y 2 de Bluesky, frente a un corpus con 38,2 % de documentos de Bluesky. Los intervalos de confianza son amplios y las diferencias de una o dos preguntas no son concluyentes. La revisión de Erika sigue pendiente y algunas correcciones las aplicó un solo revisor.
5. **Conjunto reservado pequeño.** 20 directas y 5 negativas. Una sola pregunta mueve 5 puntos porcentuales y los intervalos son amplios. La recuperación híbrida se eligió sobre este conjunto, así que sus métricas de recuperación y respuesta son de desarrollo; la compuerta se midió antes y conserva su carácter externo.
6. **Recall con un solo documento.** El gold reservado tiene un documento de referencia por pregunta. Si otro documento contiene la misma respuesta, el recall lo cuenta como fallo; r-005, r-008, r-017 y r-019 responden bien sin el documento de referencia. El recall@10 de 0,700 es una cota inferior de la recuperación útil.
7. **Compuerta no concluyente.** La compuerta nueva rechaza las 5 negativas del conjunto reservado y 3 de 20 directas; dos de esos tres son preguntas que la recuperación híbrida sí puede responder, pero la compuerta solo ve el top-5 denso. La tasa real sigue sin estimarse con precisión.
8. **Ruido del juez.** RAGAS depende de un modelo local que falla en algunas muestras y cambia con el timeout y la concurrencia. La comparación con la arquitectura anterior cambia juez y embedding, así que no es completamente equivalente.
9. **Hardware e infraestructura.** La estación tiene 16 GB de VRAM y 31 GB de RAM. El contexto de 116K ocupa 13,9 GB; el reordenador en GPU añade 1,6 GB y el margen es estrecho. La capa de datos (etcd, MinIO y Milvus) corre en un servidor de la red local y el API se conecta por un túnel SSH; si el túnel cae, no hay recuperación.
10. **Alcance.** El sistema está diseñado para un corpus concreto de prensa y redes. No es un RAG de propósito general y las decisiones de limpieza, chunking y compuerta no se transfieren sin medir.

XI. Conclusiones y trabajo futuro

En el gold exploratorio el sistema responde 37 de 38 preguntas respondibles y se abstiene en las 5 sin respuesta. De las 37, 25 coinciden de forma exacta con la respuesta de referencia; de las 12 restantes, la revisión manual de una persona juzgó correctas 8, parciales 3 e incorrecta 1. En el conjunto reservado, con 20 directas y 5 sin respuesta, entrega 19, acierta 17 de forma exacta y se abstiene en las 5; el

recall@10 es 0,700 y la compuerta rechaza las 5 sin respuesta y 3 de 20 directas. En conversación alcanza 14 de 14 con compuerta y 11 de 14 sin ella. RAGAS reporta 0,952 de fidelidad, 0,881 de precisión del contexto, 0,921 de cobertura y 0,657 de corrección. La latencia media del conjunto reservado con la configuración final es de 6,2 s (mediana 5,6 s).

La primera lección es metodológica: el piloto sobreestima la recuperación. Con el mismo codificador y las mismas preguntas, Recall@10 cae de 0,947 a 0,684 al pasar de 1.932 a 161.868 documentos. Cualquier comparación de codificadores o de chunking hecha solo sobre una muestra pequeña habría elegido la configuración equivocada. La unión con BM25 y el reordenamiento en GPU recuperan parte de esa caída: en el conjunto reservado el recall@10 sube de 0,600 a 0,700 y las entregas de 17 a 19. La segunda es que el orden y la cobertura se atacan en sitios distintos. Reordenar el top-5 sube el nDCG 5,6 puntos y el P@1 13,1 sin perder cobertura, pero no recupera lo que falta; la unión con BM25 sí recupera entidades que el denso no trae. La profundidad de la unión tampoco es monotónica: 50/50 recupera más documentos de referencia, pero baja las respuestas exactas; 10/20 es el mejor equilibrio. La tercera es que la limpieza conservadora basta: ninguna variante supera a otra de forma significativa, y la ganancia real es eliminar páginas de error, no reescribir el texto.

La cuarta lección es que la abstención barata es la compuerta. Rechazar antes de generar cuesta decenas de milisegundos y evita que el modelo improvise sobre temas ajenos. La quinta es que la evaluación automática necesita cobertura: una media de RAGAS con 4 valores de 38 invirtió una conclusión sobre la precisión del contexto. Reportar n junto a cada media no es un detalle de estilo; cambia lo que se concluye. La sexta lección es que el gold exploratorio no basta. El conjunto reservado confirma la caída de recuperación y muestra que la compuerta anterior no generalizaba un cero: rechazaba 4 de 5 negativas y dejaba entrar una. La compuerta con cross-encoder rechaza las 5 y baja los falsos rechazos de 6 a 3, pero no los elimina; dos de esos tres son preguntas que la recuperación híbrida sí puede responder. Un conjunto de 5 negativas no distingue una tasa nula de una tasa baja.

El trabajo futuro tiene cinco frentes. Primero, cerrar los fallos de recuperación: g-046 exige revisar la consulta o el índice, g-031 requiere un conjunto de candidatos mayor con un coste que hoy no se justifica, y el conjunto reservado añade r-006 (abstención) y r-016 (pregunta ambigua). La recuperación híbrida ya resolvió r-012 y r-014. Segundo, alinear la compuerta con el conjunto reordenado, porque hoy rechaza dos preguntas que el generador podría responder. Tercero, mejorar la corrección de la respuesta, la métrica más débil de RAGAS. Cuarto, completar la revisión del gold con la cuarta anotadora y ampliar el conjunto de prueba para reducir los intervalos de confianza. Quinto, probar un chunking distinto y una reindexación completa, que es la única vía que queda para atacar la pérdida de contexto sin sacrificar cobertura.

Tabla XIX
MODELOS, ETIQUETA Y PAPEL EN EL SISTEMA.

Papel	Etiqueta	Cuantización
Generador	`gemma4:e4b`	Q4_K_M
Condensador y juez	`gemma2:2b`	Q4_K_M
Embedding	`BAAI/bge-m3`	fp16 en GPU
Reordenador	`BAAI/bge-reranker-v2-m3`	fp16 en GPU
Comparación E4	`qwen2.5:1.5b`	Q4_K_M
Comparación E4	`llama3.2:3b`, `llama3.2:1b`	Q4_K_M
Comparación E3	`qwen3-embedding:8b`	Q4_K_M

XII. REPRODUCIBILIDAD

XII-A. Hardware y software

El sistema se ejecutó en una estación con Ryzen 9 5950X, 31 GB de RAM y una GPU AMD Radeon RX 9070 XT de 16 GB con ROCm 7.2.4. La capa de datos (etcd, MinIO y Milvus 2.6.6) corre en un servidor de la red local con 16 núcleos y 62 GB de RAM; el API, el embedding y el generador siguen en la estación. La conexión al Milvus remoto va por un túnel SSH a `localhost:19530`. Los contenedores usan Python 3.12, PyTorch 2.10 con ROCm, FastAPI, Streamlit y Ollama. RAGAS 0.4.3 y LangChain 0.3 corren en un contenedor aparte con Python 3.12 y `BAAI/bge-m3` en CPU.

XII-B. Modelos

La Tabla XIX fija la versión de cada modelo. Los identificadores son las etiquetas de Ollama y de Hugging Face usadas en el código; no se usan alias móviles.

El artículo se compila con IEEEtran V1.8b y un parche local que sustituye la raya del resumen y de las palabras clave por dos puntos. La corrida de referencia de la configuración densa es el commit `125bbc7`; la de la configuración híbrida es `experimento_recuperacion_hibrida.py`. Las figuras y tablas se regeneran desde `reports/tablas/`. RAGAS 0.4.3 corre con LangChain 0.3 y `BAAI/bge-m3` en CPU.

XII-C. Comandos

El stack se levanta con un comando:

```
docker compose up -d --build
docker compose ps
curl http://localhost:8010/health
```

La capa de datos se levanta en el servidor con `docker compose -f docker-compose.data.yml up -d` y la estación abre el túnel con `ssh -N -L 19530:localhost:19530 carlos@192.168.1.100`. El servicio `prewarm` carga el generador, el embedding y el reranker cuando la API está sana. La evaluación completa se ejecuta con:

```
python src/scripts/run_evaluation.py
```

Ese pipeline corre la evaluación de desempeño en el worker GPU, la de conversación contra la API y RAGAS en el contenedor de evaluación. Los resultados se escriben en `reports/tablas/` y la comparación en `reports/tablas/evaluacion_comparativa.md`.

XII-D. Artefactos

El gold consolidado está en `eval/gold/gold_standard.jsonl`, con su versión ampliada en `gold_standard_ampliado.jsonl`. Las tablas de recuperación, respuesta, conversación, compuerta y RAGAS están en `reports/tablas/`. El conjunto reservado está en `eval/gold/gold_reservado.jsonl`, con su construcción y sus hashes en `README_RESERVADO.md`; la corrida densa escribe `reports/corridas/reservado_raw.jsonl` y `reports/tablas/reservado_resumen.csv`, y la híbrida, `reservado_hibrida_raw.jsonl`, `reservado_hibrida_resumen.csv` y `reservado_hibrida_por_pregunta.csv`. La capa de datos remota se define en `docker-compose.data.yml`. Las figuras del artículo están en `reports/figuras/`. Los registros crudos de cada corrida están en `reports/corridas/` y los modelos de la compuerta en `modelos/`.

XII-E. Datos

El corpus completo no se publica por derechos de las fuentes. Se incluyen el gold, las anotaciones, la muestra del piloto y los Parquet de evaluación necesarios para reproducir las métricas. Las cifras de este artículo se pueden verificar contra esos artefactos sin volver a descargar el corpus.

Referencias

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[2] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava, and I. Gurevych, "BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models," in *NeurIPS Datasets and Benchmarks Track*, 2021, arXiv:2104.08663.

[3] N. Muennighoff, N. Tazi, L. Magne, and N. Reimers, "MTEB: Massive text embedding benchmark," in *Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, 2023, arXiv:2210.07316.

[4] X. Zhang, N. Thakur, O. Ogundepo, E. Kamalloo, D. Alfonso-Hermelo, X. Li, Q. Liu, M. Rezagholizadeh, and J. Lin, "MIRACL: A multilingual retrieval dataset covering 18 diverse languages," *Transactions of the Association for Computational Linguistics*, vol. 11, pp. 1114–1131, 2023, arXiv:2210.09984.

[5] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated evaluation of retrieval augmented generation," *arXiv preprint arXiv:2309.15217*, 2023.

[6] J. Saad-Falcon, O. Khattab, C. Potts, and M. Zaharia, "ARES: An automated evaluation framework for retrieval-augmented generation systems," in *North American Chapter of the Association for Computational Linguistics (NAACL)*, 2024, arXiv:2311.09476.

[7] A. Salemi and H. Zamani, "Evaluating retrieval quality in retrieval-augmented generation," in *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2024, arXiv:2404.13781.

[8] D. Ru, L. Qiu, X. Hu, T. Zhang, P. Shi, S. Chang, C. Jiayang, C. Wang, S. Sun, P. Li *et al.*, "RAGChecker: A fine-grained framework for diagnosing retrieval-augmented generation," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024, arXiv:2408.08067.

[9] Zilliz, "Milvus documentation," https://milvus.io/docs, 2026.

[10] Ollama, "Ollama: Get up and running with large language models locally," https://github.com/ollama/ollama, 2026.

[11] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.

[12] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, "Reciprocal rank fusion outperforms condorcet and individual rank learning methods," in *Proceedings of the 32nd International ACM SIGIR Conference*, 2009, pp. 758–759.

[13] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi, "Self-rag: Learning to retrieve, generate, and critique through self-reflection," *arXiv preprint arXiv:2310.11511*, 2023.

[14] S.-Q. Yan, J.-C. Gu, Y. Zhu, and Z.-H. Ling, "Corrective retrieval augmented generation," *arXiv preprint arXiv:2401.15884*, 2024.

[15] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," *arXiv preprint arXiv:2402.05672*, 2024.

[16] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," *arXiv preprint arXiv:2402.03216*, 2024.

[17] R. Nogueira and K. Cho, "Passage re-ranking with bert," *arXiv preprint arXiv:1901.04085*, 2019.

[18] Y. A. Malkov and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 824–836, 2020.

[19] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157–173, 2024, arXiv:2307.03172.

[20] C. Niu, Y. Wu, J. Zhu, S. Xu, K. Shum, R. Zhong, J. Song, and T. Zhang, "Ragtruth: A hallucination corpus for developing trustworthy retrieval-augmented language models," *arXiv preprint arXiv:2401.00396*, 2024.

[21] S. Ramírez, "FastAPI documentation," https://fastapi.tiangolo.com, 2026.

[22] Streamlit Inc., "Streamlit documentation," https://docs.streamlit.io, 2026.