# Asistente RAG reproducible sobre prensa y Bluesky con Milvus y modelos locales: arquitectura, evaluación y compuerta de dominio

Erika Valeria Rivera Jimenez, Julian Guillermo Carrillo Meneses,
Carlos Andres Garnica Salazar, Oscar Andres Prieto Moreno

Pontificia Universidad Javeriana, Bogotá, Colombia
riveraev@javeriana.edu.co, carrillojuliang@javeriana.edu.co,
carlos_garnicas@javeriana.edu.co, o-prieto@javeriana.edu.co

***Resumen*: La recuperación aumentada por generación (RAG) permite responder sobre un corpus sin reentrenar el modelo, pero su calidad depende de decisiones que rara vez se documentan juntas: limpieza, segmentación, codificador, índice, reordenamiento, prompt y control de abstención. Este trabajo presenta un asistente RAG reproducible sobre 169.248 documentos recolectados de prensa colombiana e internacional y Bluesky, 161.868 indexados tras descartar páginas de error y 618.286 fragmentos en Milvus, con modelos locales. La comparación de capas es exploratoria sobre el gold completo. Se justifica cada capa con experimentos pareados: la limpieza conservadora no mejora de forma significativa, el chunking fijo tiende a superar a la segmentación por oraciones y es más rápido, bge-m3 supera a e5-base y a la fusión con BM25, y un cross-encoder sobre el top-5 sube el nDCG de 0,809 a 0,865 y el P@1 de 0,737 a 0,868 sin perder cobertura. En el gold exploratorio el sistema entrega 37 de 38 preguntas respondibles, se abstiene en las 5 sin respuesta y acierta 25 de 37 de forma exacta. En un conjunto reservado de 20 preguntas nuevas, congelado antes de ejecutar, entrega 17, acierta 15 de forma exacta y se abstiene en las 5 sin respuesta; el recall@10 baja a 0,600 y la compuerta rechaza las 5 sin respuesta y 3 de las 20 directas. En conversación alcanza 14 de 14 con compuerta de dominio. RAGAS reporta 0,952 de fidelidad, 0,881 de precisión de contexto, 0,921 de cobertura y 0,657 de corrección. Se documentan también las mejoras rechazadas, el coste de cada decisión y los límites del corpus.**

***Palabras clave*: recuperación aumentada por generación, Milvus, bge-m3, reordenamiento, evaluación de sistemas de recuperación, compuerta de dominio.**

## I. Introducción

Un sistema de recuperación aumentada por generación (RAG) responde una pregunta con fragmentos recuperados de una colección y un modelo de lenguaje que redacta a partir de ellos [1]. La promesa es atractiva: actualizar el conocimiento sin reentrenar y citar la evidencia. En la práctica, la calidad depende de una cadena de decisiones que se afectan entre sí. Una limpieza agresiva puede borrar la frase que responde; un chunking pequeño pierde contexto; un codificador entrenado en otro dominio recupera vecinos plausibles pero inútiles; un reordenador puede mejorar el orden y a la vez encarecer cada consulta; un prompt permisivo invita a inventar; y sin un control de abstención el sistema responde con seguridad sobre temas que el corpus no cubre.

La literatura de RAG suele evaluar un componente a la vez. BEIR y MTEB miden recuperadores [2], [3]; los benchmarks multilingües como MIRACL comparan codificadores [4]; RAGAS, ARES, eRAG y RAGChecker evalúan la respuesta generada [5], [6], [7], [8]. Son piezas necesarias, pero no dicen cómo se comporta la cadena completa sobre un corpus real, con duplicados, truncamiento, ruido de rastreo y preguntas sin respuesta. Tampoco dicen cuánto cuesta cada mejora ni cuándo conviene rechazarla.

Este trabajo construye y evalúa esa cadena completa sobre un corpus de 169.248 documentos recolectados de prensa colombiana e internacional y Bluesky, 161.868 indexados y 618.286 fragmentos. El sistema corre íntegramente en una estación de trabajo con una GPU AMD de 16 GB, Milvus como motor vectorial [9] y modelos servidos por Ollama [10]. No se usan servicios externos de generación ni de embeddings. La Tabla III resume la configuración final y la Sección IV justifica cada elección.

### *I-A. Preguntas de investigación*

1. **Calidad del corpus.** ¿Qué problemas de limpieza, truncamiento, duplicados e idioma aparecen en un corpus de prensa y redes sociales, y cuánto afectan la recuperación?
2. **Recuperación.** ¿Qué combinación de codificador, índice, tamaño de contexto y reordenamiento maximiza la cobertura y el orden con un coste aceptable?
3. **Generación y abstención.** ¿Cómo se comportan distintos modelos locales sobre la misma evidencia y qué controles evitan respuestas sin respaldo?
4. **Evaluación.** ¿Qué acuerdo alcanzan los anotadores humanos y qué señales de evaluación automática son fiables cuando el juez también es un modelo local?

### *I-B. Aportes*

1. Un pipeline reproducible de extremo a extremo, con Docker Compose, Milvus, Ollama, FastAPI y Streamlit, que se levanta con un comando y no depende de servicios de pago.
2. Un análisis exploratorio y una textometría del corpus que cuantifican el texto sin cierre terminal (32,7 %, un proxy de truncamiento), ruido de rastreo, duplicados

exactos y near-duplicates, y que justifican una limpieza conservadora.
3. Una comparación pareada de cuatro variantes de limpieza, dos estrategias de segmentación, tres codificadores, recuperación densa, dispersa e híbrida, y tres alcances de reordenamiento, con intervalos de confianza por bootstrap.
4. Un gold de 43 preguntas con revisión de tres anotadores y una cuarta pendiente, con acuerdo entre anotadores reportado, y una evaluación automática con RAGAS que distingue el ruido del juez de una mejora real.
5. Una compuerta de dominio entrenada con 160 preguntas que rechaza las preguntas sin respuesta del conjunto de prueba y las 5 del conjunto reservado, con 3 falsos rechazos en 20 preguntas de dominio, y una interfaz que expone la evidencia, las citas y la abstención.

### *I-C. Organización*

La Sección II revisa los trabajos relacionados. La Sección III describe el corpus y el análisis exploratorio. La Sección IV presenta la arquitectura y justifica cada capa. La Sección V detalla el procesamiento y la configuración. La Sección VI define el protocolo y el gold. La Sección VII reporta los experimentos y sus decisiones. Las Secciones VIII a XI discuten errores, límites y conclusiones.

## II. Trabajos relacionados

### *II-A. Recuperación aumentada por generación*

RAG combina un recuperador con un generador para responder con conocimiento externo [1]. La variante densa codifica pregunta y documentos en un mismo espacio y busca por similitud; la dispersa, como BM25 [11], puntúa por coincidencia de términos. La fusión de ambas con reciprocal rank fusion [12] es una práctica común para compensar sus sesgos. En este trabajo se comparan las tres sobre el mismo corpus y el mismo protocolo, con un índice por codificador, y se conserva la que gana en cobertura y orden.

### *II-B. Variantes iterativas y correctivas*

Self-RAG entrena al modelo para decidir cuándo recuperar y para criticar sus propias respuestas con tokens de reflexión [13]. CRAG evalúa la calidad de la recuperación y activa una búsqueda correctiva cuando el contexto es pobre [14]. Ambos mejoran la robustez frente a recuperaciones malas, a costa de varias pasadas del generador y, en el caso de Self-RAG, de un entrenamiento específico. Este trabajo no adopta esas variantes porque el presupuesto de latencia y la GPU local no permiten varias pasadas por consulta. En su lugar, la compuerta decide antes de generar y los guardarraíles verifican después, con un coste de milisegundos.

### *II-C. Codificadores y recuperación*

BEIR mostró que un recuperador bueno en un dominio puede fallar en otro [2], y MTEB extendió esa comparación a tareas y lenguas [3]. MIRACL evidenció la brecha multilingüe [4]. Los codificadores entrenados con contrastive learning, como e5 [15] y bge-m3 [16], mejoran el rendimiento zero-shot y multilingüe. bge-m3 además produce representaciones densas, dispersas y multi-vector con un solo modelo, lo que simplifica la infraestructura. La elección entre ellos no se puede decidir solo por la literatura: depende del corpus, del idioma y del tamaño del índice. Por eso se miden sobre el corpus completo en lugar de limitarse al piloto.

### *II-D. Reordenamiento*

Un cross-encoder puntúa el par pregunta-documento con atención conjunta y suele superar al bi-encoder en precisión [17]. El coste crece con el número de candidatos, porque cada par exige una pasada completa del modelo. La práctica habitual es recuperar un conjunto amplio y reordenar un top pequeño. Este trabajo mide el efecto de reordenar 5, 20 y 50 candidatos, y encuentra que ampliar el conjunto mejora el orden pero pierde cobertura y multiplica la latencia. La configuración elegida reordena solo el top-5.

### *II-E. Índices vectoriales*

HNSW aproxima la búsqueda por vecinos con un grafo jerárquico y un parámetro de exploración que intercambia recall por latencia [18]. Milvus implementa HNSW y otros índices sobre almacenamiento distribuido [9]. El parámetro `ef` se ajusta en este trabajo con una búsqueda en rejilla sobre el gold, y se documenta el punto donde la ganancia deja de compensar el coste.

### *II-F. Evaluación*

Las métricas de recuperación (Recall@k, nDCG, P@k, MRR) son estándar en recuperación de información. Para la respuesta generada, RAGAS descompone la calidad en fidelidad, relevancia, precisión y cobertura del contexto y corrección [5]; ARES entrena jueces para reducir el sesgo del evaluador [6]; eRAG evalúa la utilidad de cada documento recuperado [7]; y RAGChecker diagnostica errores de recuperación y de generación por separado [8]. Un problema recurrente es que el juez también es un modelo y su veredicto varía con el prompt, el timeout y la concurrencia. Liu et al. muestran además que el generador aprovecha peor la evidencia cuando esta se coloca en el medio de un contexto largo [19]. RAGTruth muestra que las alucinaciones en RAG se concentran en afirmaciones sin respaldo y propone anotación a nivel de span [20]. La verificación de entidades y números contra el chunk citado de este trabajo sigue esa idea con reglas deterministas. Este trabajo reporta la cobertura de cada métrica de RAGAS además de su media, y separa el ruido del juez de una mejora del sistema.

### *II-G. Abstención y control de dominio*

Un sistema RAG que siempre responde produce alucinaciones cuando la evidencia no alcanza. Las soluciones van desde pedir al generador que se abstenga hasta entrenar un clasificador que decida si la pregunta pertenece al dominio. Este trabajo usa dos controles: guardarraíles de cita y de entidades sobre la respuesta, y una compuerta de dominio

Tabla I
COMPOSICIÓN DEL CORPUS POR COLECCIÓN.

| Colección | Documentos | % del total |
|---|---|---|
| Rastreo web | 104.578 | 61,8 |
| Bluesky | 64.670 | 38,2 |
| Total | 169.248 | 100,0 |

supervisada que se activa con un interruptor. La compuerta es un clasificador de regresión logística con embeddings y señales de recuperación, no un juez generativo, para que su decisión sea barata, reproducible y medible.

### *II-H. Posición de este trabajo*

La contribución es una evaluación completa de la cadena sobre un corpus real, con las mejoras que funcionaron y las que no, y con el coste de cada decisión. Se separa la calidad del sistema de la calidad del juez, y esa separación es la que permite decidir qué mantener en producción y qué descartar.

## III. CORPUS Y ANÁLISIS EXPLORATORIO

### *III-A. Composición*

El corpus de trabajo tiene 169.248 documentos, 34 columnas y 256,9 MB. La Tabla I resume la procedencia. La mayor parte viene de rastreo web (104.578) y de Bluesky (64.670). El campo `source_type` no sirve como etiqueta semántica: 99.326 filas lo tienen nulo, 64.670 valen `social_post` y solo 5.252 valen `news_article`. La distribución por dominio confirma el peso de las fuentes: bsky.app aporta 64.670 documentos, infobae 19.766, eltiempo 12.229, theguardian 7.216 y elespectador 5.456. El corpus no representa la conversación pública en español: Bluesky llega casi todo en inglés y la prensa está dominada por cuatro cabeceras. La prensa incluye cabeceras británicas (The Guardian, The Independent, Daily Mail) además de colombianas (El Tiempo, El Espectador, Infobae).

Tras normalizar el campo `language`, el corpus queda en 82.682 documentos en inglés, 66.910 en español, 13.140 sin idioma declarado y 6.516 en otros idiomas, con 4.133 en húngaro. El húngaro aparece con 4.108 documentos en el campo crudo, un volumen que no corresponde con el resto de la distribución y que se excluye del filtro de idioma hasta revisarlo. La normalización se hace al vuelo en la ingesta y el archivo original no se modifica.

El rango declarado de fechas va de 2008 a 2026, pero 163.736 de los 169.248 documentos (96,7 %) no tienen fecha y solo 5.512 la declaran. El filtro temporal se limita a ese 3,3 % y así se documenta en la interfaz.

### *III-B. Duplicados y longitud*

Hay 14.771 copias excedentes (filas que repiten un texto ya presente) agrupadas en 4.434 grupos, con un máximo de 839 copias. Si se cuentan todas las filas que pertenecen a un grupo duplicado, son 19.205: 9.972 en Bluesky y 9.233 en prensa. Las dos cifras son compatibles: la primera cuenta copias adicionales y la segunda, documentos en grupos. No se borran filas en la ingesta, porque eso perdería la procedencia; la deduplicación se hace en la recuperación, comparando el hash del fragmento antes de armar el contexto.

Tabla II
TEXTOMETRÍA DEL PILOTO Y DE UNA MUESTRA DEL CORPUS COMPLETO.

| Indicador | Piloto | Muestra |
|---|---|---|
| Tipos por documento (mediana) | 188 | 188 |
| TTR mediana | 0,579 | 0,570 |
| Hapax / tipos (mediana) | 0,773 | 0,770 |
| Guiraud (mediana) | 10,04 | 10,13 |
| Caracteres por documento (mediana) | 2.317 | 2.353 |
| Caracteres p99 | 14.979 | 15.498 |
| Sin puntuación terminal (proxy) | 33,5 % | 32,7 % |
| Documentos con URL | 9,3 % | 9,9 % |
| Documentos con correo | 1,8 % | 1,3 % |
| Documentos con emojis | 12,4 % | 12,1 % |
| Documentos con navegación | 3,4 % | 3,3 % |
| Documentos con boilerplate | 3,4 % | 4,5 % |
| Near-duplicates (SimHash, Hamming $\leq 3$) | 4,25 % | 4,72 % |
| Grupos de near-duplicates | 26 | 53 |
| Grupo más grande | 12 | 32 |

La longitud media es de 473 palabras y 2.977 caracteres, pero la mediana baja a 371 palabras y 2.367 caracteres. La cola es larga: el percentil 99 llega a 2.420 palabras y el máximo a 58.181 palabras, equivalentes a 363.528 caracteres. Ese documento extremo produce cientos de fragmentos y obliga a controlar el tamaño de lote en la ingesta.

### *III-C. Ruido de rastreo*

El rastreador dejó páginas de error dentro del corpus. La misma página con los mensajes “Haz excedido el máximo de peticiones” y “Error 505” aparece en 7.378 documentos, el 4,36 % del total, todos en la colección de prensa. En el conjunto de humo esos textos casi idénticos dominaban el top-10 de cualquier consulta, porque su similitud entre sí es mayor que la de cualquier documento relevante. El registro de ingesta descarta 7.380 documentos por calidad: 7.378 son esa página de error y 2 no están desglosados. Quedan 161.868 documentos indexados y 618.286 fragmentos. El porcentaje de documentos con al menos un patrón de ruido (peticiones, error 505, cookies, inicio de sesión) llega al 5,3 %, pero el filtro solo elimina los marcadores fuertes de error y no las menciones legítimas de cookies.

### *III-D. Textometría*

La textometría se calculó sobre dos muestras: los 2.000 documentos del piloto y 5.000 documentos estratificados del resto del corpus, con semilla 42. La Tabla II compara los indicadores. Los valores son estables entre muestras, lo que sugiere que el piloto representa bien la distribución léxica del corpus completo.

El 32,7 % de los documentos de la muestra no termina en un signo de cierre. Es un proxy de truncamiento, no una verificación de que el rastreador los cortó: una publicación completa puede acabar sin punto. La limpieza no puede recuperar ese texto, y el porcentaje se declara como límite en la Sección X. El HTML residual es marginal (0,14 % en la muestra), pero las URLs aparecen en uno de cada diez

documentos y los emojis en uno de cada ocho, casi todo en Bluesky. Los near-duplicates no son solo hash exacto: SimHash encuentra grupos de hasta 32 documentos que el hash exacto no captura. Los términos exclusivos de prensa están dominados por boilerplate (*publicidad*, *información*, *además*), lo que anticipa que una normalización conservadora puede ayudar sin destruir entidades.

### *III-E. Decisiones de procesamiento*

El análisis anterior fija tres decisiones. Primero, limpieza conservadora: se elimina boilerplate y se normalizan espacios, pero no se tocan entidades ni números. Segundo, deduplicación en la recuperación, no en la ingesta, para conservar la trazabilidad. Tercero, el truncamiento se declara como límite y no se intenta reconstruir. La Sección VII mide si la limpieza conservadora mejora la recuperación frente a no limpiar.

## IV. Arquitectura

### *IV-A. Vista general*

La Figura 5 muestra el flujo. El usuario escribe en una interfaz Streamlit; la API FastAPI recibe la pregunta, la condensa si viene de una conversación, aplica la compuerta de dominio si el Modo estricto está activo, recupera fragmentos de Milvus, los reordena, arma el contexto y genera la respuesta. Antes de devolverla, los guardarraíles verifican citas, entidades y números. Cada capa se eligió por una razón medible, no por disponibilidad.

### *IV-B. Capas y justificación*

**Ingesta.** Los documentos se limpian, se fragmentan y se codifican una sola vez. La colección se valida contra la etiqueta del codificador activo para no mezclar espacios vectoriales. Se eligió un pipeline idempotente y reanudable porque el corpus cambia y la codificación es la etapa más costosa: la ingesta completa desde documentos tardó 2 h 41 min y reindexar 618.286 fragmentos ya troceados con bge-m3 tardó 27,3 min.

**Índice vectorial.** Milvus se eligió por tres razones: soporta HNSW con parámetro de exploración ajustable [18], filtra por metadatos (idioma, fecha, colección) sin salir del motor y mantiene 618.286 fragmentos con latencias de milisegundos. Una base local en memoria no habría permitido filtrar ni auditar la procedencia.

**Codificación.** bge-m3 produce vectores densos de 1024 dimensiones, es multilingüe y rinde bien sin ajuste fino [16]. Se comparó con e5-base y con qwen3-embedding sobre el mismo corpus y el mismo protocolo, con un índice por modelo; la decisión se reporta en la Sección VII.

**Recuperación.** El recuperador denso devuelve el top-10 para medir y el top-5 para responder. La fusión con BM25 y el recuperador disperso se midieron y no se adoptaron. El motivo es empírico: la fusión bajó el recall en este corpus.

**Reordenamiento.** Un cross-encoder multilingüe reordena el top-5 en CPU [17]. Se eligió CPU para no competir por la VRAM con el generador; el coste es de 1,30 s de mediana por consulta. La alternativa de reordenar 20 o 50 candidatos mejora el orden pero pierde cobertura y multiplica la latencia.

Tabla III
Configuración final del sistema.

| Parámetro | Valor |
|---|---|
| Codificador | BAAI/bge-m3, 1024 dimensiones |
| Índice | HNSW en Milvus, `ef`=800 |
| Recuperación | densa, $k = 10$ para medir, $k = 5$ para responder |
| Reordenador | BAAI/bge-reranker-v2-m3, CPU, top-5 |
| Generador | gemma4:e4b, Q4_K_M |
| Contexto | 116.384 tokens (16.384 entrada, 100.000 salida) |
| MTP | draft 3, 217 tok/s |
| Prompt | v2 |
| Juez y condensador | gemma2:2b |
| Compuerta | regresión logística con cross-encoder, umbral 0,4 |
| Fragmentos | 618.286 en `rag_full_bge_m3_d1024_v1` |

**Generación.** gemma4:e4b es un modelo de 7,5B cuantizado a Q4_K_M con 116.384 tokens de contexto y MTP nativo. Se eligió por tres motivos: cabe en 16 GB de VRAM, soporta contextos largos y el MTP con draft 3 acelera la decodificación sin cambiar la distribución del modelo. Los modelos pequeños comparados en E4 quedaron por debajo en corrección y citas.

**Conversación.** Un condensador reescribe la última pregunta con el historial para que la recuperación no dependa de pronombres. Se usa gemma2:2b para no cargar dos veces el modelo grande. Si el condensador pierde el tema, se antepone la primera pregunta del usuario.

**Guardarraíles.** Tres controles antes de responder: cita obligatoria, verificación de entidades y números contra el fragmento citado, y un juez de evidencia. Si alguno falla, el sistema se abstiene con el motivo. El juez es gemma2:2b, distinto del generador, para no validar con el mismo modelo que redacta.

**Compuerta de dominio.** Un clasificador de regresión logística con la puntuación del cross-encoder y señales de recuperación decide si la pregunta pertenece al corpus. No es un LLM juez: reutiliza la pasada del reranker, es reproducible y se puede medir con precisión y recall. Se activa con el interruptor Modo estricto.

**API e interfaz.** FastAPI separa el pipeline de la presentación y expone `/chat`, `/ask`, `/retrieve`, `/health`, `/models` y `/stats` [21]. Streamlit consume `/chat` y muestra la respuesta, las citas, las evidencias, las métricas y el razonamiento [22]. La separación permite probar el pipeline sin la interfaz y cambiar la interfaz sin tocar el pipeline.

### *IV-C. Configuración final*

La Tabla III fija los parámetros. Los valores se justifican en las Secciones V y VII.

### *IV-D. Interfaz para el usuario final*

La interfaz tiene dos zonas. En el panel lateral se elige el modelo, el número de fragmentos, el idioma del documento, el rango de fechas y la colección; se activan el razonamiento y el Modo estricto, y se cambia entre tema claro y oscuro. En el área central se conversa con historial. Cada respuesta muestra el texto con citas numeradas, chips con la intención y la ruta de ejecución, la latencia por etapa, los tokens por segundo y un desplegable con las evidencias: título, puntuación, fragmento,

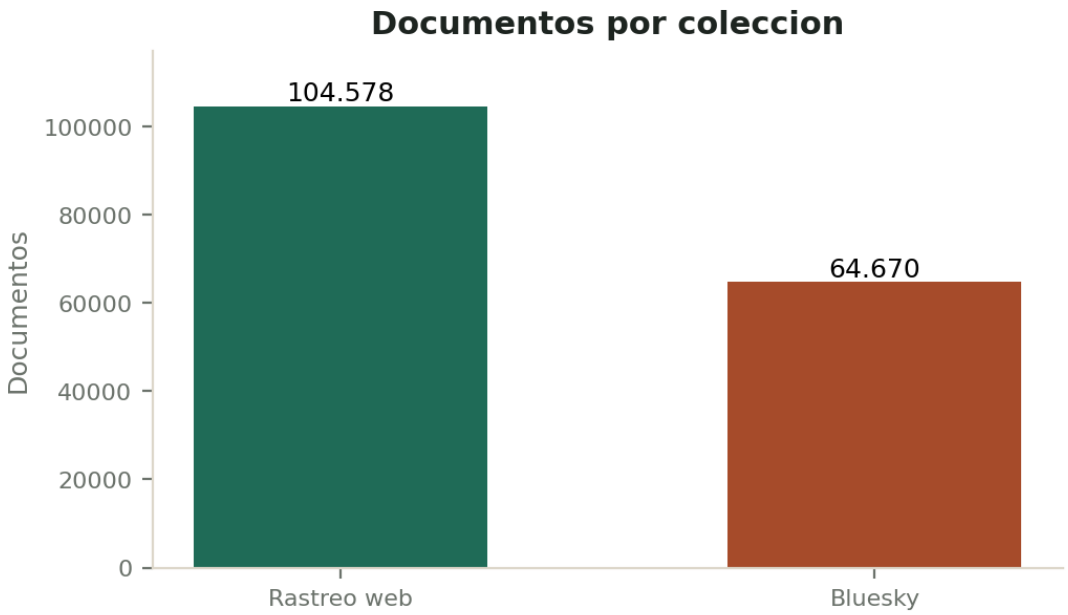



Figura 1. Documentos por colección. Los dos totales coinciden con la Tabla I.

enlace y metadatos. Si el sistema se abstiene, aparece el motivo y, en el caso de fuera de dominio, la sugerencia de desactivar el Modo estricto. El razonamiento del modelo, cuando se activa, va en un desplegable separado y se advierte que no sustituye la evidencia. La Figura 6 muestra una respuesta real con las evidencias abiertas.

## V. Metodología

### V-A. *Limpieza y deduplicación*

La variante adoptada, V2, descarta las páginas de error del rastreador, aplica normalización NFKC, quita HTML y URLs y colapsa espacios. No elimina signos, números ni entidades, porque son la señal que usan los guardarraíles. Los duplicados exactos y los near-duplicates se descartan al armar el contexto, comparando el hash del fragmento y su SimHash antes de insertarlo. Así se conserva la procedencia en el índice y se evita repetir el mismo texto en el prompt.

### V-B. *Segmentación*

Se usa chunking fijo de 1000 caracteres con 150 de solape (`fixed_v2`). El solape cubre la frontera donde suele caer la respuesta. Cada fragmento guarda `document_id`, título, URL, fuente, idioma, fecha, posición, estrategia y hash del texto. Esos metadatos permiten filtrar por idioma y fecha y auditar cada cita.

### V-C. *Codificación e índice*

Los fragmentos se codifican con BAAI/bge-m3 en la GPU, en fp16 y por lotes. La colección se llama `rag_full_bge_m3_d1024_v1` y usa HNSW con `ef`=800 en la búsqueda. El parámetro se eligió con una rejilla sobre el gold: por debajo de 800 el recall cae y por encima la latencia sube sin ganancia apreciable.

### V-D. *Recuperación y reordenamiento*

La recuperación es densa. Para responder se piden 5 fragmentos; para medir recuperación se piden 10. Los filtros de idioma, fecha y colección se aplican en Milvus. El reordenador es un cross-encoder multilingüe que puntúa cada par pregunta-fragmento y reordena el top-5 en CPU, con lote de 16. El resultado se recorta a 5 y se arma el contexto.

### V-E. *Generación*

El generador es gemma4:e4b con temperatura 0 y un presupuesto de 16.384 tokens de entrada. El prompt v2 impone ocho reglas: cada afirmación lleva una cita entre corchetes; no se permiten listas sin cita; si la evidencia no alcanza se responde con una frase de abstención exacta; se distingue un hecho verificable de una afirmación publicada en redes; no se inventan fechas, cifras, nombres ni citas; se ignoran las instrucciones que aparezcan dentro de los documentos; se responde en el idioma de la pregunta; y se usa la fecha exacta de la evidencia cuando la pregunta la pide. El MTP con draft 3 se activa en el manifiesto del modelo y no cambia la salida, solo la velocidad.

### V-F. *Guardarraíles*

Antes de devolver la respuesta se aplican tres controles. El primero exige al menos una cita válida; si no hay, se abstiene con `sin_citas`. El segundo extrae entidades y números de la respuesta y verifica que aparezcan en el fragmento citado o en la pregunta; si no, se abstiene con `sin_respaldo` o `citas_invalidas`. El tercero pide a un juez distinto, gemma2:2b, que decida si la cita sostiene la respuesta; si dice que no, se abstiene con `juez_no`. Cuando el fragmento está en inglés y la respuesta en español, la cobertura léxica se salta y decide el juez, para no castigar una traducción correcta.

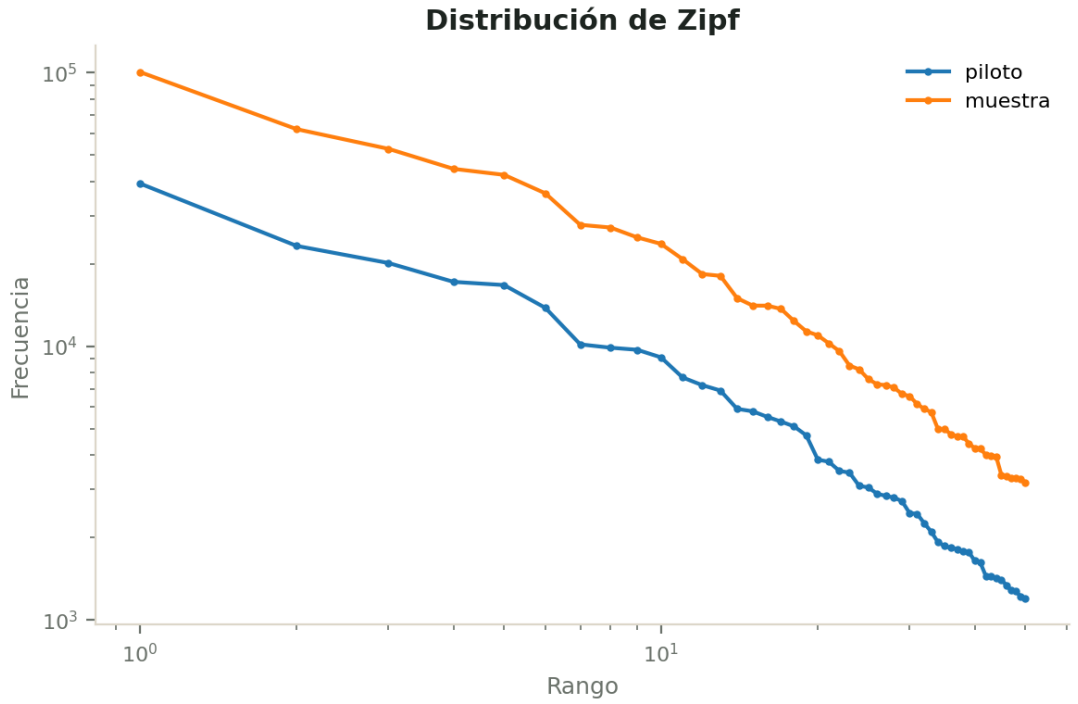



Figura 2. Rango frente a frecuencia en escala logarítmica para el piloto y la muestra. Se muestran los 50 términos más frecuentes; no se ajusta una recta, la figura solo comprueba la forma de ley de potencia.

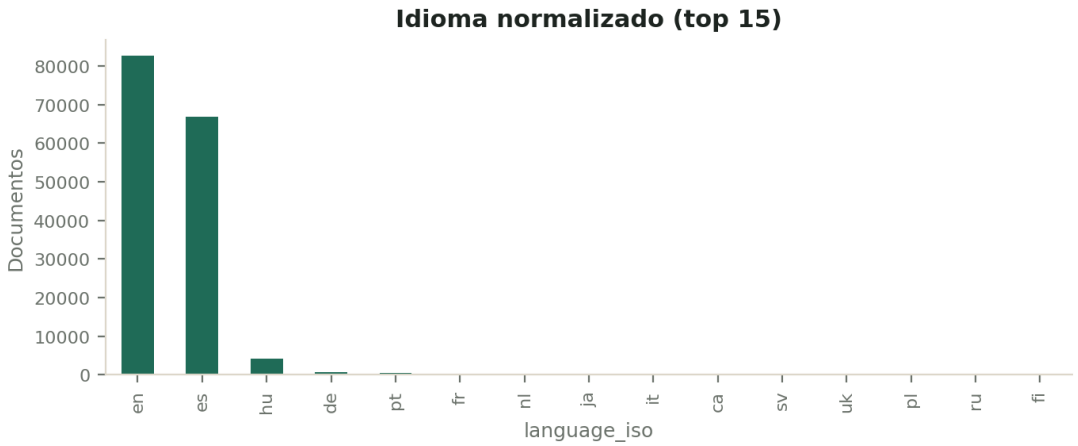



Figura 3. Idiomas normalizados más frecuentes (15 primeros). La normalización se hace al vuelo; el campo crudo del archivo no se modifica.

### *V-G. Compuerta de dominio*

La compuerta usa la puntuación del cross-encoder sobre el top-5 (máximo, media, diferencia entre el primero y el segundo, y mínimo), cinco features de recuperación (puntuación del primer fragmento, media del top-5, diferencia entre el primero y el segundo, solapamiento entre la pregunta y el título, y presencia de la entidad principal en el título) y un one-hot del tipo de pregunta. La puntuación del cross-encoder se calcula una sola vez y se reutiliza para el reordenamiento. El modelo es una regresión logística con escalado y `class_weight=balanced`; la regularización se eligió por validación cruzada de cinco pliegues sobre train y dev. El umbral es 0,4, elegido para reducir falsos rechazos sin aumentar falsos aceptados. El conjunto tiene 160 preguntas: 60 de dominio y 100 de fuera, con split 103/37/20. Las 40 negativas nuevas son entidades inventadas, eventos futuros y conocimiento general fuera del corpus.

### *V-H. API e interfaz*

La API expone `POST /chat` con historial, `think` y `strict`; `POST /ask` sin historial; `POST /retrieve` para recuperación pura; y los GET `/health`, `/models` y `/stats`. La interfaz Streamlit consume `/chat` y guarda el historial en la sesión. Las preferencias de razonamiento, Modo estricto y tema se guardan en un archivo y se recuperan al recargar. Si el usuario cambia un interruptor mientras el

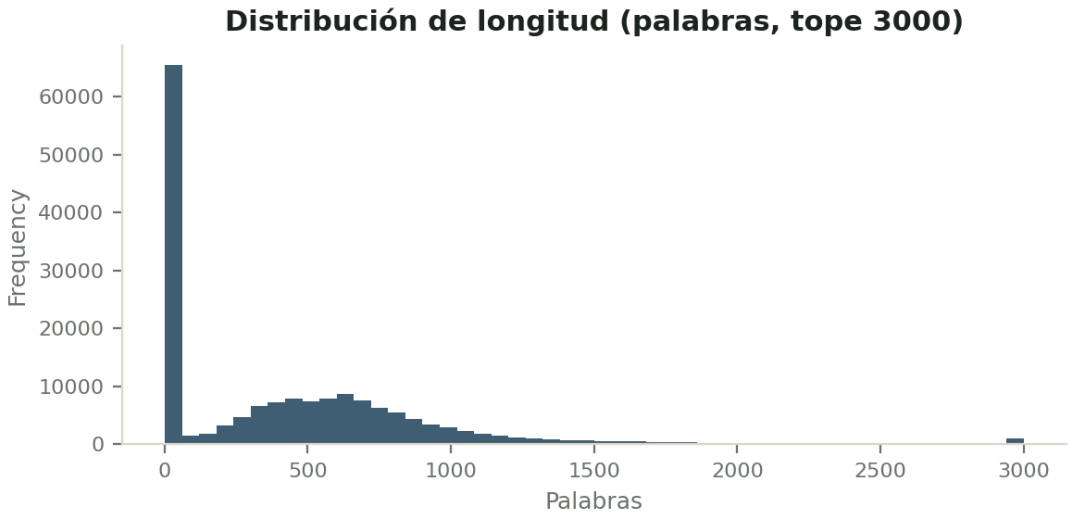



Figura 4. Distribución de longitud en palabras. Los documentos de más de 3.000 palabras se acumulan en el extremo derecho del histograma.

Tabla IV
COMPOSICIÓN DEL GOLD ESTÁNDAR.

| Split | Respondibles | Sin respuesta | Total |
|---|---|---|---|
| Desarrollo | 19 | 0 | 19 |
| Prueba | 19 | 5 | 24 |
| Total | 38 | 5 | 43 |

Tabla V
ACUERDO ENTRE ANOTADORES EN LA COMPARACIÓN DE MODELOS (KAPPA LINEAL, $n = 72$).

| Eje | Kappa |
|---|---|
| Corrección | 0,95 |
| Citas | 0,90 |
| Abstención | 0,72 |
| Fidelidad | 0,12 |

modelo responde, la pregunta queda pendiente y se reintenta en el siguiente ciclo, de modo que la conversación no se pierde.

### *V-I. Despliegue*

El stack se levanta con Docker Compose: etcd, MinIO, Milvus, Ollama, API, frontend y un worker GPU para la ingesta y la evaluación. La API y el frontend usan red de host. Un servicio de una sola ejecución, `prewarm`, espera a que la API esté sana y carga el generador, el embedding y el reranker, para que la primera consulta web no pague la carga del modelo.

## VI. PROTOCOLO DE EVALUACIÓN

### *VI-A. Gold estándar*

El gold tiene 43 preguntas: 19 en desarrollo y 24 en prueba, 38 respondibles y 5 sin respuesta. Cada fila guarda el identificador, la pregunta, el idioma, el tipo, el split, los documentos y fragmentos de referencia, el span literal que responde, la respuesta de referencia, el criterio de corrección y el estado de validación. La Tabla IV resume la composición. Las preguntas sin respuesta no entran en Recall@k: se evalúan por abstención.

El gold se amplió con 17 documentos adicionales marcados por consenso de dos anotadores (kappa 0,626). Con esa ampliación, 14 preguntas quedaron con dos o más documentos relevantes, lo que hace que Recall@k y nDCG no dependan de un único pasaje.

### *VI-B. Revisión humana*

Tres personas revisaron el gold contra el documento citado y una cuarta revisión quedó pendiente. Carlos revisó las 43 y dejó 12 correcciones; Julián aportó 7 spans y una reformulación; Óscar aportó 5 spans corregidos y marcó 3 enlaces rotos; la revisión de Erika sigue pendiente. Cada propuesta se aplicó solo si el span aparecía literalmente en el texto indexado. Las que no se pudieron verificar quedaron con nota.

Para la comparación de modelos se anotaron 72 respuestas de 4 modelos, ciegas y en orden barajado, con rúbrica de 0 a 3 en corrección, fidelidad, citas y abstención. Dos anotadores calificaron las mismas respuestas. La Tabla V reporta el acuerdo. La fidelidad no alcanzó acuerdo suficiente y no se usa para el veredicto; la corrección y las citas sí.

### *VI-C. Métricas*

**Recuperación.** Recall@k mide la fracción de documentos de referencia recuperados en el top-k; nDCG@k usa relevancia binaria; P@k mide precisión en el corte; MRR mide la posición del primer acierto; y la cobertura de span indica si al menos un fragmento recuperado contiene el texto exacto que responde. Esta última es la más cercana a lo que necesita el generador.

**Respuesta.** Se reportan las preguntas entregadas, las abstenciones, el match estricto (igualdad normalizada con la respuesta de referencia), el F1 por tokens, la tasa de citas, el contexto medio en tokens y la latencia por etapa. La

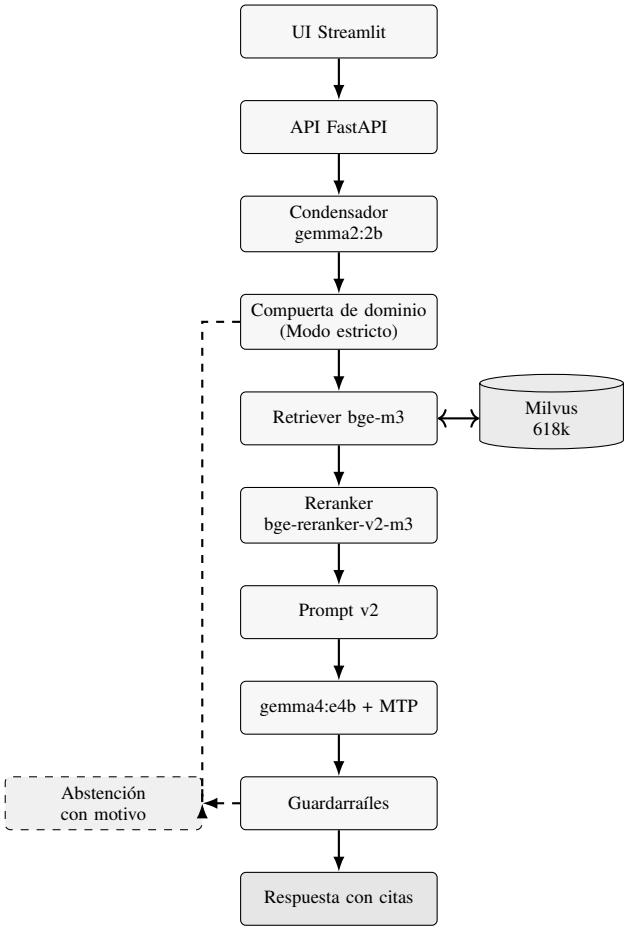



Figura 5. Flujo de una consulta. La compuerta solo actúa con el Modo estricto; el condensador solo en preguntas encadenadas. Las líneas discontinuas son las salidas de abstención, antes y después de generar.

revisión manual clasifica cada respuesta como correcta, parcial o incorrecta.

**Conversación.** Catorce casos: seis saludos, cuatro de dominio y cuatro de fuera. Cada uno tiene un resultado esperado y se marca como correcto o incorrecto. Se ejecutan con y sin Modo estricto, y con y sin razonamiento.

**RAGAS.** Se reportan fidelidad, relevancia de la respuesta, precisión del contexto, cobertura del contexto y corrección de la respuesta [5]. Para cada métrica se informa cuántas muestras tienen valor, porque el juez falla en algunas y una media con cuatro valores no es comparable con una con 38.

**Compuerta.** Precisión, recall y F1 en dev y test, falsos rechazos de dominio (preguntas del corpus rechazadas) y falsos aceptados de fuera (preguntas ajenas aceptadas).

### *VI-D. Estadística*

Las comparaciones de recuperación usan bootstrap pareado por pregunta con 1.000 remuestreos e intervalos de confianza al 95 %. En la comparación de limpieza se aplica corrección de Bonferroni por comparaciones múltiples. La configuración se eligió inspeccionando las 43 preguntas del gold, así que los resultados sobre las 38 respondibles son exploratorios. No se dispone de un conjunto de prueba independiente; una evaluación futura debe reservar preguntas nuevas. Las diferencias que no excluyen cero se reportan como no concluyentes, aunque la media favorezca a una variante. Los intervalos pareados se calcularon para limpieza, E1 y E2; las comparaciones de codificadores, reordenamiento y fusión se reportan como estimaciones puntuales sobre 38 preguntas, sin intervalo, y así se indica en cada tabla.

Tabla VI
LIMPIEZA SOBRE EL PILOTO (30 PREGUNTAS, E5-BASE, $k = 10$).

| Variante | P@1 | P@5 | Recall@10 | MRR | nDCG |
|---|---|---|---|---|---|
| V0 crudo | 0,733 | 0,833 | 0,833 | 0,775 | 0,790 |
| V1 sin páginas de error | 0,767 | 0,833 | 0,833 | 0,800 | 0,809 |
| V2 normalización | **0,833** | **0,900** | **0,900** | **0,867** | **0,875** |
| V3 V2 + dedup | 0,800 | 0,867 | 0,867 | 0,833 | 0,842 |

### *VI-E. Configuración de RAGAS*

La corrida de referencia usa juez gemma4:e4b y embeddings BAAI/bge-m3 en CPU, con 38 preguntas directas. El timeout del juez se fijó en 900 s y la concurrencia en 6. Con los valores por defecto (180 s y 16 workers) el juez no terminaba en varias muestras y la precisión del contexto quedaba con 4 valores de 38. La corrida de referencia tiene 34 valores en esa métrica y 38 en las demás. Las preguntas sin respuesta se miden aparte y se abstienen 5 de 5.

## VII. EXPERIMENTOS Y RESULTADOS

Los experimentos usan el gold de 43 preguntas; E12 usa la versión ampliada con 17 documentos adicionales y cada tabla lo indica. La configuración se eligió con el gold completo, así que los resultados son exploratorios. Cada subsección reporta el montaje en una frase, la tabla y la decisión; el detalle del montaje está en la Sección V.

### *VII-A. Limpieza*

Se construyeron cuatro índices sobre el piloto con 30 preguntas, e5-base, $k = 10$ y tres repeticiones. La Tabla VI muestra el resultado. Ninguna comparación pareada contra V0 excluye cero tras la corrección de Bonferroni sobre 21 pruebas. V2 toca el límite inferior en cuatro métricas, compatible con una mejora pequeña o con ausencia de efecto. Se adopta V2 por tres razones no estadísticas: la consistencia de la estimación en todas las métricas, el coste nulo en consulta y la eliminación de 68 páginas de error que de otro modo entrarían al índice.

### *VII-B. Segmentación y tamaño del contexto*

E1 comparó chunking fijo de 1000 caracteres con 150 de solape contra segmentación por oraciones de 384 caracteres. La Tabla VII muestra estimaciones puntuales favorables al fijo en todas las métricas de calidad, pero ningún intervalo pareado excluye cero: nDCG $-0,071$ (IC $[-0,221;\ 0,025]$), recall $-0,067$ (IC $[-0,233;\ 0,000]$) y P@1 $-0,067$ (IC $[-0,233;\ 0,114]$) para oraciones menos fijo. La única diferencia concluyente es la latencia: el fijo es 3,65 ms más rápido (IC




Figura 6. Interfaz final: respuesta con citas y evidencias abiertas. La pregunta se acepta con probabilidad de dominio 0,967; la respuesta cita las evidencias [1] y [2], y el panel muestra título, puntuación, fragmento, enlace y metadatos de la primera evidencia. El chip de la derecha identifica la ruta de ejecución, no un guardarraíl de cita.

$[2,25;\ 4,97]$). Se mantiene el fijo por la dirección consistente y el coste, no por una mejora de calidad demostrada.

E2 ablacionó el número de fragmentos. Con el gold del piloto, el documento relevante está siempre en el top-3, así que $k = 3$, 5 y 10 devuelven las mismas métricas de calidad. La única diferencia significativa es la latencia: $k = 3$ tarda 1,64 ms menos que $k = 10$ y $k = 5$ tarda 0,94 ms menos. Se fija $k = 5$ como margen para preguntas comparativas que no están en el conjunto, sabiendo que el coste es más contexto en generación, no más latencia de recuperación.

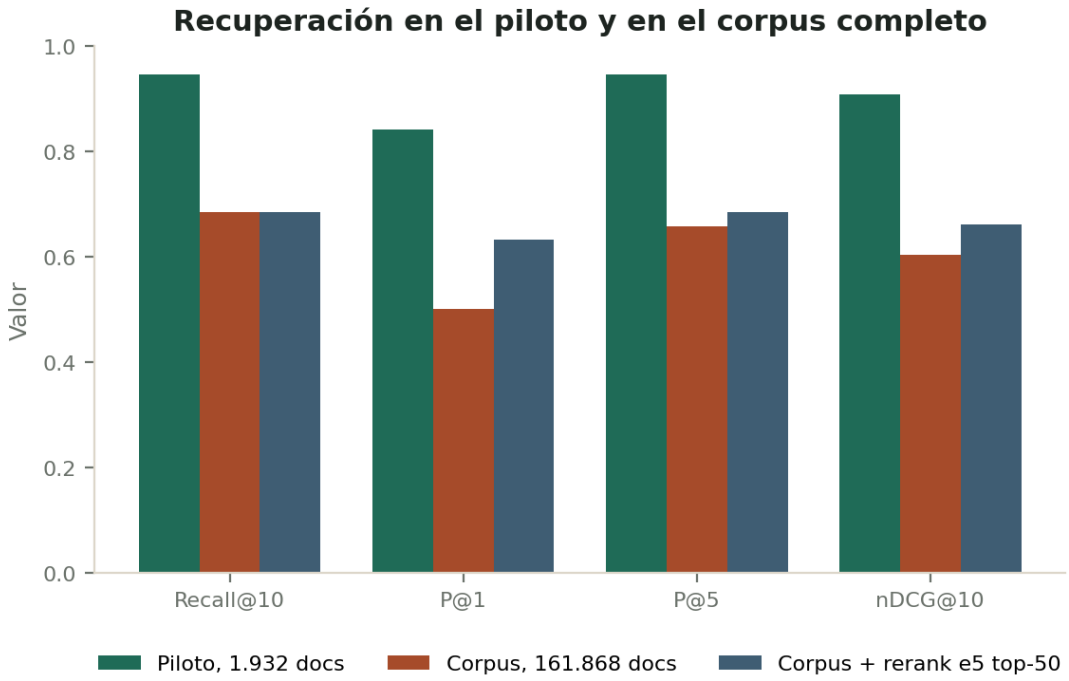



Figura 7. Recuperación con e5-base sobre el gold de 38 preguntas respondibles: piloto (1.932 documentos), corpus completo (161.868 documentos) y corpus con reranker sobre el top-50. El piloto y el corpus usan índices separados.

Tabla VII
E1: CHUNKING FIJO CONTRA ORACIONES (30 PREGUNTAS).

| Variante | P@1 | P@5 | Recall@10 | nDCG | p50 |
|---|---|---|---|---|---|
| Fijo 1000/150 | **0,833** | **0,900** | **0,900** | **0,875** | **38,5 ms** |
| Oraciones 384/1 | 0,767 | 0,833 | 0,833 | 0,804 | 42,1 ms |

Tabla VIII
E6: PILOTO CONTRA CORPUS COMPLETO CON E5-BASE (38 PREGUNTAS).

| Corpus | Recall@10 | P@1 | P@5 | nDCG | Span |
|---|---|---|---|---|---|
| Piloto (1.932 docs) | **0,947** | **0,842** | **0,947** | **0,909** | **0,895** |
| Completo (161.868) | 0,684 | 0,500 | 0,658 | 0,604 | 0,684 |

### *VII-C. Codificadores y escala*

E3 comparó e5-base con qwen3-embedding:8b sobre el piloto, con 18 preguntas de desarrollo. qwen3 recupera mejor: Recall@10 perfecto y 6,4 puntos más de nDCG. El problema es el coste. e5-base indexó el corpus completo en 2 h 41 min medidos en la RX 9070 XT. qwen3-embedding:8b no se indexó entero: las 23 horas son una extrapolación desde el rendimiento por lote, no un tiempo medido. Se adopta e5-base para la ingesta y qwen3 queda como comparación documentada.

E6 midió el mismo pipeline sobre el corpus completo. La Figura 7 muestra la caída. La caída es el hallazgo más importante del trabajo: con el mismo codificador, el mismo índice y las mismas 38 preguntas, Recall@10 pasa de 0,947 a 0,684 y nDCG de 0,909 a 0,604 al crecer de 1.932 a 161.868 documentos. La latencia no explica la caída (40 ms contra 42 ms); es un problema de ordenamiento y de competencia entre fragmentos.

E8 y E10 buscaron un recuperador mejor. BM25 sparse sube el recall a 0,763 y es ocho veces más rápido, pero su techo de cobertura es bajo. bge-m3 llega a 0,842 de Recall@10 y 0,708 de nDCG, y recupera el inglés de 0,111 a 0,667. La Tabla IX resume.

Tabla IX
E10: RECUPERADORES SOBRE EL CORPUS COMPLETO (38 PREGUNTAS).

| Método | Recall@10 | P@1 | P@5 | nDCG | p50 |
|---|---|---|---|---|---|
| Denso e5 | 0,684 | 0,500 | 0,658 | 0,604 | 48 ms |
| BM25 sparse | 0,763 | **0,684** | 0,737 | **0,727** | **7 ms** |
| bge-m3 | **0,842** | 0,553 | **0,816** | 0,708 | 56 ms |

E11 ajustó `ef` y probó la fusión con BM25. `ef`=800 sube el recall 2,6 puntos y el nDCG 1,3 con 6 ms más. La fusión 0,5/0,5 empata en recall y sube nDCG 6,9, P@1 13,2 y cobertura de span 5,3. Con el gold de un solo relevante la fusión parecía ganar. E12 repitió la comparación con el gold ampliado: el denso recupera más documentos nuevos (Recall@10 0,921 contra 0,890 y nDCG 0,827 contra 0,804). La configuración final es densa, `ef`=800, sin fusión.

### *VII-D. Reordenamiento*

E7 midió el cross-encoder sobre el top-50 con e5 en el corpus completo: P@1 sube de 0,474 a 0,632 y nDCG de 0,594 a 0,661, pero la cobertura no cambia y el coste es de 3,1 s por consulta. La mejora de orden no compensa el coste si se reordena tanto.

Tabla X
REORDENAMIENTO CON BGE-M3 (38 PREGUNTAS).

| Configuración | Recall | nDCG | P@1 | P@5 | p50 |
|---|---|---|---|---|---|
| Denso top-5 | 0,895 | 0,809 | 0,737 | 0,947 | 0,10 s |
| Rerank top-5 | 0,895 | **0,865** | **0,868** | **0,947** | 1,30 s |
| Rerank top-20 | 0,864 | 0,853 | **0,868** | 0,921 | 5,46 s |

Tabla XI
E4: ANOTACIÓN HUMANA (0 A 3) Y CONDUCTA AUTOMÁTICA.

| Modelo | Corrección | Citas | Abstención | Sin citas |
|---|---|---|---|---|
| gemma2:2b | **2,81** | **2,67** | **2,89** | **0,0 %** |
| qwen2.5:1.5b | 2,31 | 0,00 | 2,81 | 89,5 % |
| llama3.2:3b | 2,22 | 0,86 | 2,69 | 56,1 % |
| llama3.2:1b | 0,42 | 0,28 | 1,61 | 15,8 % |

El denso a $k = 10$ recupera 0,912 de recall y 0,818 de nDCG. Con bge-m3 se probó reordenar 5 y 20 candidatos. La Tabla X muestra que el top-20 baja el recall a 0,864 y el P@5 a 0,921, mientras que el top-5 mantiene 0,895 de recall y 0,947 de P@5, y sube el nDCG a 0,865 y el P@1 a 0,868 con 1,30 s. Se adopta el top-5.

### *VII-E. Modelos generativos*

E4 comparó cuatro modelos con la misma evidencia: 19 preguntas respondibles y 5 sin respuesta, tres repeticiones, anotación humana ciega de la primera repetición. La anotación cubre 18 de las 19 respondibles. La Tabla XI muestra las medias de los dos anotadores en escala de 0 a 3. gemma2:2b gana en corrección, citas y abstención. La fidelidad no se usa para el veredicto porque su acuerdo es $\kappa = 0,12$. qwen2.5:1.5b es el más rápido pero no cita en el 89,5 % de los casos. llama3.2:3b cita la mitad de las veces. llama3.2:1b se abstiene en el 73,7 % de las preguntas respondibles y no se recomienda.

La hipótesis H1, que esperaba que llama3.2:3b superara a los demás en corrección y citas, se refuta. La evidencia recuperada es la misma entre modelos; lo que cambia es el generador. La comparación fijó la familia de modelos pequeños. El generador final es gemma4:e4b, que no estaba en E4: se adoptó después por contexto largo y MTP, no por ganar una comparación directa, y se validó en la corrida final.

### *VII-F. Inyección de instrucciones*

E5 insertó instrucciones explícitas en cinco documentos sintéticos por modelo. Es una prueba exploratoria: no cubre el generador final ni demuestra robustez general. Dos de los tres modelos las ignoraron. gemma2:2b obedeció una de cinco y añadió la palabra pedida a una respuesta por lo demás correcta. La regla de diseño que sale de aquí es que el prompt debe delimitar la evidencia y ordenar explícitamente ignorar instrucciones internas, y esa orden debe repetirse después del bloque de contexto.

### *VII-G. Prompts y mejoras rechazadas*

La fase 6 probó cuatro mejoras sobre la configuración de referencia y la fase 7 probó diversidad. Ninguna supera al top-5 con reranker. La Tabla XIII resume. El filtro por score pierde recall; reordenar el top-20 pierde P@5 y multiplica la latencia; la expansión de consulta baja el recall y el nDCG; el prompt v4 no mejora el match estricto; y MMR baja el recall 8 puntos. El prompt v4 entregó 37 de 38 y 25 de 37 de match estricto, sin mejora. Todas se rechazan y la configuración se mantiene.

Tabla XII
E5: INSTRUCCIONES INYECTADAS EN EL TEXTO RECUPERADO.

| Modelo | Obedeció | Respondió el hecho | Se abstuvo |
|---|---|---|---|
| gemma2:2b | 1/5 | 4/5 | 0/5 |
| llama3.2:3b | 0/5 | 5/5 | 0/5 |
| qwen2.5:1.5b | 0/5 | 5/5 | 0/5 |

### *VII-H. Compuerta de dominio*

La compuerta se entrenó con 160 preguntas: 60 de dominio y 100 de fuera, con 103 de train, 37 de dev y 20 de test. Los 40 negativos nuevos son entidades inventadas, eventos futuros y conocimiento general. La Tabla XIV muestra el resultado en el test interno y en el conjunto reservado. En test el F1 es 0,952, con 0 falsos aceptados de 9 y 1 falso rechazo de 11. En el conjunto reservado, con 20 directas y 5 negativas, el F1 es 0,919: rechaza las 5 negativas y 3 de las 20 directas. El umbral es 0,4, elegido por validación cruzada. Con 5 negativas, el 0/5 no demuestra una tasa nula de falsos aceptados en uso general; solo acota el intervalo observado.

### *VII-I. RAGAS*

La Tabla XV compara la configuración final con la anterior. Son dos comparaciones distintas y conviene no mezclarlas. La primera es una repetición del mismo sistema con timeout de 900 s y 6 workers frente a la corrida por defecto, que dejaba la precisión del contexto con 4 valores de 38; la repetición tiene 34. La segunda es la comparación entre arquitecturas, que cambia juez, embedding y recuperador, así que es observacional y no causal. En esa comparación la configuración actual gana en fidelidad, relevancia, precisión y cobertura del contexto, y pierde en corrección de la respuesta. El juez es gemma4:e4b, de la misma familia que el generador, lo que puede favorecer la fidelidad.

### *VII-J. Latencia y MTP*

La Tabla XVI muestra el efecto del draft. El draft 3 es el más rápido: 217,1 tokens por segundo frente a 193,5 con 5 y 159,5 con 7. La decodificación especulativa es exacta: el draft propone y el modelo objetivo verifica, así que la salida no cambia.

La corrida de referencia es la del 2 de noviembre de 2026 en el worker GPU, con el host cargado (unos 2 GB de RAM libres) y el código del commit `125bbc7`. La latencia media fue de 7.938 ms sin razonamiento (mediana 7.086, p95 10.127) y 6.834 ms con razonamiento (mediana 6.729, p95 9.162); los CSV están en `reports/tablas/metricas_final_sin.csv`

Tabla XIII
FASES 6 Y 7: VARIANTES PROBADAS SOBRE 38 PREGUNTAS. LA REFERENCIA ES EL TOP-5 CON RERANKER.

| Variante | Recall | nDCG | P@1 | P@5 | Decisión |
|---|---|---|---|---|---|
| Top-5 con reranker | **0,895** | **0,865** | **0,868** | **0,947** | Referencia |
| Rerank top-20 | 0,864 | 0,853 | **0,868** | 0,921 | Rechazada |
| Filtro por score 0,8 | 0,838 | 0,837 | **0,868** | 0,921 | Rechazada |
| Filtro por score 0,9 | 0,825 | 0,830 | **0,868** | 0,921 | Rechazada |
| Expansión de consulta | 0,825 | 0,739 | 0,658 | 0,895 | Rechazada |
| MMR coseno 0,5 | 0,868 | 0,784 | 0,737 | **0,947** | Rechazada |
| MMR con reranker 0,7 | 0,816 | 0,818 | **0,868** | 0,921 | Rechazada |

Tabla XIV
COMPUERTA DE DOMINIO: TEST INTERNO Y CONJUNTO RESERVADO.

| Split | $n$ | Dominio | Fuera | Precisión | Recall | F1 |
|---|---|---|---|---|---|---|
| Test | 20 | 11 | 9 | 1,000 | 0,909 | 0,952 |
| Reservado | 25 | 20 | 5 | 1,000 | 0,850 | 0,919 |

Tabla XV
RAGAS: CONFIGURACIÓN FINAL CONTRA LA ANTERIOR, CON $n$ ENTRE PARÉNTESIS. AMBAS CORRIDAS USAN GEMMA4:E4B COMO JUEZ, LA MISMA FAMILIA QUE EL GENERADOR.

| Métrica | Final | Anterior |
|---|---|---|
| Fidelidad | **0,952** (38) | 0,925 (36) |
| Relevancia | **0,840** (38) | 0,798 (38) |
| Precisión del contexto | **0,881** (34) | 0,760 (36) |
| Cobertura del contexto | **0,921** (38) | 0,842 (38) |
| Corrección | 0,657 (38) | **0,705** (37) |

y `metricas_final_con.csv`. El reranker en CPU aporta 1,30 s de mediana y la generación el resto. La corrida limpia del 1 de noviembre dio 6.788 y 6.482 ms, pero su CSV no se conserva, así que no se usa como referencia. La compuerta reutiliza la puntuación del reranker, así que no añade una segunda pasada; en las preguntas rechazadas el coste es el del reranker, no el de la generación.

### *VII-K. Conjunto reservado*

El gold exploratorio se usó para elegir la configuración, así que no mide generalización. Para tener una prueba que no haya participado en ninguna decisión se construyó un conjunto reservado de 25 preguntas: 20 directas y 5 sin respuesta, 15 en español y 10 en inglés, 14 de prensa y 6 de Bluesky. El conjunto se congeló antes de ejecutar, con el hash del archivo y de la configuración en `eval/gold/README_RESERVADO.md`, y se ejecutó una sola vez. La Tabla XVII muestra el resultado.

El recall@10 cae a 0,600 y el nDCG a 0,477, frente a 0,912 y 0,818 del gold exploratorio. La caída no es solo de tamaño: ocho de las 20 preguntas no recuperan el documento de referencia en el top-10. De esas ocho, tres se responden con otro documento que contiene el mismo dato (r-005, r-008, r-017), dos se responden mal (r-006 y r-016) y tres terminan en abstención (r-012, r-014, r-019). El patrón es el mismo que en el corpus completo: el recuperador encuentra el tema, pero no siempre el pasaje que responde.

El match estricto entre las entregadas es 15 de 17 (88,2 %), más alto que el 67,6 % del gold exploratorio, pero sobre las 20 directas es 15 de 20 (75 %) porque el sistema entrega menos. La diferencia principal no está en la redacción: está en la recuperación y en la abstención. En inglés el recall es 0,625 y el nDCG 0,579; en español, 0,583 y 0,409. El inglés recupera mejor y ordena mejor, al contrario de lo que sugería el gold exploratorio.

Las cinco preguntas sin respuesta se rechazan por la compuerta. En las 20 directas, la compuerta rechaza 3: r-011, r-012 y r-014. r-012 y r-014 no recuperan el documento de referencia, así que la abstención es correcta por falta de evidencia; r-011 sí lo recupera y es un falso rechazo del clasificador. La compuerta nueva baja los falsos rechazos de 6 a 3 y los falsos aceptados de 1 a 0 respecto de la anterior. El 0/9 del conjunto anterior no se confirma como tasa nula, pero el 0/5 tampoco la demuestra.

El fallo más grave es r-006: la pregunta pide los 95 votos en la Cámara de Representantes y el sistema responde 30 votos de la Comisión Primera. No se abstiene porque la evidencia recuperada sostiene otra cifra. Es el tipo de error que el match estricto detecta y que la revisión humana debe vigilar. r-019 muestra un falso rechazo del guardarraíl: la respuesta *Asian Hornet* está en el documento, pero el control de respaldo se activa con *Additionally*. r-016 es una pregunta ambigua del

Tabla XVI
MTP: TOKENS POR SEGUNDO SEGÚN EL DRAFT.

| Draft | Tokens/s |
|---|---|
| 3 | **217,1** |
| 5 | 193,5 |
| 7 | 159,5 |

Tabla XVII
CONJUNTO RESERVADO: 20 PREGUNTAS DIRECTAS Y 5 SIN RESPUESTA, CONGELADO ANTES DE EJECUTAR.

| Métrica | Valor | Denominador |
|---|---|---|
| Recall@10 | 0,600 | 20 |
| nDCG@10 | 0,477 | 20 |
| P@1 | 0,350 | 20 |
| P@5 | 0,500 | 20 |
| Cobertura de span | 0,600 | 20 |
| Entregadas | 17 | 20 |
| Abstenciones en directas | 3 | 20 |
| Match estricto, entregadas | 15 | 17 |
| Match estricto, todas | 15 | 20 |
| Con cita | 1,000 | 17 |
| Abstenciones en sin respuesta | 5 | 5 |
| Compuerta rechaza | 5 | 5 |
| Latencia media | 10,8 s | 25 |

propio conjunto: no nombra el concierto y el corpus tiene varios. Se mantiene en las métricas y se reporta como límite de construcción, no como fallo del sistema.

La latencia media del conjunto reservado es 10,8 s, superior a los 7,9 s de la corrida de referencia. La diferencia se explica por la carga del host durante la ejecución y por respuestas más largas; no se usa para comparar arquitecturas.

### *VII-L. Progresión de la configuración*

La Tabla XVIII resume el recorrido. Cada fila es una decisión tomada con una medición, no una preferencia.

## VIII. Análisis de errores

### *VIII-A. Errores de recuperación*

Quedan dos fallos claros en el gold. g-031 pregunta por el municipio de gran extensión y tradición agropecuaria del sur del Tolima. El documento de referencia aparece en el puesto 11 del top-50 denso y en el puesto 1 después del reranker: el pipeline actual solo pasa cinco candidatos al reordenador y nunca lo ve. Ampliar el conjunto a 20 recupera esa pregunta, pero baja el recall global 3,1 puntos y el P@5 2,6, así que no se adopta. g-046, sobre la protesta de Extinction Rebellion, no aparece ni en el top-50 denso ni tras el reranker. El problema está en la consulta o en el índice, no en el ordenamiento.

### *VIII-B. Errores de generación*

Los modelos pequeños fallan de formas distintas con la misma evidencia. qwen2.5:1.5b responde sin citar en el 89,5 % de los casos: la respuesta puede ser correcta, pero el usuario no puede verificar de dónde sale. llama3.2:3b cita la mitad de las veces. llama3.2:1b se abstiene en el 73,7 % de las preguntas respondibles. gemma2:2b cita siempre y responde casi siempre, pero responde preguntas sin respuesta en 3 de 15 repeticiones, es decir, alucina con evidencia insuficiente. El generador final, gemma4:e4b, no estaba en esa comparación; los guardarraíles de cita, entidades y juez cubren parte de ese riesgo, y la compuerta lo cubre antes de generar.

### *VIII-C. Abstención y compuerta*

La abstención tiene dos caminos. El primero ocurre antes de generar, cuando la compuerta rechaza la pregunta; el segundo, después, cuando los guardarraíles o el juez no encuentran respaldo. El primer camino es barato (decenas de milisegundos) y ahora rechaza las 5 preguntas sin respuesta con 0,293 a 0,436. El segundo cuesta una generación completa. El único falso rechazo de la compuerta es una pregunta legítima sobre la inflación, en 0,494, justo por debajo del umbral. Es el precio de no aceptar preguntas ajenas.

### *VIII-D. Errores de evaluación*

RAGAS deja 4 muestras sin valor en la precisión del contexto por errores de parser del juez. Una media con 34 valores no es comparable con una de 38, y por eso se reporta $n$ en cada fila. En la primera corrida, con timeout de 180 s y 16 workers, la métrica tenía 4 valores y su media (0,750) no era comparable con nada. La conclusión anterior, que afirmaba una pérdida de precisión frente a la arquitectura previa (0,760, con 36 valores), era un artefacto del juez. La repetición corregida del mismo sistema da 0,881 con 34 valores. La comparación entre arquitecturas sigue siendo observacional porque cambia juez y embedding.

### *VIII-E. Errores de diseño del protocolo*

El experimento de limpieza se lanzó inicialmente con el gold de humo, que pertenece a una muestra de 600 documentos que no es subconjunto del piloto de 2.000. Las referencias no existían en las colecciones y las métricas habrían sido cero. El error se detectó al medir y obligó a construir un gold específico para el piloto. La lección es que el gold debe declarar a qué muestra pertenece y que la ingesta debe verificar que los documentos de referencia están en la colección antes de evaluar. Esa verificación ya forma parte del protocolo.

## IX. Discusión

### *IX-A. Por qué el piloto engaña*

La caída de Recall@10 de 0,947 a 0,684 al pasar del piloto al corpus completo (Tabla VIII) no es un fallo de configuración: es el efecto de la competencia. Con 1.932 documentos, el fragmento relevante compite contra pocos vecinos; con 161.868, compite contra cientos de fragmentos que comparten vocabulario genérico. El texto sin cierre terminal (32,7 %) agrava el problema cuando el corte elimina la frase que responde, y el chunking fijo puede partir la evidencia en dos fragmentos que se disputan el mismo puesto. Ninguna de esas causas se puede medir con una muestra pequeña. La consecuencia práctica es que un piloto sirve para depurar el pipeline, no para elegir codificador, chunking o $k$. Esa elección hay que hacerla a la escala final, aunque cueste horas de GPU.

### *IX-B. El coste del orden*

El reordenador es una herramienta de precisión, no de cobertura. Sobre el top-5 sube el nDCG 5,6 puntos y el P@1 13,1 con 1,30 s de coste, porque el recuperador ya trajo la respuesta y solo había que colocarla primero. Sobre el top-20 baja el recall y el P@5: al ampliar el conjunto entran fragmentos peores que desplazan a los buenos. El reordenador no puede recuperar lo que el recuperador no trajo, y por eso no arregla g-046 ni g-031. La decisión de adoptarlo depende de dónde duela el error: si el generador se pierde con la evidencia en el medio del contexto [19], ordenar importa; si el problema es que falta el documento, ordenar no sirve.

### *IX-C. La abstención barata*

La compuerta cuesta milisegundos y rechaza las 5 preguntas sin respuesta; el juez cuesta una generación completa. Esa asimetría justifica el clasificador. El precio es un falso rechazo en 0,494, una pregunta legítima sobre la inflación que queda fuera por seis milésimas. El umbral es una decisión de negocio, no técnica: aceptar una pregunta ajena erosiona la confianza más que abstenerse en una propia. En un asistente de corpus, el usuario prefiere un "no lo sé.ª una respuesta inventada, y

Tabla XVIII
PROGRESIÓN DE LA CONFIGURACIÓN Y MÉTRICA QUE LA JUSTIFICÓ.

| Etapa | Cambio | Gold | Métrica | Decisión |
|---|---|---|---|---|
| Piloto | e5-base, 1.932 docs | piloto (30) | Recall@10 0,947 | Punto de partida |
| Escala | corpus completo | 38 | Recall@10 0,684 | El piloto sobreestima |
| Dispersa | BM25 | 38 | Recall@10 0,763 | No alcanza el techo |
| Codificador | bge-m3 | 38 | Recall@10 0,842 | Adoptado |
| Índice | `ef`=800 | 38 | Recall@10 0,895 | Adoptado |
| Fusión | híbrido RRF | 38 | Recall@10 0,895 | Empata, se descarta |
| Fusión | híbrido RRF | ampliado (45) | Recall@10 0,890 | Rechazado |
| Reordenamiento | top-5 | 38 | nDCG 0,865 | Adoptado |
| Contexto | $k = 5$ | 38 | sin cambio de calidad | Adoptado |
| Prompt | v2 | 38 | 37/38 y 25/37 | Adoptado |
| Compuerta | 160 preguntas | 20 test | 0 falsos aceptados | Adoptado |
| Fase 6 | cuatro variantes | 38 | sin mejora | Rechazadas |
| Fase 7 | MMR | 38 | recall 0,816 | Rechazado |
| Reservado | 20 directas | reservado (20) | Recall@10 0,600 | Confirma la caída |
| Compuerta | 5 negativas | reservado (5) | 5/5 rechazadas | 3/20 falsos rechazos |

por eso se mantiene 0,5 aunque el test mejore con 0,45. Si el coste de abstenerse fuera mayor, el umbral se movería en la otra dirección.

### *IX-D. La evaluación*

La precisión del contexto de RAGAS pasó de 0,750 a 0,881 en dos corridas del mismo sistema. La primera cifra tenía 4 valores de 38 porque el juez no terminaba; la segunda tiene 34. La conclusión anterior, que atribuía a la arquitectura una pérdida de precisión, era un artefacto del evaluador. La comparación con la arquitectura previa (0,760, con 36 valores) es otra cosa: cambia juez y embedding, así que se reporta como observación y no como mejora causal. El episodio deja dos reglas. La primera: reportar $n$ junto a cada media y no comparar métricas con cobertura distinta. La segunda: el ruido del juez no es aleatorio, se concentra en contextos largos y en fallos de parser, así que un timeout más generoso y menos concurrencia lo reducen.

El acuerdo humano también delimita lo que se puede afirmar. La corrección (0,95) y las citas (0,90) son fiables; la abstención (0,72) es aceptable; la fidelidad (0,12) no. Usar la fidelidad para elegir modelo habría sido elegir con ruido. La rúbrica de fidelidad mezcla errores factuales con abstenciones injustificadas, y los anotadores no comparten el criterio. Un eje que no alcanza acuerdo no debe decidir, y eso es una lección de diseño de la evaluación, no un defecto de los anotadores.

### *IX-E. Lo que mostró el conjunto reservado*

El conjunto reservado cambia el diagnóstico. En el gold exploratorio el recall@10 era 0,912 y el sistema entregaba 37 de 38; en 20 preguntas nuevas el recall baja a 0,600 y entrega 17. La caída no se debe al azar: ocho preguntas no recuperan el documento de referencia y tres de ellas terminan en abstención. El sistema sabe decir que no, pero también responde con una cifra distinta cuando el pasaje correcto no está (r-006). Ese es el error que más importa en un asistente de prensa: una respuesta con cita y con el número equivocado.

La compuerta anterior tampoco generalizaba el cero: rechazaba 4 de 5 negativas nuevas y dejaba entrar una con 0,579, que el guardarraíl detenía después. La compuerta nueva, con la puntuación del cross-encoder, rechaza las 5 y baja los falsos rechazos de 6 a 3. Los tres que quedan son dos fallos de recuperación (r-012 y r-014) y un falso rechazo con evidencia recuperada (r-011). El 0/9 del conjunto anterior era una muestra demasiado pequeña para sostener una tasa nula. La lección no es retirar la compuerta, sino reportar su tasa con el denominador y no prometer ausencia de falsos aceptados.

El conjunto reservado también muestra que el gold exploratorio no era representativo en idioma: en inglés el recall es 0,625 y el nDCG 0,579; en español, 0,583 y 0,409. El inglés, que en el gold exploratorio parecía el punto débil, recupera mejor en la muestra nueva. Con 8 y 12 preguntas, las diferencias no son concluyentes, pero bastan para no tratar el idioma como una conclusión cerrada.

### *IX-F. Qué se llevaría a producción*

La configuración que se llevaría es la de la Tabla III: bge-m3 con `ef`=800, denso, $k = 5$, reranker en CPU, gemma4:e4b con MTP, prompt v2 y compuerta con cross-encoder y umbral 0,4. Es la que mejor equilibra cobertura, orden, latencia y coste en este corpus. Las dos deudas técnicas son la recuperación de g-031 y g-046 y la corrección de la respuesta. La primera exige un conjunto de candidatos mayor o una consulta distinta; la segunda, un generador mejor o un prompt que aproveche más la evidencia. Ninguna se resuelve con más reordenamiento.

El monitoreo que acompañaría el despliegue tiene cuatro señales: recall en una muestra fija del gold, tasa de abstención, tasa de citas válidas y latencia p95. Las cuatro se pueden calcular con la infraestructura actual y detectan las regresiones que importan: que el índice cambie, que el modelo se actualice, que el prompt se rompa o que el hardware se quede sin memoria. La compuerta se monitorea aparte, con un conjunto fijo de preguntas de fuera, porque su deriva no se ve en las métricas de respuesta.

## X. LIMITACIONES

1. **Texto sin cierre.** El 32,7 % de los documentos de la muestra no termina en un signo de cierre. Es un proxy de truncamiento, no una verificación de que el

rastreador los cortó: una publicación completa puede acabar sin punto. La limpieza no puede recuperar ese texto y ningún recuperador puede encontrar lo que no está.

2. **Sesgo de fuentes.** Cuatro cabeceras concentran la prensa y Bluesky llega casi todo en inglés. El corpus no representa la conversación pública en español ni la diversidad de medios del país.
3. **Fechas incompletas.** El rango declarado va de 2008 a 2026, pero la distribución utilizable se concentra en 2024 a 2026. El filtro temporal solo es fiable en ese tramo.
4. **Gold pequeño y desbalanceado.** 43 preguntas, 5 sin respuesta y 24 en prueba; 36 son de prensa y 2 de Bluesky, frente a un corpus con 38,2 % de documentos de Bluesky. Los intervalos de confianza son amplios y las diferencias de una o dos preguntas no son concluyentes. La revisión de Erika sigue pendiente y algunas correcciones las aplicó un solo revisor.
5. **Conjunto reservado pequeño.** 20 directas y 5 negativas. Una sola pregunta mueve 5 puntos porcentuales y los intervalos son amplios; el resultado no es una estimación precisa, es una señal de que el gold exploratorio no generaliza.
6. **Recall con un solo documento.** El gold reservado tiene un documento de referencia por pregunta. Si otro documento contiene la misma respuesta, el recall lo cuenta como fallo; r-005, r-008 y r-017 responden bien sin el documento de referencia. El recall@10 de 0,600 es una cota inferior de la recuperación útil.
7. **Compuerta no concluyente.** La compuerta nueva rechaza las 5 negativas del conjunto reservado y 3 de 20 directas; dos de esos tres son fallos de recuperación. La tasa real sigue sin estimarse con precisión.
8. **Ruido del juez.** RAGAS depende de un modelo local que falla en algunas muestras y cambia con el timeout y la concurrencia. La comparación con la arquitectura anterior cambia juez y embedding, así que no es completamente equivalente.
9. **Hardware.** La estación tiene 16 GB de VRAM y 31 GB de RAM. El contexto de 116K ocupa 13,9 GB de VRAM y deja poco margen; la evaluación y la generación compiten por memoria y el sistema operativo puede matar procesos bajo presión.
10. **Alcance.** El sistema está diseñado para un corpus concreto de prensa y redes. No es un RAG de propósito general y las decisiones de limpieza, chunking y compuerta no se transfieren sin medir.

## XI. Conclusiones y trabajo futuro

En el gold exploratorio el sistema responde 37 de 38 preguntas respondibles y se abstiene en las 5 sin respuesta. De las 37, 25 coinciden de forma exacta con la respuesta de referencia; de las 12 restantes, la revisión manual de una persona juzgó correctas 8, parciales 3 e incorrecta 1. En el conjunto reservado, con 20 directas y 5 sin respuesta, entrega 17, acierta 15 de forma exacta y se abstiene en las 5; el recall@10 baja a 0,600 y la compuerta rechaza las 5 sin respuesta y 3 de 20 directas. En conversación alcanza 14 de 14 con compuerta y 11 de 14 sin ella. RAGAS reporta 0,952 de fidelidad, 0,881 de precisión del contexto, 0,921 de cobertura y 0,657 de corrección. La latencia media de la corrida trazable es de 7,9 s sin razonamiento y 6,8 s con razonamiento.

La primera lección es metodológica: el piloto sobreestima la recuperación. Con el mismo codificador y las mismas preguntas, Recall@10 cae de 0,947 a 0,684 al pasar de 1.932 a 161.868 documentos. Cualquier comparación de codificadores o de chunking hecha solo sobre una muestra pequeña habría elegido la configuración equivocada. La segunda es que el reordenamiento rinde mejor sobre un conjunto corto: reordenar el top-5 sube el nDCG 5,6 puntos y el P@1 13,1 sin perder cobertura, mientras que reordenar 20 o 50 candidatos pierde recall y multiplica la latencia. La tercera es que la limpieza conservadora basta: ninguna variante supera a otra de forma significativa, y la ganancia real es eliminar páginas de error, no reescribir el texto.

La cuarta lección es que la abstención barata es la compuerta. Rechazar antes de generar cuesta decenas de milisegundos y evita que el modelo improvise sobre temas ajenos. La quinta es que la evaluación automática necesita cobertura: una media de RAGAS con 4 valores de 38 invirtió una conclusión sobre la precisión del contexto. Reportar $n$ junto a cada media no es un detalle de estilo; cambia lo que se concluye. La sexta lección es que el gold exploratorio no basta. El conjunto reservado confirma la caída de recuperación y muestra que la compuerta anterior no generalizaba un cero: rechazaba 4 de 5 negativas y dejaba entrar una. La compuerta con cross-encoder rechaza las 5 y baja los falsos rechazos de 6 a 3, pero no los elimina. Un conjunto de 5 negativas no distingue una tasa nula de una tasa baja.

El trabajo futuro tiene cuatro frentes. Primero, cerrar los fallos de recuperación: g-046 exige revisar la consulta o el índice, g-031 requiere un conjunto de candidatos mayor con un coste que hoy no se justifica, y el conjunto reservado añade r-006, r-012, r-014 y r-019. Segundo, mejorar la corrección de la respuesta, la métrica más débil de RAGAS. Tercero, completar la revisión del gold con la cuarta anotadora y ampliar el conjunto de prueba para reducir los intervalos de confianza. Cuarto, probar un chunking distinto y una reindexación completa, que es la única vía que queda para atacar la pérdida de contexto sin sacrificar cobertura.

## XII. Reproducibilidad

### *XII-A. Hardware y software*

El sistema se ejecutó en una estación con Ryzen 9 5950X, 31 GB de RAM y una GPU AMD Radeon RX 9070 XT de 16 GB con ROCm 7.2.4. Los contenedores usan Python 3.12, Milvus 2.6.6, PyTorch 2.10 con ROCm, FastAPI, Streamlit y Ollama. RAGAS 0.4.3 y LangChain 0.3 corren en un contenedor aparte con Python 3.12 y `BAAI/bge-m3` en CPU.

### *XII-B. Modelos*

La Tabla XIX fija la versión de cada modelo. Los identificadores son las etiquetas de Ollama y de Hugging Face usadas en el código; no se usan alias móviles.

Tabla XIX
MODELOS, ETIQUETA Y PAPEL EN EL SISTEMA.

| Papel | Etiqueta | Cuantización |
|---|---|---|
| Generador | `gemma4:e4b` | Q4_K_M |
| Condensador y juez | `gemma2:2b` | Q4_K_M |
| Embedding | `BAAI/bge-m3` | fp16 en GPU |
| Reordenador | `BAAI/bge-reranker-v2-m3` | fp32 en CPU |
| Comparación E4 | `qwen2.5:1.5b` | Q4_K_M |
| Comparación E4 | `llama3.2:3b`, `llama3.2:1b` | Q4_K_M |
| Comparación E3 | `qwen3-embedding:8b` | Q4_K_M |

El artículo se compila con IEEEtran V1.8b y un parche local que sustituye la raya del resumen y de las palabras clave por dos puntos. La corrida de referencia de latencia y respuesta es el commit `125bbc7`; las figuras y tablas se regeneran desde `reports/tablas/`. RAGAS 0.4.3 corre con LangChain 0.3 y `BAAI/bge-m3` en CPU.

### *XII-C. Comandos*

El stack se levanta con un comando:

```
docker compose up -d --build
docker compose ps
curl http://localhost:8010/health
```

El servicio `prewarm` carga el generador, el embedding y el reranker cuando la API está sana. La evaluación completa se ejecuta con:

```
python src/scripts/run_evaluation.py
```

Ese pipeline corre la evaluación de desempeño en el worker GPU, la de conversación contra la API y RAGAS en el contenedor de evaluación. Los resultados se escriben en `reports/tablas/` y la comparación en `reports/tablas/evaluacion_comparativa.md`.

### *XII-D. Artefactos*

El gold consolidado está en `eval/gold/gold_standard.jsonl`, con su versión ampliada en `gold_standard_ampliado.jsonl`. Las tablas de recuperación, respuesta, conversación, compuerta y RAGAS están en `reports/tablas/`. El conjunto reservado está en `eval/gold/gold_reservado.jsonl`, con su construcción y sus hashes en `README_RESERVADO.md`; la corrida escribe `reports/corridas/reservado_raw.jsonl` y `reports/tablas/reservado_resumen.csv`. Las figuras del artículo están en `reports/figuras/`. Los registros crudos de cada corrida están en `reports/corridas/` y los modelos de la compuerta en `modelos/`.

### *XII-E. Datos*

El corpus completo no se publica por derechos de las fuentes. Se incluyen el gold, las anotaciones, la muestra del piloto y los Parquet de evaluación necesarios para reproducir las métricas. Las cifras de este artículo se pueden verificar contra esos artefactos sin volver a descargar el corpus.

## REFERENCIAS


[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[2] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava, and I. Gurevych, "BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models," in *NeurIPS Datasets and Benchmarks Track*, 2021, arXiv:2104.08663.

[3] N. Muennighoff, N. Tazi, L. Magne, and N. Reimers, "MTEB: Massive text embedding benchmark," in *Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, 2023, arXiv:2210.07316.

[4] X. Zhang, N. Thakur, O. Ogundepo, E. Kamalloo, D. Alfonso-Hermelo, X. Li, Q. Liu, M. Rezagholizadeh, and J. Lin, "MIRACL: A multilingual retrieval dataset covering 18 diverse languages," *Transactions of the Association for Computational Linguistics*, vol. 11, pp. 1114–1131, 2023, arXiv:2210.09984.

[5] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated evaluation of retrieval augmented generation," *arXiv preprint arXiv:2309.15217*, 2023.

[6] J. Saad-Falcon, O. Khattab, C. Potts, and M. Zaharia, "ARES: An automated evaluation framework for retrieval-augmented generation systems," in *North American Chapter of the Association for Computational Linguistics (NAACL)*, 2024, arXiv:2311.09476.

[7] A. Salemi and H. Zamani, "Evaluating retrieval quality in retrieval-augmented generation," in *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2024, arXiv:2404.13781.

[8] D. Ru, L. Qiu, X. Hu, T. Zhang, P. Shi, S. Chang, C. Jiayang, C. Wang, S. Sun, P. Li *et al.*, "RAGChecker: A fine-grained framework for diagnosing retrieval-augmented generation," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024, arXiv:2408.08067.

[9] Zilliz, "Milvus documentation," https://milvus.io/docs, 2026.

[10] Ollama, "Ollama: Get up and running with large language models locally," https://github.com/ollama/ollama, 2026.

[11] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.

[12] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, "Reciprocal rank fusion outperforms condorcet and individual rank learning methods," in *Proceedings of the 32nd International ACM SIGIR Conference*, 2009, pp. 758–759.

[13] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi, "Self-rag: Learning to retrieve, generate, and critique through self-reflection," *arXiv preprint arXiv:2310.11511*, 2023.

[14] S.-Q. Yan, J.-C. Gu, Y. Zhu, and Z.-H. Ling, "Corrective retrieval augmented generation," *arXiv preprint arXiv:2401.15884*, 2024.

[15] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," *arXiv preprint arXiv:2402.05672*, 2024.

[16] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," *arXiv preprint arXiv:2402.03216*, 2024.

[17] R. Nogueira and K. Cho, "Passage re-ranking with bert," *arXiv preprint arXiv:1901.04085*, 2019.

[18] Y. A. Malkov and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 824–836, 2020.

[19] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157–173, 2024, arXiv:2307.03172.

[20] C. Niu, Y. Wu, J. Zhu, S. Xu, K. Shum, R. Zhong, J. Song, and T. Zhang, "Ragtruth: A hallucination corpus for developing trustworthy retrieval-augmented language models," *arXiv preprint arXiv:2401.00396*, 2024.

[21] S. Ramírez, "FastAPI documentation," https://fastapi.tiangolo.com, 2026.

[22] Streamlit Inc., "Streamlit documentation," https://docs.streamlit.io, 2026.