Material suplementario: asistente RAG sobre prensa colombiana

Erika Valeria Rivera Jimenez, Julian Guillermo Carrillo Meneses,
Carlos Andres Garnica Salazar, Oscar Andres Prieto Moreno

Presentación

Este suplemento reúne las tablas y figuras que el cuerpo del artículo referencia como S1 a S5. Se separaron para mantener el cuerpo en 16 páginas; los datos, las corridas y los artefactos son los mismos y se describen en la sección de reproducibilidad del artículo.

Reordenamiento con bge-m3

La Tabla S1 mide el reordenador en CPU sobre 38 preguntas. El top-5 mantiene el recall y sube el nDCG y el P@1; el top-20 pierde P@5 y multiplica la latencia.

Tabla S1
Reordenamiento con bge-m3 (38 preguntas).

Configuración	Recall	nDCG	P@1	P@5	p50
Denso top-5	0,895	0,809	0,737	0,947	0,10 s
Rerank top-5	0,895	**0,865**	**0,868**	**0,947**	1,30 s
Rerank top-20	0,864	0,853	**0,868**	0,921	5,46 s

Fases 6 y 7

La Tabla S2 resume las variantes de prompt y diversidad probadas sobre 38 preguntas. Ninguna supera a la referencia del top-5 con reranker.

Tabla S2
Fases 6 y 7: variantes probadas sobre 38 preguntas. La referencia es el top-5 con reranker.

Variante	Recall	nDCG	P@1	P@5	Decisión
Top-5 con reranker	**0,895**	**0,865**	**0,868**	**0,947**	Referencia
Rerank top-20	0,864	0,853	**0,868**	0,921	Rechazada
Filtro por score 0,8	0,838	0,837	**0,868**	0,921	Rechazada
Filtro por score 0,9	0,825	0,830	**0,868**	0,921	Rechazada
Expansión de consulta	0,825	0,739	0,658	0,895	Rechazada
MMR coseno 0,5	0,868	0,784	0,737	**0,947**	Rechazada
MMR con reranker 0,7	0,816	0,818	**0,868**	0,921	Rechazada

Conjunto reservado

La Tabla S3 reporta el conjunto reservado de 25 preguntas, congelado antes de evaluar la compuerta. La recuperación híbrida se eligió después con ese mismo conjunto, así que las métricas de recuperación y respuesta son de desarrollo.

Tabla S3
Conjunto reservado: 20 preguntas directas y 5 sin respuesta, congelado antes de ejecutar.

Métrica	Valor	Denominador
Recall@10	0,700	20
nDCG@10	0,612	20
P@1	0,500	20
P@5	0,650	20
Cobertura de span	0,700	20
Entregadas	19	20
Abstenciones en directas	1	20
Match estricto, entregadas	17	19
Match estricto, todas	17	20
Con cita	1,000	19
Abstenciones en sin respuesta	5	5
Compuerta rechaza	5	5
Latencia media	6,2 s	25

Inyección de instrucciones

La Tabla S4 mide E5 sobre 38 preguntas. Las instrucciones inyectadas en el texto recuperado no alteran la respuesta del generador en este corpus.

Tabla S4
E5: instrucciones inyectadas en el texto recuperado.

Modelo	Obedeció	Respondió el hecho	Se abstuvo
gemma2:2b	1/5	4/5	0/5
llama3.2:3b	0/5	5/5	0/5
qwen2.5:1.5b	0/5	5/5	0/5

Figuras del análisis exploratorio

Las Figuras S1 a S4 muestran la composición por colección, la relación rango-frecuencia, los idiomas normalizados y la distribución de longitud. No cambian las decisiones de diseño; los totales citados están en las Tablas I y II del artículo.

Progresión de la configuración

La Tabla S5 resume el recorrido de la configuración: cada fila es una decisión tomada con una medición.

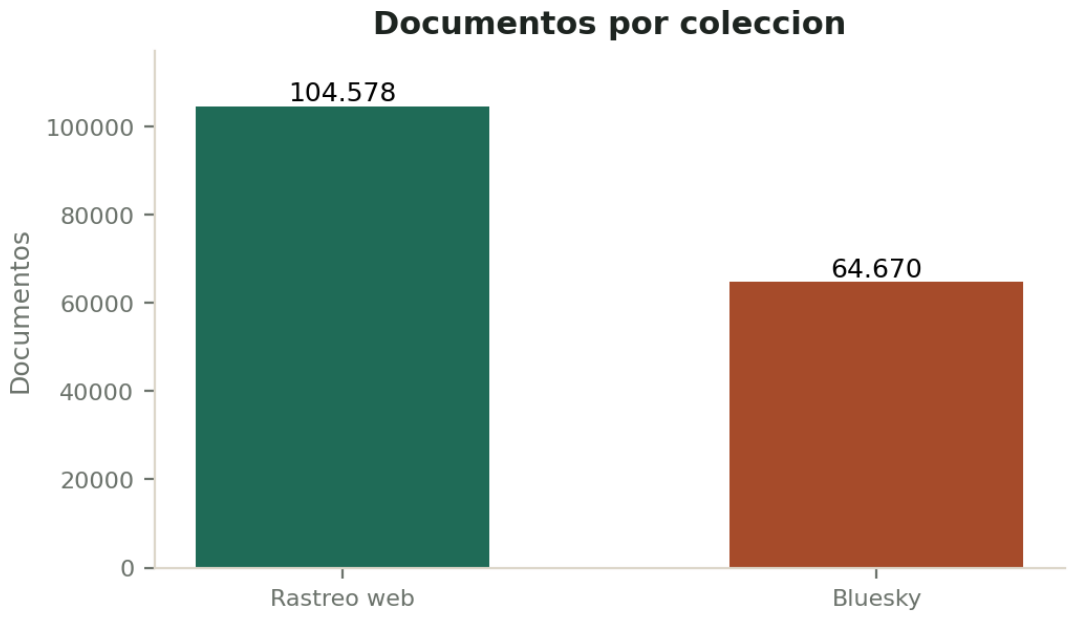


Figura S1. Documentos por colección. Los dos totales coinciden con la Tabla I del artículo.

Tabla S5
PROGRESIÓN DE LA CONFIGURACIÓN Y MÉTRICA QUE LA JUSTIFICÓ.

Etapa	Cambio	Gold	Métrica	Decisión
Piloto	e5-base, 1.932 docs	piloto (30)	Recall@10 0,947	Punto de partida
Escala	corpus completo	38	Recall@10 0,684	El piloto sobreestima
Dispersa	BM25	38	Recall@10 0,763	No alcanza el techo
Codificador	bge-m3	38	Recall@10 0,842	Adoptado
Índice	`ef`=800	38	Recall@10 0,895	Adoptado
Fusión	híbrido RRF	38	Recall@10 0,895	Empata, se descarta
Fusión	híbrido RRF	ampliado (45)	Recall@10 0,890	Rechazado
Reordenamiento	unión densa+BM25	reservado (20)	Recall@10 0,700	Adoptado
Contexto	$k = 10$	reservado (20)	19/20 entregadas	Adoptado
Prompt	v2	38	37/38 y 25/37	Adoptado
Compuerta	160 preguntas	20 test	0 falsos aceptados	Adoptado
Fase 6	cuatro variantes	38	sin mejora	Rechazadas
Fase 7	MMR	38	recall 0,816	Rechazado
Reservado	20 directas	reservado (20)	Recall@10 0,700	Recupera parte de la caída
Compuerta	5 negativas	reservado (5)	5/5 rechazadas	3/20 falsos rechazos

VERSIONES DE LOS MODELOS

La Tabla S6 fija la versión de cada modelo. Los identificadores son las etiquetas de Ollama y de Hugging Face usadas en el código.

Tabla S6
MODELOS, ETIQUETA Y PAPEL EN EL SISTEMA.

Papel	Etiqueta	Cuantización
Generador	`gemma4:e4b`	Q4_K_M
Condensador y juez	`gemma2:2b`	Q4_K_M
Embedding	`BAAI/bge-m3`	fp16 en GPU
Reordenador	`BAAI/bge-reranker-v2-m3`	fp16 en GPU
Comparación E4	`qwen2.5:1.5b`	Q4_K_M
Comparación E4	`llama3.2:3b`, `llama3.2:1b`	Q4_K_M
Comparación E3	`qwen3-embedding:8b`	Q4_K_M

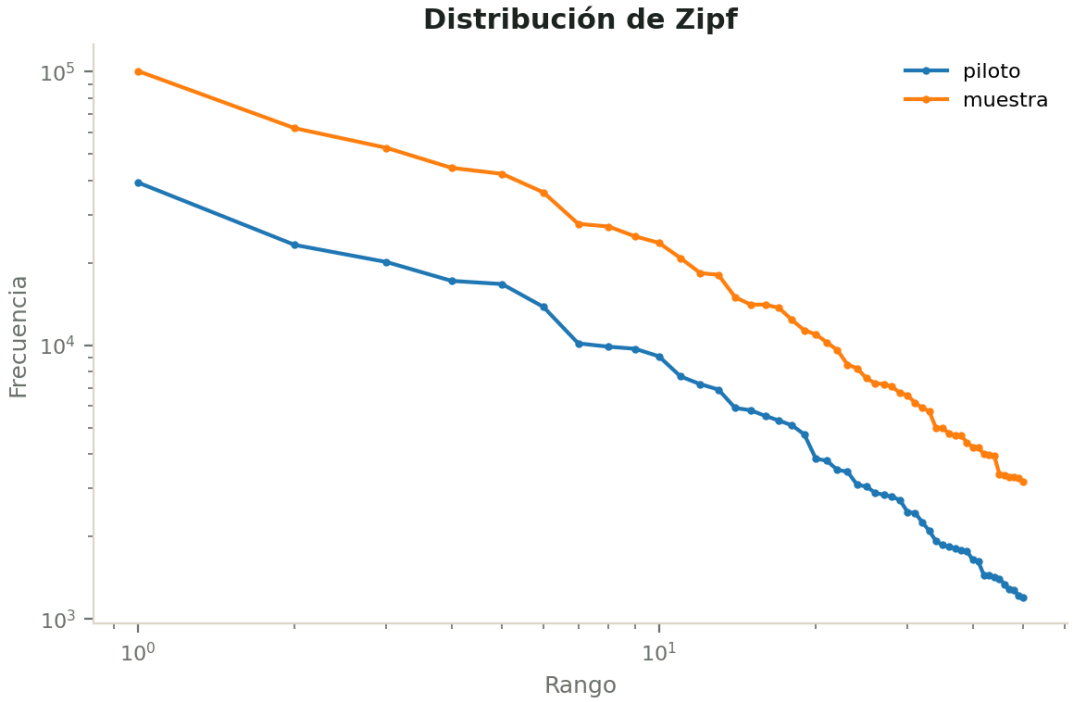


Figura S2. Rango frente a frecuencia en escala logarítmica para el piloto y la muestra. Se muestran los 50 términos más frecuentes; no se ajusta una recta, la figura solo comprueba la forma de ley de potencia.

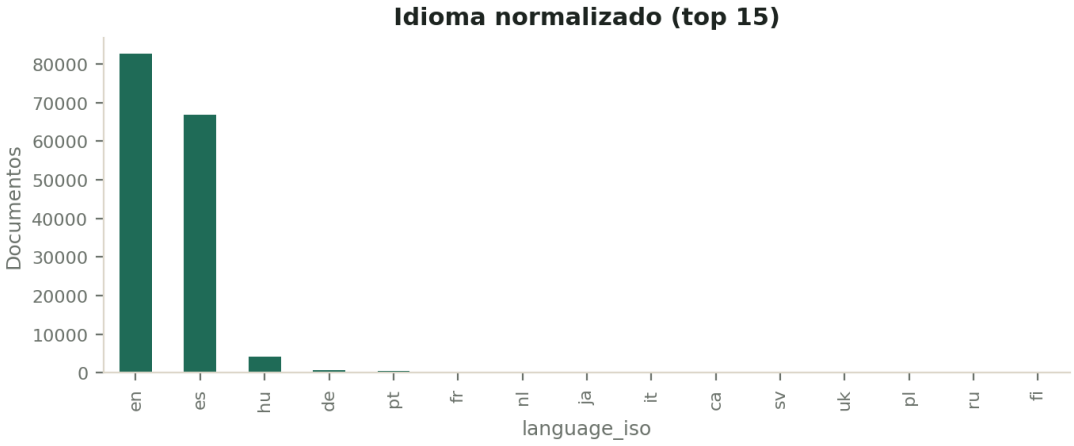


Figura S3. Idiomas normalizados más frecuentes (15 primeros). La normalización se hace al vuelo; el campo crudo del archivo no se modifica.

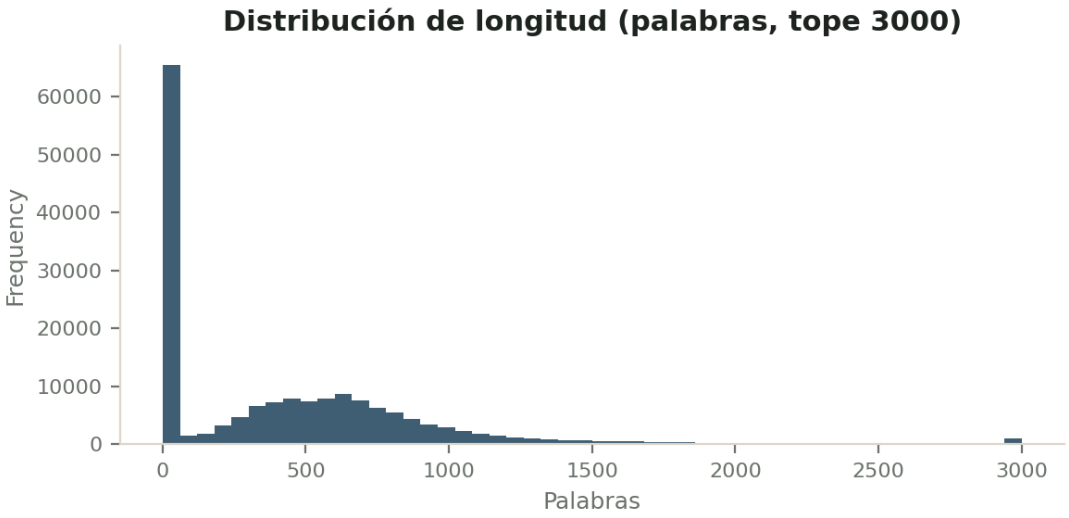


Figura S4. Distribución de longitud en palabras. Los documentos de más de 3.000 palabras se acumulan en el extremo derecho del histograma.