Taller de Procesamiento de Lenguaje Natural (NLP)

Título: Análisis de discursos presidenciales en Colombia

Nivel: Intermedio
Modalidad: Práctica con Google Colab - Informe
Librerías necesarias: nltk, spacy, es_core_news_md, matplotlib, wordcloud, pandas, textstat==0.2, textdescriptives
Corpus: presidentes (colección de discursos de presidentes colombianos)

https://puj-nlp.github.io/open_corpus_co_es/corpus

Objetivos de aprendizaje

- Aplicar técnicas fundamentales de procesamiento de lenguaje natural (NLP) en español, comparando un enfoque clásico (NLTK) con un pipeline moderno basado en spaCy.
- Analizar la frecuencia léxica y patrones de estilo en textos políticos, incluyendo patrones gramaticales identificados con el Matcher de spaCy.
- Medir la diversidad léxica y complejidad discursiva con herramientas de estilometría (TextStat y textdescriptives).
- Explorar entidades nombradas (personas, lugares, organizaciones) como huella temática de cada discurso y periodo.
- Explorar el cambio del discurso político colombiano a lo largo del tiempo.
- Interpretar resultados lingüísticos desde una perspectiva crítica e histórica.

Corpus

El corpus presindetes contiene discursos de diferentes presidentes de Colombia. Se espera que esté organizado como un diccionario de Python:

```
{
 [
'text': '…. clamorosa de las masas en en las plazas y las calles…'

 'file': '1942_1946_Jorge_Eliecer_Gaitan.txt'}]
 ]
}
```

Cada entrada incluye al menos el texto y la fecha del discurso.

Taller

1. Exploración inicial del corpus: Se verifica la estructura del corpus, se listan los presidentes disponibles, se cuenta cuántos discursos hay por cada uno y se muestra un fragmento representativo del contenido.

2. Se implementa una función para limpiar los textos del subcorpus, convirtiéndolos a minúsculas y eliminando signos de puntuación y números. A partir de ahí, se procesa cada discurso por dos vías. Primero, aplicando tokenización y remoción de stopwords en español con la librería NLTK. Segundo, procesando el mismo discurso como un Doc de spaCy (modelo es_core_news_md, usando nlp.pipe para eficiencia), obteniendo tokens, lemas y etiquetas POS, y realizando la remoción de stopwords mediante el atributo token.is_stop. Compara los resultados de ambas vías para al

menos un discurso: ¿cuántos tokens y cuántas stopwords quedan removidos en cada caso?, ¿spaCy elimina palabras que NLTK conserva (o viceversa)?, ¿qué diferencia notas entre trabajar con tokens crudos (NLTK) y trabajar con lemas (spaCy) para el análisis de frecuencia que viene más adelante? Reporta al menos una cifra concreta del subcorpus que respalde la comparación y concluye cuál de las dos rutas te parece más adecuada para los análisis léxicos del resto del taller, justificando la elección.

3. Análisis de frecuencia léxica

Se extraen y grafican las palabras más frecuentes en los discursos de cada presidente, lo que permite comparar visualmente los términos más repetidos y analizar posibles diferencias en el uso del lenguaje.

4. Nube de palabras

Se visualizan los términos dominantes en los discursos mediante la generación de nubes de palabras, las cuales pueden elaborarse por presidente o por periodo, facilitando la identificación de temas recurrentes y palabras clave.

5. Extracción de n-gramas

Se calculan los bigramas y trigramas más frecuentes en los discursos, lo que permite identificar patrones lingüísticos relevantes, como "pueblo colombiano" o "plan nacional de", que reflejan temas recurrentes o estructuras comunes en el discurso político. Calcula estos n-gramas a partir de dos insumos distintos: los tokens crudos (vía NLTK) y los tokens lematizados y filtrados (vía spaCy), y compara si los n-gramas resultantes cambian entre uno y otro. Adicionalmente, diseña al menos dos patrones propios con el Matcher de spaCy (por ejemplo, estructuras ADJ+NOUN o NOUN+ADP+NOUN) y aplícalos sobre tu subcorpus. Comenta qué diferencia hay entre los n-gramas simples (secuencias fijas de palabras) y las coincidencias encontradas con tus patrones (estructuras gramaticales flexibles), y cuál de los dos enfoques te permite capturar mejor los temas recurrentes del discurso político.

6. Comparación de diversidad léxica

Se calcula la métrica de diversidad léxica definida como el cociente entre el número de tokens únicos y el total de tokens (diversidad = len(set(tokens)) / len(tokens)). Esta medida permite comparar qué tan variado es el vocabulario empleado por cada presidente. Además, se sugiere complementar este análisis explorando otras métricas de diversidad léxica, como el Índice de Diversidad de Tipo-Token (TTR), la Razón de Diversidad Léxica Avanzada (MTLD), y la Entropía de Shannon, con el fin de obtener una visión más robusta y matizada de la riqueza del lenguaje en los discursos.

7. Análisis estilométrico con TextStat y spaCy/textdescriptives

Se realiza un análisis estilométrico para evaluar la legibilidad y complejidad del estilo discursivo de cada presidente, calculado por dos vías. Primero, instalando la librería textstat (!pip install textstat==0.2) y aplicando sus métricas: longitud promedio de palabras y frases, e índices clásicos de legibilidad como Flesch Reading Ease, Gunning Fog, SMOG, ARI, Coleman-Liau y Dale-Chall. Segundo, incorporando textdescriptives como componente del pipeline de spaCy

(nlp.add_pipe('textdescriptives/readability')), obteniendo métricas equivalentes (Flesch, longitud promedio de oración, longitud promedio de palabra) directamente sobre los objetos Doc. Los resultados de ambas vías se representan visualmente utilizando matplotlib y pandas, permitiendo comparar y caracterizar el estilo lingüístico de los discursos presidenciales. Compara las cifras obtenidas con textstat frente a las de textdescriptives para al menos un presidente: ¿coinciden los valores?, ¿hay diferencias en cómo cada librería segmenta oraciones o cuenta sílabas?, y concluye cuál de las dos vías te resultó más práctica de integrar en el pipeline de spaCy.

8. Análisis temporal del discurso presidencial:

Se realiza un análisis de cómo evolucionan el lenguaje y el estilo presidencial a lo largo del tiempo. Para ello, se ordenan cronológicamente los discursos de cada presidente según su fecha y se calcula, para cada año, una serie de métricas clave: el número total de palabras, la diversidad léxica, la frecuencia de términos específicos (como paz, guerra, justicia, economía) y los índices de legibilidad. Este análisis permite identificar tendencias temáticas, cambios en el nivel de complejidad discursiva y variaciones en el enfoque retórico a lo largo del tiempo.

9. Entidades nombradas (NER): Aplica el reconocimiento de entidades nombradas de spaCy (doc.ents) sobre el subcorpus para identificar las personas, lugares y organizaciones mencionadas con mayor frecuencia. Compara estas entidades entre presidentes y periodos, y discute qué revelan sobre los actores y prioridades políticas de cada época.

10. Grafos de relacionamiento sujeto–adjetivo y sujeto–verbo con NetworkX

A partir del análisis de dependencias sintácticas de spaCy sobre los objetos Doc del subcorpus, extrae por separado dos tipos de relaciones: sujeto–verbo (dependencia nsubj entre un token sujeto y su verbo rector) y sujeto–adjetivo. Con cada conjunto de relaciones, construye un grafo independiente usando NetworkX: un primer grafo sujeto–verbo, cuyos nodos sean los lemas de los sujetos y los verbos, y un segundo grafo sujeto–adjetivo, cuyos nodos sean los lemas de los sujetos y los adjetivos; en ambos casos las aristas deben representar la relación sintáctica encontrada, ponderadas por su frecuencia de aparición en el subcorpus.

Visualización sugerida (Proponer gráficos de análisis temporal):

```
import pandas as pd
import matplotlib.pyplot as plt

# Supón que tienes una lista de dicts con 'fecha', 'diversidad', 'flesch', etc.
df = pd.DataFrame(resultados_temporales)
df['fecha'] = pd.to_datetime(df['fecha'])
df = df.sort_values('fecha')

plt.figure(figsize=(12,6))
plt.plot(df['fecha'], df['diversidad'], marker='o', label='Diversidad léxica')
```

```
plt.plot(df['fecha'], df['flesch'], marker='s', label='Flesch')
plt.title("Evolución del discurso presidencial")
plt.xlabel("Fecha")
plt.ylabel("Valor")
plt.legend()
plt.grid(True)
plt.show()
```

Informe Final: Además del análisis cuantitativo y visual, el informe debe incluir una reflexión crítica sobre los resultados obtenidos. En particular, se sugiere responder a las siguientes preguntas orientadoras:

- ¿Se observan cambios significativos en el uso del lenguaje a lo largo de diferentes periodos presidenciales?
- ¿El discurso presidencial tiende a volverse más complejo o más accesible con el paso del tiempo?
- ¿La aparición o frecuencia de ciertos términos clave (como paz, justicia, guerra, desarrollo, entre otros) coincide con eventos o contextos históricos específicos?

Estas reflexiones permitirán contextualizar los hallazgos y dar mayor profundidad al análisis del discurso presidencial.

Entregables

Cada grupo deberá entregar los siguientes dos productos:

1. Notebook de Google Colab:
   Debe contener:
   - El código implementado para cada una de las actividades.
   - Visualizaciones generadas (gráficas de frecuencia, nubes de palabras, curvas temporales, entre otras).
   - Resultados diferenciados por presidente, con comentarios breves que acompañen las salidas clave.
2. Análisis escrito (mínimo 300 palabras):
   Documento que incluya una reflexión argumentada sobre:
   - Comparación de los estilos y léxicos utilizados por los diferentes presidentes.
   - Comparaciónes entre NLTK y spacy
   - Evolución del discurso presidencial a lo largo del tiempo.
   - Reflexión crítica sobre el rol del lenguaje en la política y su relación con el contexto histórico.